ARTICLE 14 October 2026

自主科研如何将实验经历转化为科学认识

Jiangjie Qiu[1,*], Yijun Li[1,*], Yaotian Yang[1,*], Honghao Chen[1], Wentao Li[1], Xiaonan Wang[1,†]
[1]Beijing Key Laboratory of Artificial Intelligence for Advanced Chemical Engineering Materials, State Key Laboratory of Chemical Engineering and Low-Carbon Technology, Department of Chemical Engineering, Tsinghua University, Beijing 100084, China.
* Jiangjie Qiu, Yijun Li and Yaotian Yang contributed equally.
† Correspondence: wangxiaonan@tsinghua.edu.cn.

图像为 ImageGen 临时预览；图形位置仅作示意，定量结果以正文和补充表为准。

自主科学的核心承诺，是使实验自主性转化为科学认识的拓展[1,2]。智能体如何将自己选择获取的证据转化为指导后续研究的关系，仍缺乏理解。我们利用可编程化学世界研究这一转化，将实验选择、同期判断和新干预预测连接起来。跨体系的操作与预测比较提出问题，平衡与结晶的 90 场重复研究则记录了前瞻检验、有依据的修订，以及指导进一步实验的工作关系。沿同一项平衡研究从事前猜想到后续预测，我们观察到一个关键转变：实验合理地削弱了一种局部解释，随后却成为将响应平台延伸到尚未解决条件的理由。结晶的三个重复研究建立了可用工艺，明确认识到高纯度，却在新条件中显著低估纯度。有依据的局部发现与不可靠的迁移，因而可以出现在同一段研究经历中。这些发现将自主科学进展的一项局限定位于：实验证据的支持如何从一个判断进入下一个判断。实验自主性能够支持有用关系的形成；关系的扩展则取决于是否保留证据实际建立的内容，以及仍未排除的可能性。

自主科学的核心承诺，是使实验自主性的增长带来科学认识的拓展。当智能体选择操作、组织测量并决定下一次实验时，它也在塑造自身认识赖以形成的研究经历：哪些现象被观察，哪些假说得到检验，哪些结果成为解释的依据。自主研究因此既改变机器能够完成的实验，也改变证据转化为认识的过程。

机器人科学家和自主实验室已经展示了假说检验、材料发现和反应优化[3–6]。语言模型智能体进一步连接科学指令、工具和实验操作[7,8]。这些进展使一个根本张力更加鲜明：真实的实验反馈，并不自动成为可靠的科学认识。一次成功实验建立特定条件下的结果；它支持什么关系、关系适用于哪里，仍需要进一步判断。有效工艺和准确预测分别呈现科学成就的一个方面，却都不能单独说明研究实际建立了什么认识[9,10]。

我们利用 ChemWorld 研究智能体如何将自己组织的实验经历转化为后续研究所依据的关系。智能体操作持续演化的虚拟样品，评价者独立控制相容的世界规律与公开信息。跨体系比较首先提出矛盾：操作进展、局部预测和新条件迁移未必同步改善。带同期记录的重复研究进一步连接具体判断的形成、修订与使用。核心观察是，一段研究能够建立有用的局部关系，同时在后续判断中改变或扩大其证据意义。发现与误解可以在同一段研究经历的不同环节出现。

自主研究成为可以核对的实验过程

ChemWorld 将材料、操作与仪器组合成具有持续状态的可编程化学体系。研究者自主选择用量、操作顺序、测量、重复与后续实验；操作可能不可逆地改变样品、消耗资源，也可能在改变物理状态之前被拒绝。评价者保留实际执行的状态转移及其底层响应。这些是受控的虚拟化学世界，不代表对物理实验室中特定真实物质的预测已经获得验证。

这一安排扩展了知识测验和给定数据型发现任务能够提供的证据[11,12]。既有交互式发现环境也已经连接了行动与观测[13–16]。在这里，可组合的化学操作使同一研究者的取证选择、逐步形成的公开解释和关系使用能够被共同考察（图 1）。

保留的广度研究包括六类体系的 240 场研究，以及其他四种模型配置的 60 场平衡研究，提供操作与预测比较的背景。在电化学 30 个匹配比较中，优化任务有 26 次给出更高分的推荐，但其中预测更好与更差各有 13 次。研究资源和先验信息也在部分条件下表现出正向作用：增加分配体系的实验预算，使有机相份额预测误差从 0.08291 降至 0.02379；相符的反应先验在两种研究目标下均改善五个世界中的四个。这些是独立研究之间的比较，并非同一研究者的纵向学习曲线。

为考察实验期间的判断形成，另一队列覆盖平衡与结晶，每种体系包含五个世界、三种信息条件、每条件三次全新会话。智能体分别获得不附加实例信息、相符的部分先验或指定的错配先验。全部使用相同的 Sol-medium 配置和十二批研究预算。90 场均到达终态，其中 84 条研究与后测链完整，保留 284 版笔记。失败保留在计划分母中。实验结束后，智能体封存科学报告，在无法继续操作实验室的条件下预测固定的新干预，随后在不见预测真值的情况下反思。重复固定世界参数和观测映射，但未控制模型采样随机性。

一次局部检验获得了更广的解释作用

一项平衡研究提供了连续案例，显示一次实验的科学作用如何发生变化。近乎平坦的试剂装料响应使研究者提出另一种解释：另一个可访问组分可能才是有效的活性坐标。在最后两次实验之前，它预测该解释若成立，这个组分应带来显著响应。研究者随后测量仅含该组分的样品，以及在少量试剂上大幅加标该组分的样品。两者仍接近原平台。下一版笔记撤回了对所测映射的支持，保留竞争解释，并将判断限定于已测条件（图 2a）。实验解决了一个明确科学问题的一部分，同时没有唯一识别隐藏机制。

我们继续追踪同一项研究的封存预测（图 3a）。面对极稀条件，研究者明确援引仅含另一组分的实验，将预测收缩到观测平台附近。解离率预测为 0.092，80% 区间为 0.043–0.155，而封存参考均值为 0.51730。先前实验反对一种特定组分映射，却没有确定平台在极稀条件下是否继续成立。同一结果先被用于作出有范围的合理修订，随后又被用于偏向一种已完成实验尚未区分的延续方式。

科学报告仍将缓冲、饱和与未识别耦合列为竞争解释。在没有收到参考答案的事后反思中，研究者承认预测区间没有充分表示这些未决可能。偏离因此发生在已

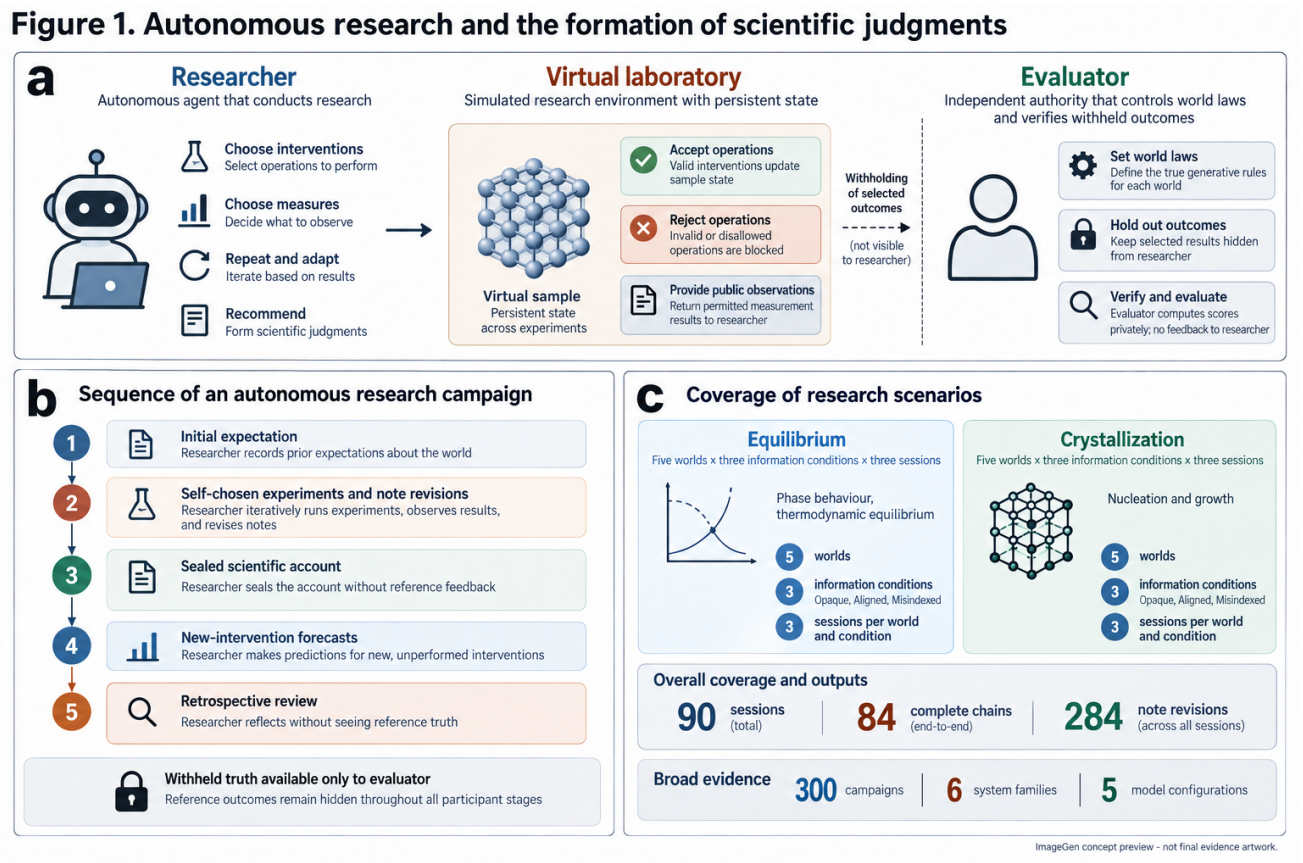


图 1 | ImageGen 临时预览：自主研究与科学判断的形成和使用。生成图形位置仅作示意，数值证据以正文和补充表为准。a，研究者自主操作持续状态的虚拟样品，评价者分别核对成功操作、公开观测与参考结果。b，同期笔记之后依次进行封存报告、新条件预测和事后反思；全部参与者阶段均看不到参考真值。c，旧广度研究与重复过程队列分别计数。每个世界和信息条件包含三次会话；总数保留六条不完整链。相同世界跨信息条件重复出现，不构成各臂独立的新世界样本。

经明确认识到不确定性的情况下。可观察的转变，是早先证据在新判断中获得的权重与适用范围。笔记、成功操作和公开预测理由将这一转变定位于同一段研究经历；它们不直接测量内部信念，也不单独识别某句表述的因果效果。

工作关系能够支持进一步探索

结晶研究提供了更直接的前瞻检验。高浓度配方未达到细粉要求后，研究者提出增加种量以改善颗粒质量。相关两批保持主要准备与冷却操作相同，成功加入的种量分别为 0.02 和 0.05 g。两批细粉份额均为 1.0。下一版笔记明确撤回该条件下的拯救预期（图 2b）。智能体最终推荐另一条独立复测合格的工艺。另一项研究在降低装料反而加重细粉后，撤回了预期的单调装料效应。因此，即使改善操作的提议失败，科学判断的修订仍可观察。

实验关系也能够成为继续研究的工作依据。在另一项结晶会话中，成功和失败工艺促成了体积窗口探索。研究者在 35 ml 获得可行工艺后，明确提出下一批检验 32.5 ml。新检验保留其他主要操作且仍然合格，随后重复 35 ml，最终推荐另经独立复测（图 2c）。该序列建立了可用配方，并支持一项后续检验。更早的低体积失败同时改变了种量或热历史，因此不能据此独立识别浓度阈值。

记录中还出现了明确的范围区分：观测到的配方趋势与独立识别的温度系数、有支持的区域与普遍溶剂排序、未决的小差异与可重复改善。适用范围本身就是所建立关系的一部分。补充材料中的结构化过程记录，将主例的预期、实际检验、随后修订、证据范围和后续使用逐项连接，并列出全部九十场的记录可用性与结果。这样可以说明选定轨迹在整个研究集合中的位置，而不把它们写成某一种机制的发生率。

重复研究呈现迁移的边界

重复平衡队列将这一主例放入更广的结果分布。相符先验使其余九题的五世界平均误差从 0.00907 降至 0.00512，却使极稀三题误差从 0.09880 增至 0.13205（图 3b）。局部改善在五个世界均出现，极稀区恶化在四个世界出现。极稀区名义 80% 区间的实际覆盖从 73.85% 降至 19.48%。错配先验对应误差为 0.00531 和 0.14848，极稀覆盖为 14.89%。这些结果保留了先验收益随区域反转的方向，但没有重复原研究约 8.7 倍的幅度；本轮相符相对不附加先验的比值约为 1.34。错配来源均在后一期执行，方法中保留了这一时期差异。

全部 45 场平衡研究的正装料源期测量均未进入 1 mM 及以下区域。尽管如此，相近的平台观测仍可支持不同的预测构造。在同一世界的重复中，不附加先验会话既出现近平台预测，也出现较大且准确的解离率预测；相符先验会话则持续更接近平台（图 3c）。另一场不附加先验会话在回答预测题时引入有效可溶浓度上限，给出较准确的稀释预测，随后承认该机制在先前报告中只是候选之一。

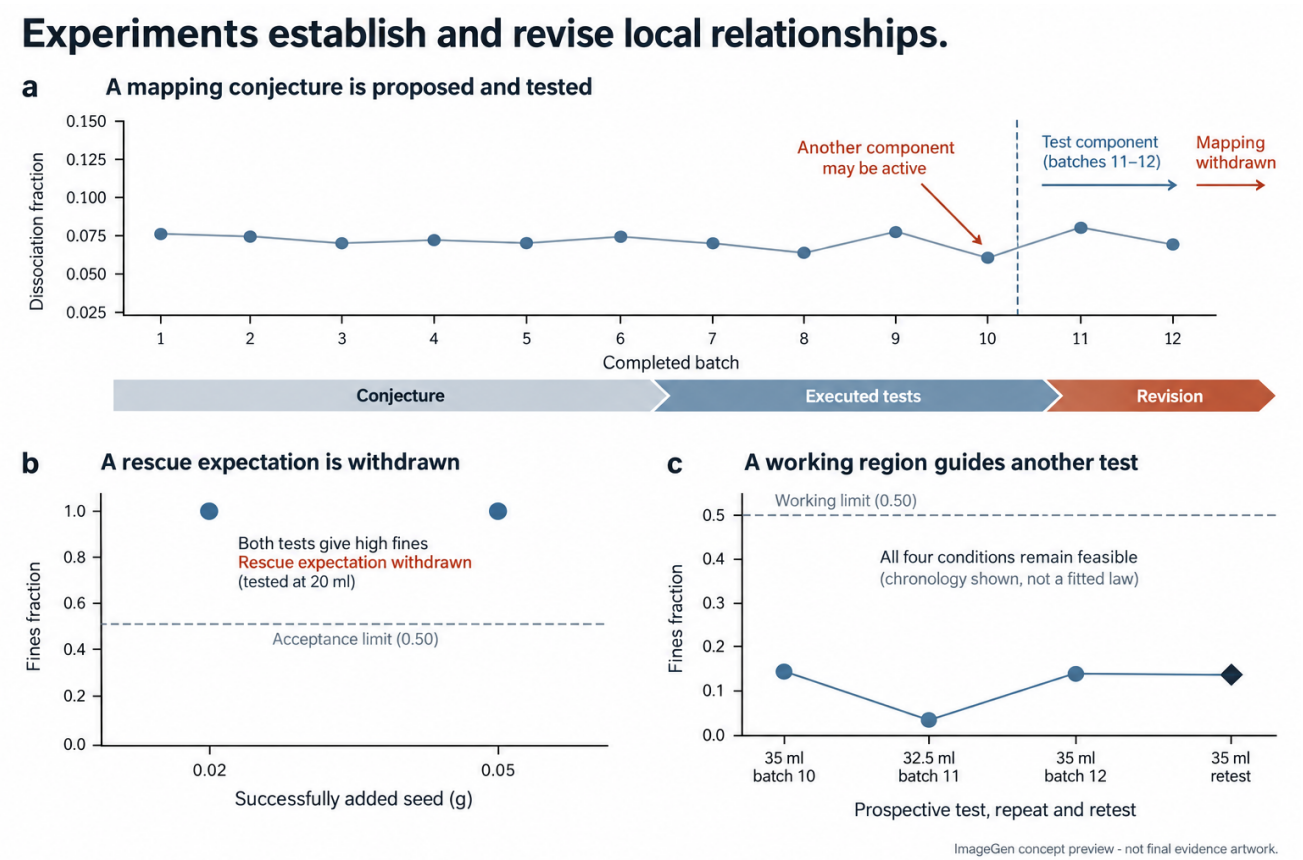


图 2 | ImageGen 临时预览：前瞻检验与有范围的工作关系。图中点位和几何仅作示意。a，平衡研究者在最后两批之前记录组分映射猜想，执行扰动后收窄解释。b，种量拯救猜想接受两种实际剂量检验，随后被撤回；虚线为细粉上限。c，32.5 ml 的前瞻检验之后进行 35 ml 重复和独立推荐复测。连线表示实验顺序，不代表拟合规律；复测为无噪参考。案例为事后选择，完整会话结果保留在补充表中。a 与图 3a 连续展示同一次研究的局部检验和后续预测。回收值沿用实际执行的初始投料口径，见方法。

因此，直接采样不是合理或成功外推的必要条件。在独立的五模型研究中，Sol/Opaque 未进入稀释区却准确外推；另一场 Astra 研究则先在低浓度自主观测到显著上升，再准确预测新的稀释条件。这些路径区分了预测准确、研究期获得证据，以及通过实验区分解释。单一终点分数会压缩这些差别。

已被认识到的关系在迁移中发生改变

结晶揭示了互补问题：研究者可以正确识别稳定响应，却在预测新条件时大幅修改它。在同一世界和错配信息下的三次会话中，每个智能体均找到了复测合格的配方，也均在科学报告中识别出高纯度。源期平均纯度分别为 99.09%、98.18%、99.09%，对新配方的平均预测却为 86.92%、86.33%、89.92%；共同参考均值为 98.45%（图 4a）。

第一次会话尤其清楚地展示了同一研究中的分化。源期报告描述了显著杂质排除和有范围的可行工艺区域。进入预测后，研究者分别对溶剂、杂质包埋、浓度和热历史作出调整。纯度 MAE 为 0.11529，十二个纯度区间无一覆盖参考。新配方确实需要判断条件变化；但在这里，这些调整使预测偏离了一项实验和研究者自身报告已在局部建立、且在新条件中仍然保持较高水平的响应。

全部 45 场结晶会话中，Opaque、Aligned、MisIndexed 的推荐满足颗粒存在、纯度与细粉要求的次数分别为 10/15、9/15、14/15；五世界平均纯度 MAE 分别为 0.01537、0.04120、0.05964。原记录中的质量与回收联合成功数为 9/15、7/15、14/15（图 4b,c）。指标定义核对发现：公开回收说明以分离前目标物为分母，但完整流程的实际观测与评分以初始试剂投料为分母。因此，回收预测分数与联合操作读数作为受协议不一致影响的诊断值保留，不作为干净的科学迁移指标。纯度和细粉不使用该分母。错配信息还保留了常用溶剂 S2 的描述，并在后一期执行，其结果不能证明错误知识带来收益。

较早的结晶研究发现，虽然源期与参考纯度均接近 98.5%，360 个纯度预测中仍有 335 个偏低。同期记录增加了更具体的发现：明确认识到高纯度的，正是后来在预测中修改它的那些研究者。结合平衡轨迹，可以看到两种不同转变：一项局部检验可能被赋予超出其解决范围的作用；一项局部建立的响应也可能在考虑新条件时获得更低权重。两者都不能等同于研究没有获得有用证据。

判断的证据地位本身也可能偏离执行记录

某些偏离发生在迁移之前。一名智能体将剂量上限理解为每次操作而非每批上限，提出检验约 2 g 累积种量。它请求四十次 0.05 g 加入，但只有第一次成功，其余三十九次均被拒绝。后续笔记仍声称，种量从 0.05 增至约 2 g 没有降低细粉，据此排除种量作为限制因

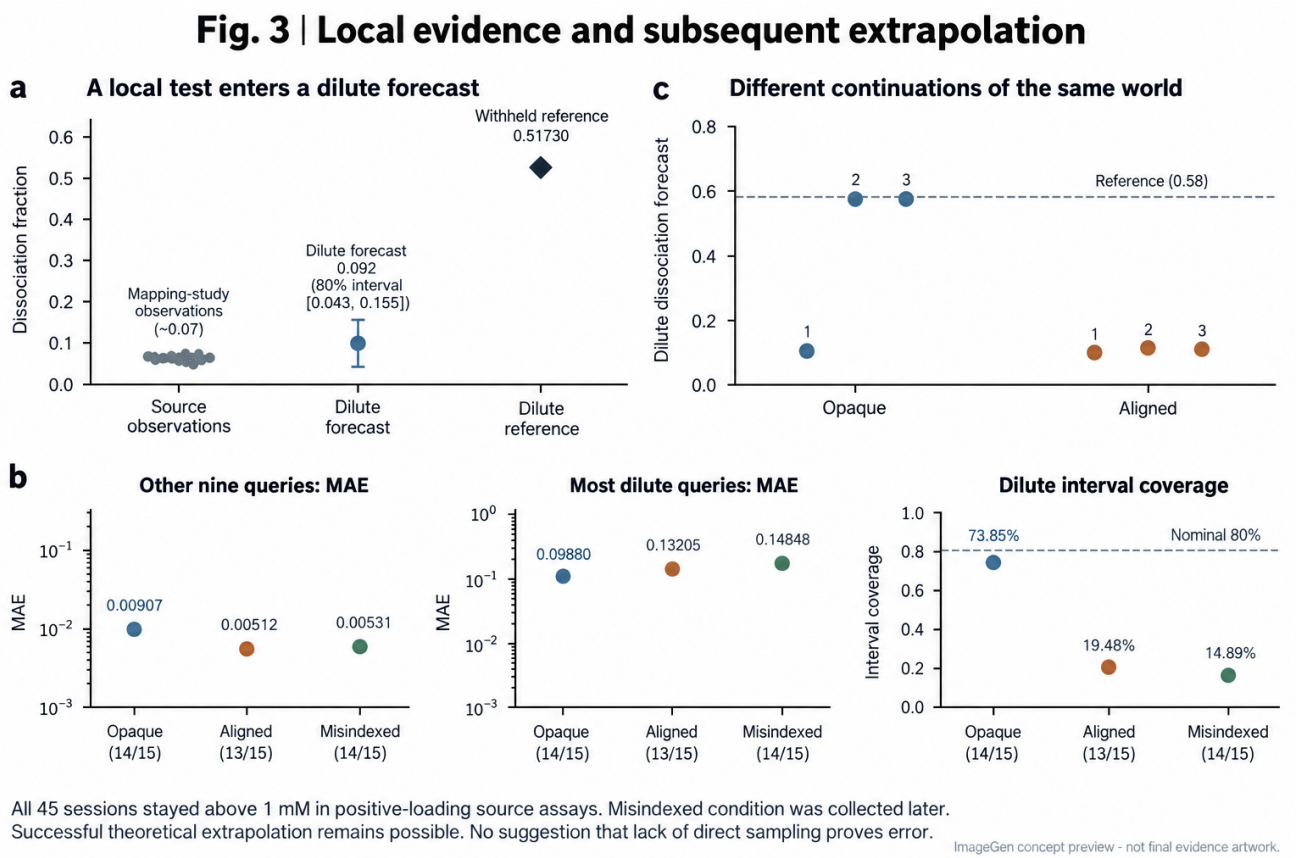


图 3 | ImageGen 临时预览：局部证据与后续外推。生成图形仅作示意。a，映射研究的公开解离率观测、封存极稀预测、原始 80% 区间与五次参考观测均值。b，极稀三题和其余九题的五世界等权 MAE，以及极稀区间覆盖；缺失预测不记零。Opaque、Aligned、MisIndexed 各计划 15 场，有效预测分别为 14、13、14；错配臂来自后一期。c，同一固定世界每信息条件三次全新会话的预测与共同参考。重复是模型会话，不是新的独立世界或测量噪声样本。a 与图 2a 是同一研究轨迹中的前后判断，不是两个独立案例。

素。最终报告和事后反思保留了这一结论（扩展数据图 1）。

所声称的剂量比较并未完成，因而不能提供大剂量无效的阴性证据。该轨迹定位了预期检验成为看似已建立排除结论的过程。另一个智能体则正确记录追加被拒绝，并据此限制后续剂量。执行失败并不必然成为科学记述错误。前一个案例涉及执行状态解释，不能单独解释其他概括错误，也没有证明错误笔记对随后行动的因果作用。

同样，认识到不确定性并不自动决定操作选择。一名研究者表示偏好细粉余量，最终却选择观测中最高回收的边界可行配方，无噪复测失败；另一名研究者放弃部分观测回收以保留余量，复测通过（扩展数据图 2）。任务奖励观测合格条件下的回收，因此边界选择并非自动不合理，但它与研究者公开表达的决策原则之间的关系仍有意义。

实验自主性与科学认识的拓展

自主研究能够形成有用的科学关系，同时留下这些关系在后续判断中的范围与用途尚未解决。我们观察到的智能体提出前瞻检验、根据反向结果修订预期，并发展出组织进一步实验的工作关系。继续追踪这些成果进入新的判断，可以看到有支持的局部发现与不可靠的迁移出现在同一项研究中。实验进展可以改变研究者对已测条件的认识，却未必同样解决它应如何判断另一种干预。

这一结果将科学认识的形成与继续使用带入自主科学的研究。实验设计和强推断说明检验如何区分解释[17–19]；这里的轨迹进一步显示，已完成检验如何获得解释作用，以及未决可能如何进入后续定量判断[20,21]。在平衡案例中，合理修订与缺乏充分支持的扩展援引同一实验结果；在结晶中，明确认识到的关系在迁移时被改变。被拒种量案例则定位了另一种偏离：计划中的检验被记述为已经完成的证据。它们共同解释研究经历如何转化为下一项判断的依据。

过程队列使用一种模型配置、固定世界和带记录职责的工作流程。解释由单一分析者事后完成，选定转变建立的是可核对案例，而非总体发生率或共同因果机制。缺少中间表述不等于某项判断未曾发生。回收定义不一致进一步限制结晶协议，尽管它不直接改变纯度与细粉。匹配淬灭对照检验固定配方中某项操作的物理后果（扩展数据图 3），但智能体没有接收干预结果或据此重新研究，因此它不能解释科学判断的形成。更强的因果或跨模型结论仍需要独立主例复核与针对性比较。

这些发现表明，实验自主性的扩展与可靠科学认识的拓展，是相互联系但并不等同的成就。证据能够修订局部解释、支持可用工艺，也可能以不同的范围或权重进入后续判断。科学进展因此取决于研究者如何将实验支持从一个问题带入下一个问题。ChemWorld 使

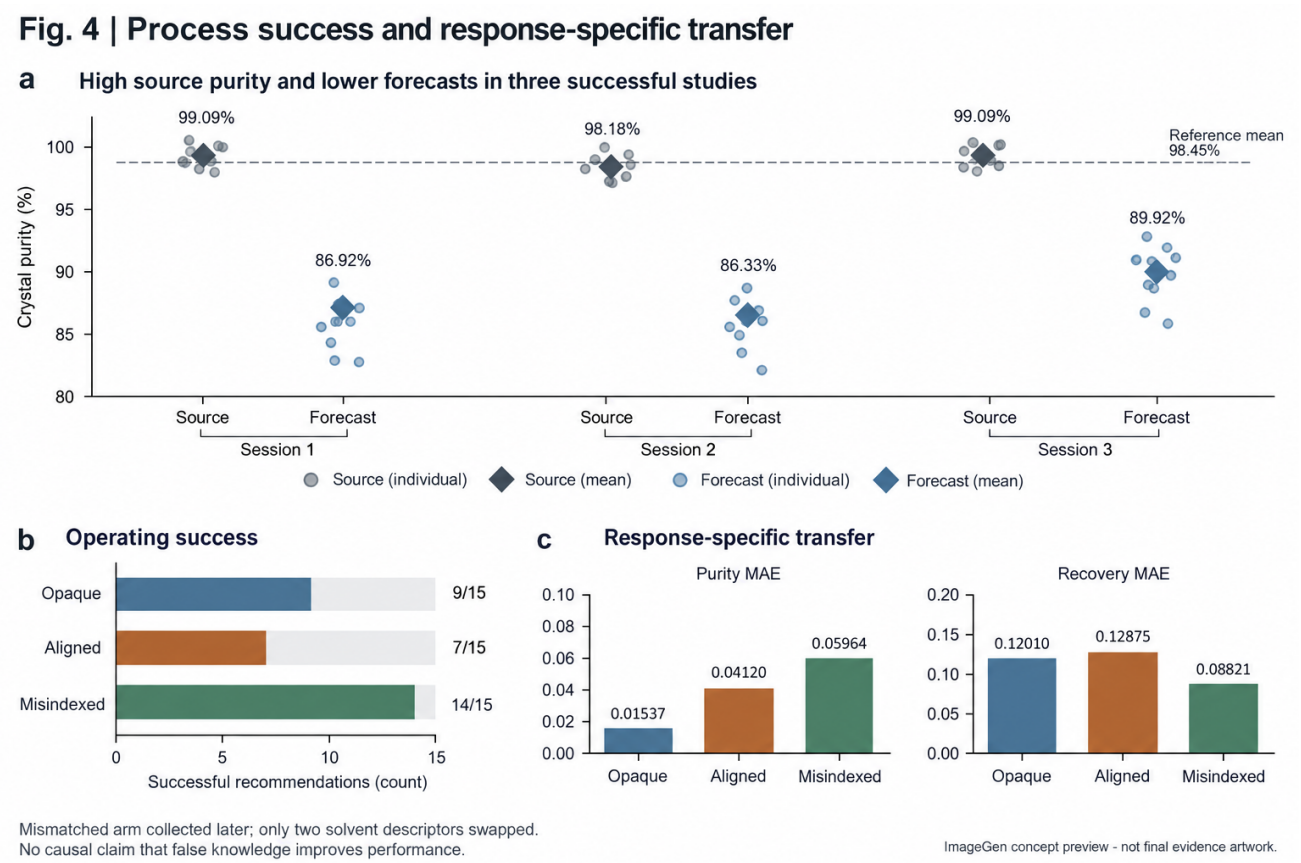


图 4 | ImageGen 临时预览：工艺成功与各响应的迁移表现。图形位置和生成散点仅为示意。a，同世界同信息条件的三次结晶会话，展示源期与预测纯度、各自均值和参考均值；三项推荐均通过复测。b，全部 45 场的推荐成功数。c，各信息臂纯度和回收预测误差的五世界等权均值，逐场数值见补充表。两期研究分别保留来源。成功要求有颗粒、纯度至少 0.80、细粉最多 0.50、扣除种晶后的回收至少 0.10。b、c 中回收误差与联合成功数是保留的受协议影响读数：提示称为阶段回收，而观测与评分使用初始投料分母，不能作为干净的回收理解指标。仅按颗粒、纯度与细粉要求，合格数为 10/15、9/15、14/15。

这一连续过程得以观察：智能体发现了什么，离不开关系通过怎样的研究获得支持，以及它随后被用于哪些新的条件。

参考文献

1. G. Tom et al. Self-Driving Laboratories for Chemistry and Materials Science. *Chemical Reviews* **124** 9633–9732 (2024). https://doi.org/10.1021/acs.chemrev.4c00055.
2. D. A. Boiko, R. MacKnight, B. Kline, and G. Gomes. Autonomous chemical research with large language models. *Nature* **624** 570–578 (2023). https://doi.org/10.1038/s41586-023-06792-0.
3. R. D. King et al. The Automation of Science. *Science* **324** 85–89 (2009). https://doi.org/10.1126/science.1165620.
4. B. Burger et al. A mobile robotic chemist. *Nature* **583** 237–241 (2020). https://doi.org/10.1038/s41586-020-2442-2.
5. B. P. MacLeod et al. Self-driving laboratory for accelerated discovery of thin-film materials. *Science Advances* **6** eaaz8867 (2020). https://doi.org/10.1126/sciadv.aaz8867.
6. N. J. Szymanski et al. An autonomous laboratory for the accelerated synthesis of inorganic materials. *Nature* **624** 86–91 (2023). https://doi.org/10.1038/s41586-023-06734-w.
7. A. M. Bran et al. Augmenting large language models with chemistry tools. *Nature Machine Intelligence* **6** 525–535 (2024). https://doi.org/10.1038/s42256-024-00832-8.
8. T. Dai et al. Autonomous mobile robots for exploratory synthetic chemistry. *Nature* **635** 890–897 (2024). https://doi.org/10.1038/s41586-024-08173-7.
9. A. N. Elmachtoub and P. Grigas. Smart Predict, then Optimize. *Management Science* **68** 9–26 (2022). https://doi.org/10.1287/mnsc.2020.3922.
10. G. Shmueli. To Explain or to Predict? *Statistical Science* **25** 289–310 (2010). https://doi.org/10.1214/10-sts330.
11. A. Mirza et al. A framework for evaluating the chemical knowledge and reasoning abilities of large language models against the expertise of chemists. *Nature Chemistry* **17** 1027–1034 (2025). https://doi.org/10.1038/s41557-025-01815-x.
12. B. P. Majumder et al. DiscoveryBench: Towards Data-Driven Discovery with Large Language Models. *International Conference on Learning Representations* **2025** 4556–4579 (2025). https://proceedings.iclr.cc/paper_files/paper/2025/file/0d70af566e69f1dfb687791ecf955e28-Paper-Conference.pdf.
13. R. Wang, P. Jansen, M.-A. Côté, and P. Ammanabrolu. ScienceWorld: Is your Agent Smarter than a 5th Grader? *Proceedings of the 2022 conference on empirical methods in natural language processing* 11279–11298 (2022). https://doi.org/10.18653/v1/2022.emnlp-main.775.
14. P. Jansen et al. DiscoveryWorld: A virtual environment for developing and evaluating automated scientific discovery agents. *Advances in neural information processing systems* **37** (2024). https://doi.org/10.52202/079017-0324.
15. K. Gandhi et al. BoxingGym: Benchmarking progress in automated experimental design and model discovery. (2025). https://arxiv.org/abs/2501.01540.
16. Y. Chen, P. Piękos, M. Ostaszewski, F. Laakom, and J. Schmidhuber. PhysGym: Benchmarking LLMs in Interactive Physics Discovery with Controlled Priors. *Advances in Neural Information Processing Systems* **38** (2025). https://doi.org/10.52202/085713-1556.
17. D. V. Lindley. On a Measure of the Information Provided by an Experiment. *The Annals of Mathematical Statistics* **27** 986–1005 (1956). https://doi.org/10.1214/aoms/1177728069.
18. K. Chaloner and I. Verdinelli. Bayesian Experimental Design: A Review. *Statistical Science* **10** 273–304 (1995). https://doi.org/10.1214/ss/1177009939.
19. J. R. Platt. Strong Inference. *Science* **146** 347–353 (1964). https://doi.org/10.1126/science.146.3642.347.
20. T. Gneiting and A. E. Raftery. Strictly Proper Scoring Rules, Prediction, and Estimation. *Journal of the American Statistical Association* **102** 359–378 (2007). https://doi.org/10.1198/016214506000001437.
21. Y. Ovadia et al. Can you trust your model's uncertainty? Evaluating predictive uncertainty under dataset shift. *Advances in Neural Information Processing Systems* **32** (2019). https://proceedings.neurips.cc/paper_files/paper/2019/file/8558cb408c1d76621371888657d2eb1d-Paper.pdf.

方法

实验世界与公开接口

ChemWorld 将兼容的过程组件编译为有状态化学环境。公开契约界定可用操作、合法范围、仪器、资源核算和任务目标；私有参数决定实例响应。研究者可以访问实验室接口及公开记录，不能访问评价者状态、模拟器源码、私有参数或封存真值。样品保留此前操作的后果，测量可以消耗材料。候选状态转移在提交前验证；被拒绝操作不产生物理干预，但可能按契约消耗尝试额度。精确重放验证环境状态转移，不要求重新生成模型的决策。

广度研究的六类体系为电化学、相分配、反应与热过程、水相平衡、反应耦合结晶和纯化。这些虚拟体系具有明确受限的范围；匿名材料和定性化学机制不能证明对特定真实物质的预测有效性。平衡响应与结晶模型的执行关系保留在协议证据和补充材料中。过程队列沿用相关早期世界规律、信息契约与查询定义，并在该队列固定的执行面上生成参考。

广度研究与证据层次

原跨体系研究包含 240 场 Sol-medium 会话：电化学 60、分配 30、反应 60、平衡 45、结晶 30、纯化 15。平衡的实体、参数和结构三个先验位置各十五场。电化学、分配和结晶包含十二批与二十四批预算；反应和电化学包含发现及优化任务。每个相关比较在五个实例世界重复三个信息条件。

按原完成规则，240 场中 238 场被记录为符合协议；保留 3,597/3,600 次计划最终测定与全部 720 个科学报告、预测、反思阶段。一场结晶在十一批测定后耗尽溶剂，一场纯化启动十二批但只有十批接受最终测定；有效预测仍纳入。另有 Luna、Terra、GPT-5.5、Astra 各十五场平衡研究，均请求 medium 推理配置，共 720 批与 240 个后测阶段。因此总计为 300 场，不能再额外加上 “75 场五模型比较”，因为其中 Sol 的十五场已包含在原 240 场。公开模型名表示请求的配置，不代表实际计算量相等。

较早的记录本可行性与选例研究用于发展过程测量。六案例及其十八次新重复共 24 场，不与广度研究或当前 90 场合并。保留研究包含开发和探索性证据；纳入稿件不会改变原资格身份。完整块计数、早期恢复和过程队列处置见补充材料。

重复过程队列

队列由两个事前确定的实验块构成。第一块有三十场平衡研究：五世界、Opaque/Aligned、各三次；另有十八场结晶，覆盖原索引的首、中、末三个世界和相同两臂、重复数。结晶世界在执行前固定，不按误差选择。扩展块加入十五场 MisIndexed 平衡、十五场 MisIndexed 结晶，以及剩余两个结晶世界的十二场 Opaque/Aligned。描述性合并后为两体系、五世界、三信息条件、三次会话，共九十场。

各源研究均使用全新工作区与模型上下文、Sol-medium 配置和十二批额度。模型自主选择配方、测量、重复和操作分组。世界参数、初态与按键固定的观测映射跨重复不变。模型采样 seed 不可用，因此这是固定世界的重复会话，不是受控模型 seed 实验。相同配方可能得到相同固定测量，不能当作新增独立噪声实现。

四个隔离工作进程消费预先确定的队列。第一块交错体系，并跨轮次改变世界和信息臂顺序；扩展块先轮换顺序再移除已覆盖单元。完成顺序不必与启动顺序一致。每条源研究只启动一次，不替换失败，不依据有利结果纳入。服务商或参与者失败保留为终态；执行、参考或重放缺陷按停止规则处置。平衡源期时限为 5,400 s，结晶为 3,600 s，沿用固定原引擎资源限制。平衡允许 180 次操作尝试、12 次中间仪器测量、12 次最终测定、0.24 mol 试剂和 0.72 L 溶剂。结晶沿用十二批资源范围、720 次尝试上限及各自材料、仪器额度。

第一块完成 576/576 批和 162/174 个后测阶段，44 条完整链、145 版笔记；扩展块完成 503/504 批和 136/141 个阶段，40 条完整链、139 版笔记。合计 1,079/1,080 批、298/315 个阶段、84 条完整链；86 个有效预测包括平衡 41 和结晶 45。六条不完整链保留在补充表中。九十条源轨迹和四十五条结晶推荐复测均通过精确重放。

信息条件与同期记录

Opaque 提供操作接口、任务与公共背景，不附加实例档案；Aligned 提供固定的部分信息。平衡包括有效酸度区间及给定锚点的局部稀释关系。MisIndexed 使用相同格式、限定词与精度，替换为另一世界的档案关系。结晶 Aligned 提供匿名名义材料描述，并非完整实例定律；MisIndexed 只交换溶剂 S1/S3 描述，S0、S2 和催化剂描述不变，并未破坏研究者可能使用的全部性质。

两个实验块前后执行。全部错配先验来源于扩展期，而 Opaque/Aligned 结晶跨两个时期。因此涉及这些来源的信息臂差异可能包含时间或服务商漂移；这里只描述结果，不估计同期随机化的错配信息因果效应。

全部研究提供相同记录角色与版本工具，要求在首次物理操作前，在存在可检验预期时写下简洁初始判断。后续更新由模型选择，不要求逐批写作；笔记不自动注入，也不提示稀释、淬灭、既往结果或对照研究。记录角色可能影响研究，不称为被动测量。全部九十条初始笔记早于物理动作；284 版记录保留事件位置与时间，以确定当时可用观测。没有显式笔记读取调用，但这不证明笔记内容在上下文中不可访问或未被使用。

封存后测与参考结果

源研究与所需推荐封存之后，智能体先提交自由形式科学报告，再预测十二个固定新批次配方，随后回答反思问题。平衡另有结构化补充阶段。证据记录将上述阶段分别记为 K1、Q、K2 和 EQS。预测题不在源期公开；预测阶段不允许实验室操作，所有参与者阶段均不可见参考真值。反思中首次提出的实验不计为已执行，也不回溯为源期计划。

过程队列的平衡参考共 300 批，覆盖五世界、十二题和五次固定观测重复；结晶为五世界、十二题，共六十批。扩展复用前期 336 个参考，只增加缺失的二十四批结晶参考。参考保存于参与者工作区之外，提前生成不意味着向参与者反馈。每项结晶推荐由成功提交的配方独立复测；被请求但被拒绝的动作不成为已成功投料。

平衡点误差与五次参考均值比较，区间覆盖逐一核对五个观测；结晶误差与区间使用最终取样前的无噪完整流程观测响应。质量要求有颗粒、纯度至少 0.80、细粉最多 0.50；保留的联合推荐读数还对实际执行的回收输出应用 0.10 阈值。热方向比较使用原指定配方对与固定评分规则。

回收定义与协议局限

沿实际观测与评价路径核对发现，提供给研究者的回收说明与观测、评分使用的响应不一致。内部结晶模块保存阶段回收率：扣除种晶的溶液来源目标物回收量，除以分离前目标物量。启用的完整流程观测路径则将该量覆盖为扣除种晶的固相目标物除以所跟踪的初始试剂投料，并截断至 [0,1]。源期最终测定是后一响应的带噪观测；推荐复测与封存查询参考捕获最终取样前的同一完整流程响应，预测评价直接读取这些捕获值，不读取模块内部阶段回收率。

两期保存的源指令与预测提示却均将回收定义为相对于分离前目标物。这两个分母不等价，两期记录的执行版本都存在这一差异。补充材料分别列明实际观测、内部模块量与参与者所见定义，接口间的差异不能解释为队列效应。

原预测、参考、分数与失败处置全部保留。回收误差仍可作为相对于实际输出的比较复现，但不能解释为对提示所要求物理量之理解的无混杂检验。联合成功数描述实际阈值下的配方结果，不代表目标被无歧义传达后的表现。因此另行报告颗粒、纯度与细粉合格数，并将回收准确率退出科学迁移的中心证据。纯度与细粉定义不受该分母差异直接影响，但研究路径确实在不一致指令下形成。未来若要对定义一致的回收理解作资格结论，需要统一接口后重新执行受影响的实验块，不能通过重命名或替换已完成结果补成。

定量与定性分析

每场研究的 MAE 对相应题目误差取均值。平衡宏观误差等权包含归一化 pH、解离份额与沉淀信号。最稀三题与其余九题的分组沿用过程说明中的既定规则；该分组在原广度研究中为事后探索，其余九题不保证全部处于分布内。源期 1 mM 覆盖阈值只是描述性指标，不是物理边界或成功标准。浓度按名义试剂总加入量除以溶剂总加入量计算，不推定实际溶解浓度。

过程队列先在每世界内平均有效会话，再对五世界等权平均，同时保留逐场值与有效分母。世界跨信息臂和重复共享；批次、查询、响应与参考观测相互嵌套且相关，不能替代独立研究者样本做推断检验。展示区间是智能体原始预测区间，不是总体均值的置信区间。每单元三次会话描述波动，但不足以确定总体成功概率。

单一分析者阅读全部 284 版源期笔记，对照相关封存报告并核对关键动作。前期 48 场与新增 42 场阅读分别保留，涵盖全部九十场及版本特定引文。精读区分世界响应、表述当时的信息、所提出关系及其范围、随后公开用途。补充材料新增全部会话的笔记可用性与后测完成清单，再以结构化主例分别列明事前预期、实际检验、随后修订、支持范围和后续使用。短引文按指定笔记版本或后测阶段核对。这些记录整理选定关系，清单不等于对九十场完成统一的机制编码。

合理修订、适当未决、范围扩展和执行记述差异分别保留，不生成自动推理分数。缺失或未经检查的关系标记为未决或未系统评定，不记为不存在。中间笔记缺口限制时间分辨率。目前没有第二位独立编码者或一致性估计，不从选例推断机制发生率。

主例按能够观察到事前预期、相应执行检验与后续报告，或源期关系与预测之间的明确连接事后选择。反例保留正确外推、正确处理操作拒绝及范围适当的判断。源期动作表可能含拒绝尝试；成功种量由事务状态核对。四十次 0.05 g 请求不代表加入 2 g。公开理由及时间对应支持解释一条已观察轨迹，不证明公开表述的因果中介作用，也不直接测量内部认识。

匹配淬灭干预

对照块在观察干预结果前固定前期全部十八条结晶推荐，每条在五个原世界分别执行有、无淬灭，形成九十对、一百八十条轨迹。原配方包含淬灭时删除原位置的该操作；否则在首次种晶或结晶冷却之前插入。移除这一操作后，两臂动作列表相同。两臂从相同世界与初态开始，使用相同固定观测身份，保留材料、时长、测量和其他操作参数；期间没有智能体适应。

全部 180 条轨迹保留并通过重放。75 对有两臂最终测量；5 对无淬灭臂没有可测颗粒，10 对有淬灭臂使下一步固定冷却目标高于当前温度。失败动作不修复，缺失终态不插补。因此完整配对效果描述受限子集，同时呈现全部

失败。主要对比使用无噪细粉与回收。淬灭改变温度、反应停止状态、时间和后续物理条件；整体效果不单独识别冷却速率或成核。共享世界和供体也意味着九十对不是九十名独立研究者。

75 对中，有减无的平均细粉变化为 0.30937，回收为 0.00741；联合成功数由 34 降为 4。原世界的十八对中十五对完整，与跨世界运输分别报告。前期热程切换主例的原世界插入淬灭会导致后续操作失败，因此没有该案例的终态配对细粉效果。新增扩展配方不是该块供体。这项干预解释环境结果，不解释智能体为何形成某种科学认识。

数据可用性

研究所用源期观测、版本科学记录、封存后测与评价者摘要保留在项目证据记录中。补充材料提供全部过程会话结果、失败处置和既有广度研究表。整合后的公开归档与永久标识符尚未最终确定；早期公开平台发布不包含这些后续研究队列。

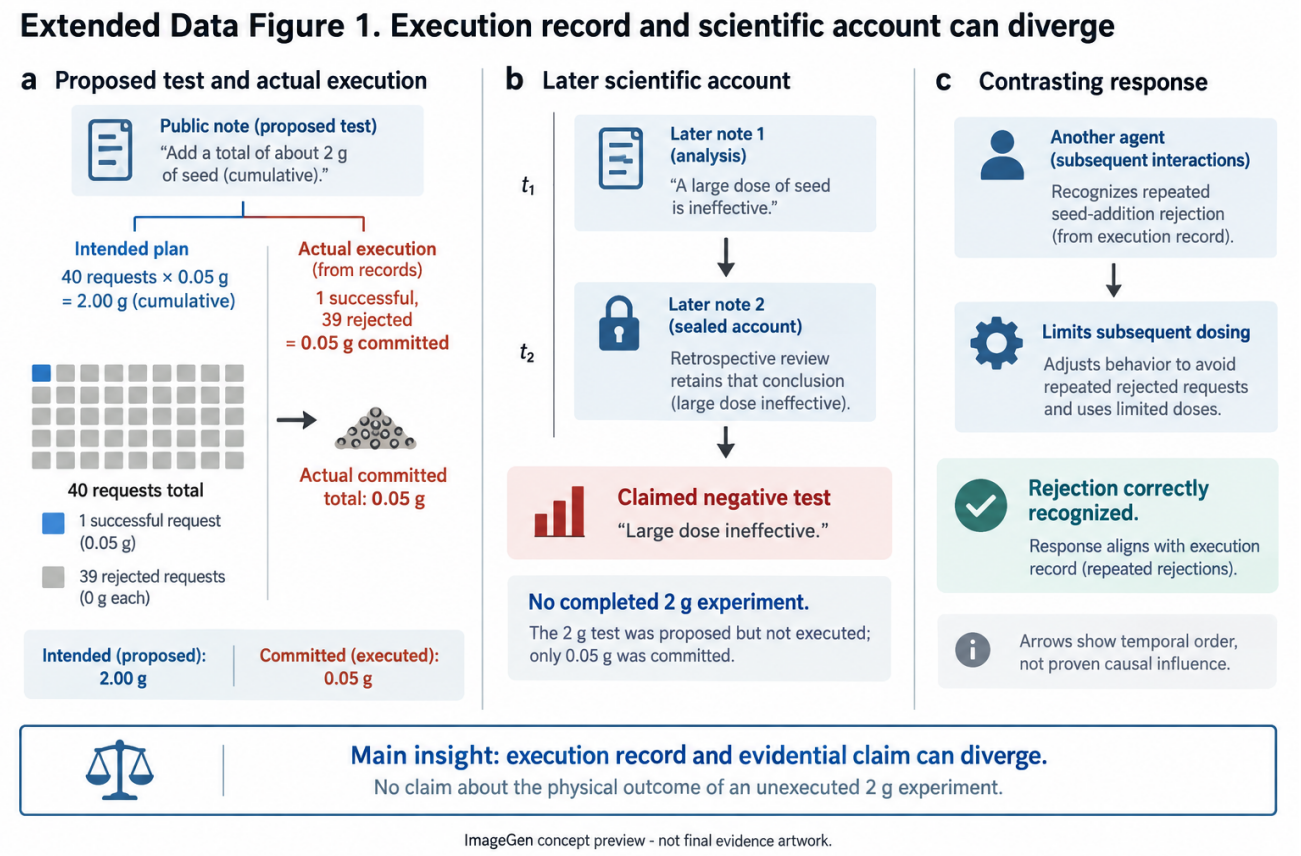
代码可用性

环境、执行、重放、评分和分析代码由 ChemWorld 项目维护。本稿分析只读取保留结果，不新增参与者或模拟器调用。准确执行版本与各展示来源保留于配套证据组织中。覆盖整合研究的公开版本归档仍须在投稿前确定。

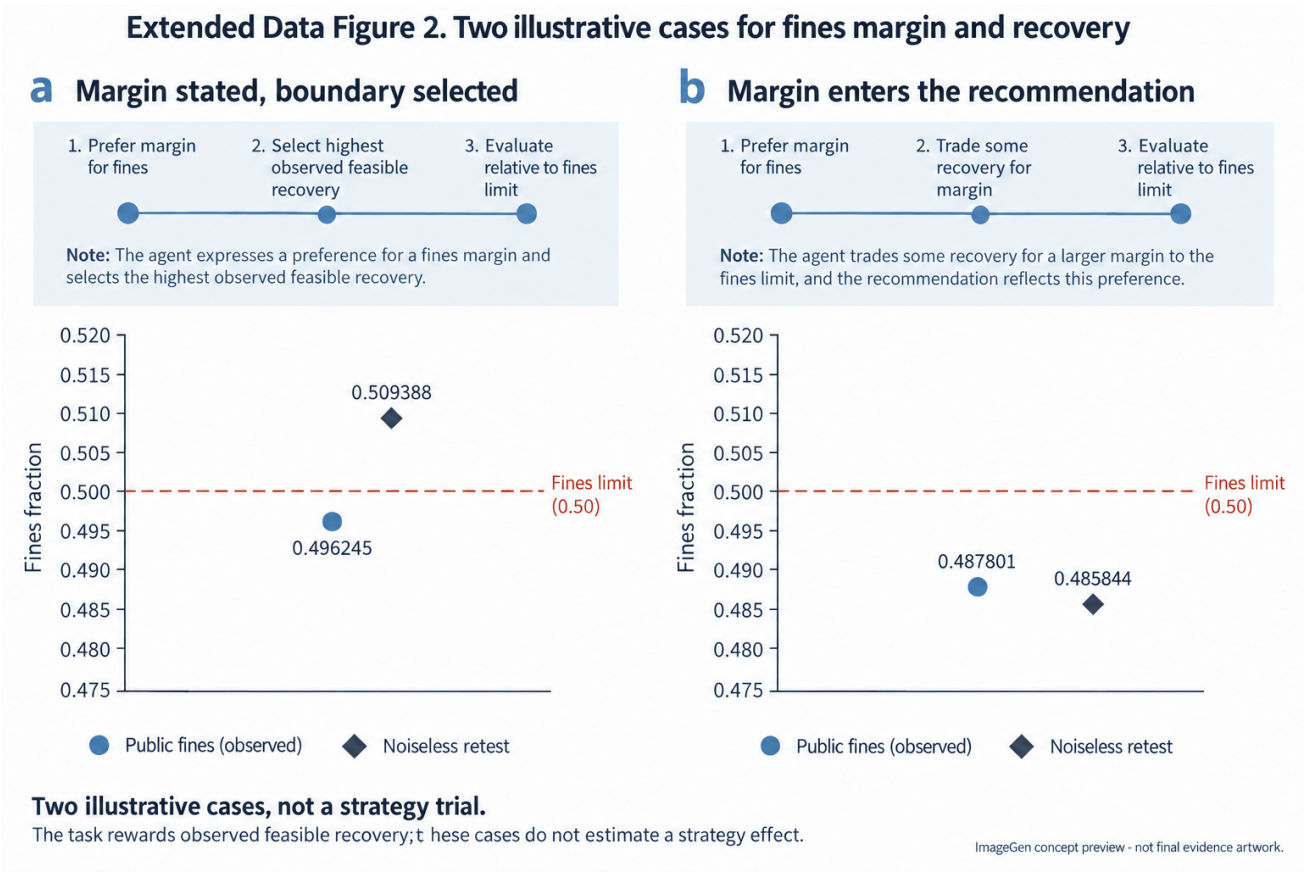
资助

This work was supported by the Shenzhen Science and Technology Program (AI2026004), the Tsinghua University Initiative Scientific Research Program and the Scientific Research Innovation Capability Support Project for Young Faculty (ZYGXQNJSKYCXNLZCXM-E7).

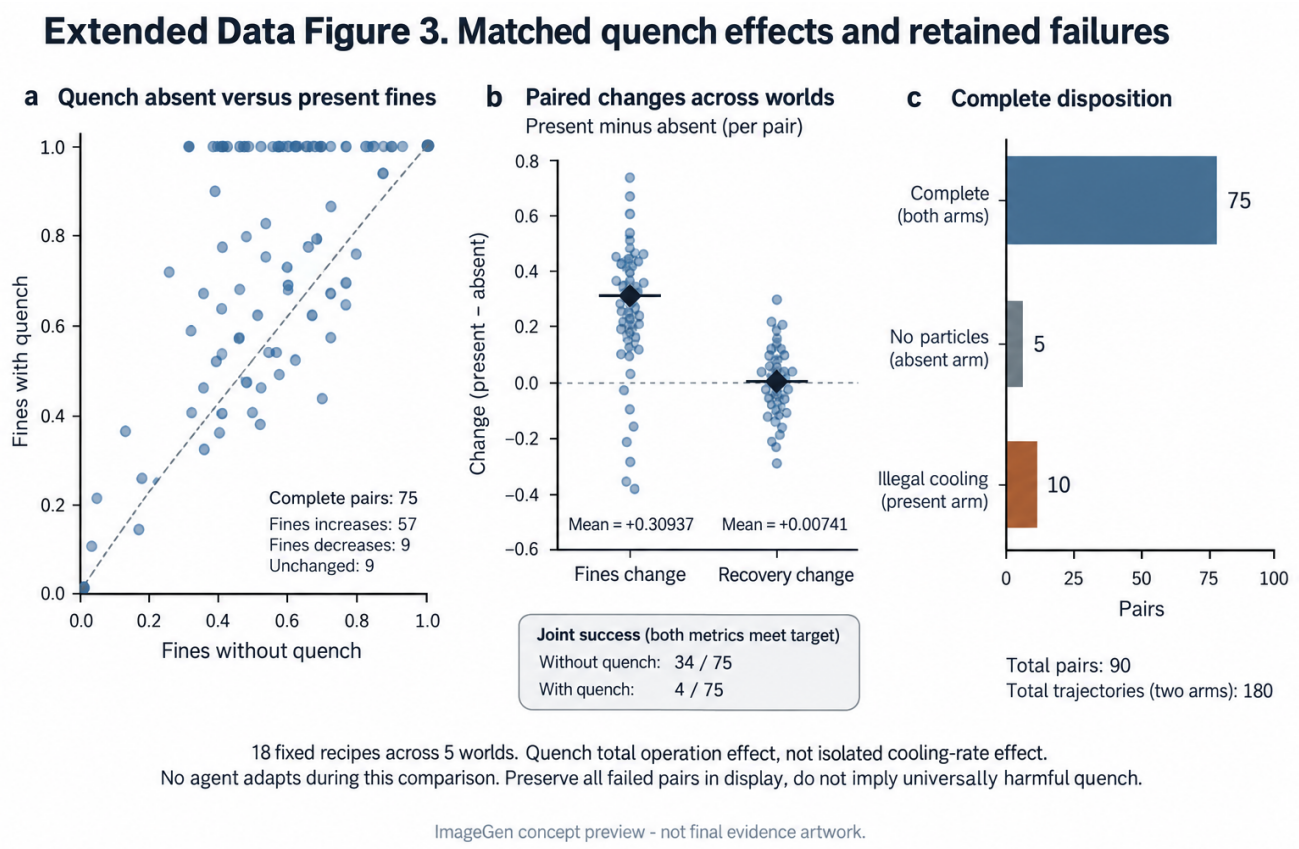
扩展数据



扩展数据图 1 | ImageGen 临时预览：计划中的干预成为被声称的阴性检验。图中文字是公开记录的概括而非逐字引文，箭头只表示顺序。a，研究者提出约 2 g 累积种量；四十次 0.05 g 请求中仅一次成功，三十九次被拒绝。b，后续笔记、封存报告与反思仍保留大剂量无效的说法。c，另一个智能体正确识别追加失败，限制后续剂量与结论。没有执行 2 g，因此本例不确定其物理效果。



扩展数据图 2 | ImageGen 临时预览：公开的不确定性与操作选择。生成点位仅作示意。a，一名研究者表达保留细粉余量的偏好，却选择最高观测可行回收；公开读数与无噪复测落在细粉上限两侧。b，另一名研究者实际放弃部分回收以保留余量，推荐仍合格。蓝色圆点表示公开测量，深色菱形表示无噪复测。两例是说明性比较，不能估计策略效果；任务允许选择最高观测可行回收。回收数值与排序沿用实际初始投料归一化输出，参与者所见定义存在方法中披露的不一致。



扩展数据图 3 | ImageGen 临时预览：匹配淬灭效果与不完整配对。生成散点与分布不是实测点位。a，75 个完整配对的有无淬灭细粉比较及方向计数。b，有减无的平均细粉与回收变化，以及同时成功数。c，全部 90 对分别为 75 对完整测量、5 对无淬灭臂无颗粒、10 对有淬灭臂后续冷却非法。对照采用前期 18 条固定推荐，在五世界分别执行；新增队列配方不是供体。淬灭比较操作的整体后果，不单独识别降温或停止反应的作用。回收变化与联合计数使用实际初始投料口径；提示不一致限制智能体表现解释，不改变这项固定配方的物理对照。