ARTICLE 15 October 2026

自主研究如何塑造科学认识

Jiangjie Qiu[1,*], Yijun Li[1,*], Yaotian Yang[1,*], Honghao Chen[1], Wentao Li[1], Xiaonan Wang[1,†]
[1]Beijing Key Laboratory of Artificial Intelligence for Advanced Chemical Engineering Materials, State Key Laboratory of Chemical Engineering and Low-Carbon Technology, Department of Chemical Engineering, Tsinghua University, Beijing 100084, China.
* Jiangjie Qiu, Yijun Li and Yaotian Yang contributed equally.
† Correspondence: wangxiaonan@tsinghua.edu.cn.

图像为 ImageGen 临时预览；图形位置仅作示意，定量结果以正文和补充表为准。

自主科学的核心承诺，是使实验自主性转化为科学认识的拓展[1,2]。我们利用 ChemWorld 的可编程化学世界，研究自主探索如何形成随后据以判断的科学关系。九十场重复过程研究连接实验选择、观测、同期判断与新条件预测；另行三十场比较在初始科学信息与评估协议匹配时，获得研究机会产生何种影响。研究使总体预测误差降低 73%，却使三道事先指定的极稀条件题误差增加 69%。同一比较中的连续记录显示，研究者修订初始预期、执行新的检验并建立有范围的局部关系，随后却在实验尚未解决的外推中赋予这一关系较大权重。修正协议后的结晶研究揭示已获证据使用的另一种分化：回收率预测在 39/42 场优于源观测均值，纯度则没有一场优于该参照。自主研究因此能够形成有效的局部认识，同时使某些超出已测范围的判断变差。它对科学认识的贡献，取决于实验结果如何被解释、所获关系的证据范围如何被保留，以及这些关系如何被用于新的条件。

自主研究者不仅干预世界，也通过实验与测量的选择，塑造科学判断赖以形成的经历：哪些现象被看见，哪些解释受到检验，哪些结果成为下一次研究的依据。因此，自主科学的承诺既涉及实验能力的扩展，也涉及实验经历向科学认识的转化。

机器人科学家与自驱动实验室已经展示了假说检验、材料发现和反应优化能力[3–6]。语言模型智能体进一步连接科学指令、工具与实验操作[7,8]。这些进展使一个更深的问题进入可研究的范围：智能体自己开展的研究，怎样改变它用来解释和预测世界的关系判断？有效方案构成实验成果，正确预测体现预测准确性；但两者都不能单独说明某项判断从何种证据中形成，以及这些证据支持多大的范围[9,10]。

我们利用 ChemWorld 考察这一过程。可编程的世界规律和独立指定的公开信息，使我们能够研究初始知识怎样进入实验选择、观测怎样支持或改变判断，以及这些判断怎样指导后续研究。证据从研究的组织方式出发，追踪工作关系的形成，再考察它们如何被用于新干预。有依据的局部检验、合理修订、缺少执行支持的解释与响应不同的迁移表现，并不必然共享同一种失败机制；它们共同说明，研究的科学后果取决于证据选择、解释和使用之间的连续转变。

使自主科学探索成为可检验的研究对象

ChemWorld 将材料、操作与仪器组合为具有持续状态的虚拟化学系统。智能体在固定资源范围内，自主决定投料、处理顺序、测量、重复及后续实验。这些选择改变样品，也决定哪些观测能够进入研究。评估者独立控制世界参数和公开信息，记录实际提交的操作，并获得封存的参考结果（图 1）。智能体在研究与评估阶段均看不到这些参考真值。

这一安排使智能体的研究过程能够被具体考察。知识测试和给定数据任务评价重要的科学能力[11,12]，交互式发现环境也已连接行动与观测[13–16]。ChemWorld 进一步在可组合的化学过程中，连接智能体自主选择的证据、不断变化的公开判断及其后续用途。一次操作请求可能在改变样品之前被拒绝；一项观测也可能只支持局部关系，尚未确定其在其他干预下是否成立。执行记录和独立评估的世界响应使这些区别能够被核对。

广度研究包含 Sol 在六类化学体系中的 240 场研究，以及另外四种模型配置的 60 场平衡研究。当前过程分析采用 45 场平衡研究和修正回收定义后重新执行的 45 场结晶研究。每个体系覆盖五个固定世界、三种信息条件、每格三次独立启动的模型会话。90 场中有 80 条完整研究—评估链、83 份有效预测；不完整会话仍保留在计划分母中。早期受回收描述不一致影响的结晶会话单独保留，不与修正版合并。

同期笔记将公开判断定位到当时可用的观测。研究结束后，智能体先封存科学解释，再在无法访问实验工具的条件下预测十二个新干预，最后在未获知真值的情况下反思。结构化过程分析在当前 90 场中的 65 场识别出 92 个可观察的 “判断—实验—修订” 窗口（扩展数据图 1）。其余 25 场在这一记录定义下缺少完整窗口，不能据此认定没有科学学习。另一个同期比较让 30 场新会话在共同评估协议下分别获得或不获得研究机会（图 4）。这些证据层回答互补问题，分别保留各自分母。

科学探索的自主组织与适应

探索始于研究目标、可用信息和受约束的行动空间。对 150 场保留研究的描述性比较显示，这些起点怎样进入证据经历。修正版结晶中，Aligned 条件的十五场均从溶剂 S2、催化剂 C1 开始；没有实例资料的十五场均从 S0、C0 开始。指定错配资料下，十三场从 S2 开始，十四场首先使用 C1。这些选择定位研究的起点，本身尚不构成学习的证明。

后续溶剂覆盖有所不同，但探索广度不足以完整说明科学探索。历史电化学发现与优化任务的溶剂覆盖接近，较大预算下均覆盖全部四种溶剂；完整路径统计和初始选择计数保留在补充材料。更有解释力的问题是：一次观测怎样改变研究者下一步要检验什么。

新增研究机会比较中的一条连续轨迹，下文统一称为 “平衡研究 A”，使这一转变具体可见（图 2）。该研究采用 Opaque 信息，没有获得实例专属的档案关系。初始笔记预期弱酸趋势：浓度升高应降低 pH 和解离分数，但前六次实验的解离分数始终约为 0.064–0.079。下一版笔记撤回原趋势在已测范围内的支持，并提出另一可操作组分可能才是相关输入。第八至十二批实际改用该组分，响应依然接近平台。封存解释保留局部关

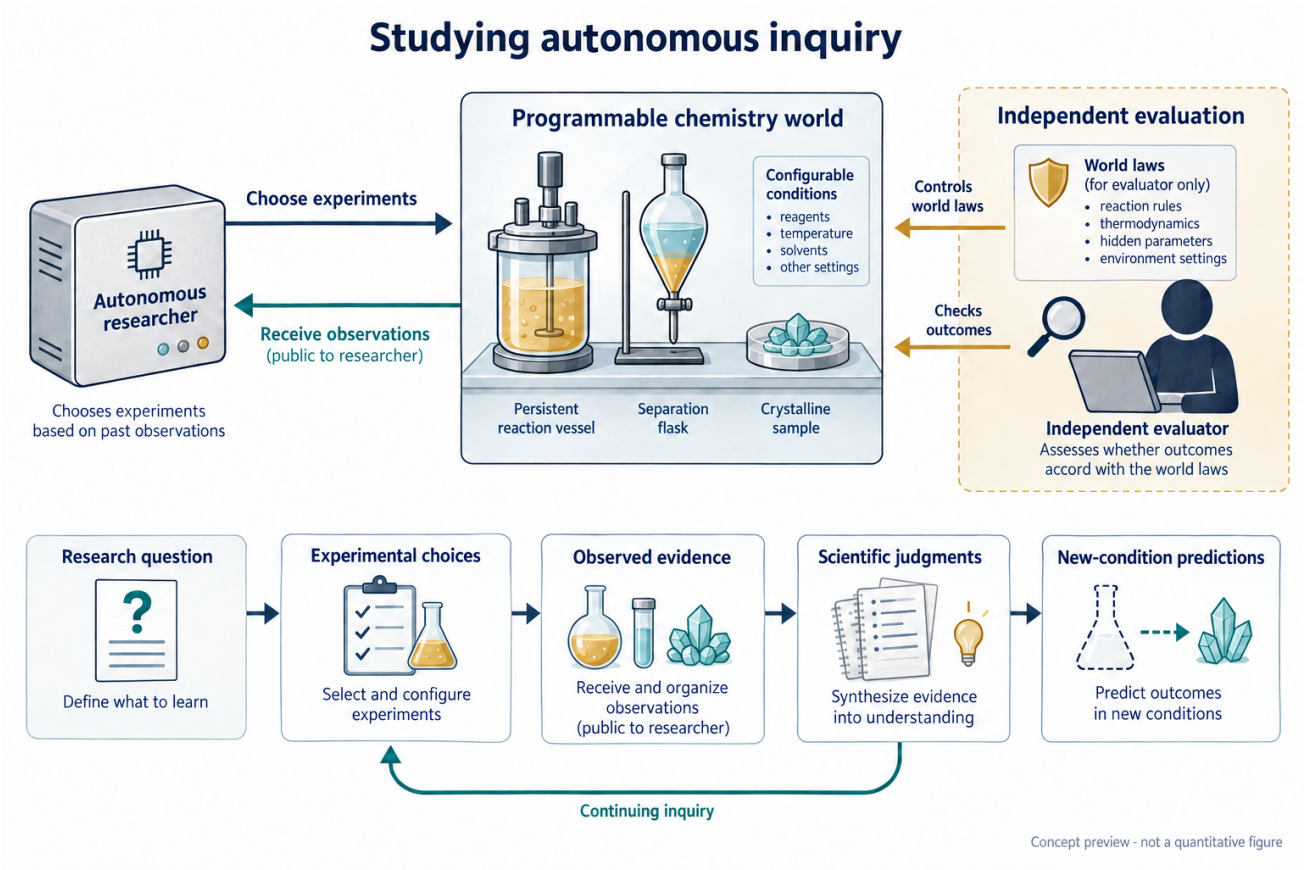


图 1 | 使自主探索成为可检验的研究对象。ImageGen 临时概念图。自主研究者选择干预，并从持续状态的化学世界获得公开观测。评估者独立控制隐藏参数并核对世界结果，参考真值不反馈给研究者。下方序列连接问题、选择、观测、公开判断和预测，判断又进入后续选择。图中概括的是可观察关系，不是内部认知的直接读数，也不代表已经识别笔记文字的因果作用。

系，同时没有认定唯一隐藏机制。这连接了事前预期、相反观测、新候选解释和真正执行的检验。

其他研究也会继续最初已经计划的扫描、缩小参数区间或重复临界配方。这些都属于研究组织，但其中只有一部分是在反馈之后新提出的检验。修正版结晶的 58 个窗口中，52 个所选即时计划与实际动作匹配，6 个部分匹配。这刻画了可观察窗口中的公开计划—行动联系，既不是发现率，也不能证明写下笔记导致了行动。接下来需要考察的是，这些行动与观测究竟建立了什么。

科学认识在实验中的形成与演变

科学关系在支持进一步检验、约束解释或指导新干预时，获得实际研究意义（图 3）。一场修正版结晶研究在获得接近细粉阈值的结果后，事前提出将试剂投料从 0.03 降至 0.02 mol。下一批执行了该提议，并通过细粉要求。这支持一项局部配方改进。然而，催化剂绝对量保持不变，其相对试剂的比例也随之改变，因此实验并未单独识别浓度机理。

另一场结晶研究检验了插值判断：根据邻近溶剂体积下不同的回收与细粉表现，研究者提出 0.065 L 应保留回收收益并改善细粉。下一批的细粉却从 0.512 升至 0.601，末版笔记随后撤回预期。一次未成功的操作干预，由此产生明确响应证据的认识修订。结合前述低投料成功检验，实验可以通过两种方式推进工作判断：建立局部改进，或撤回观测未能支持的预测。

干预是否真正发生，也决定能够从中学到什么。播种案例 B 计划累计加入约 1 g 晶种，实际只有 0.05 g 提交，随后十九次请求被拒；后续笔记正确识别高剂量检验尚未执行。播种案例 C 遇到类似拒绝，却把 1 g 描述为已测条件，并用结果反对播种解释。对照揭示同类执行限制怎样被赋予不同证据意义。其他热历史解释及临界条件重复案例保留在补充记录中。

同一项平衡研究 A 随后将有依据的局部修订带入了新条件判断（图 2c,d）。面对极稀条件，研究者写道：“The point estimate still favors the experimentally supported fixed acidic background”，预测解离分数为 0.085、80% 区间为 0.035–0.350，封存参考均值则为 0.716。解释与预测都承认这一条件未经检验，因此问题比遗漏一句范围声明更具体：得到局部支持的关系，在实验尚未解决的外推中获得了较大权重。同题匹配的无研究会话预测为 0.569、区间为 0.040–0.980，并明确依赖未经检验的先验假设。其数值更准确，并不等于形成了更好的实验发现。

这种延续并不必然发生。另一固定平衡世界中的两场研究都只在较高投料区间观察到平台，极稀宏平均误差却分别为 0.16287 和 0.01462。同一道极稀问题中，它们预测解离分数为 0.130 和 0.626，参考均值为 0.65463。更准确的一场采用了与平台观测相容的弱酸延续，同时明确称其为推测。准确外推不要求直接采样每个目标条件；准确本身也不等于研究已经通过实验识别了正确解释。连续记录使局部支持、未决可能及其后续预测用途能够被分别考察。

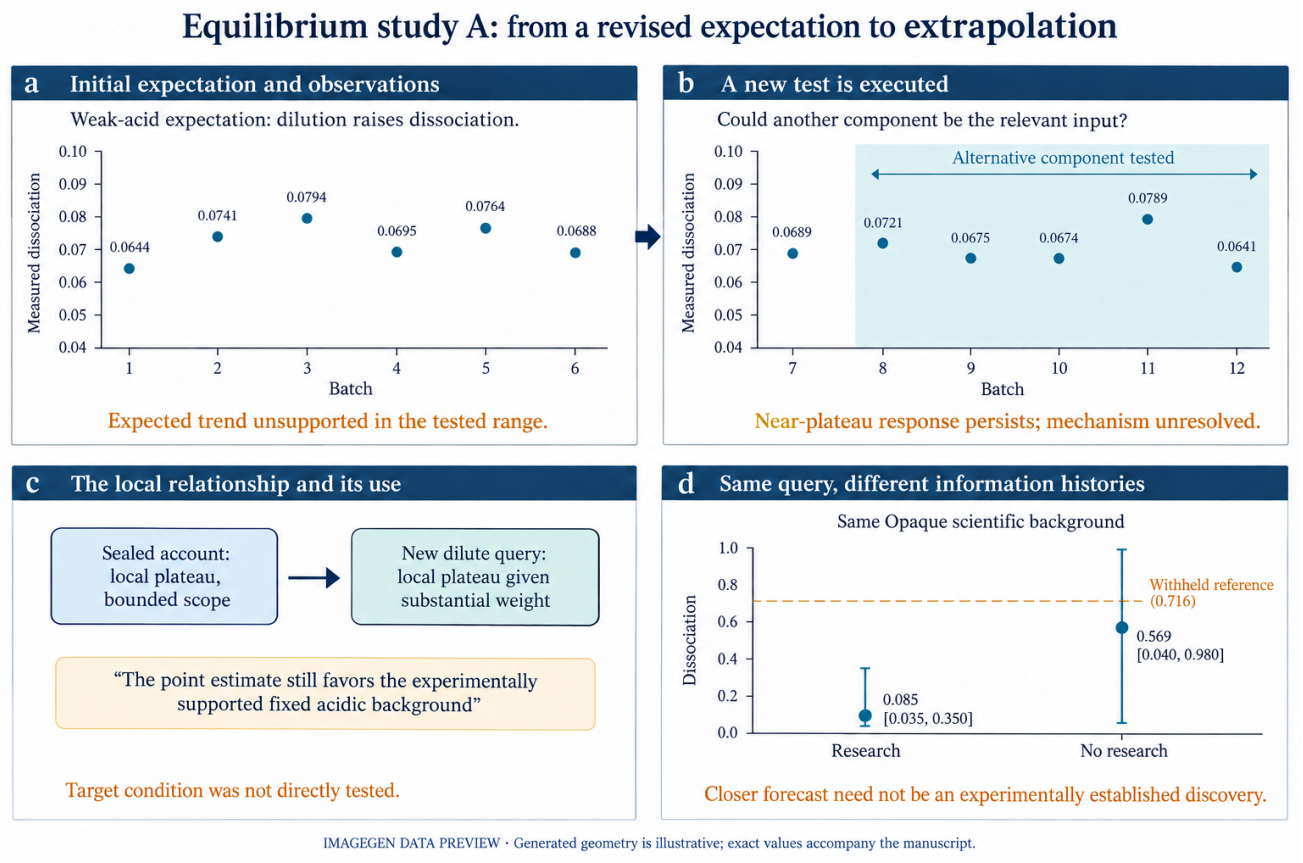


图 2 | 平衡研究 A：从修订预期到外推。同一研究会话及其匹配无研究预测的 ImageGen 数据预览。a，前六次测定不支持初始弱酸趋势在当前范围内的适用性。b，新候选解释进入第 8–12 批替代组分检验，响应仍接近平台。c，封存解释中的局部关系随后在极稀预测中获得较大权重，引文为原文。d，研究组预测解离分数 0.085 [0.035, 0.350]，无研究组 0.569 [0.040, 0.980]，封存参考均值为 0.716。区间为研究者给出的 80% 预测区间，源点为单次测定。这是新增研究机会比较的案例，证据包保留完整身份；生成几何为示意。

自主探索中科学进展的性质与条件

过程记录定位判断怎样形成和被使用，匹配的研究机会比较则检验获得研究机会是否改变后续预测（图 4）。三十场均采用 Opaque 信息：提供公开任务、材料标识、测量尺度、合法操作与初态，没有提供实例专属档案定律或拟合关系。五个平衡世界各配置三场拥有十二批源实验机会的新会话，以及三场没有源实验的新会话；同世界同重复的两组科学输入与封存评估相匹配。三十场全部终态，180 批计划源实验全部完成，二十九场提供有效预测。一场因网络中断缺失预测及随后阶段，其源观测和科学解释仍予保留。

研究总体上大幅降低了平均误差。先在世界内平均有效会话、再对五个世界等权，归一化宏平均绝对误差由无研究的 0.132086 降至有研究的 0.035632，下降 73.0%，五个世界方向一致。但在事前指定的三道极稀问题上，误差从 0.061467 增至 0.103677，增加 68.7%，五个世界中四个恶化。其余九题的误差则从 0.155625 降至 0.012950。这一比较考察整个研究机会组合，包括实验选择、反馈与可用记录工具，不单独归因于其中某个组成部分。

同一研究机会因此可以改善总体预测，同时损害特定区域的预测。极稀子集中，三个响应的平均点预测误差均增加，幅度不同：研究减无研究的 MAE 差值，归一化 pH 为 +0.00777、解离分数为 +0.10795、沉淀信号为 +0.01092；解离分数贡献了宏平均误差增量的 85.2%。这是总体拆分，不意味着每道题、每个世界或每次会话均恶化。图 4 展示会话点和世界均值，完整逐会话逐响应及逐题结果随稿提供。平衡研究 A 则给出一条从有效局部发现走向远端判断的可观察路径，不能据此认定它解释所有会话差异。

这一结果还涉及区间判断，却不支持统一的“更自信但更错误”叙事。在极稀条件下，有研究组三个名义 80% 区间的实际覆盖率均低于无研究组，但无研究组区间明显更宽。兼顾宽度与漏覆盖惩罚的区间分数，在 pH 上支持有研究组，在解离分数上支持无研究组，在沉淀信号上接近；全部问题合计，研究改善三个响应的区间分数。让唯一缺失会话的宏平均误差取遍合法范围的保守敏感性分析，也不能翻转总体收益或极稀损失这两个平均方向（方法）。

结晶揭示已获证据使用的互补现象（扩展数据图 2）。对 42 份有效预测，我们构建只利用该会话源观测的透明参照。五世界等权纯度误差，智能体为 0.03853，全部源观测均值为 0.00510，且每个有效会话中后者都更准确。回收率方向相反：智能体误差为 0.10129，参照为 0.20443，39/42 场优于均值。按精确已提交溶剂集合限定参照后，两个总体方向仍保留；粒度、细粉分别有 5/42、23/42 场胜出。该比较诊断已有证据在不同响应中怎样被使用，源均值既不是无研究组，也不是另一名自主研究者，因而不直接估计结晶研究的因果收益。

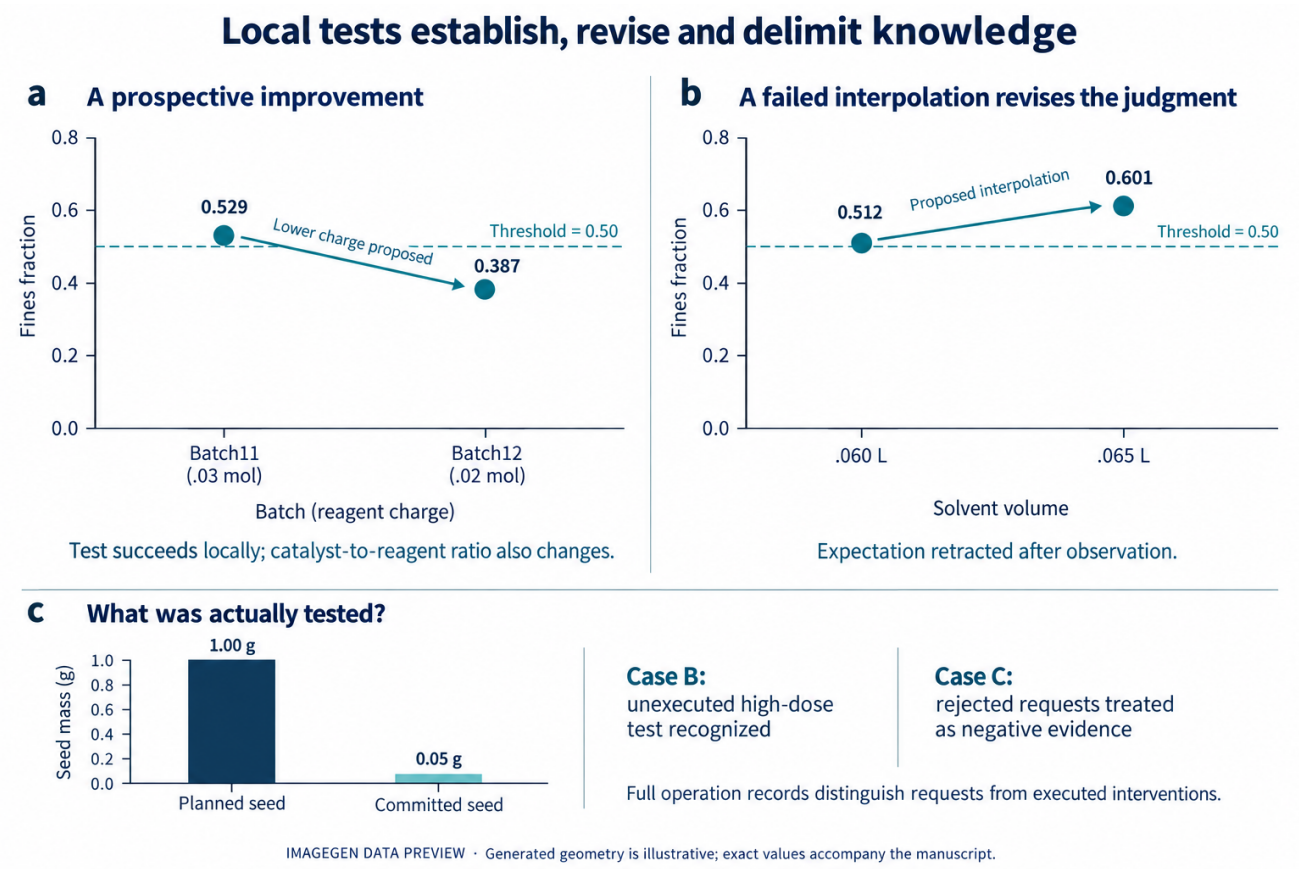


图 3 | 局部检验建立、修订并限定认识。不同结晶研究的 ImageGen 数据预览。a，低投料使细粉由 0.529 降至 0.387、跨过 0.50 阈值，同时改变催化剂相对试剂的比例。b，溶剂体积插值使细粉由 0.512 升至 0.601，研究者随后撤回预期。a、b 的点是单次测定，不是附有不确定区间的均值。c，计划 1 g 播种，实际仅 0.05 g 提交；案例 B 识别高剂量检验未执行，案例 C 将拒绝请求用作阴性证据。两者是不同研究，不是同一轨迹的连续状态。生成几何为示意，完整记录随稿提供。

这些发现补充了早期的操作—预测比较。电化学优化在三十个匹配条件中的二十六个获得更好的推荐方案，其中预测更好与更差各十三个。重复平衡队列中，正确但不完整的先验使九题误差从 0.00907 降至 0.00512，却使极稀误差从 0.09880 增至 0.13205。初始信息、实验成就与后续预测都参与构成科学结果，但都不能替代对 “研究支持了何种关系，以及它被怎样使用” 的考察。

讨论

自主研究能够形成有效的局部认识，却不保证这些认识在后续应用中保持与证据相称的范围。匹配比较中，研究大幅改善总体预测，同时使事先指定的极稀区域预测变差。连续轨迹表明，这种分化可以与合理修订和新的实验并存：研究者撤回初始预期、检验竞争可能并建立有范围的经验关系，随后却在尚未解决的条件中赋予这一关系较大权重。结晶参照揭示互补局限：同一研究历史支持某些响应的有效预测，却未能充分保留另一些已经观察到的关系。这些结果具体说明了研究贡献什么，以及研究成果如何被使用。

研究科学认识的形成，需要具体说明提出了什么关系、当时什么信息支持它、世界实际检验了什么，以及关系随后怎样被使用。记录既包含合理撤回和范围明确的改进，也包含缺少实际执行支持的解释；还包含依赖未被实验确定的可能性所作出的准确预测。这些区别与科学研究中区分性检验和推断的作用相一致 [17–19]，但不能从成功调用工具或连贯的科学解释中，直接假定自主智能体已经实现了它们。

对照实验限定了可以作出的因果解释。匹配的研究机会比较，在共同评估协议下估计整段研究机会的作用。另一个固定配方淬灭对照识别操作在虚拟世界中的物理效果，其结果没有交给能够适应的研究者（扩展数据图 3）。两者均未单独识别笔记的作用，也不能证明某项判断通过选择性实验维持自身。解释已经观察到的关系形成与使用，不要求每条轨迹共享这类机制，也不要求最终以一种纠错策略成功收束。

本研究局限于选定的可编程体系、少量固定世界，以及重复过程分析中的一种模型配置。新会话既不是受控模型 seed 重复，也不是世界规律的独立样本。笔记是公开记录，不是内部认知读数；记录间隔限制时间推断。案例从系统保留的记录中事后选取，由单一分析者解释，没有第二评分者的一致性估计。历史与当前协议分别保留来源，包括修正版结晶及全部失败。这些边界限制发生率和普遍性主张，同时保留可核对的过程转变与限定明确的比较。

自主研究的价值因此不仅取决于有效实验结果的积累，还取决于这些结果建立了什么关系，以及研究者如何将关系的证据范围带入后续探索。本研究既显示大幅的总体收益，也显示这一收益在明确预测区域中的方向逆转；连续记录进一步连接了预期、局部发现和后续判断的具体转变。自主探索中的科学进展，发生在证据被持续解释和使用的过程中。ChemWorld 使这些转变能够接受实验比较与核验。

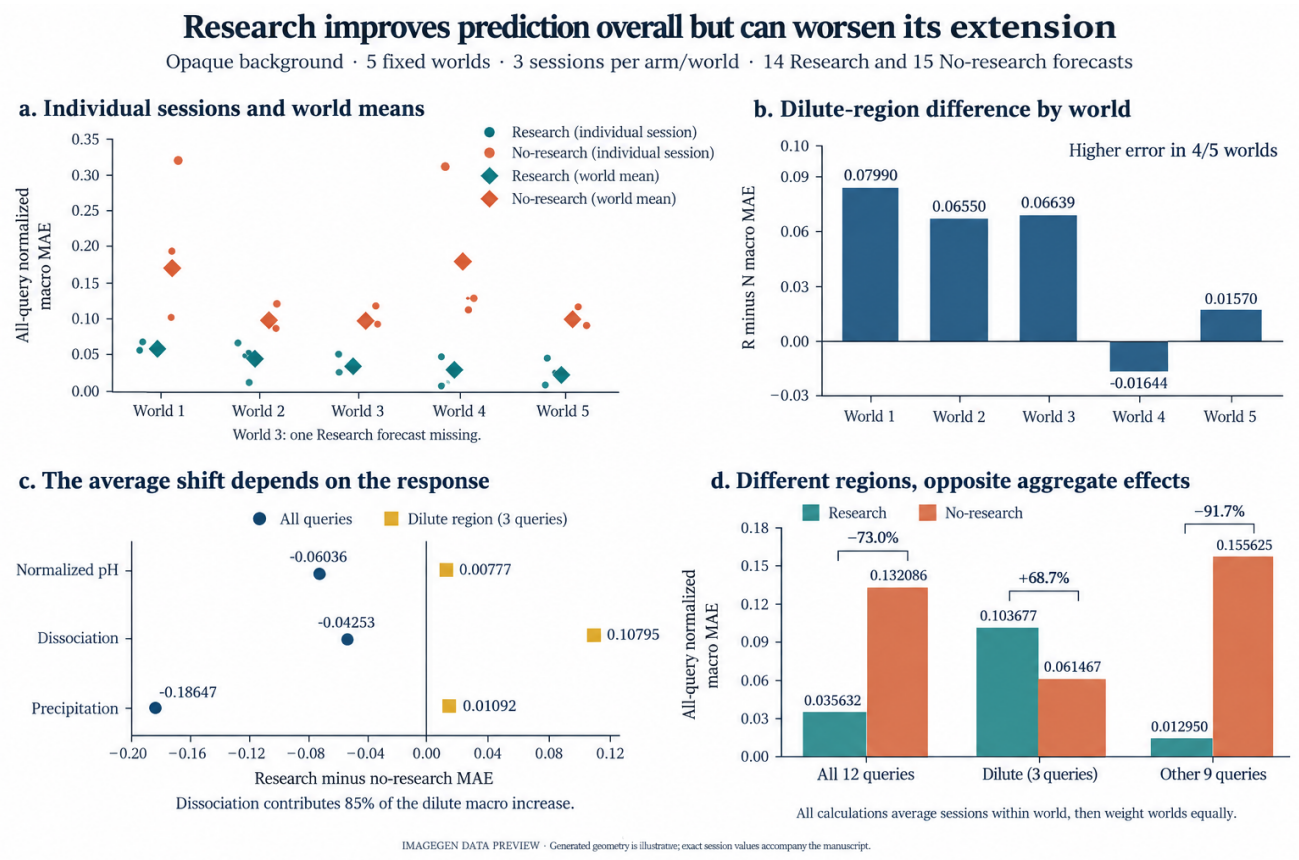


图 4 | 研究带来的总体收益与区域性反转。ImageGen 数据预览。三十场均采用 Opaque 信息，科学输入匹配。a，逐会话总体宏误差与世界内均值，研究/无研究分别有十四/十五份有效预测；世界 3 保留一份研究组缺失。b，极稀区域研究减无研究的宏误差在五世界中的四个为正。c，各响应变化幅度不同，解离分数贡献极稀宏误差增量的 85.2%。d，全部十二题、极稀三题、其余九题的五世界等权误差分别变化 −73.0%、+68.7%、−91.7%。生成点位与几何为示意，准确会话值、响应误差及全部 1,044 条有效逐题逐响应记录见证据包；不表示置信区间或总体抽样推断。

资助

本研究获得深圳市科技计划项目（AI2026004）、清华大学自主科研计划，以及青年教师科研创新能力支持项目（ZYGXQNJSKYCXNLZCXM-E7）资助。

参考文献

1. G. Tom et al. Self-Driving Laboratories for Chemistry and Materials Science. *Chemical Reviews* **124** 9633–9732 (2024). https://doi.org/10.1021/acs.chemrev.4c00055.
2. D. A. Boiko, R. MacKnight, B. Kline, and G. Gomes. Autonomous chemical research with large language models. *Nature* **624** 570–578 (2023). https://doi.org/10.1038/s41586-023-06792-0.
3. R. D. King et al. The Automation of Science. *Science* **324** 85–89 (2009). https://doi.org/10.1126/science.1165620.
4. B. Burger et al. A mobile robotic chemist. *Nature* **583** 237–241 (2020). https://doi.org/10.1038/s41586-020-2442-2.
5. B. P. MacLeod et al. Self-driving laboratory for accelerated discovery of thin-film materials. *Science Advances* **6** eaaz8867 (2020). https://doi.org/10.1126/sciadv.aaz8867.
6. N. J. Szymanski et al. An autonomous laboratory for the accelerated synthesis of inorganic materials. *Nature* **624** 86–91 (2023). https://doi.org/10.1038/s41586-023-06734-w.
7. A. M. Bran et al. Augmenting large language models with chemistry tools. *Nature Machine Intelligence* **6** 525–535 (2024). https://doi.org/10.1038/s42256-024-00832-8.
8. T. Dai et al. Autonomous mobile robots for exploratory synthetic chemistry. *Nature* **635** 890–897 (2024). https://doi.org/10.1038/s41586-024-08173-7.
9. A. N. Elmachtoub and P. Grigas. Smart Predict, then Optimize. *Management Science* **68** 9–26 (2022). https://doi.org/10.1287/mnsc.2020.3922.
10. G. Shmueli. To Explain or to Predict? *Statistical Science* **25** 289–310 (2010). https://doi.org/10.1214/10-sts330.
11. A. Mirza et al. A framework for evaluating the chemical knowledge and reasoning abilities of large language models against the expertise of chemists. *Nature Chemistry* **17** 1027–1034 (2025). https://doi.org/10.1038/s41557-025-01815-x.
12. B. P. Majumder et al. DiscoveryBench: Towards Data-Driven Discovery with Large Language Models. *International Conference on Learning Representations* **2025** 4556–4579 (2025). `https://proceedings.iclr.cc/paper_files/paper/2025/file/0d70af566e69f1dfb687791ecf955e28-Paper-Conference.pdf`.
13. R. Wang, P. Jansen, M.-A. Côté, and P. Ammanabrolu. ScienceWorld: Is your Agent Smarter than a 5th Grader? *Proceedings of the 2022 conference on empirical methods in natural language processing* 11279–11298 (2022). https://doi.org/10.18653/v1/2022.emnlp-main.775.
14. P. Jansen et al. DiscoveryWorld: A virtual environment for developing and evaluating automated scientific discovery agents. *Advances in neural information processing systems* **37** (2024). https://doi.org/10.52202/079017-0324.
15. K. Gandhi et al. BoxingGym: Benchmarking progress in automated experimental design and model discovery. (2025). `https://arxiv.org/abs/2501.01540`.
16. Y. Chen, P. Piękos, M. Ostaszewski, F. Laakom, and J. Schmidhuber. PhysGym: Benchmarking LLMs in Interactive Physics Discovery with Controlled Priors. *Advances in Neural Information Processing Systems* **38** (2025). https://doi.org/10.52202/085713-1556.
17. J. R. Platt. Strong Inference. *Science* **146** 347–353 (1964). https://doi.org/10.1126/science.146.3642.347.
18. D. V. Lindley. On a Measure of the Information Provided by an Experiment. *The Annals of Mathematical Statistics* **27** 986–1005 (1956). https://doi.org/10.1214/aoms/1177728069.
19. K. Chaloner and I. Verdinelli. Bayesian Experimental Design: A Review. *Statistical Science* **10** 273–304 (1995). https://doi.org/10.1214/ss/1177009939.
20. T. Gneiting and A. E. Raftery. Strictly Proper Scoring Rules, Prediction, and Estimation. *Journal of the American Statistical Association* **102** 359–378 (2007). https://doi.org/10.1198/016214506000001437.

方法

世界、接口与实验单位

ChemWorld 将兼容的过程组件编译为具有持续状态的虚拟化学环境。公开契约指定材料、合法操作、仪器、资源和任务目标，私有参数决定具体世界的响应。智能体能够访问实验室和公开记录，不能访问评估者状态、模拟器代码、私有参数或封存参考结果。操作改变样品，测量可能消耗材料。候选转变在提交之前接受校验；被拒绝的操作不构成所请求的物理干预，但尝试可能消耗契约规定的资源。精确重放核对环境状态转变，不重新生成模型决策。

广度研究覆盖电化学、分配、反应与热处理、水溶液平衡、反应耦合结晶和纯化。这些是受控虚拟系统，不是对具名现实物质经过实验验证的预测。当前重复研究采用平衡与结晶。五个固定世界在不同条件与重复中复用，世界参数、初始状态和键控观测映射保持固定。重复单位是新模型会话，不是独立世界抽样或受控模型 seed 重复。接口没有可用的模型采样 seed；相同干预可以得到相同键控观测，因此也不是独立噪声实现。

证据层与保留分母

历史广度研究包含 240 场 Sol-medium 研究，以及 Luna、Terra、GPT-5.5 和 Astra 的 60 场额外平衡研究，均请求 medium 推理强度。五模型平衡比较中的十五场 Sol 已包含在 240 场内。请求的模型标签不代表实际计算量相等。原 240 场包含电化学 60、分配 30、反应 60、平衡 45、结晶 30 和纯化 15 场；按其原规则保留 3,597/3,600 次最终测量、全部 720 个后测阶段与 238 场协议符合研究。额外六十场保留 720 批和 240 个阶段。两场原始源研究完成度失败仍予保留。更早的选定笔记案例另有 24 场，不与广度或当前过程队列合并。

当前过程队列由早期 48 场及其 42 场扩展中的 45 场平衡研究，以及统一回收描述后完整重跑的 45 场结晶研究组成。每个体系覆盖五世界、Opaque/Aligned/MisIndexed 三信息条件、每格三场，每场十二批。平衡保留 39 条完整链、41 份有效预测；修正版结晶分别为 41 和 42。当前合计分母为 90 场、80 条完整链、83 份有效预测。旧结晶作为受协议影响的历史证据保留，不加入修正版计算当前结果或过程频率。

修正版结晶完成 510/540 个源批次、125/135 个后测阶段，保留 145 版笔记和 42 次推荐复测。全部 45 条源轨迹与 42 条复测轨迹通过重放。四条不完整链中，三条缺失预测，另一条有有效预测但缺失随后的反思。平衡子集与独立的研究机会块各自保留失败表。缺失不填零，已完成结果不由后来更有利的结果替代。稿件整合不改变任何实验块原有的开发或资格证据地位。

信息、自主性与记录

Opaque 提供公开任务和操作背景，不提供额外实例资料。Aligned 提供与体系相符的部分信息；平衡包括有效酸度区间和带锚点的局部稀释关系。MisIndexed 使用另一世界的历史关系，格式与限定相同。结晶 Aligned 提供匿名材料名义描述，MisIndexed 交换 S1/S3 溶剂描述，保留 S0、S2 和催化剂描述。两者均不是完整世界规律。

原平衡 Opaque/Aligned 早于 MisIndexed 扩展；修正版结晶是更晚的完整实验块。这些描述性比较并非全部同期随机处理，新旧结晶也不能估计修正提示的因果作用。下文单列的新研究机会比较采用共同的同期协议。

智能体在固定预算内选择操作、用量、测量、重复与操作分组。平衡允许十二批、180 次操作尝试、十二次中间仪器与十二次最终测量；结晶采用固定十二批材料预算和 720 次尝试上限。记录角色要求在适用时先写出可检验预期，后续由智能体自主更新，不要求每批书写，也不自动重新注入笔记。记录角色可能影响研究，不被视为被动观察。笔记保存版本与公开事件游标，不揭示内部认知。没有调用笔记读取工具，不代表无法访问会话中此前出现的内容。

后测与回收定义

源研究及操作推荐结束后，智能体依次封存科学解释、在无实验工具条件下回答十二个固定新干预问题，再在没有真值反馈的情况下反思。平衡另有结构化补充评估。证据中的 K1/Q/K2/EQS 分别表示这些阶段。源研究期间不展示预测问题；后测提出的方案不计为已执行源实验。

平衡点误差以每题五个参考观测的均值为比较对象，覆盖率检查全部五次观测。结晶使用最终测量采样之前的无噪声完整流程响应，源观测则带噪声。修正版保留六十个参考批次，数值与旧参考一致，并对每份可用的已提交推荐单独复测。

修正后的回收定义为：扣除晶种贡献的固相目标产物摩尔量，除以所跟踪的初始试剂投料摩尔量，截断到 [0,1]。源指令、预测提示、观测与评分现在指向同一完整流程量。内部结晶阶段指标则以分离前的目标产物为分母。旧过程指令描述后者，而观测与评分使用初始投料；原分数作为受协议影响的诊断值保留，不进入修正版队列。修正版完整重跑，没有事后为旧分数更名。

质量要求有颗粒、纯度至少 0.80、细粉至多 0.50；联合推荐成功还要求修正定义的回收率至少 0.10。按可用复测，修正版联合成功为 Opaque 13/15、Aligned 10/14、MisIndexed 10/13，每臂仍各计划十五场。粒度采用公开指数 min(d50/250 微米, 1)，其误差不能写成微米。

研究路径与过程解释

事后路径提取覆盖历史电化学六十场、平衡四十五场和修正版结晶四十五场。五十个世界内条件比较保留目标、预算、信息与队列。计数采用实际提交操作，溶剂覆盖包括再悬浮添加；拒绝请求不构成成功材料使用，中断会话保留在计划分母中。

结构提取检查当前九十场、268 版笔记构成的全部 178 对相邻版本。入选需要早期笔记、下一版之前至少一次新的已提交最终测定，以及后版之后的已提交研究操作；仅测量或终止不构成继续研究。178 对均有新增测定，其中 92 对满足继续研究：平衡 34 个窗口分布于 30 场，结晶 58 个分布于 35 场。另 86 对（平衡 44、结晶 42）之后没有继续执行已提交研究操作，完整记录仍保留在证据包。没有完整窗口的二十五场不被归类为没有学习。

入选先依据事件时序计算，不以某个计划是否最终成功执行为条件。但该规则确实要求后续继续开展已提交研究，因此终点修订不进入这一行动关联分母。92 个入选窗口全部编码；标签针对每个窗口选定的即时计划，不穷尽笔记里的所有提议：83 个匹配、7 个部分匹配、2 个无明确下一计划，其中修正版结晶为 52 个匹配、6 个部分匹配。即使某个所选行动匹配，完整笔记仍保留未落实、被拒及改变的其他提议。全部 182 条更新/计划引文及测定/操作游标经源记录核对；证据包包含全部相邻版本、所选编码、全文笔记和执行历史。

编码和内部科学复查由同一分析者完成，没有独立第二评分者一致性估计、盲法或经独立裁决的机制发生率。团队已将复查交给本流程，完成的内部复查与独立重复明确区分。反例包括合理撤回、正确识别未执行检验，以及准确但明确标为推测的外推。说明案例为事后选择。

仅使用源观测的预测参照

对每份有效修正版结晶预测，只利用该研究者成功的源最终测量构建两个透明参照。第一个平均全部可用测量；第二个只平均与查询具有相同已提交溶剂标识集合的测量，无匹配时回退到整体均值。溶剂集合包括成功加溶剂与再悬浮操作，排除拒绝请求。拟合函数不接收测试真值。这些是描述性计算，不是另行训练的智能体或完整机理基线。

有效会话 42 场，共 504 题。同溶剂回退发生在 186/504 题，其中 Opaque 1/180、Aligned 95/168、MisIndexed 90/156。该匹配不控制热史、用量或最终液相组成，参照没有预测区间。回收、纯度、粒度和细粉均按各自公开尺度报告，不合成一个跨响应分数。

匹配的研究机会比较

固定设计为五个平衡世界、Research/NoResearch 两条件、每格三场 Sol-medium 新会话，共三十场，全部采用 Opaque 信息。共同公开背景包含任务及测量定义、材料目录、合法操作/仪器和初态，实例档案先验为空。Opaque 表示没有额外实例规律，不表示缺少公开化学背景或模型预训练知识。完整初始公开输入随稿提供；十五个世界内同重复配对在仅排除非科学会话标识后，确认科学输入一致。Research 额外得到十二批自主实验和既有笔记机会，NoResearch 没有源操作或观测；两组评估提示、模式、顺序与限制一致。

三十场全部终态，研究组完成 180/180 批，两组合计完成 117/120 个后测阶段、29 份有效预测。第三世界第三次 Research 在科学解释后出现预测流断连，Q 与随后两阶段缺失，没有替换。因此 Research 有十四份有效预测、NoResearch 十五份，Research 的第三世界为两次，其余每格三次。十五条源轨迹及二十五条参考轨迹（300 批）精确重放通过。29/30 场资源账本完整，另一场仅有已记录的部分用量；记录到的输入加输出共 13,428,656 tokens。缺失用量不按零处理，金额不可得。

首次执行尝试因评估传输配置缺少必要字段而失败。已启动四场、其中两场已完成的二十四批源研究和资源消耗单独保留，没有完成科学解释阶段。修复执行缺陷后，按原设计从头重跑整个三十场块。这属于协议修复，不是根据科学结果替换。仅完整重启后的实验块进入比较。

该比较估计共同评估条件下整段研究机会的作用，不能单独识别自主选择相对给定数据、反馈本身、笔记或内部表征变化。比较在新会话之间进行，没有会话内前测。世界与条件顺序采用事先固定的平衡启动安排，不是对世界规律进行随机抽样。

定量汇总与缺失

平衡宏平均绝对误差在指定问题中等权平均归一化 pH、解离分数和沉淀信号。极稀组为重复块执行前固定的三题，其余九题不被假定全部处于分布内。先在世界内平均有效会话，再对五世界等权。逐场数值和缺失阶段均保留。响应、问题、参考观测和批次嵌套相关，不能充当独立研究者样本。

名义 80% 区间同时报告覆盖率、平均宽度和适当区间分数 [20]。下界 l、上界 u、观测 y、alpha = 0.2 时，分数为 (u-l)，若 y 低于 l 加上 (2/alpha)(l-y)，若高于 u 加上 (2/alpha)(y-u)，越低越好。汇总按世界等权；智能体区间不是组均值的置信区间。

事后敏感性分析允许唯一缺失的研究机会预测取 [0,1] 内任意宏平均误差，并按每格计划三次和五世界等权重算。有研究减无研究的保守范围，总体为 [-0.098659, -0.031992]，极稀为 [+0.036768, +0.103434]。这是缺失结果影响的界限，不是填补、置信区间或总体推断。固定条件下三次会话描述波动，不建立总体可靠率。

匹配淬灭干预

独立保留的对照将原第一期十八份结晶推荐置于五个世界中，比较有无单个淬灭操作，共九十对、一百八十条轨迹。其他动作参数和初态匹配；淬灭从原位置删除，或插入首次播种/结晶冷却之前。没有智能体适应，也不向智能体反馈结果。

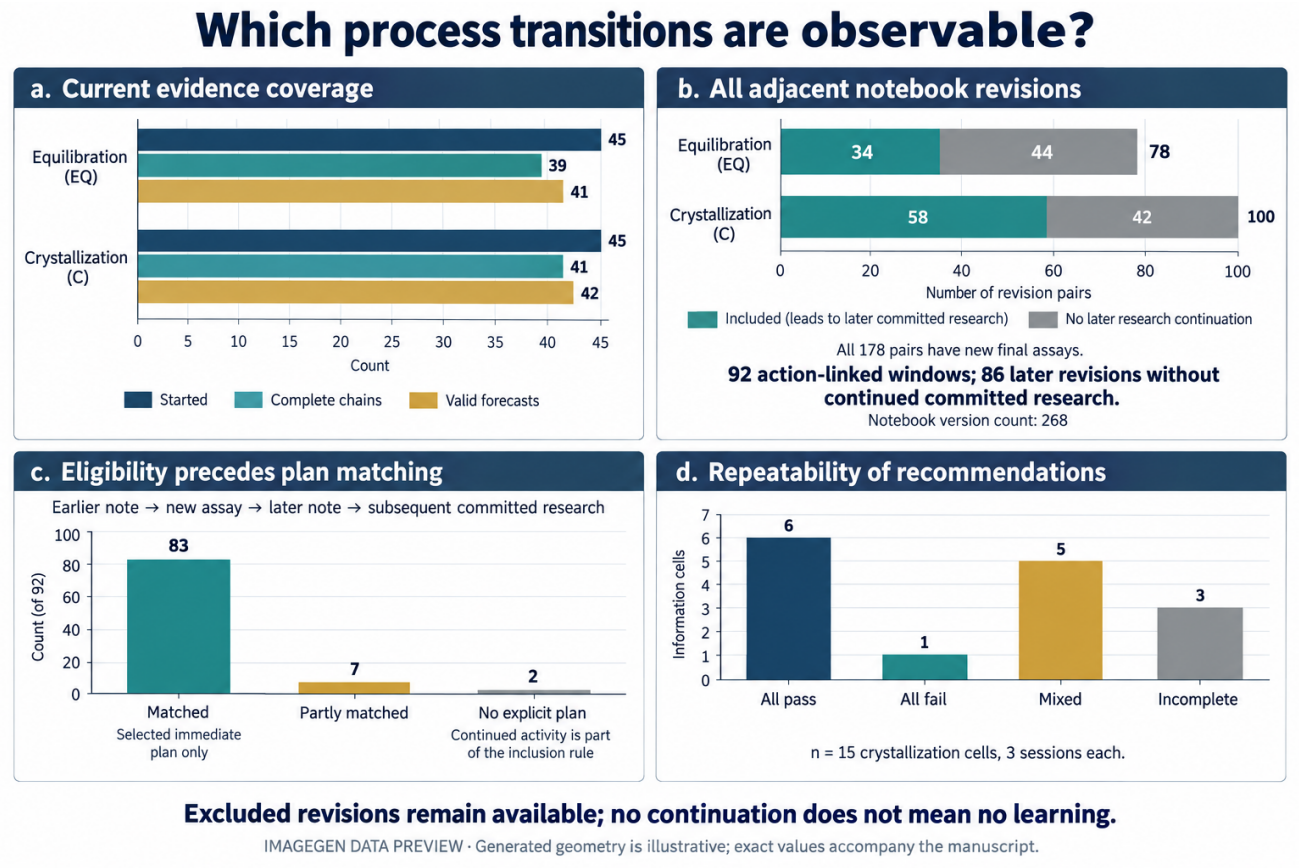
全部轨迹保留并重放，七十五对具有两侧最终测量。五对无淬灭侧缺颗粒，十对有淬灭侧使后续固定冷却请求失效，失败不修复。完整对中，有减无的平均细粉变化为 +0.30937、回收变化为 +0.00741，联合成功从 34 降至 4。这些条件性效果描述实际初始投料回收口径下的物理操作。淬灭改变多个物理状态量，不单独识别冷却速率或科学判断的成因。供体配方来自历史队列，不来自修正版。

数据与代码可用性

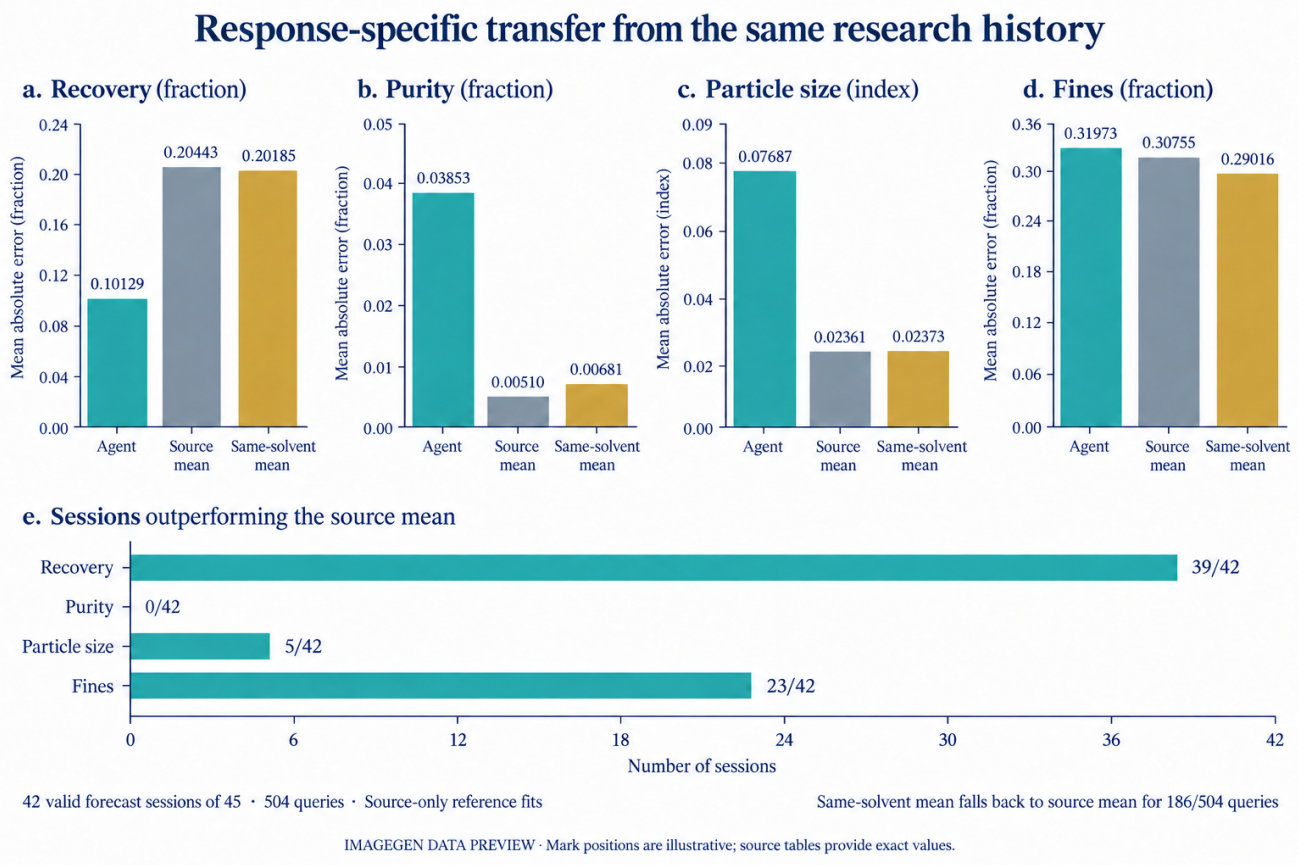
随稿证据包包含完整初始公开输入、1,044 条逐题逐响应预测、全部 270 个计划会话/问题组/响应单元、世界汇总、连续主例、178 对相邻笔记及当前九十场完整公开历史，明确保留缺失预测。原摘要、精确重放与资源记录仍在项目仓库；该包不增加参与者证据，也不构成独立第二评分者复核。补充材料报告误差拆分和编码筛选规则，永久公开存档仍待落实。本轮稿件构建只读取保留结果，不调用模型或模拟器开展新实验。

七张插图均为 ImageGen 临时预览，包括一张框架图与六张数据预览。图中以保留观测及统计摘要为数值锚点，生成的点位、点数和几何形状仅作示意。精确数值由正文和表格承载，生成提示与来源记录随图片保留。

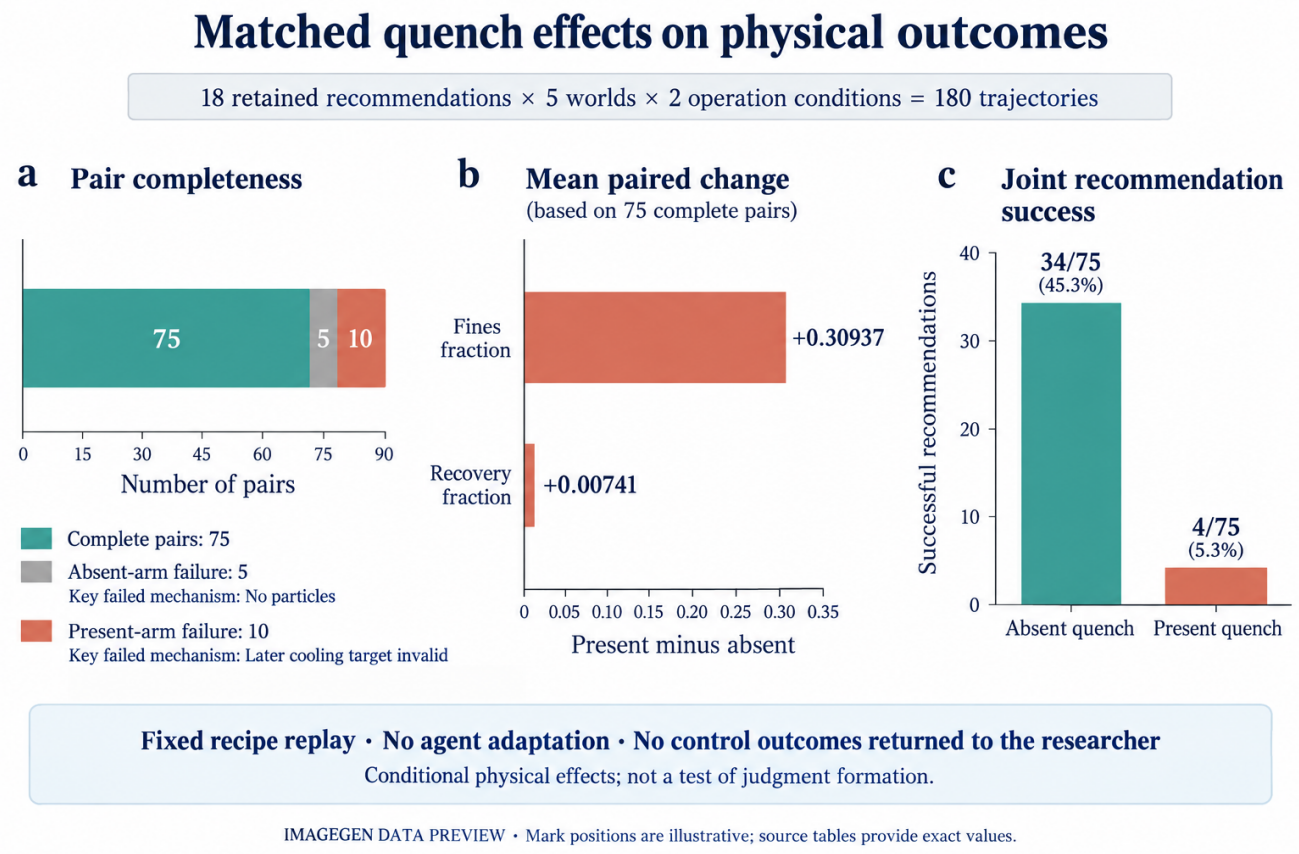
扩展数据



扩展数据图 1 | 哪些过程转变能够被观察？ImageGen 数据预览。a，当前会话覆盖和有效预测。b，178 对相邻版本均包含新测定，平衡 34/78 对、结晶 58/100 对还具有后续已提交研究行动，合计 92 个入选窗口；另 86 对修订完整保留但不赋予行动关联编码。c，所选即时计划有 83 个匹配、7 个部分匹配、2 个没有明确下一计划。入选先于语义匹配，但以继续行动为条件；计数不代表学习成功，也不涵盖全部提议。d，十五个结晶世界 × 信息条件单元各三场，六组全达标、一组全未达标、五组混合、三组缺失。生成几何为示意。



扩展数据图 2 | 同一研究经历的响应特异性迁移。ImageGen 数据预览。a–d，比较研究者预测与两种仅用源观测拟合的参照，分别展示回收率、纯度、粒径指数和细粉，保留各响应自身尺度。粒径为无量纲指数 min(d50/250 微米, 1)。e，研究者胜过总体源均值的会话数依次为 39/42、0/42、5/42、23/42。修正版结晶 42 份有效预测共含 504 道题；同溶剂参照在 186/504 题回退至总体均值，未匹配热史或数量。两种参照均未使用封存真值拟合。图形位置为示意，五世界等权误差详见补充表。



扩展数据图 3 | 匹配淬灭对物理结果的影响。ImageGen 数据预览。十八份历史推荐在五世界分别有/无淬灭重放，共九十对、一百八十条轨迹。a，七十五对获得双方终测；无淬灭分支五次无颗粒，有淬灭分支十次使后续固定冷却目标无效。b，完整对的细粉平均变化为 +0.30937，回收变化为 +0.00741。c，联合达标从无淬灭 34/75 变为有淬灭 4/75。该结果是初始投料回收定义下的条件性物理作用；研究者未调整操作，也未获得对照结果，因此不能据此识别判断形成原因。图形位置为示意，失败配对全部保留。