ARTICLE 15 October 2026

自主研究如何塑造科学认识

Jiangjie Qiu[1,*], Yijun Li[1,*], Yaotian Yang[1,*], Honghao Chen[1], Wentao Li[1], Xiaonan Wang[1,†]
[1]Beijing Key Laboratory of Artificial Intelligence for Advanced Chemical Engineering Materials, State Key Laboratory of Chemical Engineering and Low-Carbon Technology, Department of Chemical Engineering, Tsinghua University, Beijing 100084, China.
* Jiangjie Qiu, Yijun Li and Yaotian Yang contributed equally.
† Correspondence: wangxiaonan@tsinghua.edu.cn.

图像为 ImageGen 临时预览；图形位置仅作示意，定量结果以正文和补充表为准。

自主科学的核心承诺，是使实验自主性转化为科学认识的拓展[1,2]。自主实验能否以及如何实现这一承诺，需要将研究过程本身作为考察对象。我们利用 ChemWorld 的可编程化学世界，连接实验选择、观测、同期判断与后续预测。在跨化学体系比较的基础上，当前过程研究覆盖平衡与结晶的 90 场会话，并另设 30 场同期研究机会对照。初始信息对应着不同的研究起点，随后获得的观测支持前瞻检验、局部关系与明确修订；这些关系如何被进一步使用，则决定了研究的不同后果。在匹配的研究机会比较中，获得研究机会使总体预测误差下降约 73%，却使极稀条件下的误差平均增加约 69%。结晶呈现互补的分化：42 份有效预测中，39 份回收率预测优于各自源观测均值，纯度预测却无一超过这一参照。连续记录进一步定位了有证据支持的局部判断、后续检验与尚未被实验确定的外推之间的转变。这些结果表明，同一研究经历中的科学进展可以发生分化；实验成就、预测迁移与证据支持，是自主研究的不同成果维度。

自主研究者不仅干预世界，也通过实验与测量的选择，塑造科学判断赖以形成的经历：哪些现象被看见，哪些解释受到检验，哪些结果成为下一次研究的依据。因此，自主科学的承诺既涉及实验能力的扩展，也涉及实验经历向科学认识的转化。

机器人科学家与自驱动实验室已经展示了假说检验、材料发现和反应优化能力[3–6]。语言模型智能体进一步连接科学指令、工具与实验操作[7,8]。这些进展使一个更深的问题进入可研究的范围：智能体自己开展的研究，怎样改变它用来解释和预测世界的关系判断？有效方案构成实验成果，正确预测体现预测准确性；但两者都不能单独说明某项判断从何种证据中形成，以及这些证据支持多大的范围[9,10]。

我们利用 ChemWorld 考察这一过程。可编程的世界规律和独立指定的公开信息，使我们能够研究初始知识怎样进入实验选择、观测怎样支持或改变判断，以及这些判断怎样指导后续研究。证据从研究的组织方式出发，追踪工作关系的形成，再考察它们如何被用于新干预。有依据的局部检验、合理修订、缺少执行支持的解释与响应不同的迁移表现，并不必然共享同一种失败机制；它们共同说明，研究的科学后果取决于证据选择、解释和使用之间的连续转变。

使自主科学探索成为可检验的研究对象

ChemWorld 将材料、操作与仪器组合为具有持续状态的虚拟化学系统。智能体在固定资源范围内，自主决定投料、处理顺序、测量、重复及后续实验。这些选择改变样品，也决定哪些观测能够进入研究。评估者独立控制世界参数和公开信息，记录实际提交的操作，并获得封存的参考结果（图 1）。智能体在研究与评估阶段均看不到这些参考真值。

这一安排使智能体的研究过程能够被具体考察。知识测试和给定数据任务评价重要的科学能力[11,12]，交互式发现环境也已连接行动与观测[13–16]。ChemWorld 进一步在可组合的化学过程中，连接智能体自主选择的证据、不断变化的公开判断及其后续用途。一次操作请求可能在改变样品之前被拒绝；一项观测也可能只支持局部关系，尚未确定其在其他干预下是否成立。执行记录和独立评估的世界响应使这些区别能够被核对。

广度研究包含 Sol 在六类化学体系中的 240 场研究，以及另外四种模型配置的 60 场平衡研究。当前过程分析采用 45 场平衡研究和修正回收定义后重新执行的 45 场结晶研究。每个体系覆盖五个固定世界、三种信息条件、每格三次独立启动的模型会话。90 场中有 80 条完整研究—评估链、83 份有效预测；不完整会话仍保留在计划分母中。早期受回收描述不一致影响的结晶会话单独保留，不与修正版合并。

同期笔记将公开判断定位到当时可用的观测。研究结束后，智能体先封存科学解释，再在无法访问实验工具的条件下预测十二个新干预，最后在未获知真值的情况下反思。结构化过程分析在当前 90 场中的 65 场识别出 92 个可观察的 “判断—实验—修订” 窗口（扩展数据图 1）。其余 25 场在这一记录定义下缺少完整窗口，不能据此认定没有科学学习。另一个同期比较让 30 场新会话在共同评估协议下分别获得或不获得研究机会（图 4）。这些证据层回答互补问题，分别保留各自分母。

科学探索的自主组织与适应

探索始于研究目标、可用信息和受约束的行动空间。这些条件参与塑造研究经历，却不以简单方式决定它（图 2）。60 场历史电化学研究中，发现与优化指令没有形成稳定的 “广泛探索—局部搜索” 分割。在十二批预算下，两种目标的平均溶剂覆盖分别为 3.93 和 3.73，中间测量分别为 12.00 和 10.53 次；二十四批预算下，两者均覆盖全部四种溶剂，并用满二十四次中间测量。这些粗粒度描述不足以解释最终方案与预测的全部差异。

初始信息与修正版结晶研究的起点具有更清楚的对应。Aligned 条件的十五场均从溶剂 S2、催化剂 C1 开始；没有额外实例资料的十五场均从 S0、C0 开始。指定错配资料下，十三场从 S2 开始，十四场首先使用 C1，另一场在成功加入催化剂之前停止。计入实际提交的再悬浮加溶剂操作后，整段研究的平均溶剂覆盖分别为 4.00、2.93 和 2.40。这些差异具体体现了智能体选择获取何种证据；覆盖更广本身并不等于认识更好，也不能由此单独识别覆盖范围对后续错误的作用。

观测还可以改变研究方向。研究机会对照中的一场平衡研究，在初始笔记中预期弱酸趋势：浓度升高应降

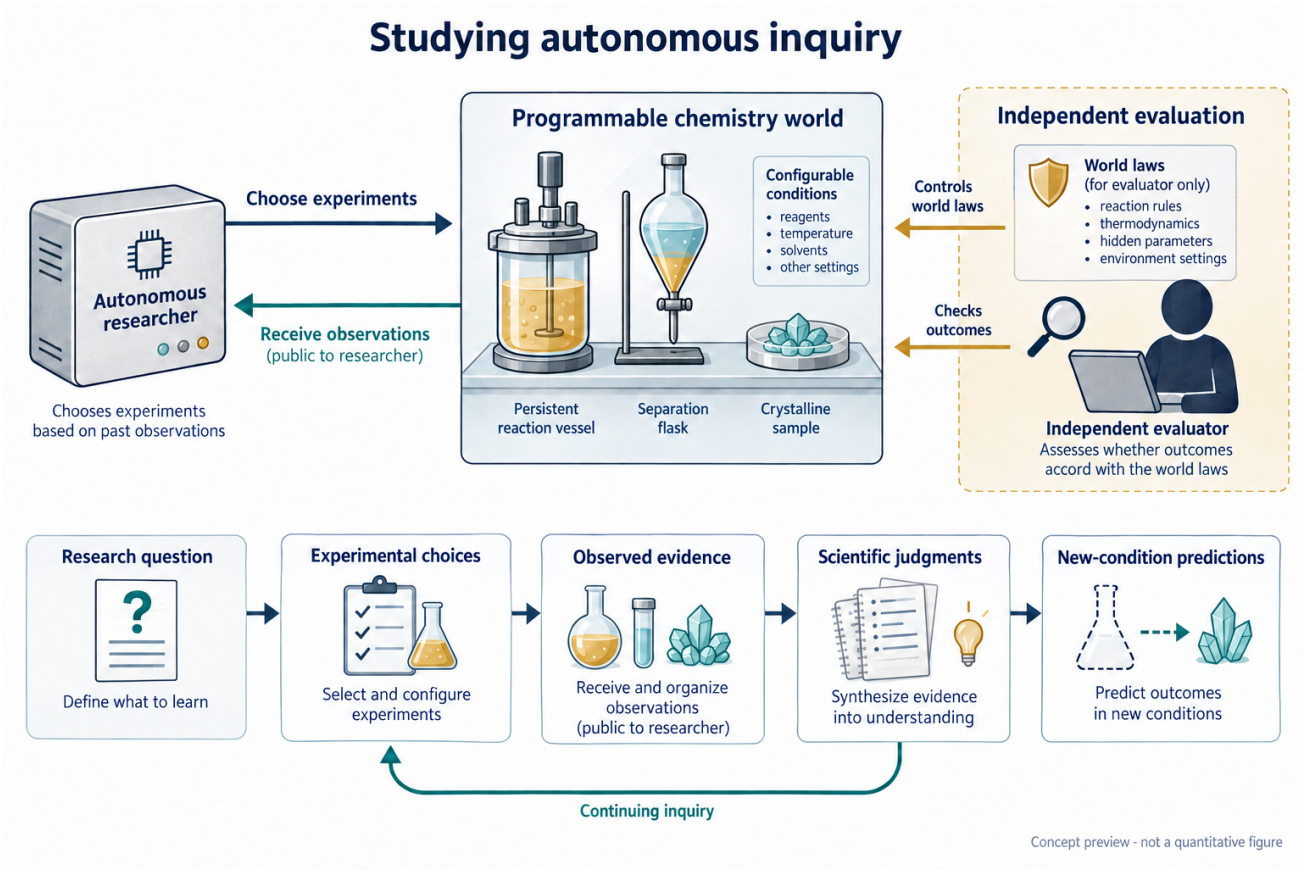


图 1 | 使自主探索成为可检验的研究对象。ImageGen 临时概念图。自主研究者选择干预，并从持续状态的化学世界获得公开观测。评估者独立控制隐藏参数并核对世界结果，参考真值不反馈给研究者。下方序列连接问题、选择、观测、公开判断和预测，判断又进入后续选择。图中概括的是可观察关系，不是内部认知的直接读数，也不代表已经识别笔记文字的因果作用。

低 pH 和解离分数。但前六次实验的解离分数始终约为 0.064–0.079。下一版笔记因此撤回原趋势在当前范围内的支持，并提出另一可操作组分可能才是相关输入。第八至十二批实际改用该组分，响应依然接近平台。最终解释保留了一项范围明确的经验关系，同时没有认定唯一的隐藏机制。

这一序列连接了事前预期、相反观测、替代解释与改变后的实验。其他研究也会继续最初已经计划的扫描、缩小参数区间或重复临界配方。这些都属于研究组织，但其中只有一部分是在反馈之后新提出的检验。修正版结晶的 58 个窗口中，52 个所选即时计划与实际动作匹配，6 个部分匹配。这刻画了可观察窗口中的公开计划—行动联系，既不是发现率，也不能证明写下笔记导致了行动。接下来需要考察的是，这些行动与观测究竟建立了什么。

科学认识在实验中的形成与演变

科学关系在支持进一步检验、约束解释或指导新干预时，获得实际研究意义（图 3）。一场修正版结晶研究在获得接近细粉阈值的结果后，事前提出将试剂投料从 0.03 降至 0.02 mol。下一批执行了该提议，并通过细粉要求。这支持一项局部配方改进。然而，催化剂绝对量保持不变，其相对试剂的比例也随之改变，因此实验并未单独识别浓度机理。

另一场研究作出了插值判断：根据邻近溶剂体积下不同的回收与细粉表现，研究者提出 0.065 L 应当保留回收收益并改善细粉。随后检验失败，末版笔记收回了这一预期。一次未成功的操作干预，由此产生了可观察的科学判断修订。另一项临界研究明确讨论测量噪声，重复 310 K、两段等待的方案，却仍推荐了复测失败的配方。认识到不确定性、主动重复和操作失败可以同时出现。

干预是否真正发生，也是其证据地位的一部分。一位研究者计划累计加入约 1 g 晶种，实际却只有 0.05 g 提交成功，后续十九次追加均被拒绝。之后的笔记正确指出，这次尝试不能确定高种量的效果。另一场会话遇到类似拒绝，却将 1 g 记为已检验条件，并用所得结果反对种量解释。这里的区别在于执行经历怎样转化为科学证据：世界并未完成后者作为阴性检验来解释的干预。

相关的一场研究将 440 K 加热后的低回收归因为热史边界，并随后检验 430 K。后续实验确实发生，但被用作依据的早期比较包含实际被拒绝的 265 和 270 K 冷却请求。这段研究具有适应和进一步实验，却未建立解释中声称的温度对照。因此，必须逐一连接行动、观测与解释，不能由一份连贯的最终报告反推它们已经相符。

前述平衡研究呈现另一种转变。组分检验合理削弱了局部平台的一项解释，但在预测极稀条件时，智能体写道：“The point estimate still favors the experimentally supported fixed acidic background”（点预测仍偏向实验支持的固定酸性背景）。其解离分数预测为 0.085，80% 区间为 0.035–0.350，而封存参考均值为 0.716。科学解释与预测均承认远端条件没有被检验。问题因此并非

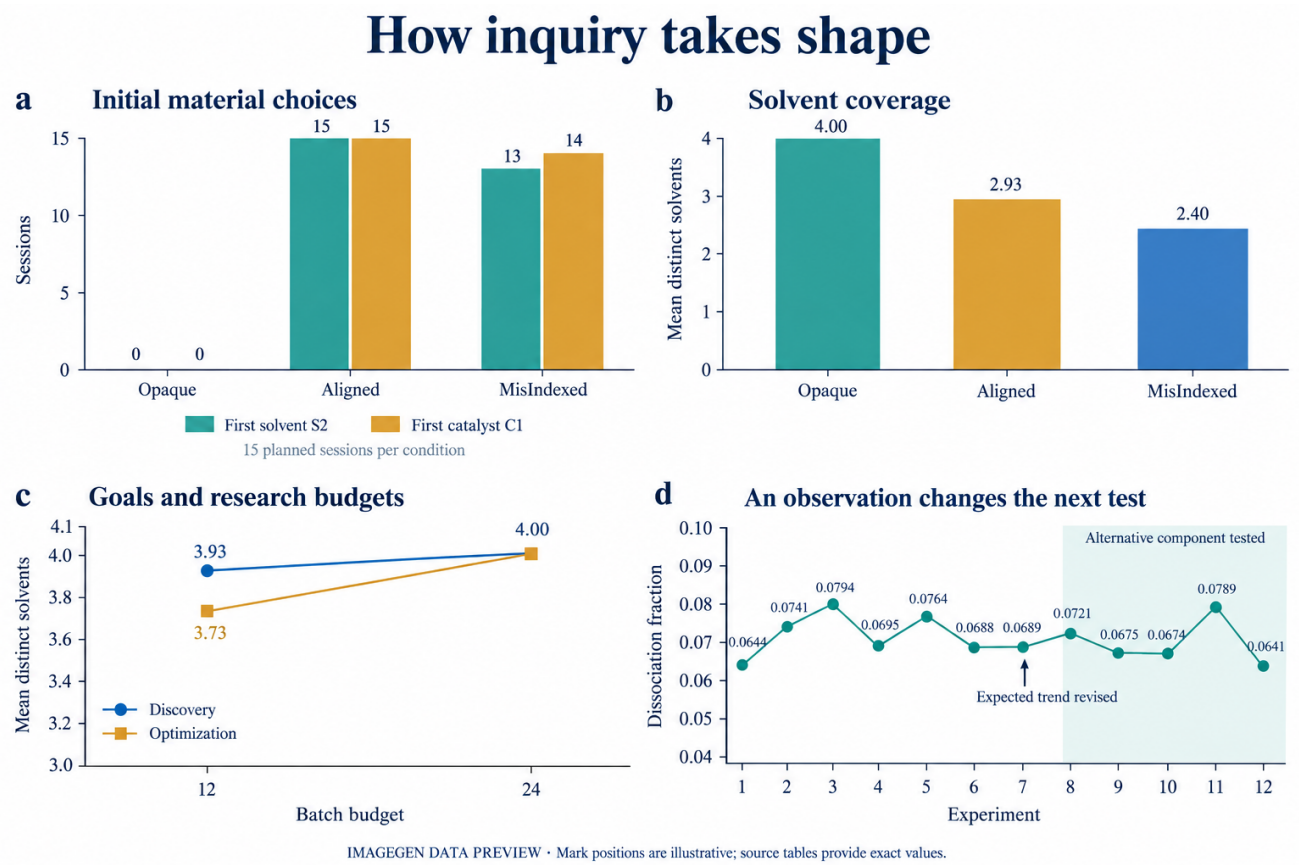


图 2 | 探索如何展开。ImageGen 数据预览。a，修正版结晶每种信息条件十五场，首次使用溶剂 S2/催化剂 C1 的场数分别为 Opaque 0/0、Aligned 15/15、MisIndexed 13/14。b，三组平均溶剂覆盖数分别为 4.00、2.93、2.40。c，历史电化学发现/优化任务在十二批时覆盖 3.93/3.73 种溶剂，二十四批时均为 4.00。d，所选平衡轨迹的解离分数为 0.064–0.079，在前六批后修订初始弱酸预期，并于第 8–12 批检验另一组分。这些是描述性选择与记录顺序，未分离信息或笔记的因果作用。图形位置为示意，准确观测保留在源记录中。

简单的“没有提到边界”，而是一项局部有依据的关系，在其延续尚未被实验确定的预测中仍获得主要权重。

这种延续并不必然发生。另一固定平衡世界中的两场研究都只在较高投料区间观察到平台，极稀宏平均误差却分别为 0.16287 和 0.01462。同一道极稀问题中，它们预测解离分数为 0.130 和 0.626，参考均值为 0.65463。更准确的一场采用了与平台观测相容的弱酸延续，同时明确称其为推测。准确外推不要求直接采样每个目标条件；准确本身也不等于研究已经通过实验识别了正确解释。连续记录使局部支持、未决可能及其后续预测用途能够被分别考察。

自主探索中科学进展的性质与条件

过程记录定位判断变化，独立的研究机会比较则检验获得研究机会对后续预测的贡献（图 4）。五个平衡世界各配置三场拥有十二批实验机会的新会话，以及三场没有源实验的新会话。两组获得相同的科学公开背景和封存评估。三十场全部终态，180 个计划源实验批次全部完成，二十九场提供有效预测。一场研究会话因网络中断缺失预测及后续阶段，源观测和科学解释仍予保留。

研究总体上大幅降低了平均误差。先在世界内平均有效会话、再对五个世界等权，归一化宏平均绝对误差由无研究的 0.132086 降至有研究的 0.035632，下降 73.0%，五个世界方向一致。但在事前指定的三道极稀问题上，误差从 0.061467 增至 0.103677，增加 68.7%，五个世界中四个恶化。其余九题的误差则从 0.155625 降至 0.012950。这一比较考察整个研究机会组合，包括实验选择、反馈与可用记录工具，不单独归因于其中某个组成部分。

同一研究机会因此可以改善总体预测，同时损害特定区域的迁移。连续的平衡案例把观测带来的修订，与局部关系在远端预测中的权重连接起来。其无研究对应会话对前述问题预测解离分数为 0.569，更接近真值，却明确依赖未经检验的先验假设。更好的预测本身，并不构成经实验建立的发现。

这一结果还涉及区间判断，却不支持统一的“更自信但更错误”叙事。在极稀条件下，有研究组三个名义 80% 区间的实际覆盖率均低于无研究组，但无研究组区间明显更宽。兼顾宽度与漏覆盖惩罚的区间分数，在 pH 上支持有研究组，在解离分数上支持无研究组，在沉淀信号上接近；全部问题合计，研究改善三个响应的区间分数。让唯一缺失会话的宏平均误差取遍合法范围的保守敏感性分析，也不能翻转总体收益或极稀损失这两个平均方向（方法）。

结晶进一步揭示了已获得证据的不均衡使用（扩展数据图 2）。对 42 份有效预测，我们构建只使用该会话源观测的透明参照。五世界等权纯度误差，智能体为 0.03853，自身全部源观测均值为 0.00510；每一个有效会话中，源均值都更准确。回收率呈相反关系：智能体误差为 0.10129，参照为 0.20443，39/42 场中智能体

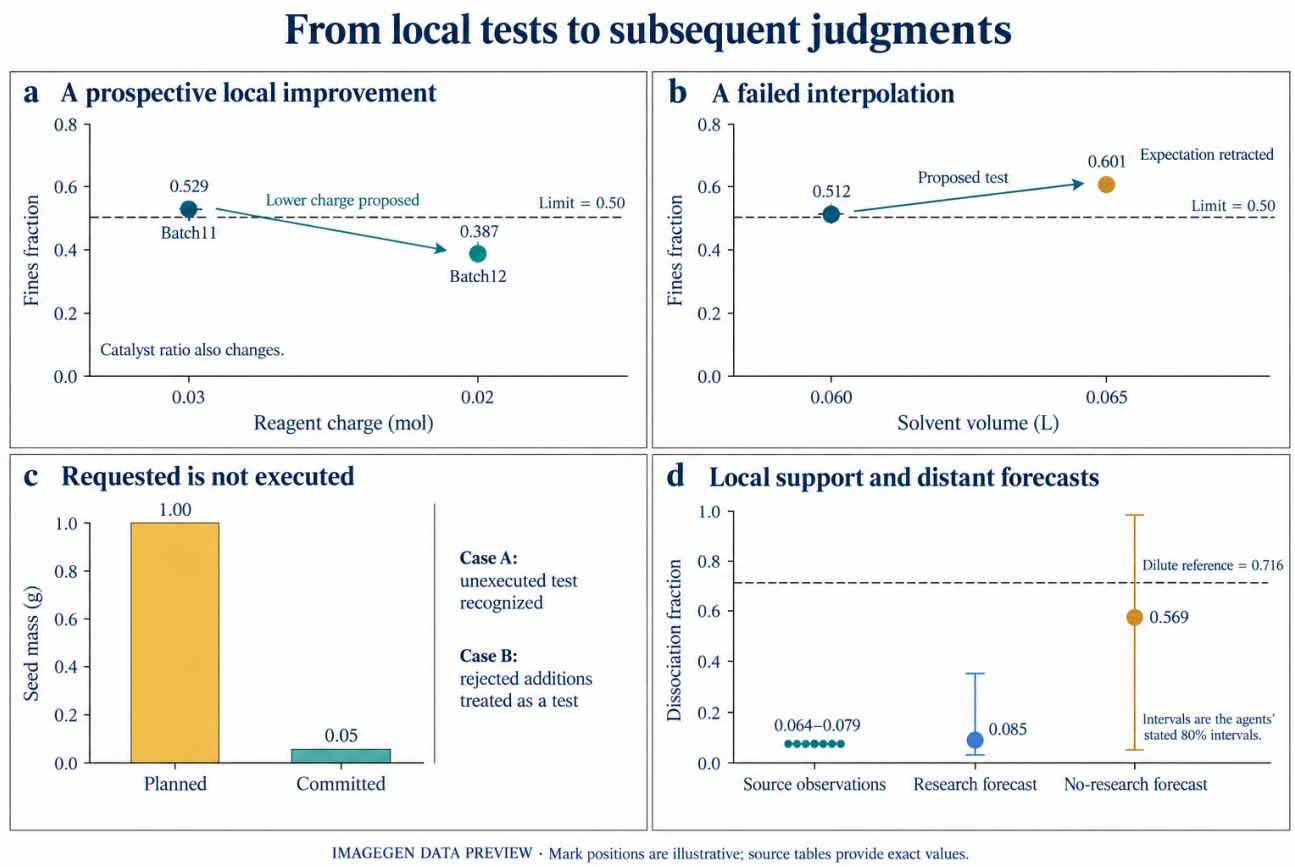


图 3 | 从局部检验到后续判断。所选案例的 ImageGen 数据预览。a，试剂投料从 0.03 降至 0.02 mol，细粉从 0.529 降至 0.387，跨过 0.50 阈值；催化剂绝对投料不变，同时改变了其比例。b，溶剂体积由 0.060 插值至 0.065 L，细粉反而由 0.512 升至 0.601，研究者随后撤回该判断。c，1 g 播种请求未成功执行，实际仅提交 0.05 g；不同研究者分别识别未执行检验，或将其记为阴性证据。d，平衡源实验平台与极稀预测对照：研究组 0.085、区间 0.035–0.350，无研究组 0.569、区间 0.040–0.980，封存参考 0.716。区间为研究者给出的 80% 预测区间。源观测点及几何位置为示意，并非逐点准确绘图。

优于均值。按实际提交的精确溶剂集合限定参照，仍保留这两个总体方向。粒度与细粉又有不同表现，因此分别报告各响应，而不将它们压成一个学习总分。

这些发现补充了早期的操作—预测比较。电化学优化在三十个匹配条件中的二十六个获得更好的推荐方案，其中预测更好与更差各十三个。重复平衡队列中，正确但不完整的先验使九题误差从 0.00907 降至 0.00512，却使极稀误差从 0.09880 增至 0.13205。初始信息、实验成就与后续预测都参与构成科学结果，但都不能替代对“研究支持了何种关系，以及它被怎样使用”的考察。

讨论

自主探索既组织对世界的干预，也组织后续判断所依赖的证据。ChemWorld 使这些活动之间的联系能够被观察：初始信息进入选择，观测支持局部关系与修订，这些关系又指导后续检验和预测。核心发现是，科学进展能够在这一过程中发生分化。一次实验可以建立有效的局部关系，却尚未确定其在其他条件下的延续；同一研究经历也可以在不同响应上支持明显不同的预测结果。

研究科学认识的形成，需要具体说明提出了什么关系、当时什么信息支持它、世界实际检验了什么，以及关系随后怎样被使用。记录既包含合理撤回和范围明确的改进，也包含缺少实际执行支持的解释；还包含依赖未被实验确定的可能性所作出的准确预测。这些区别与科学研究中区分性检验和推断的作用相一致 [17–19]，但不能从成功调用工具或连贯的科学解释中，直接假定自主智能体已经实现了它们。

对照实验限定了可以作出的因果解释。匹配的研究机会比较，在共同评估协议下估计整段研究机会的作用。另一个固定配方淬灭对照识别操作在虚拟世界中的物理效果，其结果没有交给能够适应的研究者（扩展数据图 3）。两者均未单独识别笔记的作用，也不能证明某项判断通过选择性实验维持自身。解释已经观察到的关系形成与使用，不要求每条轨迹共享这类机制，也不要求最终以一种纠错策略成功收束。

本研究局限于选定的可编程体系、少量固定世界，以及重复过程分析中的一种模型配置。新会话既不是受控模型 seed 重复，也不是世界规律的独立样本。笔记是公开记录，不是内部认知读数；记录间隔限制时间推断。案例从系统保留的记录中事后选取，由单一分析者解释，没有第二评分者的一致性估计。历史与当前协议分别保留来源，包括修正版结晶及全部失败。这些边界限制发生率和普遍性主张，同时保留可核对的过程转变与限定明确的比较。

自主科学的承诺，关系到自行组织的探索怎样改变研究者据以理解世界的科学关系。ChemWorld 连接选择、证据、判断及后续用途，使这种转化成为可检验的研究对象，也使实验进展、有依据的认识和可靠迁移能够被共同研究，而不被视为同一项成就。

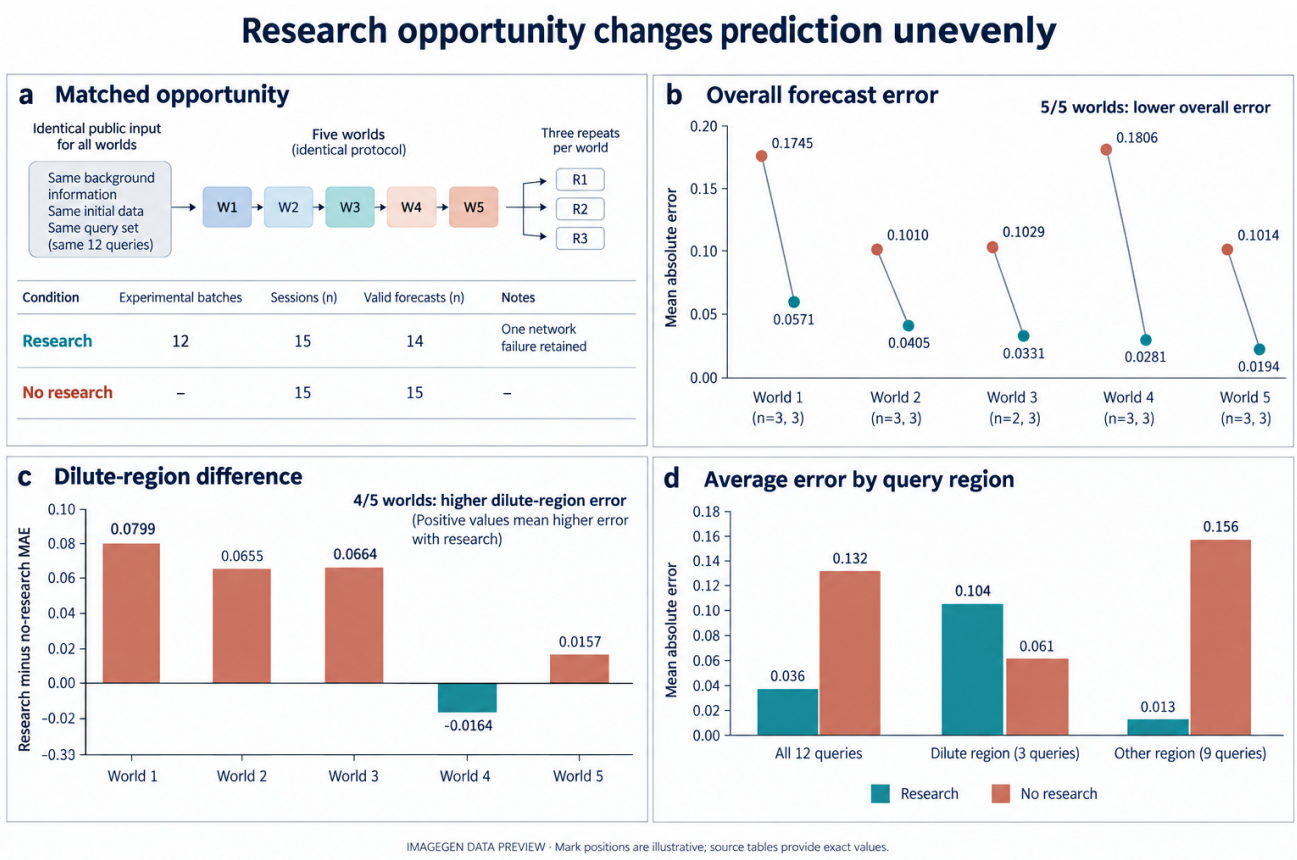


图 4 | 研究机会使预测表现发生不均衡变化。ImageGen 数据预览。a，五世界的十五对研究/无研究会话匹配公开信息与后测，研究组可开展十二批源实验；有效预测分别为十四、十五份，一次网络失败保留。b，五世界的总体平均绝对误差均随研究降低。c，极稀三题的研究减无研究误差差值在四世界为正。d，五世界等权误差分别为：全部十二题 0.035632/0.132086，极稀三题 0.103677/0.061467，其余九题 0.012950/0.155625。世界 3 研究组有两份有效预测，其余单元各三份。图形位置为示意；比较对应完整研究机会的组合效应。

资助

本研究获得深圳市科技计划项目（AI2026004）、清华大学自主科研计划，以及青年教师科研创新能力支持项目（ZYGXQNJSKYCXNLZCXM-E7）资助。

参考文献

1. G. Tom et al. Self-Driving Laboratories for Chemistry and Materials Science. *Chemical Reviews* **124** 9633–9732 (2024). https://doi.org/10.1021/acs.chemrev.4c00055.
2. D. A. Boiko, R. MacKnight, B. Kline, and G. Gomes. Autonomous chemical research with large language models. *Nature* **624** 570–578 (2023). https://doi.org/10.1038/s41586-023-06792-0.
3. R. D. King et al. The Automation of Science. *Science* **324** 85–89 (2009). https://doi.org/10.1126/science.1165620.
4. B. Burger et al. A mobile robotic chemist. *Nature* **583** 237–241 (2020). https://doi.org/10.1038/s41586-020-2442-2.
5. B. P. MacLeod et al. Self-driving laboratory for accelerated discovery of thin-film materials. *Science Advances* **6** eaaz8867 (2020). https://doi.org/10.1126/sciadv.aaz8867.
6. N. J. Szymanski et al. An autonomous laboratory for the accelerated synthesis of inorganic materials. *Nature* **624** 86–91 (2023). https://doi.org/10.1038/s41586-023-06734-w.
7. A. M. Bran et al. Augmenting large language models with chemistry tools. *Nature Machine Intelligence* **6** 525–535 (2024). https://doi.org/10.1038/s42256-024-00832-8.
8. T. Dai et al. Autonomous mobile robots for exploratory synthetic chemistry. *Nature* **635** 890–897 (2024). https://doi.org/10.1038/s41586-024-08173-7.
9. A. N. Elmachtoub and P. Grigas. Smart Predict, then Optimize. *Management Science* **68** 9–26 (2022). https://doi.org/10.1287/mnsc.2020.3922.
10. G. Shmueli. To Explain or to Predict? *Statistical Science* **25** 289–310 (2010). https://doi.org/10.1214/10-sts330.
11. A. Mirza et al. A framework for evaluating the chemical knowledge and reasoning abilities of large language models against the expertise of chemists. *Nature Chemistry* **17** 1027–1034 (2025). https://doi.org/10.1038/s41557-025-01815-x.
12. B. P. Majumder et al. DiscoveryBench: Towards Data-Driven Discovery with Large Language Models. *International Conference on Learning Representations* **2025** 4556–4579 (2025). `https://proceedings.iclr.cc/paper_files/paper/2025/file/0d70af566e69f1dfb687791ecf955e28-Paper-Conference.pdf`.
13. R. Wang, P. Jansen, M.-A. Côté, and P. Ammanabrolu. ScienceWorld: Is your Agent Smarter than a 5th Grader? *Proceedings of the 2022 conference on empirical methods in natural language processing* 11279–11298 (2022). https://doi.org/10.18653/v1/2022.emnlp-main.775.
14. P. Jansen et al. DiscoveryWorld: A virtual environment for developing and evaluating automated scientific discovery agents. *Advances in neural information processing systems* **37** (2024). https://doi.org/10.52202/079017-0324.
15. K. Gandhi et al. BoxingGym: Benchmarking progress in automated experimental design and model discovery. (2025). `https://arxiv.org/abs/2501.01540`.
16. Y. Chen, P. Piękos, M. Ostaszewski, F. Laakom, and J. Schmidhuber. PhysGym: Benchmarking LLMs in Interactive Physics Discovery with Controlled Priors. *Advances in Neural Information Processing Systems* **38** (2025). https://doi.org/10.52202/085713-1556.
17. J. R. Platt. Strong Inference. *Science* **146** 347–353 (1964). https://doi.org/10.1126/science.146.3642.347.
18. D. V. Lindley. On a Measure of the Information Provided by an Experiment. *The Annals of Mathematical Statistics* **27** 986–1005 (1956). https://doi.org/10.1214/aoms/1177728069.
19. K. Chaloner and I. Verdinelli. Bayesian Experimental Design: A Review. *Statistical Science* **10** 273–304 (1995). https://doi.org/10.1214/ss/1177009939.
20. T. Gneiting and A. E. Raftery. Strictly Proper Scoring Rules, Prediction, and Estimation. *Journal of the American Statistical Association* **102** 359–378 (2007). https://doi.org/10.1198/016214506000001437.

方法

世界、接口与实验单位

ChemWorld 将兼容的过程组件编译为具有持续状态的虚拟化学环境。公开契约指定材料、合法操作、仪器、资源和任务目标，私有参数决定具体世界的响应。智能体能够访问实验室和公开记录，不能访问评估者状态、模拟器代码、私有参数或封存参考结果。操作改变样品，测量可能消耗材料。候选转变在提交之前接受校验；被拒绝的操作不构成所请求的物理干预，但尝试可能消耗契约规定的资源。精确重放核对环境状态转变，不重新生成模型决策。

广度研究覆盖电化学、分配、反应与热处理、水溶液平衡、反应耦合结晶和纯化。这些是受控虚拟系统，不是对具名现实物质经过实验验证的预测。当前重复研究采用平衡与结晶。五个固定世界在不同条件与重复中复用，世界参数、初始状态和键控观测映射保持固定。重复单位是新模型会话，不是独立世界抽样或受控模型 seed 重复。接口没有可用的模型采样 seed；相同干预可以得到相同键控观测，因此也不是独立噪声实现。

证据层与保留分母

历史广度研究包含 240 场 Sol-medium 研究，以及 Luna、Terra、GPT-5.5 和 Astra 的 60 场额外平衡研究，均请求 medium 推理强度。五模型平衡比较中的十五场 Sol 已包含在 240 场内。请求的模型标签不代表实际计算量相等。原 240 场包含电化学 60、分配 30、反应 60、平衡 45、结晶 30 和纯化 15 场；按其原规则保留 3,597/3,600 次最终测量、全部 720 个后测阶段与 238 场协议符合研究。额外六十场保留 720 批和 240 个阶段。两场原始源研究完成度失败仍予保留。更早的选定笔记案例另有 24 场，不与广度或当前过程队列合并。

当前过程队列由早期 48 场及其 42 场扩展中的 45 场平衡研究，以及统一回收描述后完整重跑的 45 场结晶研究组成。每个体系覆盖五世界、Opaque/Aligned/MisIndexed 三信息条件、每格三场，每场十二批。平衡保留 39 条完整链、41 份有效预测；修正版结晶分别为 41 和 42。当前合计分母为 90 场、80 条完整链、83 份有效预测。旧结晶作为受协议影响的历史证据保留，不加入修正版计算当前结果或过程频率。

修正版结晶完成 510/540 个源批次、125/135 个后测阶段，保留 145 版笔记和 42 次推荐复测。全部 45 条源轨迹与 42 条复测轨迹通过重放。四条不完整链中，三条缺失预测，另一条有有效预测但缺失随后的反思。平衡子集与独立的研究机会块各自保留失败表。缺失不填零，已完成结果不由后来更有利的结果替代。稿件整合不改变任何实验块原有的开发或资格证据地位。

信息、自主性与记录

Opaque 提供公开任务和操作背景，不提供额外实例资料。Aligned 提供与体系相符的部分信息；平衡包括有效酸度区间和带锚点的局部稀释关系。MisIndexed 使用另一世界的历史关系，格式与限定相同。结晶 Aligned 提供匿名材料名义描述，MisIndexed 交换 S1/S3 溶剂描述，保留 S0、S2 和催化剂描述。两者均不是完整世界规律。

原平衡 Opaque/Aligned 早于 MisIndexed 扩展；修正版结晶是更晚的完整实验块。这些描述性比较并非全部同期随机处理，新旧结晶也不能估计修正提示的因果作用。下文单列的新研究机会比较采用共同的同期协议。

智能体在固定预算内选择操作、用量、测量、重复与操作分组。平衡允许十二批、180 次操作尝试、十二次中间仪器与十二次最终测量；结晶采用固定十二批材料预算和 720 次尝试上限。记录角色要求在适用时先写出可检验预期，后续由智能体自主更新，不要求每批书写，也不自动重新注入笔记。记录角色可能影响研究，不被视为被动观察。笔记保存版本与公开事件游标，不揭示内部认知。没有调用笔记读取工具，不代表无法访问会话中此前出现的内容。

后测与回收定义

源研究及操作推荐结束后，智能体依次封存科学解释、在无实验工具条件下回答十二个固定新干预问题，再在没有真值反馈的情况下反思。平衡另有结构化补充评估。证据中的 K1/Q/K2/EQS 分别表示这些阶段。源研究期间不展示预测问题；后测提出的方案不计为已执行源实验。

平衡点误差以每题五个参考观测的均值为比较对象，覆盖率检查全部五次观测。结晶使用最终测量采样之前的无噪声完整流程响应，源观测则带噪声。修正版保留六十个参考批次，数值与旧参考一致，并对每份可用的已提交推荐单独复测。

修正后的回收定义为：扣除晶种贡献的固相目标产物摩尔量，除以所跟踪的初始试剂投料摩尔量，截断到 [0,1]。源指令、预测提示、观测与评分现在指向同一完整流程量。内部结晶阶段指标则以分离前的目标产物为分母。旧过程指令描述后者，而观测与评分使用初始投料；原分数作为受协议影响的诊断值保留，不进入修正版队列。修正版完整重跑，没有事后为旧分数更名。

质量要求有颗粒、纯度至少 0.80、细粉至多 0.50；联合推荐成功还要求修正定义的回收率至少 0.10。按可用复测，修正版联合成功为 Opaque 13/15、Aligned 10/14、MisIndexed 10/13，每臂仍各计划十五场。粒度采用公开指数 min(d50/250 微米, 1)，其误差不能写成微米。

研究路径与过程解释

事后路径提取覆盖历史电化学六十场、平衡四十五场和修正版结晶四十五场。五十个世界内条件比较保留目标、预算、信息与队列。计数采用实际提交操作，溶剂覆盖包括再悬浮添加；拒绝请求不构成成功材料使用，中断会话保留在计划分母中。

结构窗口连接前后公开判断，以及其间实际实验和新增观测。系统提取在三十场平衡会话中识别 34 个窗口，在三十五场修正版结晶会话中识别 58 个窗口，92 个均完成编码。十五场平衡、十场结晶没有完整可观察窗口。窗口嵌套于会话，既不是独立参与者重复，也不是学习成功率的分母。

解释区分事前预期、新提出或早已计划的检验、真实动作、下一判断前可用的观测、修订、支持范围及后续用途。修正版结晶核对了 116 条逐字引文，所选即时计划在 52 个窗口中匹配、六个部分匹配；这是行动联系读数，不是笔记因果效应。所选主例还连接封存预测与源记录。引文位置、操作游标和各案例支持范围保存在补充证据组织中。

编码和内部科学复查由同一分析者完成，没有独立第二评分者一致性估计、盲法或经独立裁决的机制发生率。团队已将复查交给本流程，完成的内部复查与独立重复明确区分。反例包括合理撤回、正确识别未执行检验，以及准确但明确标为推测的外推。说明案例为事后选择。

仅使用源观测的预测参照

对每份有效修正版结晶预测，只利用该研究者成功的源最终测量构建两个透明参照。第一个平均全部可用测量；第二个只平均与查询具有相同已提交溶剂标识集合的测量，无匹配时回退到整体均值。溶剂集合包括成功加溶剂与再悬浮操作，排除拒绝请求。拟合函数不接收测试真值。这些是描述性计算，不是另行训练的智能体或完整机理基线。

有效会话 42 场，共 504 题。同溶剂回退发生在 186/504 题，其中 Opaque 1/180、Aligned 95/168、MisIndexed 90/156。该匹配不控制热史、用量或最终液相组成，参照没有预测区间。回收、纯度、粒度和细粉均按各自公开尺度报告，不合成一个跨响应分数。

匹配的研究机会比较

固定设计为五个平衡世界、Research/NoResearch 两条件、每格三场 Sol-medium 新会话，共三十场。两组获得相同任务、材料、合法操作、仪器与初态。十五个配对检查在仅排除随机会话标识后，确认科学公开输入一致。Research 额外得到十二批自主实验和既有笔记机会；NoResearch 没有源操作或观测。两组评估提示、模式、顺序和限制一致。

三十场全部终态，研究组完成 180/180 批，两组合计完成 117/120 个后测阶段、29 份有效预测。第三世界第三次 Research 在科学解释后出现预测流断连，Q 与随后两阶段缺失，没有替换。因此 Research 有十四份有效预测、NoResearch 十五份，Research 的第三世界为两次，其余每格三次。十五条源轨迹及二十五条参考轨迹（300 批）精确重放通过。29/30 场资源账本完整，另一场仅有已记录的部分用量；记录到的输入加输出共 13,428,656 tokens。缺失用量不按零处理，金额不可得。

首次执行尝试因评估传输配置缺少必要字段而失败。已启动四场、其中两场已完成的二十四批源研究和资源消耗单独保留，没有完成科学解释阶段。修复执行缺陷后，按原设计从头重跑整个三十场块。这属于协议修复，不是根据科学结果替换。仅完整重启后的实验块进入比较。

该比较估计共同评估条件下整段研究机会的作用，不能单独识别自主选择相对给定数据、反馈本身、笔记或内部表征变化。比较在新会话之间进行，没有会话内前测。世界与条件顺序采用事先固定的平衡启动安排，不是对世界规律进行随机抽样。

定量汇总与缺失

平衡宏平均绝对误差在指定问题中等权平均归一化 pH、解离分数和沉淀信号。极稀组为重复块执行前固定的三题，其余九题不被假定全部处于分布内。先在世界内平均有效会话，再对五世界等权。逐场数值和缺失阶段均保留。响应、问题、参考观测和批次嵌套相关，不能充当独立研究者样本。

名义 80% 区间同时报告覆盖率、平均宽度和适当区间分数 [20]。下界 l、上界 u、观测 y、alpha = 0.2 时，分数为 (u-l)，若 y 低于 l 加上 (2/alpha)(l-y)，若高于 u 加上 (2/alpha)(y-u)，越低越好。汇总按世界等权；智能体区间不是组均值的置信区间。

事后敏感性分析允许唯一缺失的研究机会预测取 [0,1] 内任意宏平均误差，并按每格计划三次和五世界等权重算。有研究减无研究的保守范围，总体为 [-0.098659, -0.031992]，极稀为 [+0.036768, +0.103434]。这是缺失结果影响的界限，不是填补、置信区间或总体推断。固定条件下三次会话描述波动，不建立总体可靠率。

匹配淬灭干预

独立保留的对照将原第一期十八份结晶推荐置于五个世界中，比较有无单个淬灭操作，共九十对、一百八十条轨迹。其他动作参数和初态匹配；淬灭从原位置删除，或插入首次播种/结晶冷却之前。没有智能体适应，也不向智能体反馈结果。

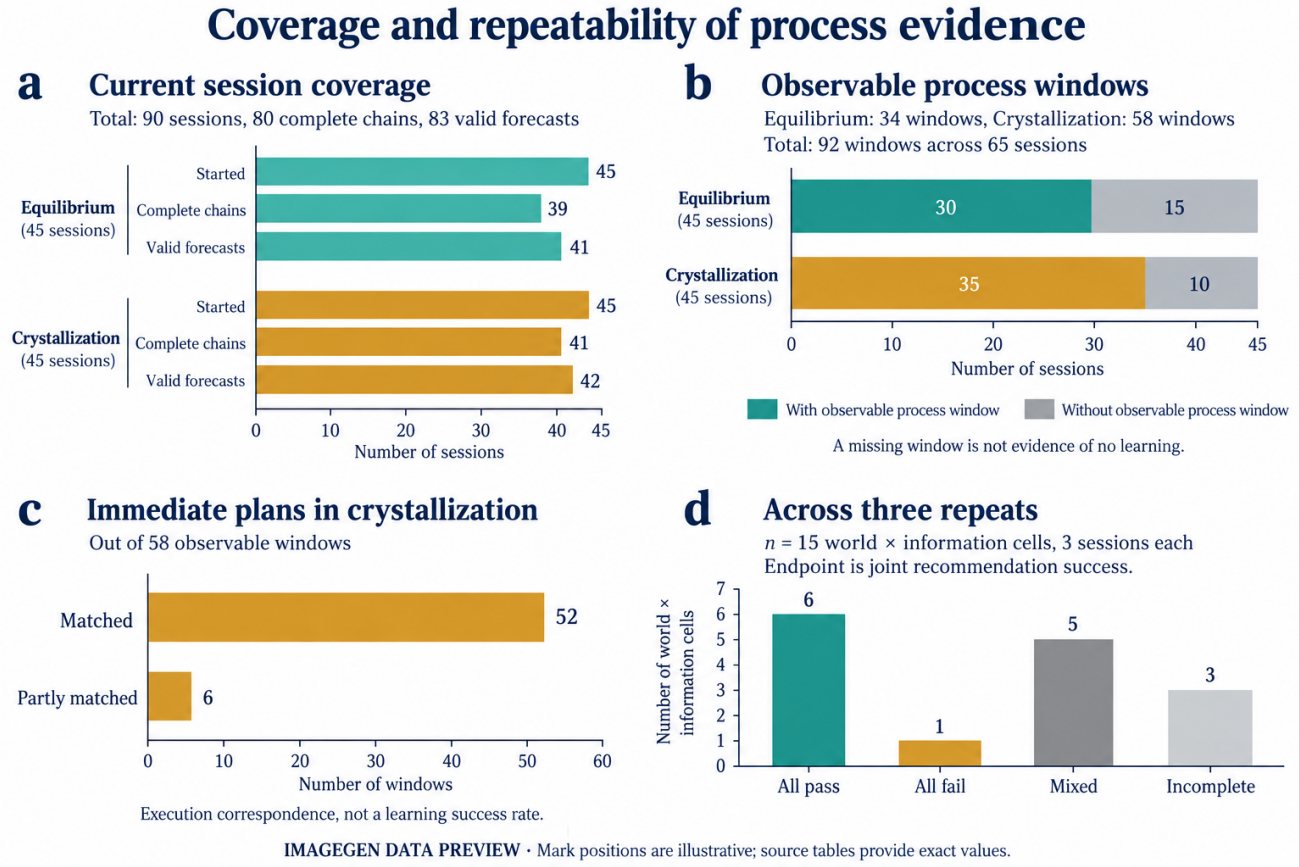
全部轨迹保留并重放，七十五对具有两侧最终测量。五对无淬灭侧缺颗粒，十对有淬灭侧使后续固定冷却请求失效，失败不修复。完整对中，有减无的平均细粉变化为 +0.30937、回收变化为 +0.00741，联合成功从 34 降至 4。这些条件性效果描述实际初始投料回收口径下的物理操作。淬灭改变多个物理状态量，不单独识别冷却速率或科学判断的成因。供体配方来自历史队列，不来自修正版。

数据与代码可用性

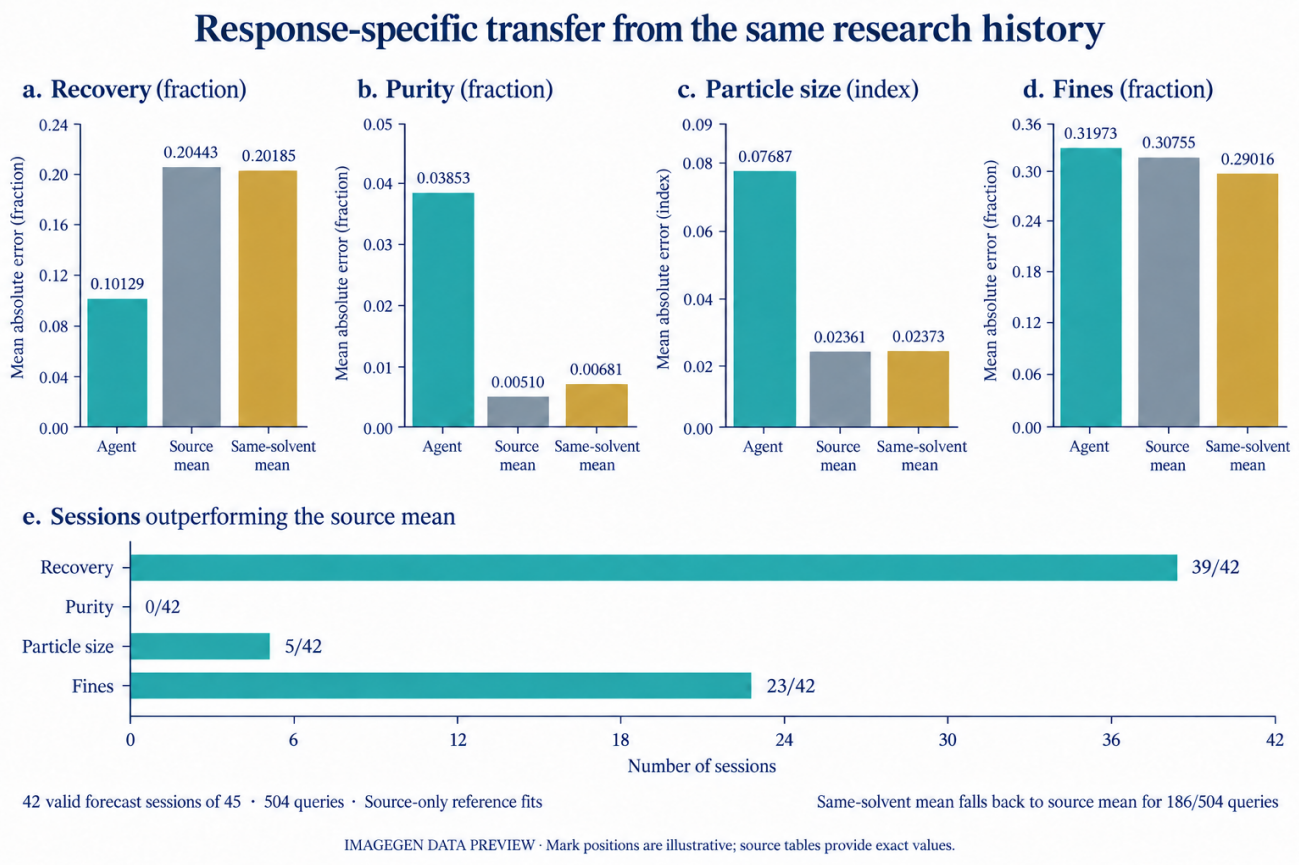
源观测、版本笔记、封存后测、重放记录和机器摘要保存在项目证据中。补充材料报告当前逐场结果、缺失、结构案例定位与广度研究保留表。完整公开归档及永久标识仍待落实，早期平台发布不能被假定包含后续队列。环境、执行与分析代码由 ChemWorld 项目维护；本轮稿件构建只读取保留结果，不调用模型或模拟器开展新实验。

七张插图均为 ImageGen 临时预览，包括一张框架图与六张数据预览。图中以保留观测及统计摘要为数值锚点，生成的点位、点数和几何形状仅作示意。精确数值由正文和表格承载，生成提示与来源记录随图片保留。

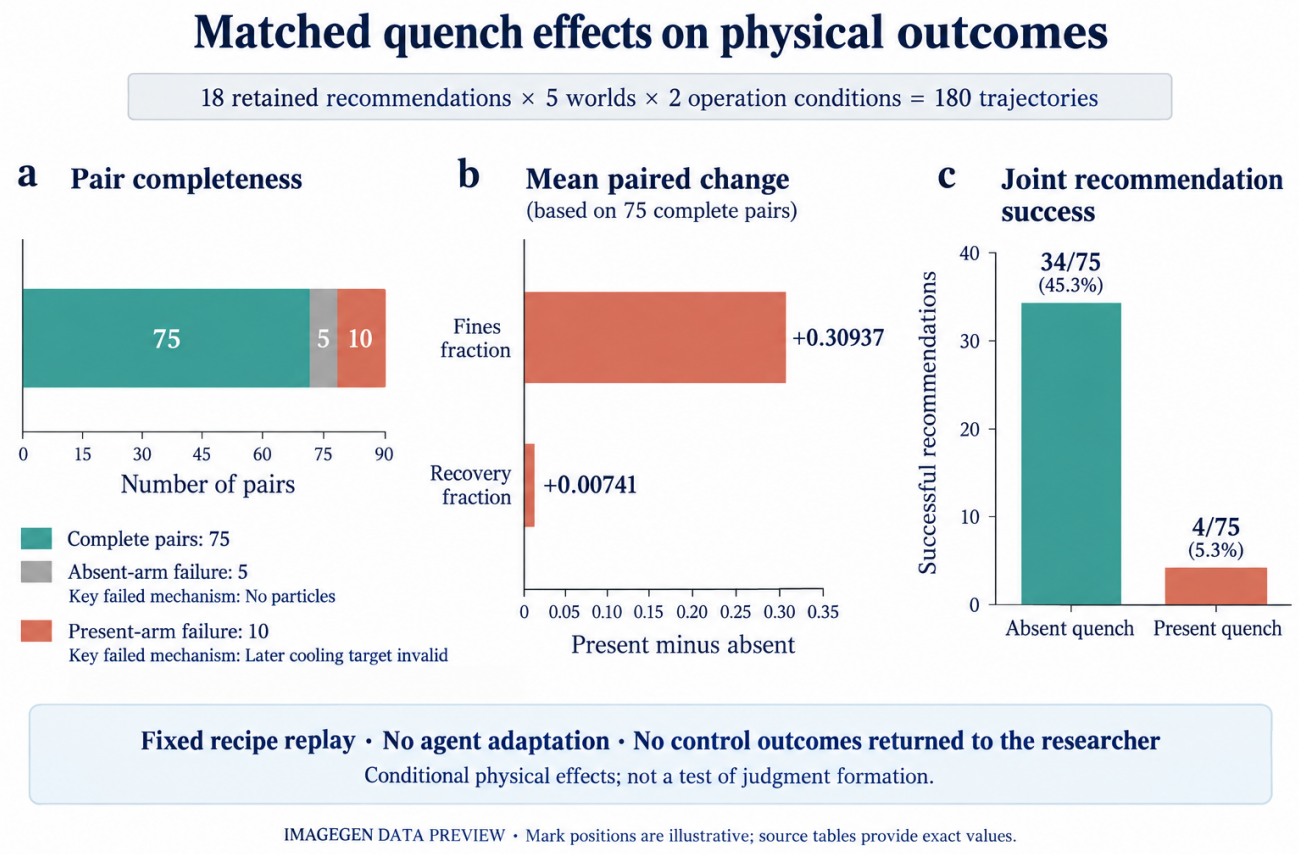
扩展数据



扩展数据图 1 | 过程证据的覆盖与重复性。ImageGen 数据预览。a，当前平衡/结晶各 45 场，完整链为 39/41，有效预测为 41/42。b，30/35 场分别提供 34/58 个过程窗口，其余 15/10 场没有完整可观察窗口，不代表没有学习。c，修正版结晶即时计划有 52 个与后续执行匹配、6 个部分匹配，不能解释为学习成功率。d，十五个世界 × 信息条件单元各重复三次，推荐联合达标结果为 6 组全达标、1 组全未达标、5 组混合、3 组缺失。旧协议受影响结晶不合并。柱形位置为示意，精确分母见表格。



扩展数据图 2 | 同一研究经历的响应特异性迁移。ImageGen 数据预览。a–d，比较研究者预测与两种仅用源观测拟合的参照，分别展示回收率、纯度、粒径指数和细粉，保留各响应自身尺度。粒径为无量纲指数 min(d50/250 微米, 1)。e，研究者胜过总体源均值的会话数依次为 39/42、0/42、5/42、23/42。修正版结晶 42 份有效预测共含 504 道题；同溶剂参照在 186/504 题回退至总体均值，未匹配热史或数量。两种参照均未使用封存真值拟合。图形位置为示意，五世界等权误差详见补充表。



扩展数据图 3 | 匹配淬灭对物理结果的影响。ImageGen 数据预览。十八份历史推荐在五世界分别有/无淬灭重放，共九十对、一百八十条轨迹。a，七十五对获得双方终测；无淬灭分支五次无颗粒，有淬灭分支十次使后续固定冷却目标无效。b，完整对的细粉平均变化为 +0.30937，回收变化为 +0.00741。c，联合达标从无淬灭 34/75 变为有淬灭 4/75。该结果是初始投料回收定义下的条件性物理作用；研究者未调整操作，也未获得对照结果，因此不能据此识别判断形成原因。图形位置为示意，失败配对全部保留。