ARTICLE 16 October 2026

自主研究如何塑造科学理解

Jiangjie Qiu[1,*], Yijun Li[1,*], Yaotian Yang[1,*], Honghao Chen[1], Wentao Li[1], Xiaonan Wang[1,†]
[1]Beijing Key Laboratory of Artificial Intelligence for Advanced Chemical Engineering Materials, State Key Laboratory of Chemical Engineering and Low-Carbon Technology, Department of Chemical Engineering, Tsinghua University, Beijing 100084, China.
* Jiangjie Qiu, Yijun Li and Yaotian Yang contributed equally.
† Correspondence: wangxiaonan@tsinghua.edu.cn.

全部插图为 ImageGen 预览；几何仅作示意，精确数值见保留证据。

自主科学的核心承诺，是使实验自主性转化为科学理解的拓展。然而，智能体如何组织探索，并将实验经历转化为知识，仍缺少充分理解。我们提出 ChemWorld，以可编程化学世界结合自主实验和对底层规律、信息供给的独立控制。通过跨化学体系、模型配置与重复研究，我们连接研究目标、先验知识、实验选择、发展中的解释及后续判断。智能体能够提出并检验解释性可能，建立有效的局部关系，并撤回缺少支持的预期。然而，相近的预测准确性可以建立在不同证据经历之上，成功的局部研究也可能留下未决的机制和适用范围。匹配化学世界使实验获得的信息与研究者赋予它的解释得以区分；研究机会比较则考察开展探索的后果。这些研究共同使自主科研本身成为可实证考察的对象，连接探索的组织与科学理解的形成、发展及其对进一步研究的引导。

科学发现不仅从既有前提推导答案，也提出重新理解现象的观念，并由此开辟新的研究方向。爱因斯坦在 1905 年狭义相对论论文的开篇指出，磁体与导体相对运动产生的可观察效应，与当时理论描述中的不对称并不相称。他提出新的原理，并推演其对同时性、时间和运动的后果 [1]。这一工作体现了科学发现中的创造性活动：重新考察理解世界所依据的前提。

反绎推理关注这一活动中的重要环节：提出值得进一步研究的解释性假设。在皮尔士的科学方法论中，反绎引入可能的解释，演绎展开其可检验后果，经验检验与归纳判断则评估哪些解释应当保留、修订或放弃 [2]。解释因此既可以是研究的产物，也可以成为进一步探索的起点。实验评价已有判断，同时也可能改变哪些现象需要解释、哪些问题值得继续研究。

自主研究者不仅干预世界，也通过实验与测量的选择，塑造科学判断赖以形成的经历：哪些现象被看见，哪些解释受到检验，哪些结果成为下一次研究的依据。随着 AI 科学家与自驱动实验室连接日益复杂的实验循环，探索的组织本身也成为委托给机器的科学活动 [3,4]。因此，自主科学的承诺既涉及实验能力的扩展，也涉及实验经历向科学认识的转化。

机器人科学家与自驱动实验室已经展示了假说检验、材料发现和反应优化能力 [5–8]。语言模型智能体进一步连接科学指令、工具与实验操作 [9,10]。这些进展使一个更深的问题进入可研究的范围：智能体自己开展的研究，怎样改变它用来解释和预测世界的关系判断？有效方案构成实验成果，正确预测体现预测准确性；但两者都不能单独说明某项判断从何种证据中形成，以及这些证据支持多大的范围 [11,12]。

困难在于，自主研究者能够获得的证据，本身就是其研究的结果。初始解释可以提出值得执行的实验；观测可以支持、缩小或取代这一解释；形成的判断又可以指导下一次干预。一连串成功实验可能建立有效的局部关系，却未解决它在已观察条件之外是否成立。相反，失败的干预也可以通过排除某项预期而推动认识。考察这种交互，需要连接研究者最初有何理由作出预期、实验实际检验了什么，以及后来把什么当作已经确立的关系 [13–15]。

我们利用 ChemWorld 考察这些联系。核心问题是：当初始信息不足以决定答案时，人工智能如何自主组织探究以发展科学理解，发展中的理解又如何重新塑造探索？四个互补的实验矩阵分别考察研究目标与信息、判断的形成、研究机会，以及匹配化学世界的判别。它们共同覆盖六类化学体系，将重复结果与完整公开研究经历连接起来。历史模型与预算比较则补充不同探索路径。这些证据区分实验取得了什么成果、支持了什么关系，以及这些关系如何进入进一步研究。

使自主科学探索成为可检验的研究对象

ChemWorld 将材料、操作与仪器组合为遵循热力学、动力学和耦合过程关系、具有持续状态的虚拟化学系统。反应、热处理、相平衡、分离和结晶组件可以连接为多阶段流程。样品状态持续保留，上游反应或热历史因而能够改变后续分离与测量。智能体在固定资源范围内，自主决定投料、处理顺序、测量、重复及后续实验。这些选择既决定所开发的方案，也决定据以推断的观测。评估者独立控制世界参数和公开信息，记录实际提交的操作，并获得封存的参考结果（图 1）。智能体在研究与评估阶段均看不到这些参考真值。

这一安排使研究过程能够被具体考察。知识测试和给定数据任务评价重要的科学能力 [16,17]，交互式发现环境也已连接行动与观测 [18–21]。ChemWorld 在可组合的化学过程中，连接证据选择、不断变化的公开判断及其后续用途。一次请求可能在改变样品之前被拒绝；一项观测也可能只支持局部关系，尚未确定其在其他干预下是否成立。执行记录和独立评估的世界响应使这些区别能够被核对。

整合设计包含四个矩阵、450 场计划研究。目标—信息矩阵包括电化学和反应处理各 90 场：五世界、三种信息条件、两种研究任务、每格三次新会话。过程矩阵包括分配、纯化、水溶液平衡和反应耦合结晶各 45 场。机会矩阵在平衡和结晶中分别比较研究与无研究，每体系 30 场。另有 30 场匹配水溶液世界研究，将实验获得的物理信息与研究者的解释相联系。最新实验块提供 300 场，另 150 场保留自此前固定协议。这是一套共同覆盖设计下的不同实验块，并非所有协议完全相同、同时开展的合并试验（扩展数据图 2）。

信息条件改变研究起点。Opaque 保留公开任务和操作契约，不提供额外实例资料；Aligned 提供正确但不完整的信息；MisIndexed 提供指定错配。发现任务侧重研究科学关系，优化任务侧重开发有效方案。各固定实验块内，模型配置、接口和实验额度遵循对应设计。新会话共享固定世界和观测键，模型采样种子不可控。

因此，这些比较考察探索的不同起点，不将世界或重复视为一般科学活动的独立抽样。

新增 300 场全部到达终态：288 场完成全链，298 场提供有效预测，完成 3,420 次计划源终检中的 3,379 次。十场纯化研究耗尽材料，缺少 41 次终检；两场反应研究的预测缺失或无效。不完整源经历中的有效预测仍保留，并标明缺口。四场服务中断经技术补跑解决，中断尝试保留；科学失败不予替换。新记录包含 873 版笔记和 31,922 条公开操作，均结合可用封存说明和预测完成精读，核对 1,363 处引文锚点。这些数量说明覆盖范围，不是发现率或反绎成功率。

笔记定位观测前后的判断。研究结束后，智能体封存科学说明，在不能访问实验室的条件下预测十二种新干预，随后在没有参考真值反馈时反思。我们追踪现象、实际提出的解释或预期、拟议检验、真实操作、后续修订及用途；终点修订和未执行计划也保留。全过程区分三件事：编程世界中真实成立什么，当时可用信息支持什么，以及研究者后来提出或采用什么。五模型平衡比较与预算研究等历史证据提供额外参照，不扩大当前矩阵分母。

匹配世界矩阵进一步检验信息与解释的区别。五对水溶液世界共享公开背景和部分参数，但沉淀是否耦合额外中性水相离子对不同。两次给定极稀测定的底层响应接近；自主改变投料、稀释和尺度则可以显露更大差异。30 场完整研究产生 360 次终检和 80 版笔记。将各自选择的行动序列在配对世界中回放，每场均至少取得一次在两个响应通道上相差三个测定标准差的观测。这说明实际获得了物理区分信息，不等于唯一机制识别，更不等于 30 次成功反绎。

科学探索的自主组织与适应

研究从目标与信息出发，其科学内容则在由此引出的选择中发展。重复电化学矩阵使这一差别可见（图 2a、b）。先在世界内平均会话、再对五世界等权汇总，优化相较发现任务将推荐复测分数从 0.4813 提高到 0.5852，选择性产物产率从 0.1310 提高到 0.4225。然而，分数预测误差从 0.1539 增至 0.1829，产率从 0.0665 增至 0.0781，法拉第效率从 0.1677 增至 0.2218，后三者方向均见于五个世界。这说明有效方案的开发与新干预的判断可以分离，尚不能据此认定操作成功本身造成误解。

过程记录显示成果与局限怎样出现。一位优化研究者在已测幅值上发现负电位优于正电位，继而沿负侧改进材料与时长；终末笔记明确拒绝将结果称为普遍极性规律。其后预测却仍把未测试的正电位内部区域赋予近底噪响应，对应区间未覆盖参考。另一场优化研究则事前挑战绝对极性特异性，执行匹配反向检验并取得 0.384 产率，将解释改为极性优势而非绝对排他，预测也保留反向产物。因此，优化任务同样可以包含真实解释检验，汇总比较不意味着所有优化都在自我确认。

信息对研究后果的影响也有类似分化（图 2c、d）。在反应优化任务中，Aligned 相较 Opaque 将推荐分数从 0.2735 提高到 0.4429、产率从 0.5502 提高到 0.7116；风险预测误差由 0.2389 降至 0.1226，转化率误差却由 0.0355 增至 0.1595。四个方向均见于五个世界。这比较的是完整信息包，不能单独归因于一句提示，也未识别唯一中介判断。将反应各响应合为单一误差均值，会掩盖这一分化。

中间结果还会改变下一步值得做什么。一位纯化研究者已有纯度 0.814、回收 0.0479 的无洗方案；另一高相量方案回收更高，但纯度为 0.7886。它在下一批之前预计 0.005 L 洗涤可使后者超过 0.80，并规定只有回收也超过 0.0479 才重复这个替代方案。实际洗涤后纯度 0.8013、回收 0.0441，于是下一批回到原无洗方案做重复，得到 0.8149 和 0.0368。实验部分实现科学预期，却未达到事前行动标准；下一选择遵循了这一区别。重复也显示了波动，并未建立全局最优。

一种解释还可以改变后来能够取得的证据。另一位纯化研究者在低回收后怀疑遗漏投料组分，随后通过两种操作添加实际消耗同一共享库存的物料。改变后的流程耗尽库存，阻止了后来计划的温度实验。终末说明正确承认这些未完成实验不能支持温度关系。在这里，候选解释进入行动，行动改变资源，资源改变剩余观测机会。这是认识塑造探索的一条可见路径，尽管解释同时涉及化学与操作语义。

不同经历也可以形成相近准确性的判断。在历史五模型平衡比较中，Astra 的 15 场有 11 场对名义浓度不高于 1 mM 的正投料样品测定，Sol、GPT-5.5、Luna 和 Terra 则各 15 场均无此测定（图 3）。一场 Astra 先观察到 6.3–7.4% 的解离，随后进入 18.5 微摩尔浓度条件，观察到 53.8%。其说明区分局部平台与稀释响应，并对 13.3 微摩尔条件预测 58.80%，80% 区间为 54.20–63.40%，参考均值为 57.97%。Sol/Opaque 则未直接采样该区域，却取得 0.01833 的极稀宏平均误差。获得新现象与成功外推是不同成就；有效推断不要求直接采样每个目标。这些历史观察描述特定研究，并非固定模型性格。

匹配化学世界显示解释性可能如何组织更具体的证据获取（图 4）。一位研究者提出，尖锐沉淀起点与缓冲的溶解响应将支持溶解度限制解释，平滑变化则也容许经验分配描述。六次测定后，它提出更密集的浓度采样、中心重复与递增投料，随后六批确实执行。最终保留平滑单调关系，却未区分展宽阈值与经验分配解释；其预测说明也明确依据未解析出尖锐阈值的平滑单调浓度响应。

另一场检验稀释是否逆转高投料响应。研究者将名义浓度从 0.75 降至 0.375 M，归一化 pH 从 0.08045 升至 0.10803，终末沉淀信号为 0.08026，稀释前测量为 0.10004。它支持近似可逆，同时保留小幅滞后的不确定性。最接近的独立制备参照为 0.4 M，沉淀读数又来自不同仪器，因此并非精确滞后测定。其科学进展在于明确替代可能成为前瞻检验，再形成适用范围有限的判断。

科学认识在实验中的形成与演变

当一项关系接受检验，并改变研究者准备提出的主张或采取的行动，研究的科学内容就变得可见。在反应处理中，一位研究者发现加热后等待期间虽然降温约 44 K，转化仍继续。它在下一次比较前预测，同样等待之前先淬灭，将使转化停留在约 0.42，而非未即时淬灭时的约 0.62。实际检验得到 0.427。这连接了偏离预期的观察、可检验解释与成功局部预测（图 5a），但并未确立后来所有溶剂或温度外推。

另一场反应研究区分化学进展与处理结束时报告的风险。事前提出的淬灭对照改变末态风险，化学作用仍未确定；研究者相应收窄结论，并将末态关系用于后续预测。另一个 410 K 时长序列观察到转化上升、选

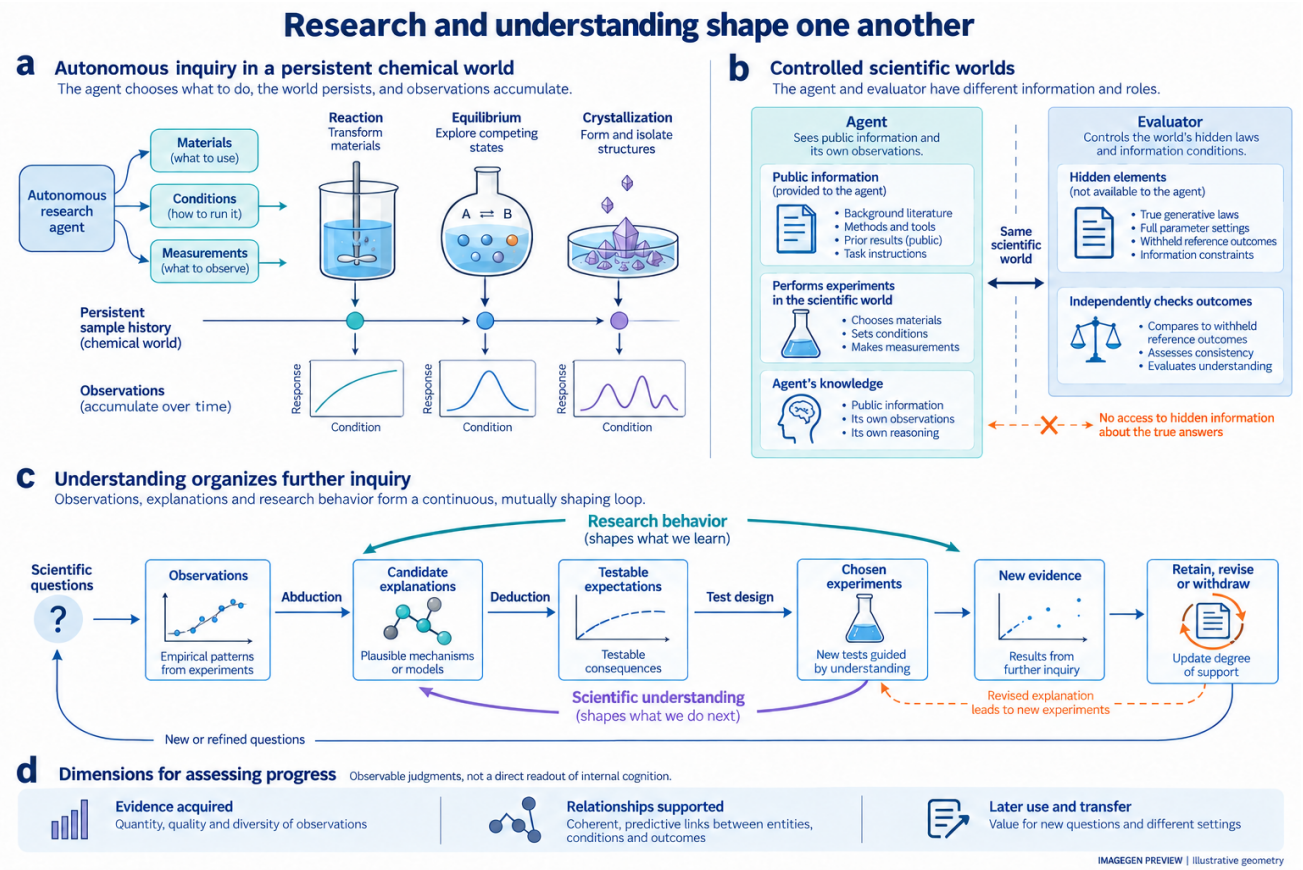


图 1 | 研究与理解相互塑造。a，选择和持续样品历史决定可获得的观测。b，智能体可见信息与评估者控制、封存参照分离。c，反绎提出解释性可能，演绎展开可检验后果，实验和修订参与组织后续探索。d，证据获取、受支持的关系与后续使用是不同进展维度。循环是公开记录的分析框架，不是认知的直接测量，也不声称每次操作都遵循它。ImageGen 预览：几何仅作示意，精确数值见保留证据。

择性下降，产率在中间时长达到较高值。研究者保留局部权衡，但未确定反应网络拓扑。因此，有效科学理解可以先表现为受约束的关系，而非已经唯一确定的机制。在本实现中，淬灭改变温度、风险与时钟，但不积分额外化学反应；淬灭前等待才继续反应。不同仪器之间的读数差本身也不能确立期间发生的化学过程。

前瞻检验失败也能收窄解释。在分配研究中，一位研究者明确将普通混合条件下接近平台视为暂定判断。弱混合的有机相分数为 0.536，普通混合为 0.631 和 0.662，更强条件则为 0.732。更强条件推翻了平台预期，后续说明予以撤回（图 5b）。由于时长和转速同时改变，证据支持修订混合关系，尚未分别确定两者作用或唯一传质机制。

结晶提供成功与失败的不同后续（图 5c、d）。一位研究者事前提出增加第三次热循环，实际得到细粉 0.494、回收 0.584；第四次未继续改善，因而收窄了单调收益预期。过滤前细粉测量为 0.506，也说明后来略低于 0.50 的数值并不是稳健跨阈值证据。另一场降低试剂投料，将细粉降至 0.583，随后预计进一步降到 0.005 mol 即可合格。实际下一批却没有可回收颗粒，过滤回滚，终检回收仅 0.0000445。说明因而将有效区域收窄为兼顾细粉与回收的局部窗口，并承认没有合格批次。这里的科学修订并不依赖最终操作成功。

这些过程补充了此前修正版结晶中降低投料形成局部收益、溶剂体积插值失败后明确撤回的案例。它们也显示，合适的研究单位是具体判断，而非整场研究。正确撤回稀释预期的那一场，在另一处却描述了一次失败的 1 g 晶种检验，而实际只提交 0.05 g。合理修订与缺少依据的经验前提可以共存。科学术语、任务成功或假说数量都无法单独区分两者。

经历的重建本身也具有后果（扩展数据图 6）。一场反应研究的两次 600 s 加热均回滚，没有实际反应时间或温度变化；终末说明却把它们当成 1,200 s 不反应，提出诱导期或历史效应，并带入后续预测。另一场则明确将回滚加热排除在化学解释之外。在结晶中，一版中途笔记同样把实际提交的 0.05 g 晶种写成已检验 1 g，并据此安排 1.5 g 检验。高剂量请求继续失败，说明却进一步描述更大已测剂量。新 15 场研究中八场存在与被拒加种相关的剂量误述，但发生时点和后续用途不同。这是具体的执行—说明差异，尚非一种统一心理机制。

解释这些错误必须核对实际实验。一些返回信息外层称实验完成，内部物理转移却回滚；不同操作也具有不同许可上限。一场反应研究把控制器 430 K 上限套用到公开允许 470 K 的直接加热，随后对预期回滚的请求给出近零响应。这些情况涉及操作语义、记述证据与科学判断，不能全部归为化学动力学误解。反过来，终末错误说明也不能被假定指导了此前源研究。我们区分中途前提及其后续行动，与研究结束后首次出现的解释。

即使没有错误执行历史，局部支持与后续应用也会分离。一位反应研究者重复 360 K、3,600 s 方案，得到分数 0.34983 和 0.34779，并发现延长加热提高转化、降低产率。这支持局部时长权衡。后来它将严重产物损

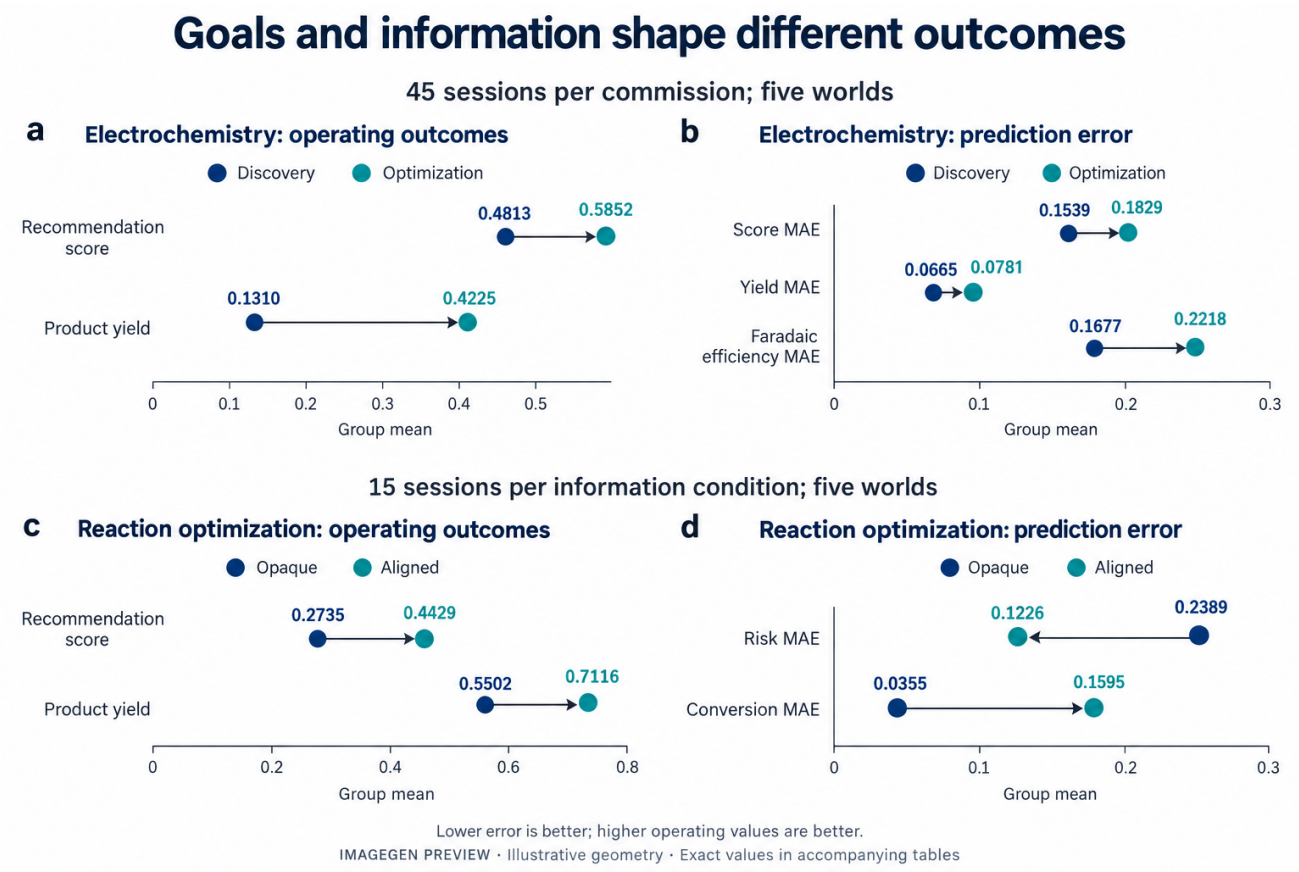


图 2 | 目标与信息对操作和预测产生不同后果。a、b，重复电化学发现—优化比较，每种任务 45 场，覆盖五世界和三种信息条件；优化提高推荐复测分数与产率，同时增加三种预测误差。c、d，反应优化的 Opaque 与 Aligned 比较，每组 15 场：推荐分数与产率提高，风险误差下降，转化率误差上升。均先在世界内平均会话、再对世界等权；箭头连接组均值，不是一位研究者的发展轨迹。ImageGen 预览：几何仅作示意，数字标注依据保留证据。

失外推到未测试条件，转化误差仅 0.00345，产率误差却为 0.31812。准确转化不能验证整套产物损失解释。平衡研究 A 中，真实解离平台同样进入极稀预测，尽管研究者承认该区域未测试（扩展数据图 5）。其原拟议投料身份对照也未实现，因为两种命令加入同一物种。经验平台与拟议解释因此具有不同证据地位。

这些案例共同显示研究转化为理解的多个环节：观察引出候选，候选选择检验，结果支持或收窄关系，关系进入下一判断。一个环节可以对某项主张成功，对另一项失败。失败检验能够产生合理修订，机制未决能够与有效局部认识共存，正确局部关系也可能获得无依据的更广应用。追踪这些区别，使研究的科学内容超越最终报告是否正确而变得可见。

自主探索中科学进展的性质与条件

上述经历表明，自主研究包含实质科学活动。机会矩阵进一步考察：在共同初始信息与评估下，获得研究机会究竟改变什么？平衡和结晶均在五个固定世界中比较十二批研究与无源实验，每世界每组三次新会话，全部使用 Opaque 信息。这估计组织实验、接受反馈和记录判断的完整机会，不单独识别反绎、相对给定数据的自主性或笔记作用。

新结晶比较提供了明确正向证据（图 6a、b）。30 场均有有效预测，180 次研究终检全部完成。相较无研究，世界等权平均绝对误差在纯度上由 0.13853 降至 0.01661，粒径指数由 0.23619 降至 0.07641，回收由 0.13532 降至 0.11579，细粉由 0.37683 降至 0.30110。纯度的名义 80% 区间覆盖率从 0.46667 升至 0.98333，同时平均宽度从 0.44744 缩至 0.09743。真实实验经历可以建立并迁移有效的稳定关系；证据未能保留并不是结晶自主研究的普遍描述。

同一比较也区分点准确性与不确定性质量。细粉区间宽度从 0.68500 缩至 0.38450，覆盖率却从 0.42778 降至 0.35556；同时惩罚宽度与漏失的区间评分从 1.4794 恶化至 1.8047，方向见于全部五个世界。平均点预测改善，并不保证不确定性充分体现尚未解决的条件。恰当结论须按响应展开：研究显著改善纯度判断，细粉预测却仍有明显不确定性问题。

保留的平衡比较揭示另一种边界（图 6c、d）。十四份有效研究预测与十五份无研究预测中，总体归一化宏平均误差由 0.132086 降至 0.035632，五世界均改善。然而，事前指定的三个极稀问题误差由 0.061467 增至 0.103677，四世界恶化；其余九题由 0.155625 降至 0.012950。解离贡献极稀宏误差增幅的 85.2%。即使允许唯一缺失研究预测取合法范围内任意误差，也不逆转两个汇总方向（方法）。这种区域反转属于特定世界与判断，不是取得证据的必然后果。

先验信息同样没有普遍排序。分配矩阵中，Aligned、Opaque 和 MisIndexed 的相分数误差依次为 0.04654、0.05621 和 0.07700，Aligned 优于 MisIndexed 的方向见于五世界。两个相分数互补，不能视为独立重复。纯化中三种条件的纯度误差相近，约 0.152–0.154，回收误差却以 MisIndexed 最低；十场材料耗尽还改变了实

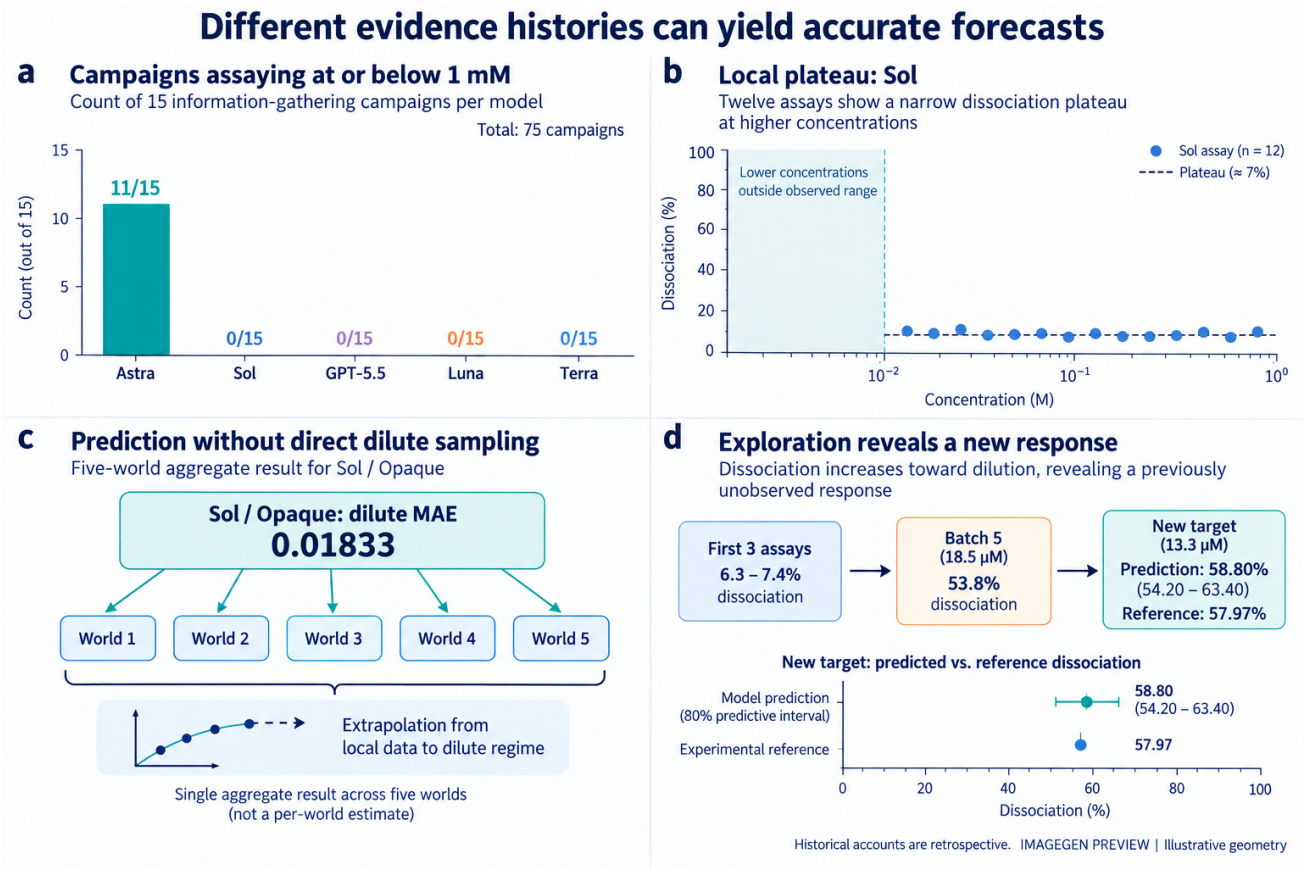


图 3 | 从证据到预测的不同路径。a，各模型 15 场中到达不高于 1 mM 的数量。b，示意性的局部解离平台。c，Sol/Opaque 极稀 MAE 是五世界汇总，不是每世界单独数值。d，一场 Astra 研究的选定阶段、封存预测及原 80% 预测区间。历史科学说明为事后记录；结果不建立固定模型特征。ImageGen 预览：几何仅作示意，精确数值见保留证据。

际取得的证据量。结合反应比较，这说明单一信息收益总分会掩盖科学上不同的判断。

历史证据补充了影响这些结果的其他条件（扩展数据图 1）。原 Sol 平衡研究中，正确部分信息将九题误差由 0.01008 降至 0.00465，却将三个极稀问题由 0.01833 增至 0.15862；保留重复队列方向相同、幅度不同，分别为 0.00907 至 0.00512 和 0.09880 至 0.13205。其他模型配置并非都发生这一反转。历史十二批与二十四批比较也出现某些预测改善，但可行结晶推荐未相应改善。这些独立实验块说明结果依赖研究者、条件及资源范围，并非新矩阵的额外重复。

互补的源观测诊断则考察：已有证据在多大程度上约束了后续判断。在修正过程队列 42 份有效预测中，智能体纯度误差 0.03853，自身源观测均值为 0.00510；回收却相反，为 0.10129 对 0.20443，智能体在 39 场更优（扩展数据图 3）。这些仅用源观测的计算诊断特定经历中未充分使用的信息，不是无研究对照，也不说明实验没有价值。新机会比较确立了相对无研究的显著纯度收益，旧诊断则说明研究者仍可能未充分使用已有证据。两者可以同时成立，无需合并队列或赋予相同基线。

最后，匹配世界研究在一些解释仍未确定时，取得归一化 pH 误差 0.00196、游离解离分数 0.00312、沉淀 0.00243。经验建立的关系可以支持准确后续推断，而不必先唯一识别机制。该实验块没有无研究组，化学规律也不同，因此低误差不是相对于此前世界的因果改善估计。四矩阵共同显示科学进展具有多个维度：有效流程、受支持的局部关系、成功迁移与可靠不确定性，可以在同一次自主探索中以不同速度发展。

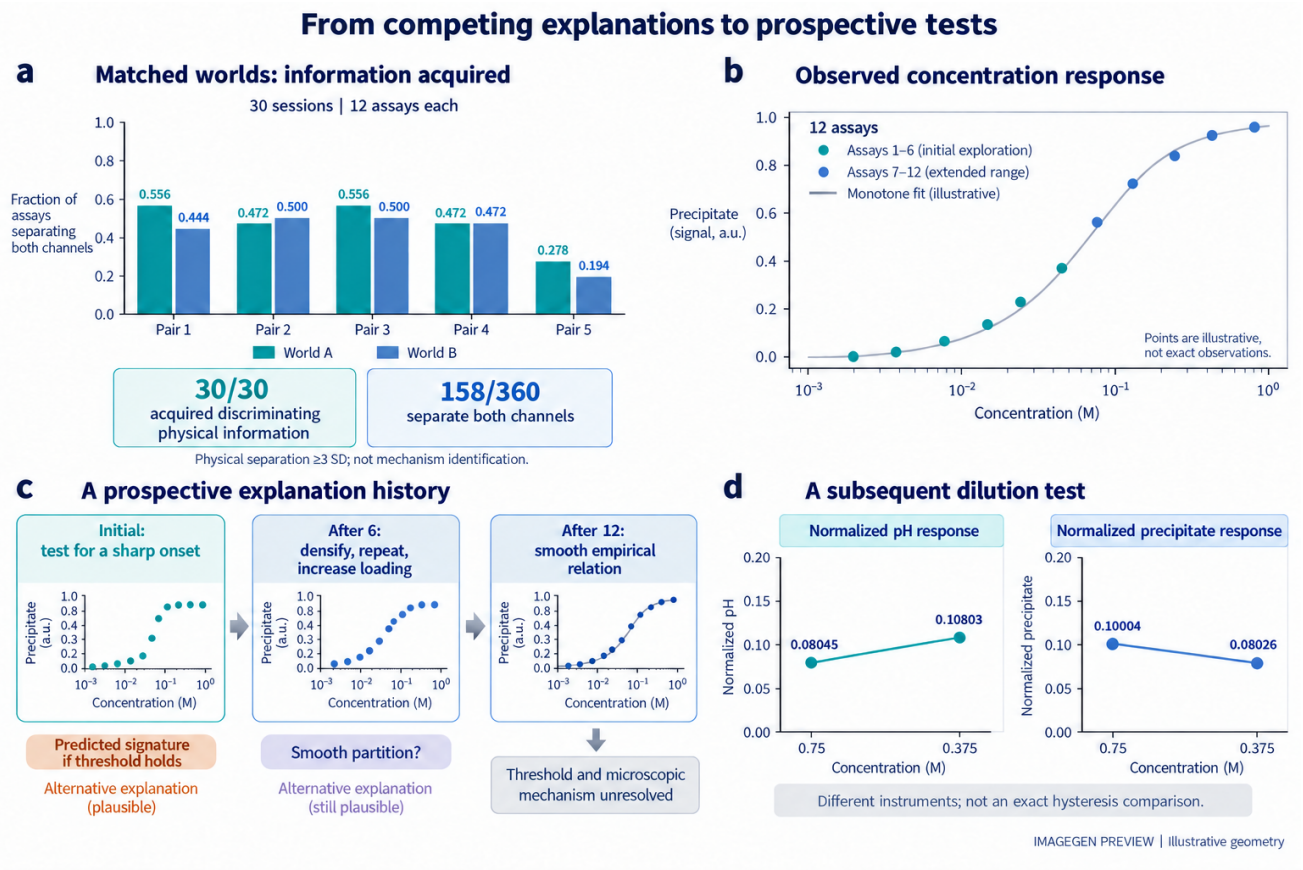


图 4 | 解释引出检验和有限范围的关系。a，十二次测定中至少两通道相差三个测定标准差的平均比例，每世界平均三会话；物理信息不等于机制识别。b、c，示意浓度响应，以及从条件性预期到加密采样、重复和受限经验关系的记录。d，另一场前瞻稀释检验及保留读数；不同仪器读数不构成精确滞后比较。ImageGen 预览：几何仅作示意，精确数值见保留证据。

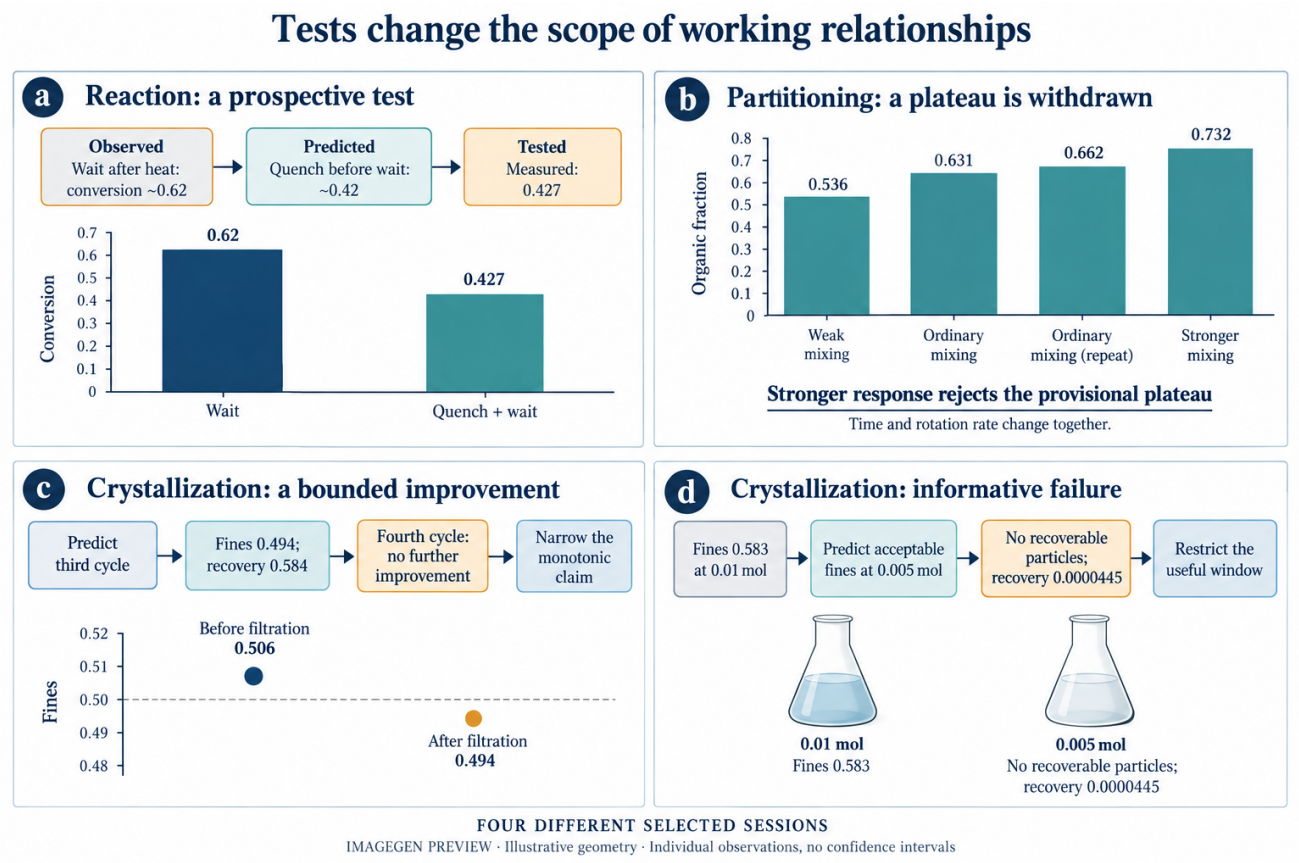


图 5 | 检验改变工作关系的范围。a，事前淬灭—等待预期为转化约 0.42，实际为 0.427。b，更强混合使分配平台预期被撤回，时长与转速仍混杂。c，第三次结晶热循环取得近阈值结果，第四次未继续改善。d，进一步稀释未保留可回收颗粒，收窄拟议操作窗口。各面板为不同选定研究；数值是单次观测，不是处理均值或置信区间估计。ImageGen 预览：几何仅作示意，精确记录随稿保留。

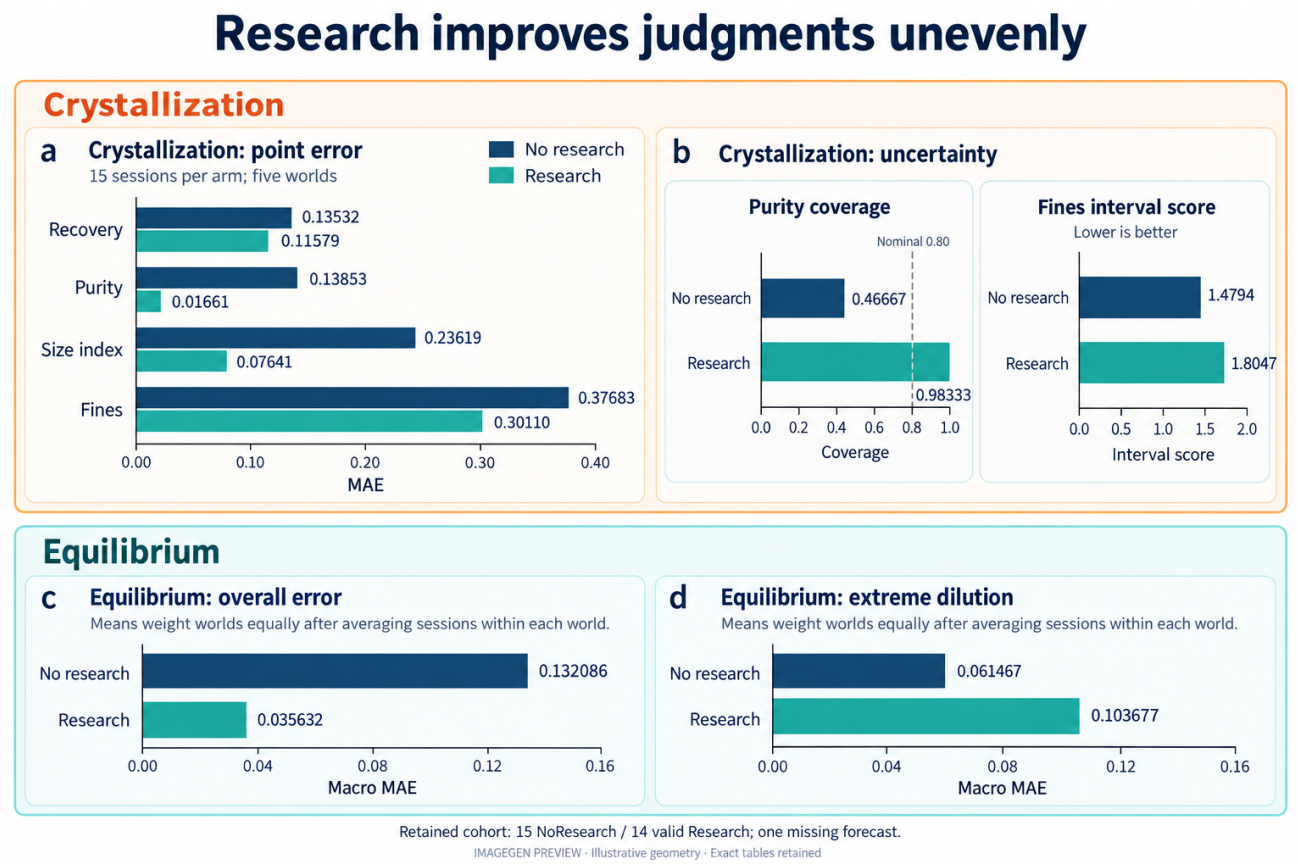


图 6 | 研究对不同响应与条件的影响。a，结晶研究与无研究的点误差，每组 15 份有效预测。b，纯度覆盖改善，细粉区间评分恶化；覆盖对应名义 80% 预测区间，不是组均值置信区间。c、d，保留的平衡比较总体预测改善、极稀预测恶化，研究组 14 份有效预测、无研究组 15 份。面板为不同实验块，均先在世界内平均会话、再对五世界等权。ImageGen 预览：几何仅作示意，精确表格和缺失保留。

讨论

自主研究既改变机器能够遇到的证据，也改变它用来理解证据的关系。四矩阵从互补层次连接这一相互作用：目标与信息改变探索起点，完整经历显示候选解释如何成为检验和修订，机会比较测量后续判断变化，匹配世界回放区分物理信息与解释。贡献在于实证考察探索如何产生、限定并应用科学关系，而不仅评价智能体是否完成实验闭环。

反绎使这一过程中的创造性环节更加明确。偏离预期的现象可以提出改变下一实验的解释，如加热后继续反应、沉淀响应和可逆性检验；演绎后果与经验比较随后改变解释的地位。其他有价值的活动包括建立局部关系、重复临界结果、撤回插值预期和识别尚未执行的检验，并非都需要称为反绎。它们的结合显示发展中的理解如何真正参与探索组织，包括检验失败、唯一机制仍未确定的情形。

结果区分真值、证据支持与后续使用。准确预测可能依赖未决解释，受支持的局部关系可能越出其检验范围，研究者也可能取得显著改善却仍未充分利用观测。结晶机会比较尤其明确：研究形成较强的纯度和粒径预测，细粉不确定性仍不可靠。旧源均值诊断考察的是另一个问题——已有证据被利用到什么程度。如果为整场研究赋予单一科学成败标签，这些差别将被抹去[12,22,23]。

过程分析进一步定位了取得证据与重建所检验内容之间的区别。被拒请求可能进入后续说明成为已完成实验，也有会话明确排除它们；文字范围限定可能与不遵循该限定的数值预测并存。与此同时，智能体能够用反例放弃绝对主张、修订行动标准、界定有效操作区域。这些是在具体判断上的发展，并非相互排斥的研究者类型。接口语义和公开表述的出现时点，决定了能在多大程度上将其归因于此前研究。

受控比较也限定所能支持的解释。机会比较估计完整研究组合，而非反绎或实验自主性的独立作用；匹配世界回放固定行动，不估计不同反馈如何改变下一选择，物理区分信息也不证明唯一机制识别。目标与信息比较不能认定某条选中经历是汇总差异的唯一中介。另行固定配方的淬灭实验识别物理效果，却不让智能体适应这些反馈（扩展数据图 4）。研究知识形成，并不要求所有设计共享一个自我确认机制，或最终给出成功纠错策略。

证据局限于可编程体系、固定世界，以及重复矩阵中的一种模型配置。新会话不是模型种子受控重复，也非世界规律的独立抽样。公开笔记不能直接读取内部认知，中途笔记缺失限制时序推断。全部新经历均已精读，但示例判断仍为事后选择，解释没有独立人类第二编码者一致性估计。整合覆盖保留不同协议时期和全部科学失败，包括材料耗尽、无效预测。区分化学理解与执行错误时，还须审查虚拟化学和操作接口。这些边界限制普遍性，但不取消已经观察到的检验、修订和按响应分化的效应。

爱因斯坦的开篇问题提示，科学发现可以要求重新考察理解的前提；它不是衡量当前智能体是否重现历史突破的测试。ChemWorld 使这一广义活动中更小、具体的过程能够被观察，将实验选择、获得证据、发展解释和后续决定放回同一研究历史。自主科学由此不仅可以通过机器执行了什么来研究，也可以通过行动如何形成可靠、可迁移的理解，以及理解如何使进一步探索成为可能来研究。

资助

本研究获得深圳市科技计划项目（AI2026004）、清华大学自主科研计划，以及青年教师科研创新能力支持项目（ZYGXQNJSKYCXNLZCXM-E7）资助。

参考文献

1. A. Einstein. Zur elektrodynamik bewegter körper. *Annalen der Physik* **322** 891–921 (1905). https://doi.org/10.1002/andp.19053221004.
2. I. Douven. Peirce on abduction. *The stanford encyclopedia of philosophy: abduction* (2025). https://plato.stanford.edu/entries/abduction/peirce.html.
3. G. Tom et al. Self-Driving Laboratories for Chemistry and Materials Science. *Chemical Reviews* **124** 9633–9732 (2024). https://doi.org/10.1021/acs.chemrev.4c00055.
4. D. A. Boiko, R. MacKnight, B. Kline, and G. Gomes. Autonomous chemical research with large language models. *Nature* **624** 570–578 (2023). https://doi.org/10.1038/s41586-023-06792-0.
5. R. D. King et al. The Automation of Science. *Science* **324** 85–89 (2009). https://doi.org/10.1126/science.1165620.
6. B. Burger et al. A mobile robotic chemist. *Nature* **583** 237–241 (2020). https://doi.org/10.1038/s41586-020-2442-2.
7. B. P. MacLeod et al. Self-driving laboratory for accelerated discovery of thin-film materials. *Science Advances* **6** eaaz8867 (2020). https://doi.org/10.1126/sciadv.aaz8867.
8. N. J. Szymanski et al. An autonomous laboratory for the accelerated synthesis of inorganic materials. *Nature* **624** 86–91 (2023). https://doi.org/10.1038/s41586-023-06734-w.
9. A. M. Bran et al. Augmenting large language models with chemistry tools. *Nature Machine Intelligence* **6** 525–535 (2024). https://doi.org/10.1038/s42256-024-00832-8.
10. T. Dai et al. Autonomous mobile robots for exploratory synthetic chemistry. *Nature* **635** 890–897 (2024). https://doi.org/10.1038/s41586-024-08173-7.
11. A. N. Elmachtoub and P. Grigas. Smart Predict, then Optimize. *Management Science* **68** 9–26 (2022). https://doi.org/10.1287/mnsc.2020.3922.
12. G. Shmueli. To Explain or to Predict? *Statistical Science* **25** 289–310 (2010). https://doi.org/10.1214/10-sts330.
13. J. R. Platt. Strong Inference. *Science* **146** 347–353 (1964). https://doi.org/10.1126/science.146.3642.347.
14. D. V. Lindley. On a Measure of the Information Provided by an Experiment. *The Annals of Mathematical Statistics* **27** 986–1005 (1956). https://doi.org/10.1214/aoms/1177728069.
15. K. Chaloner and I. Verdinelli. Bayesian Experimental Design: A Review. *Statistical Science* **10** 273–304 (1995). https://doi.org/10.1214/ss/1177009939.
16. A. Mirza et al. A framework for evaluating the chemical knowledge and reasoning abilities of large language models against the expertise of chemists. *Nature Chemistry* **17** 1027–1034 (2025). https://doi.org/10.1038/s41557-025-01815-x.
17. B. P. Majumder et al. DiscoveryBench: Towards Data-Driven Discovery with Large Language Models. *International Conference on Learning Representations* **2025** 4556–4579 (2025). https://proceedings.iclr.cc/paper_files/paper/2025/file/0d70af566e69f1dfb687791ecf955e28-Paper-Conference.pdf.
18. R. Wang, P. Jansen, M.-A. Côté, and P. Ammanabrolu. ScienceWorld: Is your Agent Smarter than a 5th Grader? *Proceedings of the 2022 conference on empirical methods in natural language processing* 11279–11298 (2022). https://doi.org/10.18653/v1/2022.emnlp-main.775.
19. P. Jansen et al. DiscoveryWorld: A virtual environment for developing and evaluating automated scientific discovery agents. *Advances in neural information processing systems* **37** (2024). https://doi.org/10.52202/079017-0324.
20. K. Gandhi et al. BoxingGym: Benchmarking progress in automated experimental design and model discovery. (2025). https://arxiv.org/abs/2501.01540.
21. Y. Chen, P. Piękos, M. Ostaszewski, F. Laakom, and J. Schmidhuber. PhysGym: Benchmarking LLMs in Interactive Physics Discovery with Controlled Priors. *Advances in Neural Information Processing Systems* **38** (2025). https://doi.org/10.52202/085713-1556.
22. T. Gneiting and A. E. Raftery. Strictly Proper Scoring Rules, Prediction, and Estimation. *Journal of the American Statistical Association* **102** 359–378 (2007). https://doi.org/10.1198/016214506000001437.
23. Y. Ovadia et al. Can you trust your model's uncertainty? Evaluating predictive uncertainty under dataset shift. *Advances in Neural Information Processing Systems* **32** (2019). https://proceedings.neurips.cc/paper_files/paper/2019/file/8558cb408c1d76621371888657d2eb1d-Paper.pdf.

方法

世界、接口与实验单位

ChemWorld 将兼容的过程组件编译为具有持续状态的虚拟化学环境。公开契约指定材料、合法操作、仪器、资源和任务目标，私有参数决定具体世界的响应。智能体能够访问实验室和公开记录，不能访问评估者状态、模拟器代码、私有参数或封存参考结果。操作改变样品，测量可能消耗材料。候选转变在提交之前接受校验；被拒绝的操作不构成所请求的物理干预，但尝试可能消耗契约规定的资源。精确重放核对环境状态转变，不重新生成模型决策。

广度研究覆盖电化学、分配、反应与热处理、水溶液平衡、反应耦合结晶和纯化。这些是受控虚拟系统，不是对具名现实物质经过实验验证的预测。整合重复设计通过互补矩阵覆盖六个体系。五个固定世界在不同条件与重复中复用，世界参数、初始状态和键控观测映射保持固定。重复单位是新模型会话，不是独立世界抽样或受控模型 seed 重复。接口没有可用的模型采样 seed；相同干预可以得到相同键控观测，因此也不是独立噪声实现。

整合矩阵与新增会话覆盖

四矩阵覆盖设计包含 450 场计划研究，由新增 300 场与保留 150 场组成。目标—信息矩阵在电化学和反应处理中各采用五世界 × 三信息 × 两任务 × 三会话，每体系 90 场。过程矩阵新增发现任务下分配 45 场、优化任务下纯化 45 场，各为五世界 × 三信息 × 三会话，加上保留的平衡 45 场与修正版结晶 45 场。机会矩阵包括新结晶 30 场和保留平衡 30 场，均为五世界 × 研究/无研究 × 三会话，全部 Opaque。保留的 30 场匹配世界研究构成第四矩阵。保留 150 场、历史广度 300 场与新增 300 场明确区分；共同覆盖结构不意味着协议和时期相同。

新参与者使用 gpt-5.6-sol，要求 medium 推理强度。源研究允许十二批，十五位无研究参与者没有源实验。科学说明、十二题预测与反思依次封存，没有参考真值反馈。300 场取得 288 条完整链、298 份有效预测、3,379/3,420 次源终检和 898/900 个有效封存阶段。电化学 90/90 全链、1,080 次终检；反应 88/90 全链、1,080 次终检、88 份有效预测；分配 45/45 全链、540 次终检；纯化 35/45 全链、499/540 次终检，但 45 份预测均保留；结晶 30/30 全链、30 份预测、180 次研究终检。285 份源回放和 240 份推荐回放凭据已验证。

十场纯化保留材料耗尽造成的缺口，不替换经历。一场反应在工具预算耗尽后缺少预测，另一场预测因区间不符合评估要求而无效；相关操作及后来可用说明全部保留。按预先确定的技术补跑规则，四场明确服务中断在主队列完成后补跑；中断尝试全部保留，不增加科学单位。此前运行时开发尝试与本块分开。不因科学分数替换已完成结果；稿件编译不开展模型或模拟器实验。

新矩阵测量与汇总

各响应保留原生评估定义。电化学和纯化参照为单个固定键终末观测；分配为采样前无噪声相分数；反应点误差参照五观测均值，覆盖使用十二题共六十个参考观测；结晶为终检采样前无噪声响应及初始投料回收。分配使用名义 90% 区间，其他体系为 80%。两个分配相分数互补，并非独立证据。不形成跨响应、跨体系科学能力总分。

先计算每场响应误差和区间诊断，再在每个固定世界内平均可用会话，最后对五世界等权。电化学任务比较还在每世界内平均三种信息条件，每任务 45 份预测全部可用。反应优化的 Opaque—Aligned 比较每组 15 份有效预测；另两个存在缺失的反应条件各为 14/15，并明确标记。纯化保留源预算不完整会话的可用预测。计划响应缺失时，不给完整网格估计；可用案例均值不将缺失填为零。重复会话、问题和响应共享世界，不作为独立抽样来估计置信区间或显著性。固定格的三次重复描述波动，不建立总体可靠率。

操作比较使用封存推荐的独立复测，与新查询干预下的预测分开。分数和产率保留公开定义，分别汇总。区间宽度、经验覆盖和保留评估器提供的适当区间评分与点误差共同报告；新结晶机会比较采用 alpha=0.2 及对应合法响应尺度。研究与无研究共享科学背景和封存评估，研究额外提供实验预算、经历与记录机会。差异估计整个组合，而非某个推理操作。

新研究经历的完整精读

新增 300 场均精读，包括十五份无研究说明、873 版笔记和 31,922 条公开操作。899 份非空封存内容中，一份含无效预测，因此仅 898 个有效阶段；另有一份预测缺失。电化学 268 版笔记、7,647 条操作；反应 293 版、7,917 条；分配与纯化 262 版、13,253 条；结晶 50 版、3,105 条。逐场阅读核对 1,363 处公开原句。缺失笔记、失败检验、被拒请求、终点修订及后期反思均保留；阅读覆盖不是解释成功率分母。

每项焦点判断区分实际提出的现象、候选解释或经验预期、首次表述、前瞻后果、真正提交的干预、测量、修订地位与后续用途。条件计划不算已执行检验，后来预测不倒填入此前笔记。终末解释可以支持后来预测的用途判断，不能单独证明此前源行动受其引导。依据源阶段公开契约与冻结执行语义，区分请求被拒、状态回滚和任务质量失败。反应风险超阈值不意味着回滚，直接加热与控制器配置具有不同温度上限。淬灭推进时钟、改变状态但不积分额外反应，淬灭前等待则可能继续反应。结晶晶种专题比较请求量和提交量，不将重复被拒请求当作剂量。

全部经历均作语义阅读，示例判断则按解释意义事后选取。同一会话可以有证据支持与结果不同的多项判断。分析不把整场分类为成功反绎，不推断内部认知，也不估计共同自我确认机制。解释与来源核查由助手分析流程承担，没有独立人类编码、盲法或第二评分者一致性估计。下文旧行动关联窗口及解释历史保留原定义和分母。

历史与保留证据层

历史广度研究包含 240 场 Sol-medium 研究，以及 Luna、Terra、GPT-5.5 和 Astra 的 60 场额外平衡研究，均请求 medium 推理强度。五模型平衡比较中的十五场 Sol 已包含在 240 场内。请求的模型标签不代表实际计算量相等。原 240 场包含电化学 60、分配 30、反应 60、平衡 45、结晶 30 和纯化 15 场；按其原规则保留 3,597/3,600 次最终测量、全部 720 个后测阶段与 238 场协议符合研究。额外六十场保留 720 批和 240 个阶段。两场原始源研究完成度失败仍予保留。更早的选定笔记案例另有 24 场，不与广度或保留平衡—结晶过程队列合并。

保留平衡—结晶过程队列由早期 48 场及其 42 场扩展中的 45 场平衡研究，以及统一回收描述后完整重跑的 45 场结晶研究组成。每个体系覆盖五世界、Opaque/Aligned/MisIndexed 三信息条件、每格三场，每场十二批。平衡保留 39 条完整链、41 份有效预测；修正版结晶分别为 41 和 42。该保留队列合计分母为 90 场、80 条完整链、83 份有效预测。旧结晶作为受协议影响的历史证据保留，不加入修正版计算当前结果或过程频率。

修正版结晶完成 510/540 个源批次、125/135 个后测阶段，保留 145 版笔记和 42 次推荐复测。全部 45 条源轨迹与 42 条复测轨迹通过重放。四条不完整链中，三条缺失预测，另一条有有效预测但缺失随后的反思。平衡子集与独立的研究机会块各自保留失败表。缺失不填零，已完成结果不由后来更有利的结果替代。稿件整合不改变任何实验块原有的开发或资格证据地位。

信息、自主性与记录

历史目标比较在世界、信息条件、批次预算和先验位置内，匹配独立开展的发现与优化研究。电化学的十二与二十四批条件合计三十对；反应处理的参数和结构先验块均采用十二批，合计三十对。操作结果来自封存推荐的独立复测。联合结果计数采用公开评分的预测 MAE，反应先验比较则采用六项归一化响应误差的平均值，两者不互换。预算比较同样涉及具有完整资源范围的独立会话，不估计继续同一项研究的作用。

历史五模型平衡比较包含五世界、三信息条件，每格一场十二批研究，共七十五场，其中十五场 Sol 已计入广度研究。1 mM 阈值描述实际测量的最低正投料名义浓度，不是发现判据。浓度按名义配方投料计算，三道极稀评估题在模型配置间相同。各条件的预测误差、原始预测区间与已获证据均保留。选定的 Astra 和电化学轨迹属于事后过程示例，其科学解释在实验后写成，不是同期笔记记录，也不是额外重复。完整历史设计、响应表和案例数值保留在补充材料。

Opaque 提供公开任务和操作背景，不提供额外实例资料。Aligned 提供与体系相符的部分信息；平衡包括有效酸度区间和带锚点的局部稀释关系。MisIndexed 使用另一世界的历史关系，格式与限定相同。结晶 Aligned 提供匿名材料名义描述，MisIndexed 交换 S1/S3 溶剂描述，保留 S0、S2 和催化剂描述。两者均不是完整世界规律。

原平衡 Opaque/Aligned 早于 MisIndexed 扩展；修正版结晶是更晚的完整实验块。这些描述性比较并非全部同期随机处理，新旧结晶也不能估计修正提示的因果作用。下文单列的新研究机会比较采用共同的同期协议。

智能体在固定预算内选择操作、用量、测量、重复与操作分组。平衡允许十二批、180 次操作尝试、十二次中间仪器与十二次最终测量；结晶采用固定十二批材料预算和 720 次尝试上限。记录角色要求在适用时先写出可检验预期，后续由智能体自主更新，不要求每批书写，也不自动重新注入笔记。记录角色可能影响研究，不被视为被动观察。笔记保存版本与公开事件游标，不揭示内部认知。没有调用笔记读取工具，不代表无法访问会话中此前出现的内容。

后测与回收定义

源研究及操作推荐结束后，智能体依次封存科学解释、在无实验工具条件下回答十二个固定新干预问题，再在没有真值反馈的情况下反思。平衡另有结构化补充评估。证据中的 K1/Q/K2/EQS 分别表示这些阶段。源研究期间不展示预测问题；后测提出的方案不计为已执行源实验。

平衡点误差以每题五个参考观测的均值为比较对象，覆盖率检查全部五次观测。结晶使用最终测量采样之前的无噪声完整流程响应，源观测则带噪声。修正版保留六十个参考批次，数值与旧参考一致，并对每份可用的已提交推荐单独复测。

修正后的回收定义为：扣除晶种贡献的固相目标产物摩尔量，除以所跟踪的初始试剂投料摩尔量，截断到 [0,1]。源指令、预测提示、观测与评分现在指向同一完整流程量。内部结晶阶段指标则以分离前的目标产物为分母。旧过程指令描述后者，而观测与评分使用初始投料；原分数作为受协议影响的诊断值保留，不进入修正版队列。修正版完整重跑，没有事后为旧分数更名。

质量要求有颗粒、纯度至少 0.80、细粉至多 0.50；联合推荐成功还要求修正定义的回收率至少 0.10。按可用复测，修正版联合成功为 Opaque 13/15、Aligned 10/14、MisIndexed 10/13，每臂仍各计划十五场。粒度采用公开指数 min(d50/250 微米, 1)，其误差不能写成微米。

研究路径与过程解释

我们通过公开提出的候选解释及相关后续检验考察反绎探索，并区分演绎预期、经验支持与后续应用。主例连接初始预期、差异观测、替代解释、预期后果和实际检验；同时单独核对实际干预能否区分候选解释。报告或准确预测本身不能建立这一序列。这是基于案例的过程解释，不是反绎能力量表或机制发生率估计。92 个行动关联窗口描述保留平衡—结晶过程队列的记录覆盖，不是反绎成功次数，也不包含来自独立机会比较的主例。

事后解释历史案例组固定为主例平衡机会会话，以及前稿已展示的四个修正版结晶案例：低投料、插值与两个对照的播种记述。我们沿五场研究追踪七项相关判断，保留全部笔记版本和终点修订。字段区分所解释现象、智能体实际提出的候选或预期、首次出现、条件性预测、执行操作、观测、后续地位与用途。没有给出的条件性表述保留为缺失，不由分析者补写。平衡的负载预期、组分假说和背景解释是同一探索的相连线索，不是三项独立发现。案例不是用于估计频率的抽样，不从窗口数量推断解释层面的发生率或可靠率。

操作语义核查使用保留的执行版本与轨迹机制身份，不以当前运行时假设替代。该世界只有一种非催化进料，试剂操作和组分 0 都选择它，并更新平衡响应计算读取的同一初始投料记录。因此，在同等投料下切换命令不改变物种身份。扩展数据图 5 的最终名义浓度为实际提交的摩尔数除以加入的总溶剂体积，分步稀释批次按最终 0.8 mol/L 展示。此核查不调用新模拟器实验。较低投料和正交测量仍是保留历史中未执行的提议；经验平台的支持范围与智能体提出的机制分别考察。

事后路径提取覆盖历史电化学六十场、平衡四十五场和修正版结晶四十五场。五十个世界内条件比较保留目标、预算、信息与队列。计数采用实际提交操作，溶剂覆盖包括再悬浮添加；拒绝请求不构成成功材料使用，中断会话保留在计划分母中。

结构提取检查保留九十场、268 版笔记构成的全部 178 对相邻版本。入选需要早期笔记、下一版之前至少一次新的已提交最终测定，以及后版之后的已提交研究操作；仅测量或终止不构成继续研究。178 对均有新增测定，其中 92 对满足继续研究：平衡 34 个窗口分布于 30 场，结晶 58 个分布于 35 场。另 86 对（平衡 44、结晶 42）之后没有继续执行已提交研究操作，完整记录仍保留在证据包。没有完整窗口的二十五场不被归类为没有学习。

入选先依据事件时序计算，不以某个计划是否最终成功执行为条件。但该规则确实要求后续继续开展已提交研究，因此终点修订不进入这一行动关联分母。92 个入选窗口全部编码；标签针对每个窗口选定的即时计划，不穷尽笔记里的所有提议：83 个匹配、7 个部分匹配、2 个无明确下一计划，其中修正版结晶为 52 个匹配、6 个部分匹配。即使某个所选行动匹配，完整笔记仍保留未落实、被拒及改变的其他提议。全部 182 条更新/计划引文及测定/操作游标经源记录核对；证据包包含全部相邻版本、所选编码、全文笔记和执行历史。

编码和内部科学复查由同一分析者完成，没有独立第二评分者一致性估计、盲法或经独立裁决的机制发生率。团队已将复查交给本流程，完成的内部复查与独立重复明确区分。反例包括合理撤回、正确识别未执行检验，以及准确但明确标为推测的外推。说明案例为事后选择。

匹配化学世界与解释历史

保留的匹配世界前瞻实验包含五组参数配对、两种化学网络、每世界三次 Sol-medium 新会话，共三十场。网络 A 将弱酸解离与自由离子直接沉淀耦合，B 额外包含中性水相离子对。每对的酸解离、溶度积、阳离子、活度和初态参数，以及公开操作契约相同。自主研究前提供两次实际起始测定，分别为 6×10^{-7} mol 配 0.080 或 0.075 L；配对的无噪声响应在每个通道相差不超过一个声明的终检标准差。任务提供化学背景与投料、稀释、尺度维度，不公开私有网络身份与参数。初始笔记因而位于给定观测之后，并非无证据前测。

执行候选的资格检查覆盖 230 个物理状态与测定、三十次精确重放及 120 项运行时均值核对。五次有界干扰参数重拟合中，受测直接网络族不能充分拟合网络 B；这不证明相对于所有替代解释均可识别。更早失败的物理候选单独保留。这些检查描述世界实际具有的信息结构，不描述智能体的学习。

每场十二个自主批次后，依次封存科学解释、十二道预测及不反馈真值的反思。源研究期间不展示题目，但智能体可能主动访问对应物理条件。三十场全部完成，合计 360 次源终检、九十个封存阶段及 1,080 条逐题逐响应预测。八十版笔记来自二十场各三版、十场各两版，不能假设每场都有连续中期修订。同一世界的三次新会话共享固定观测随机键，模型采样 seed 不可控。

实际源动作序列在自身及配对世界原样重放，三十次源回放与六十条自身/配对轨迹均通过。区分量为无噪声均值的绝对差除以终检标准差：归一化 pH 为 0.002，两项比例各 0.006。360 次终检中，326 次在至少一个通道达到三倍标准差，158 次在至少两个通道达到该值；三十场均包含后一类测定。阈值表示物理信息，不表示统计显著性、判别意图或反绎成功。反事实回放固定动作，不估计智能体面对另一种观测后会如何适应。

预测误差以每题五个保留参考观测的均值计算，区间覆盖检查全部五个观测；同世界会话共享这些参考。先在世界内平均会话，再对十世界等权。名义 80% 预测区间不是均值的置信区间，较高经验覆盖率必须与宽度一起理解，不能单独证明校准良好。该块没有无研究组，化学规律也不同于研究机会比较。

结合实际动作，精读全部八十版笔记与九十个封存阶段；六十七条选定焦点历史保留 365 条经核对引文。另对 105 场既有研究的 309 版笔记进行回溯阅读，追踪 112 条选定历史和 218 个笔记锚点，四个选定封存后续增加十三个锚点。105 场由保留九十场与十五场研究机会会话组成，不是新增实验。历史可在同一会话内相互交叠，并包含终点修订；它们是按解释相关性选择的描述单位，不是独立发现或总体反绎频率。初始预期、候选解释、经验关系、实际检验和后续使用分别记录，分析者不补入原文没有的因果或条件表述。

源操作共 1,901 次尝试：1,893 次提交、六次回滚、两次验证拒绝；另外 131 次恢复的工具故障单独计数。第一轮启动包含四场启动失败、二十六场未启动，没有科学操作；修复线程配置后，整块三十场重新执行。旧失败与资源记录完整保留，不因科学结果优劣替换已完成结果。

仅使用源观测的预测参照

对每份有效修正版结晶预测，只利用该研究者成功的源最终测量构建两个透明参照。第一个平均全部可用测量；第二个只平均与查询具有相同已提交溶剂标识集合的测量，无匹配时回退到整体均值。溶剂集合包括成功加溶剂与再悬浮操作，排除拒绝请求。拟合函数不接收测试真值。这些是描述性计算，不是另行训练的智能体或完整机理基线。

有效会话 42 场，共 504 题。同溶剂回退发生在 186/504 题，其中 Opaque 1/180、Aligned 95/168、MisIndexed 90/156。该匹配不控制热史、用量或最终液相组成，参照没有预测区间。回收、纯度、粒度和细粉均按各自公开尺度报告，不合成一个跨响应分数。

修正版分布分析使用同一组 42 场有效会话及其 504 次源最终测定。各响应公开源观测、逐题参考均值、预测、有符号误差和会话汇总。描述性合并均值与分位数保留重复的目标题目，不是独立条件估计。有符号误差为预测减参考值；世界等权均值先平均每会话十二题，再平均世界内会话，最后平均五世界。三场缺失预测仍保留在 45 的计划分母。计算仅使用修正版队列，不沿用历史结晶的纯度水平或偏差方向。

保留的平衡研究机会比较

固定设计为五个平衡世界、Research/NoResearch 两条件、每格三场 Sol-medium 新会话，共三十场，全部采用 Opaque 信息。共同公开背景包含任务及测量定义、材料目录、合法操作/仪器和初态，实例档案先验为空。Opaque 表示没有额外实例规律，不表示缺少公开化学背景或模型预训练知识。完整初始公开输入随稿提供；十五个世界内同重复配对在仅排除非科学会话标识后，确认科学输入一致。Research 额外得到十二批自主实验和既有笔记机会，NoResearch 没有源操作或观测；两组评估提示、模式、顺序与限制一致。

三十场全部终态，研究组完成 180/180 批，两组合计完成 117/120 个后测阶段、29 份有效预测。第三世界第三次 Research 在科学解释后出现预测流断连，Q 与随后两阶段缺失，没有替换。因此 Research 有十四份有效预测、NoResearch 十五份，Research 的第三世界为两次，其余每格三次。十五条源轨迹及二十五条参考轨迹（300 批）精确重放通过。29/30 场资源账本完整，另一场仅有已记录的部分用量；记录到的输入加输出共 13,428,656 tokens。缺失用量不按零处理，金额不可得。

首次执行尝试因评估传输配置缺少必要字段而失败。已启动四场、其中两场已完成的二十四批源研究和资源消耗单独保留，没有完成科学解释阶段。修复执行缺陷后，按原设计从头重跑整个三十场块。这属于协议修复，不是根据科学结果替换。仅完整重启后的实验块进入比较。

该比较估计共同评估条件下整段研究机会的作用，不能单独识别自主选择相对给定数据、反馈本身、笔记或内部表征变化。比较在新会话之间进行，没有会话内前测。世界与条件顺序采用事先固定的平衡启动安排，不是对世界规律进行随机抽样。

定量汇总与缺失

平衡宏平均绝对误差在指定问题中等权平均归一化 pH、解离分数和沉淀信号。极稀组为重复块执行前固定的三题，其余九题不被假定全部处于分布内。先在世界内平均有效会话，再对五世界等权。逐场数值和缺失阶段均保留。响应、问题、参考观测和批次嵌套相关，不能充当独立研究者样本。

名义 80% 区间同时报告覆盖率、平均宽度和适当区间分数 [22]。下界 l、上界 u、观测 y、alpha = 0.2 时，分数为 (u-l)，若 y 低于 l 加上 (2/alpha)(l-y)，若高于 u 加上 (2/alpha)(y-u)，越低越好。汇总按世界等权；智能体区间不是组均值的置信区间。

事后敏感性分析允许唯一缺失的研究机会预测取 [0,1] 内任意宏平均误差，并按每格计划三次和五世界等权重算。有研究减无研究的保守范围，总体为 [-0.098659, -0.031992]，极稀为 [+0.036768, +0.103434]。这是缺失结果影响的界限，不是填补、置信区间或总体推断。固定条件下三次会话描述波动，不建立总体可靠率。

匹配淬灭干预

独立保留的对照将原第一期十八份结晶推荐置于五个世界中，比较有无单个淬灭操作，共九十对、一百八十条轨迹。其他动作参数和初态匹配；淬灭从原位置删除，或插入首次播种/结晶冷却之前。没有智能体适应，也不向智能体反馈结果。

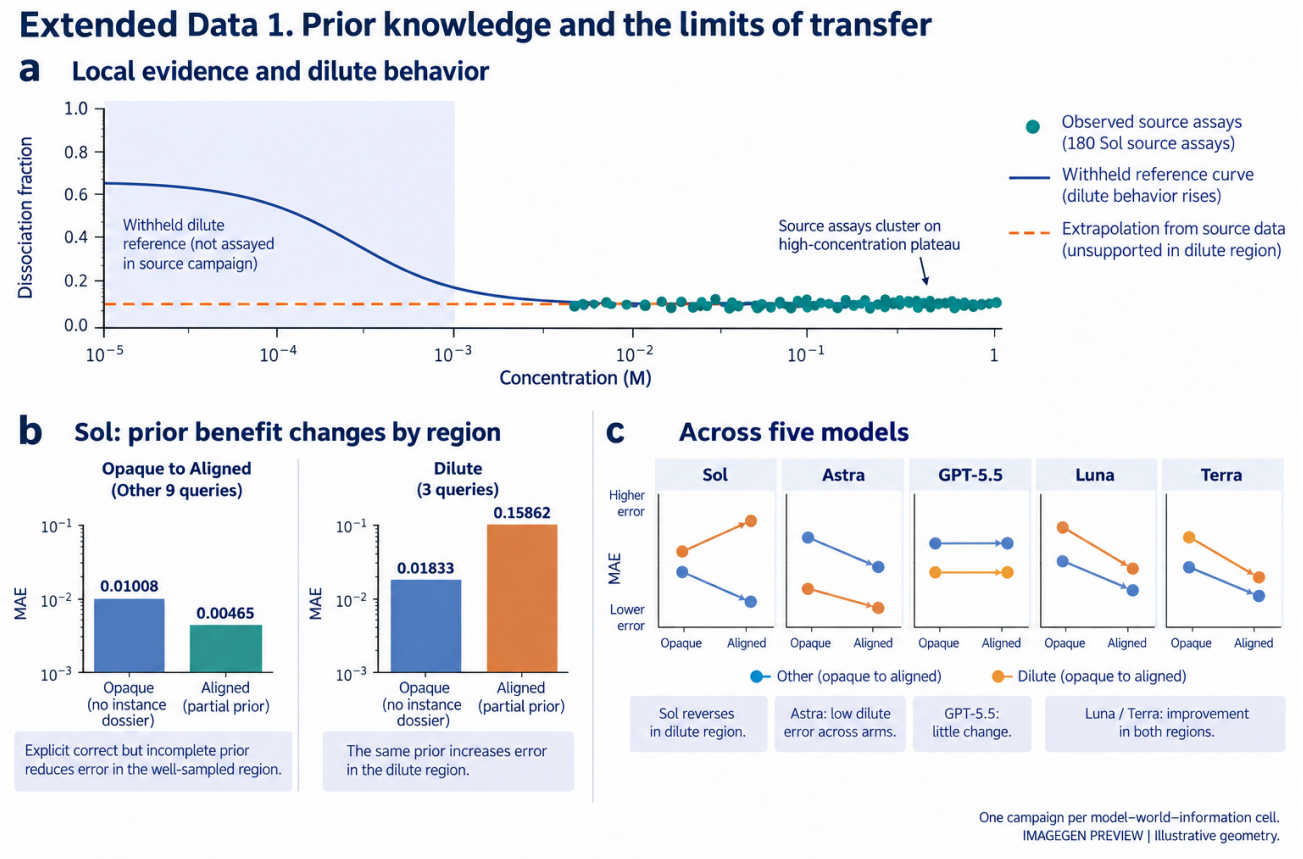
全部轨迹保留并重放，七十五对具有两侧最终测量。五对无淬灭侧缺颗粒，十对有淬灭侧使后续固定冷却请求失效，失败不修复。完整对中，有减无的平均细粉变化为 +0.30937、回收变化为 +0.00741，联合成功从 34 降至 4。这些条件性效果描述实际初始投料回收口径下的物理操作。淬灭改变多个物理状态量，不单独识别冷却速率或科学判断的成因。供体配方来自历史队列，不来自修正版。

数据与代码可用性

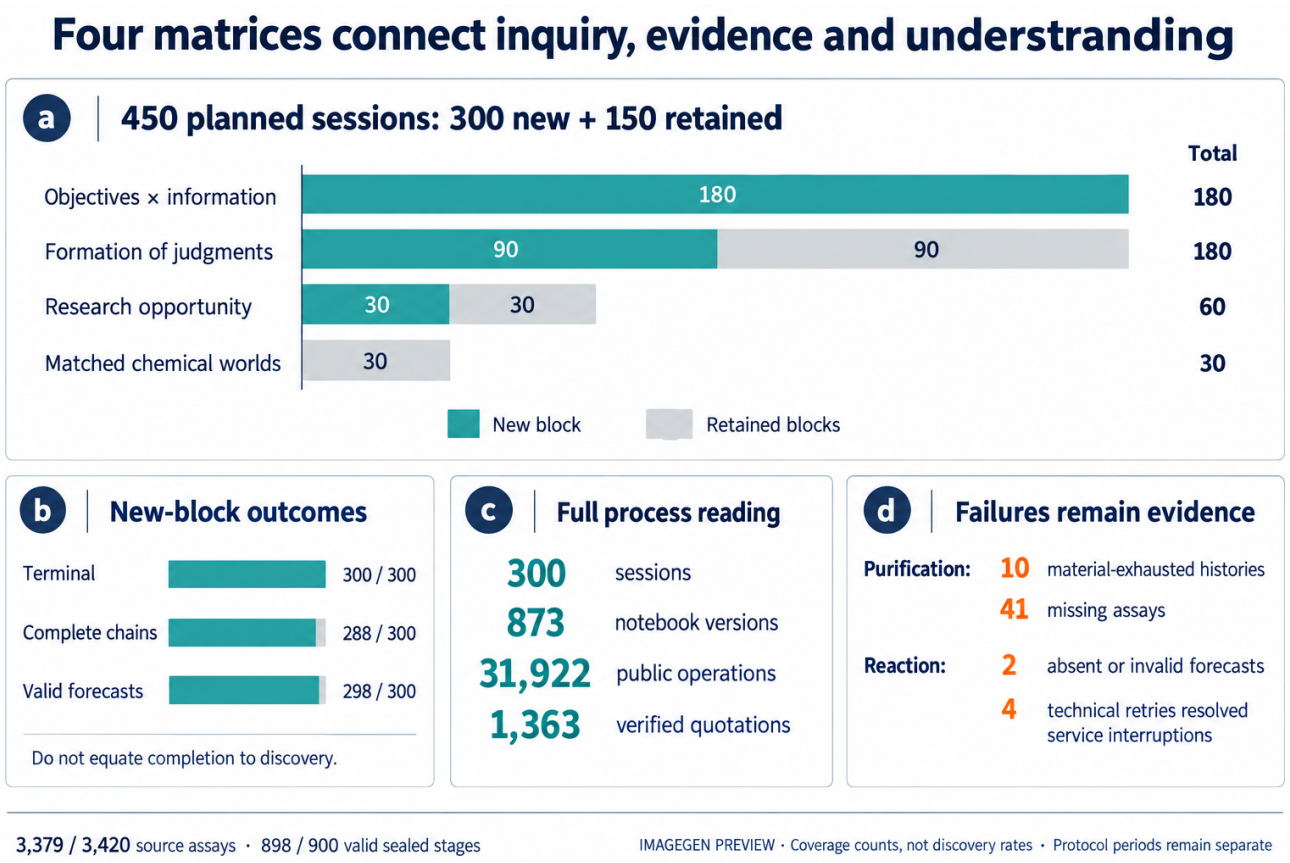
随稿证据包包含新增 300 场机器摘要、全部 1,380 个计划会话—响应行、推荐结果、失败、完整整理的公开经历、语义精读与引文锚点，以及五体系覆盖表和四矩阵设计。保留平衡机会数据、旧 90 场过程队列 178 对相邻笔记、修正版结晶分布与 30 场匹配世界经历分别可查。缺失明确保留；公开科学内容纳入，原始提供方封包和凭据不纳入。原回放与资源记录保留在项目证据位置，永久公开存档仍待落实。

六张主图和六张扩展图全部为 ImageGen 预览。数字标注依据保留证据，但点位、曲线和分布形状仅作示意，不是精确观测或统计不确定性。新定量表是新矩阵的数值依据；旧原生图仅对应其历史队列。投稿前须将预览替换为数据绘图。补充材料区分每个实验块，并完整保留 34 张历史数值表。编译读取保留数据，不改变实验及证据地位。

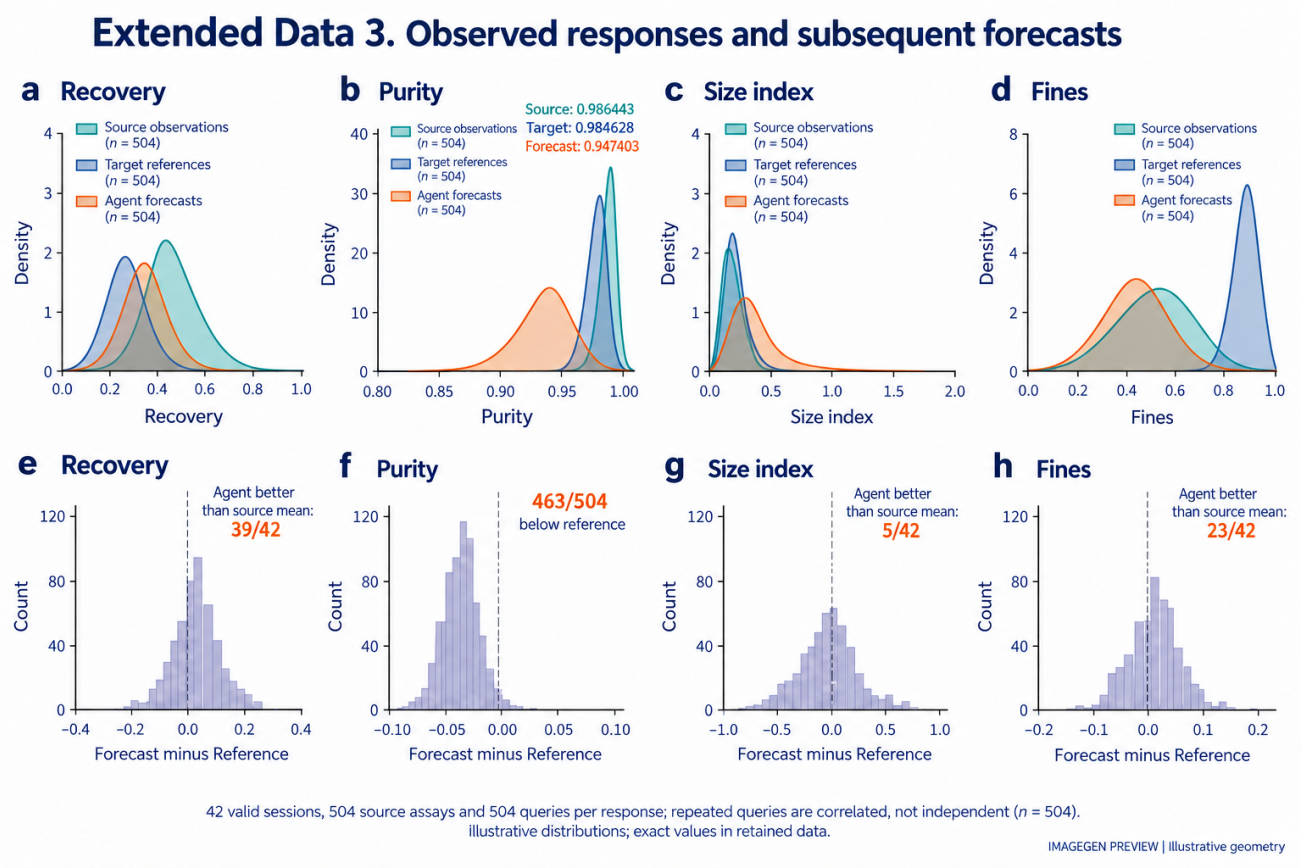
扩展数据



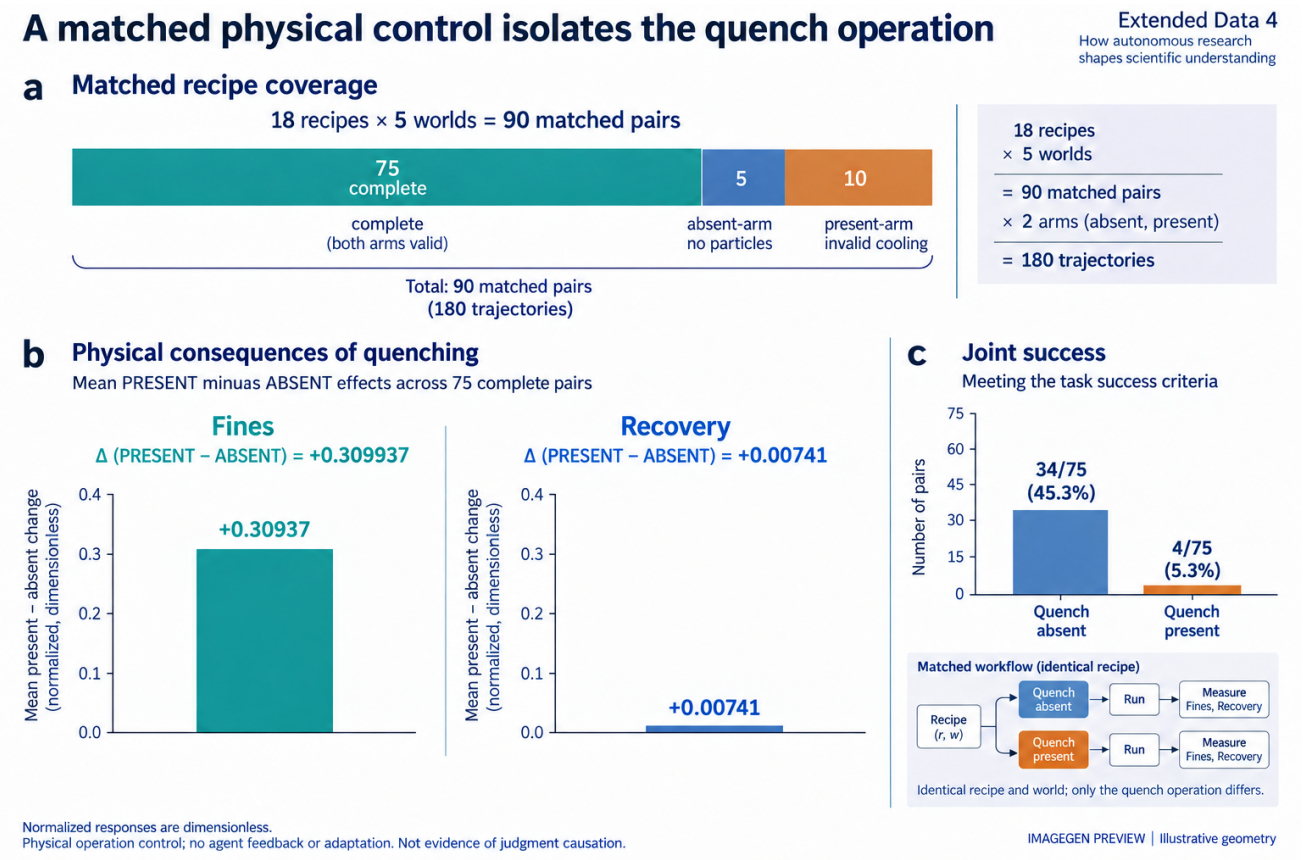
扩展数据图 1 | 局部先验与迁移范围。a，局部平台、极稀参照行为与未经支持的延续示意。b，历史 Sol/Opaque 与 Aligned 在两组条件的误差。c，五模型的定性模式，不是数值效应估计。历史各条件仅一场；极稀分组在该队列中为事后划分，在后续重复块前固定。本图不合并重复队列估计。ImageGen 预览：几何仅作示意，精确数值见保留证据。



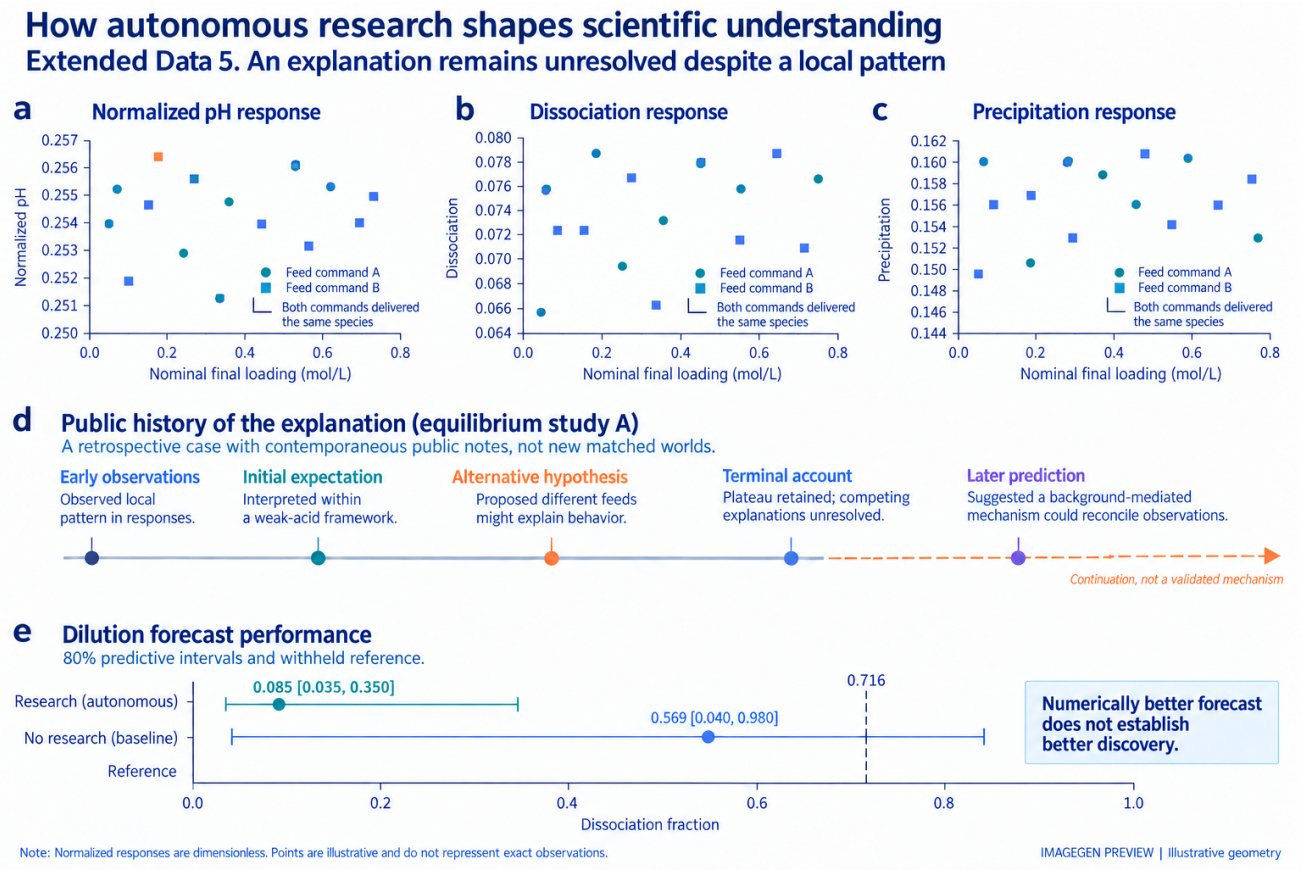
扩展数据图 2 | 整合设计与新实验覆盖。a，四矩阵共 450 场计划研究，新增 300 场、另 150 场按独立协议保留。b，新块保留 288 条完整链与 298 份有效预测；完成不等于科学成功。c，完整精读覆盖 873 版笔记和 31,922 条公开操作，核对 1,363 处引文。d，十场纯化因材料耗尽缺少 41 次终检，两场反应预测缺失或无效。四场服务中断经技术补跑解决，不替换科学结果。ImageGen 预览：几何仅作示意。



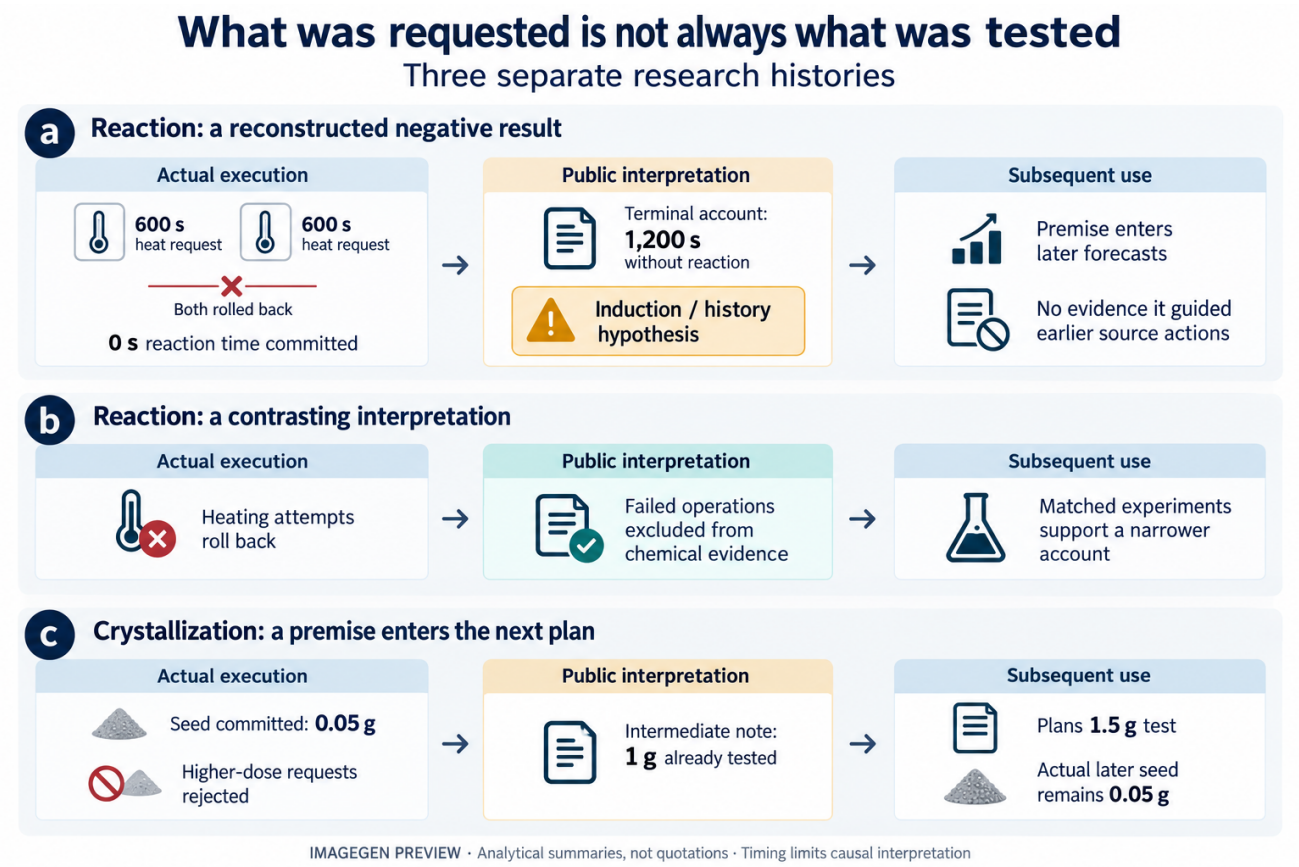
扩展数据图 3 | 修正版结晶响应分布。a–d，源观测、目标参照与智能体预测的分布示意。e–h，有符号误差分布示意，其几何与分箱计数不是实测值。保留队列含 42 份有效预测，每响应有 504 源测定和 504 题；共享目标不是独立研究者样本。数字标注来自保留汇总；粒径为无量纲指数。三份缺失预测仍计入 45 场计划分母。ImageGen 预览：几何仅作示意，精确数值见保留证据。



扩展数据图 4 | 淬灭操作的匹配物理效应。a，十八个历史配方在五世界形成九十对，七十五对完整，五个无淬灭组无颗粒，十个有淬灭组使后续冷却无效。b，完整配对中有淬灭减无淬灭的平均变化。c，同一 75 对中的联合任务成功。结果采用已实现的初始投料回收口径；智能体未适应或接收这些结果，不据此推断判断形成效应。ImageGen 预览：几何仅作示意，精确数值见保留证据。



扩展数据图 5 | 局部模式与未解决的解释。a–c，平衡研究 A 的源响应模式示意；试剂命令与组分命令在该执行版本中加入同一物种。d，公开历史从初始预期连接终点未决与后续使用；文字为分析概括，不是额外引文。e，保留的极稀解离预测、原始 80% 预测区间与封存均值。数值准确性不建立发现机制。ImageGen 预览：几何仅作示意，精确数值见保留证据。



扩展数据图 6 | 重建实验实际检验了什么。a，一场反应的两次回滚加热在终末说明中成为 1,200 s 阴性结果，后来预测引用诱导期或历史解释。b，另一场将回滚加热排除在化学解释之外。c，一版结晶中途笔记在实际仅提交 0.05 g 时声称已检验 1 g，再提出更高剂量。时点区分后来预测用途与后续源行动受到影响。不同选定经历，并非随机纠错组或统一机制估计。ImageGen 预览：文字为分析概括，几何仅作示意。