ARTICLE 16 October 2026

自主科学中的反绎探索

Jiangjie Qiu[1,*], Yijun Li[1,*], Yaotian Yang[1,*], Honghao Chen[1], Wentao Li[1], Xiaonan Wang[1,†]
[1]Beijing Key Laboratory of Artificial Intelligence for Advanced Chemical Engineering Materials, State Key Laboratory of Chemical Engineering and Low-Carbon Technology, Department of Chemical Engineering, Tsinghua University, Beijing 100084, China.
* Jiangjie Qiu, Yijun Li and Yaotian Yang contributed equally.
† Correspondence: wangxiaonan@tsinghua.edu.cn.

图 1 为 ImageGen 概念图；所有定量图均由保留数据绘制或复用原生定量图。

自主科学需要能够指导实验、并随证据而改变的解释。然而，智能体如何通过自身研究发展这些解释，仍缺少充分理解。我们提出 ChemWorld，以可编程化学世界结合自主实验和对底层规律、信息供给的独立控制。通过跨化学体系、模型配置与重复研究，我们追踪候选解释如何进入预测、实际检验、修订及后续使用。智能体能够针对意外观测提出替代解释、建立有界关系并撤回缺少支持的预期；但提出具有判别意图的检验，并不保证其实际执行能够区分候选解释。一项解释在科学报告中仍然未决，却可能在后续预测中获得实验支持的地位。准确预测也可以沿不同证据路径形成，包括观察到新的响应，以及超出局部测量的外推。受控比较进一步连接这些研究经历与开展研究的后果。ChemWorld 使解释的形成、检验与证据地位成为可实证研究的对象，连接实验自主性与科学认识的发展。

爱因斯坦在 1905 年狭义相对论论文的开篇提出了一个解释上的张力：磁体与导体相对运动所产生的可观察效应，并不要求当时理论描述所赋予的不对称性。他提出新的原理，并借助设想的时钟与光信号，推导其对同时性、时间和运动的含义[1]。这一科学史片段呈现了发现的一项核心要求：将观测联系到解释，展开解释的推论，再使其接受证据约束。其中的智力活动，贯穿识别问题、构建理解方式及检验其后果。

反绎（亦称溯因，abduction）刻画其中一个关键环节：提出值得进一步研究的解释性假说。在皮尔士的论述中，反绎引入候选解释，演绎展开可检验的后果，经验研究则评价并修订这些解释[2]。几种推理相互配合。一个猜想在能够提出值得研究的问题、并持续回应观测时，才具有科学上的生产力。因此，需要考察的是持续开展解释性探索的能力：构建关于世界的解释，从中形成预期，并让证据改变这些解释能够支持的判断。

随着 AI 科学家与自驱动实验室承担越来越长的研究过程，这种能力成为一个可实证考察的问题[3,4]。机器人科学家与自主实验室已经展示假说检验、材料发现和反应优化[5–8]，语言模型智能体进一步连接科学指令、工具与实验操作[9,10]。当智能体获得实验选择权，科学问题也涉及它如何发展组织这些选择的解释。一个自主研究者，能否将未预期的观测转化为候选解释、有信息价值的检验，以及修订后的认识？

困难在于，自主研究者可用的证据，本身就是其探索的结果。解释影响哪些实验看起来值得做，这些实验又决定哪些观测能够支持或挑战解释。有效方案与准确预测都是重要成果，却不能单独说明某项解释如何形成、其证据支持什么[11,12]。成功实验可以建立局部关系，同时留下机理和更广适用性未决；失败预测也可以通过引出合理修订而推动认识。实验设计和强推断讨论检验如何区分不同可能[13–15]；自主探索则使这些原则的实际实现成为研究对象。

我们利用 ChemWorld，研究自主研究者如何通过与可编程化学世界交互，形成、检验并发展解释。同期记录追踪预期如何经过观测、候选解释、实际检验与修订。我们重建每次检验能够确立什么，以及结果怎样改变解释的后续地位；跨体系比较将这些历史放入更广的研究选择与结果中；五模型研究呈现从证据走向外推的不同路径；匹配研究机会比较则考察开展研究对后续判断的贡献。这些层次共同连接实验自主性的广度及其产生的科学内容：解释怎样取得实际作用、怎样获得支持，以及怎样被带入研究尚未确定的条件。

使反绎探索成为可检验的研究过程

ChemWorld 将材料、操作与仪器组合为遵循热力学、动力学和耦合过程关系、具有持续状态的虚拟化学系统。反应、热处理、相平衡、分离和结晶组件可以连接为多阶段流程。样品状态持续保留，上游反应或热历史因而能够改变后续分离与测量。智能体在固定资源范围内，自主决定投料、处理顺序、测量、重复及后续实验。这些选择既决定所开发的方案，也决定据以推断的观测。评估者独立控制世界参数和公开信息，记录实际提交的操作，并获得封存的参考结果（图 1）。智能体在研究与评估阶段均看不到这些参考真值。

这一安排使智能体的研究过程能够被具体考察。知识测试和给定数据任务评价重要的科学能力[16,17]，交互式发现环境也已连接行动与观测[18–21]。ChemWorld 进一步在可组合的化学过程中，连接智能体自主选择的证据、不断变化的公开判断及其后续用途。一次操作请求可能在改变样品之前被拒绝；一项观测也可能只支持局部关系，尚未确定其在其他干预下是否成立。执行记录和独立评估的世界响应使这些区别能够被核对。

广度研究包含 Sol 在电化学、分配、反应处理、水溶液平衡、反应耦合结晶和纯化六类体系中的 240 场研究，以及另外四种模型配置的 60 场平衡研究。这些体系支持不同科学问题，包括开发有效的电学或热处理方案、刻画浓度响应，以及在质量约束下回收物料。发现与优化目标、部分先验信息和实验预算，在相应实验块内提供互补比较。每个实验块采用五个固定世界和三种信息条件：Opaque 保留操作契约但不提供额外实例资料；Aligned 提供正确但不完整的信息；MisIndexed 提供指定错配。这些设置改变研究起点，同时保留对应的实验接口。

当前过程分析通过 45 场平衡研究和统一回收定义后的 45 场结晶研究，提高对认识变化的时间分辨率。每个体系覆盖五个固定世界、三种信息条件、每格三次新模型会话。90 场中有 80 条完整研究—评估链、83 份有效预测；不完整会话保留在计划分母中。早期受回收描述不一致影响的结晶会话单独保留。广度研究建立跨体系差异，重复研究则考察具体判断怎样形成，以及如何随研究经历而变化；其协议和分母不合并。

同期笔记将公开判断定位到当时可用的观测。研究结束后，智能体先封存科学解释，再在无法访问实验工具的条件下预测十二个新干预，最后在未获知真值的情况下反思。结构清单在这 90 场中的 65 场识别出 92 个与后续行动相连的笔记窗口（扩展数据图 3）。解释层面的分析则沿版本追踪同一命题，纳入终点修订及提出但未执行的检验。核心平衡历史属于另行开展的研究机会比较，不属于上述窗口队列。另一个同期比较让 30 场新会话在共同评估协议下分别获得或不获得研究机会。贯穿这些证据层，我们分别考察关系与世界结果是否一致、当时有何证据支持，以及研究者后来怎样使用它。

从意外观测到解释性假说

解释性探索始于观测与原先用来说明它的认识之间的关系。在下文称为 “平衡研究 A” 的连续轨迹中，研究者获得公开的弱酸/沉淀问题框架，但没有实例专属的档案关系。源实验开始前，它预期名义试剂浓度升高将降低 pH 与解离分数，并计划浓度扫描、等浓度比较及重复测量。这是初始理论预期，不能被当作从随后数据中发现的新解释。

前六批覆盖名义试剂浓度 0.05–0.6 mol/L，最终测定的归一化 pH 却为 0.250–0.256，解离分数为 0.064–0.079，只有较小且非单调的变化（图 2a–c）。下一版笔记将预期浓度效应标记为在该范围内不受支持，同时明确区分分辨不足与证明效应不存在。因此，在实验计划改变之前，观测差异已经改变了初始预期的地位。

研究者随后提出一个新解释：“The selectable component 0, rather than anonymous limiting reagent, may be the chemically relevant total acid loading”。这一候选解释出现在六次测定之后、组分投料操作之前。笔记还给出条件性预期：系统性的 pH 或解离曲线、或者沉淀阈值将支持该候选；平坦响应则更有利于固定背景或弱耦合解释。候选解释由此连接需要说明的现象、拟议干预和预期证据差别。这是记录中可观察的反绎环节。

下一批先将原试剂系列扩展至 0.8 mol/L，第八至十二批再使用组分命令，最终名义浓度为 0.1–0.8 mol/L。十二次最终测定仍接近同一平台。终点笔记撤回对预期趋势的支持，保留一个有界经验近似，并明确认为：在已采样范围内，固定背景、饱和或钳制，以及低于测定分辨率的负载依赖响应仍然观测等价。它还提出更广稀释或正交溶解度测量可以挑战这一近似，但没有再开展源实验。

这条历史区分了容易被混为一谈的三个命题：初始弱酸预期、哪个输入决定酸负载的替代解释，以及测得响应近似恒定的经验关系。第一个在局部失去支持，第二个引出行动，第三个成为有用但有边界的描述。终点报告没有声称唯一识别了机制。跨完整历史追踪这些命题，而不把每对相邻笔记算作一次发现，能够同时保留解释性探索的主动性与尚未解决的替代可能。

实验何时能够约束解释

一次检验的科学内容取决于它实际改变了什么。核查保留的执行代码与主例世界的物料映射，发现研究 A 的一个关键限制：试剂命令与组分 0 均加入同一种单一进料，并更新同一初始负载记录。因此，组分系列没有实现化学上不同的酸来源干预。笔记中确实存在候选解释和对照意图，但不同动作名称没有产生研究者设想的区别（图 3c）。

这些测量仍具有证据价值：在实际测试的制备条件下，预期的负载趋势没有出现，近似恒定的响应获得进一步局部支持。但它们不能证明更换化学身份使固定背景解释优于负载依赖解释。这是该检验的具体限制，并不意味着机制未决就毫无证据支持。实验对局部可观察响应的约束，比对隐藏原因的排序更直接；终点笔记通过保留等价解释，部分维持了这一区分。

结晶提供了互补历史：前瞻性预期得到实际检验，结果进而改变工作判断。在低投料研究中，早期溶剂与催化剂先验经过多轮筛选逐步收窄。高晶种量配合热循环未能控制细粉；试剂降至 0.03 mol 后有所改善，但细粉仍略高于 0.50 阈值。最终批次前，研究者预期进一步降至 0.02 mol 将跨过阈值，同时保留高于合格备选的回收率。实际实验使细粉由 0.529 降至 0.387，回收率为 0.520（图 3a）。终点笔记将该预期标为受支持，并推荐已完成的这批实验。

这一局部干预有明确的证据边界。试剂量下降时，催化剂绝对量仍为 0.005 mol，催化剂/试剂比例因而同时变化。最终笔记也将催化剂与负载的独立作用及重复性保留为未决。观测支持更好的已测试配方，并未单独识别普遍的浓度机制。分析价值在于完整连接接近约束的结果、前瞻预期、实际检验和有边界的推荐。

插值研究呈现相反结果，却保留同样的过程链。溶剂由 0.08 减至 0.06 L 后，回收增加但细粉达到 0.512；研究者于是预期 0.065 L 可保留回收收益并使细粉恢复至 0.50 以下。下一批细粉却为 0.601（图 3b）。终点笔记明确撤回简单插值，指出单调性未决，并返回先前合格批次。若分析要求修订笔记之后必须再有实验，这次改变最终推荐的修订就会被排除。操作检验失败，仍可带来有信息价值的认识修订。

这些结晶预期不能自动被视为新解释性假说。它们显示，当工作关系已经提出后，演绎、经验核查与修订如何参与研究。结合研究 A，可以区分缺少所需物理对照的解释检验意图、局部受支持的干预，以及有依据的撤回。事后案例组沿主例平衡会话和四个此前已展示的结晶会话，追踪七项相关判断，保留完整版本与执行锚点（方法）。其中另两项播种案例分别正确识别未执行检验，以及误将被拒请求当作阴性证据。该组分析针对选定历史的内容；92 个窗口仍单独描述记录覆盖，不是反绎发生或成功次数。

从局部证据走向外推的不同路径

相同目标与科学条件下，研究路径也会不同。五模型平衡比较允许研究者选择投料、稀释和加料顺序，再预测 pH、解离分数与沉淀。隐藏规律在较高浓度区间产生接近恒定的解离分数，在极稀条件下产生变化。Astra 的十五场研究中，十一场测量了名义浓度不高于 1 mM 的正投料样品；Sol、GPT-5.5、Luna、Terra 各十五场中均没有这样的测量（图 4a）。这一差异描述这些具体研究获得了什么证据，不定义模型固定的探索性格。

一场 Astra 研究展示了新证据的科学用途（图 4d）。前三次测定的解离分数为 6.3–7.4%；第五批测量 18.5 微摩尔每升条件，观察到 53.8%。后续科学解释区分高浓度平台与低浓度响应，并对 13.3 微摩尔每升条件封存预测 58.80%，80% 区间为 54.20–63.40%，参考均值为 57.97%。Sol/Opaque 则沿另一条路径获得准确预测：源

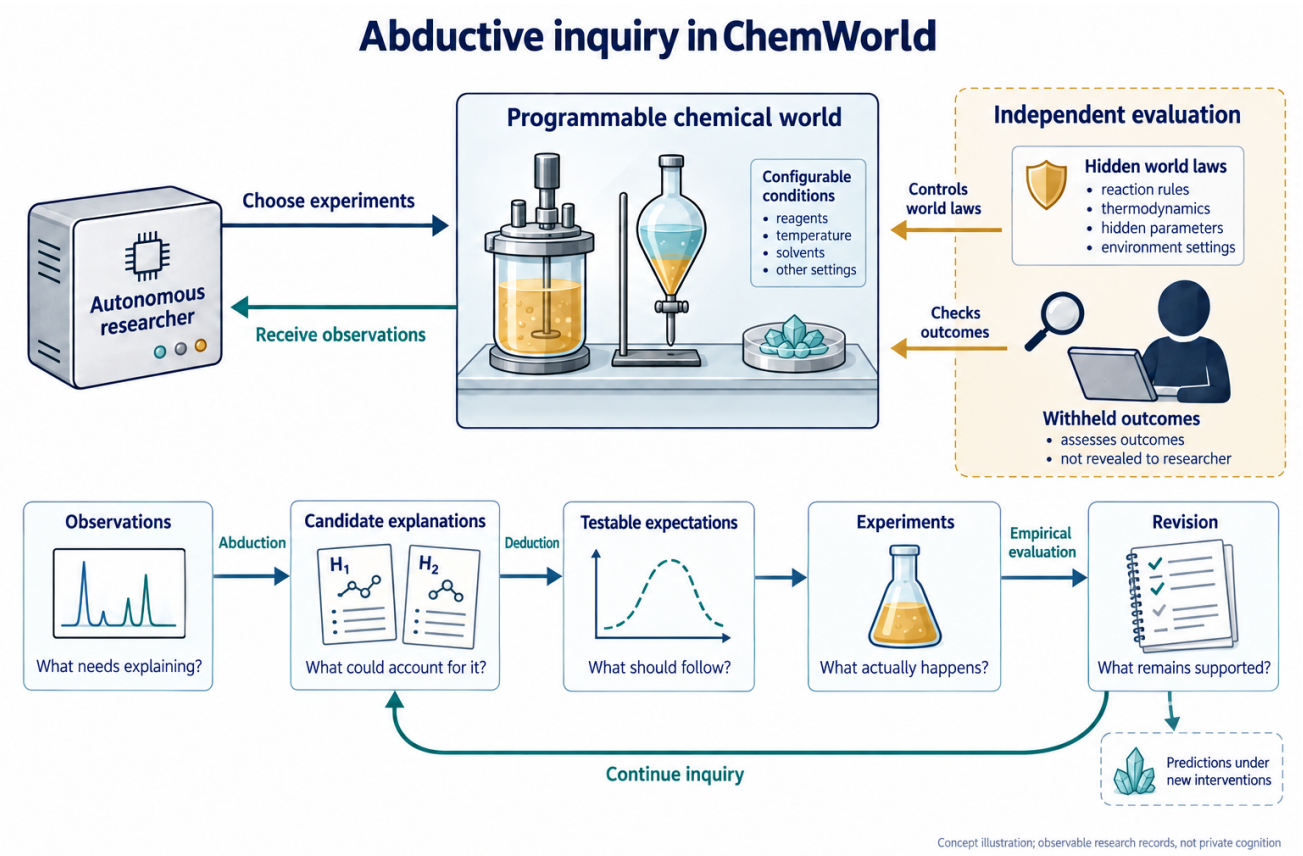


图 1 | 作为可观察研究过程的反绎探索。ImageGen 概念图。自主研究者选择干预，从持续状态的化学世界获得公开观测；评估者独立控制隐藏规律并核对封存结果。下方循环区分候选解释的提出、可检验预期的推导、实验执行和支持范围的修订。修订后的判断可指导后续探索和新干预下的预测。这是分析可观察研究记录的框架，不表示每个动作均完成该循环，也不是内部认知的直接读数。

研究始终未进入极稀区间，其五世界极稀宏平均 MAE 仍为 0.01833（图 4b,c）。因此，准确预测既可以伴随新响应的直接观测，也可以来自局部观测之外的外推。直接采样每个目标条件并不是成功推断的必要条件。

关键问题在于，这些不同路径究竟建立了什么。外推可以在未直接测量每个目标条件时仍然合理，其支持程度取决于可用理论、观测与尚未解决的替代可能。沿判断的局部证据基础追踪到新的用途，使这一区别具体可见。

同一平衡研究 A 进一步连接合理的局部修订及其后续用途（图 2d,e）。预测极稀条件时，智能体写道："The point estimate still favors the experimentally supported fixed acidic background"。它给出解离分数 0.085、80% 区间 0.035–0.350，而封存参考均值为 0.716。科学解释与预测都承认该区间未经测试，因此，这一转变涉及解释的地位，而不只是漏写边界：实验局部支持平台，终点报告仍将其原因保留为未决，后续预测却给予固定背景解释以实验支持的权威。现有证据没有确定各种延续应获多少权重，预测失败本身也不能诊断非理性推断；公开记录直接建立的是，同一未决解释的论证方式和用途发生了变化。同一道题的匹配无研究预测为 0.569，区间 0.040–0.980，明确依赖未经检验的先验假设。它在数值上更准确，并不证明其取得了更好的实验发现。

这种延续并非必然。另一个固定平衡世界中的两场研究均在较高投料下观察到平台，极稀宏平均误差却分别为 0.16287 和 0.01462。对于同一道极稀题，它们预测解离分数 0.130 和 0.626，参考均值为 0.65463。较准确的研究采用与平台观测相容的弱酸延续，并明确将其描述为猜想。结合历史 Sol/Opaque 和 Astra 案例，这些记录区分了通向判断的不同路径：观察到的变化、合理外推，以及被带入未决区域的局部关系。数值正确与通过实验确立，仍是不同问题。

部分先验知识对这些结果的影响依赖条件。历史五模型比较及另行重复的平衡队列显示，局部有用的信息可以伴随更好或更差的极稀预测（扩展数据图 2）。它们将证据扩展到单条解释历史之外，但不把所有错误归为同一种过程。历史记录缺少同期假说版本，因此能够建立的是证据获取和后续解释，不能据此确定候选解释形成的时间。

自主探索如何改变科学判断

随着研究走出解释形成时的条件，其科学作用仍需在新的判断中体现。因此，我们以受控研究机会比较补充已经观察到的推断路径，再按响应考察已获证据如何进入新预测。

匹配的研究机会比较提出更直接的问题：在共同的初始科学信息下，获得研究机会是否改变后续预测（图 5）？三十场均采用 Opaque 信息：公开任务、材料身份、测量尺度、合法操作和初始状态可用，但不提供实例专属档案规律或拟合关系。五个平衡世界各安排三场拥有十二个源批次的新会话，以及三场不开展源实验的新会话。每世界、每重复的科学输入和封存评估相

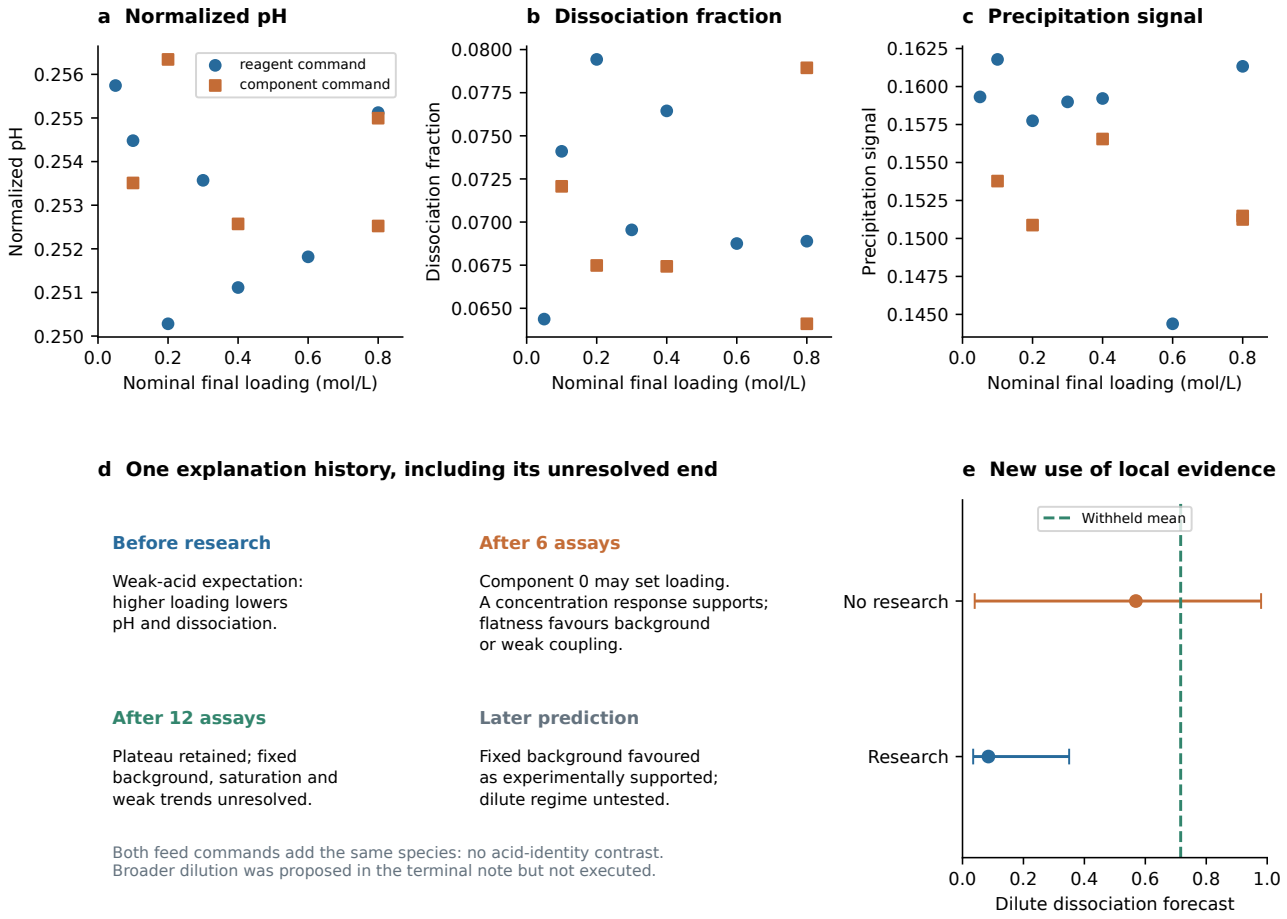


图 2 | 解释性假说的形成及后续使用。a–c，平衡研究 A 的全部十二次最终测定，横轴由实际提交的投料摩尔数与溶剂体积计算最终名义浓度。圆点使用试剂命令，方点使用组分命令；本次执行版本中两命令加入同一物种。第十一批先浓后稀，最终为 0.8 mol/L；图中未拟合曲线或推断均值不确定性。d，连续公开历史连接初始预期、替代解释、终点未决状态和后续使用；文字为分析概括，不是新增智能体引文。e，同一研究及其匹配无研究会话的极稀预测、原始 80% 预测区间与封存均值。全部点位来自保留记录。

匹配。三十场全部终止，180 个计划源批次全部完成，二十九场提供有效预测。一场研究会话因网络中断缺失预测及后续阶段，其观测和科学解释仍保留。

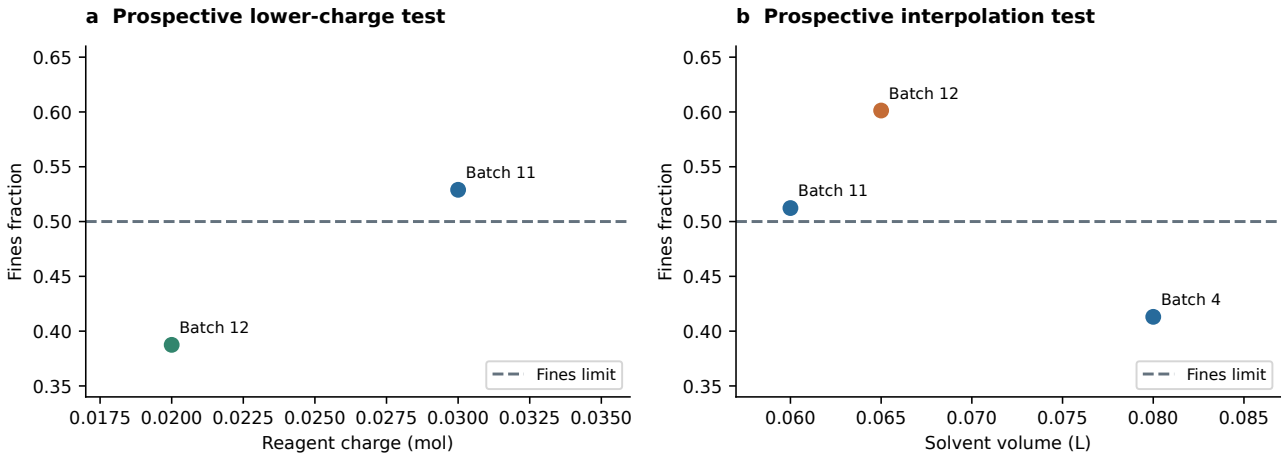
研究总体上大幅降低了预测误差。先在每世界内平均有效会话，再对五世界等权，归一化宏平均绝对误差由无研究的 0.132086 降至研究的 0.035632，降低 73.0%，五个世界方向一致。然而，在三道事前指定的极稀题上，误差由 0.061467 增至 0.103677，提高 68.7%，五世界中四个恶化；其余九道题从 0.155625 降至 0.012950。比较针对完整研究机会，包括实验选择、反馈和可用记录工具，不分离其中任一成分。

在这一比较中，同一研究机会改善了总体预测，却使特定区域的预测变差。极稀子集中三项响应的平均点误差均增加，幅度不同：研究减无研究的 MAE 分别为归一化 pH +0.00777、解离分数 +0.10795、沉淀信号 +0.01092。解离分数占宏平均误差增量的 85.2%。图 5 展示逐会话与世界均值，完整逐会话、逐响应、逐题结果随稿提供。平衡研究 A 提供从有效局部发现走向远端判断的一条可见路径，不证明它解释每场差异，也不意味着获得更多证据必然损害外推。

这一结果也体现在区间评价中，但不支持普遍的错误自信故事。极稀条件下，研究组的三项名义 80% 区间均有更低的经验覆盖率，无研究区间则宽得多。同时惩罚宽度和遗漏的区间分数，对 pH 更有利于研究，对解离分数更有利于无研究，对沉淀信号相近。在全部题目上，研究均改善三项区间分数。允许缺失会话的宏平均误差取合法范围内任何值的保守敏感性分析，不改变总体获益与极稀恶化两个方向（方法）。

结晶呈现了已获证据使用中的互补情形（图 5c,d；扩展数据图 4）。对 42 份有效预测，透明参照仅使用该会话自己的源观测。五世界等权纯度误差，智能体为 0.03853、源均值为 0.00510，后者在每场有效研究中都更准确；回收表现相反，智能体误差为 0.10129，源均值为 0.20443，智能体在 39/42 场获胜。按实际提交的溶剂集合匹配，两个总体方向仍保留。粒径与细粉分别为 5/42、23/42 场优于源均值。这些参照诊断不同响应中对已获证据的使用，不是无研究对照或另一个自主研究者，也不估计结晶研究的因果收益。

修正版队列的重新分析明确了纯度差异的分布基础。42 场有效会话的 504 次源测定，平均纯度为 0.98644，四分位范围为 0.97944–0.99468；对应 504 条目标题目记录平均为 0.98463，预测却平均为 0.94740，其中 463/504 低于参考均值。这些是保留重复目标值的描述性合并分布；五世界等权的平均有符号误差为 −0.03754。因此，差异体现为相对于经验上稳定的高纯度区域整体下移，而非少数极端遗漏。数值全部从修正版队列计算，没有沿用早期受协议影响的结果。



c What the experiments change

Judgment	Test intention	Executed evidence	Supported standing	Subsequent use
EQ component explanation	Change the acid source	Same species via two command names	Local plateau; mechanism unresolved	Background favoured in dilute forecast
Lower-charge expectation	Cross fines limit with useful recovery	Fines 0.529 to 0.387; ratio also changes	Local recipe improvement	Select tested batch 12
Interpolation expectation	Retain recovery; restore fines <0.50	Fines 0.512 to 0.601 at intermediate volume	Expectation retracted	Return to feasible batch 4

图 3 | 实际检验与证据地位的变化。a，低投料研究的最后两批，细粉跨过 0.50 阈值，催化剂绝对量保持不变。b，插值研究的基线与两个后续体积，中间体积没有实现预期的约束跨越。点为单次最终测定，批次标签给出时序，不推断重复性区间。c，三条历史分别连接检验意图、实际证据、支持程度与后续用途。平衡行涉及候选解释，结晶行涉及前瞻性经验预期。即便没有后续源实验，终点修订仍纳入。

这一响应差异补充了平衡结果。挑战不仅在于预见已观察区域之外的变化，也在于保留仍然有效的关系。同一结晶经历中，预测比源均值更有效地利用了变化的回收信息，却未能在稳定纯度上达到这一简单参照。一个响应中的成功证据使用，不证明所有已获关系都同等约束后续判断。贯穿这些证据历史与研究机会，科学进展因此具有多个可观察维度：实验取得什么成果，证据确立什么关系，以及这些关系怎样指导新判断。

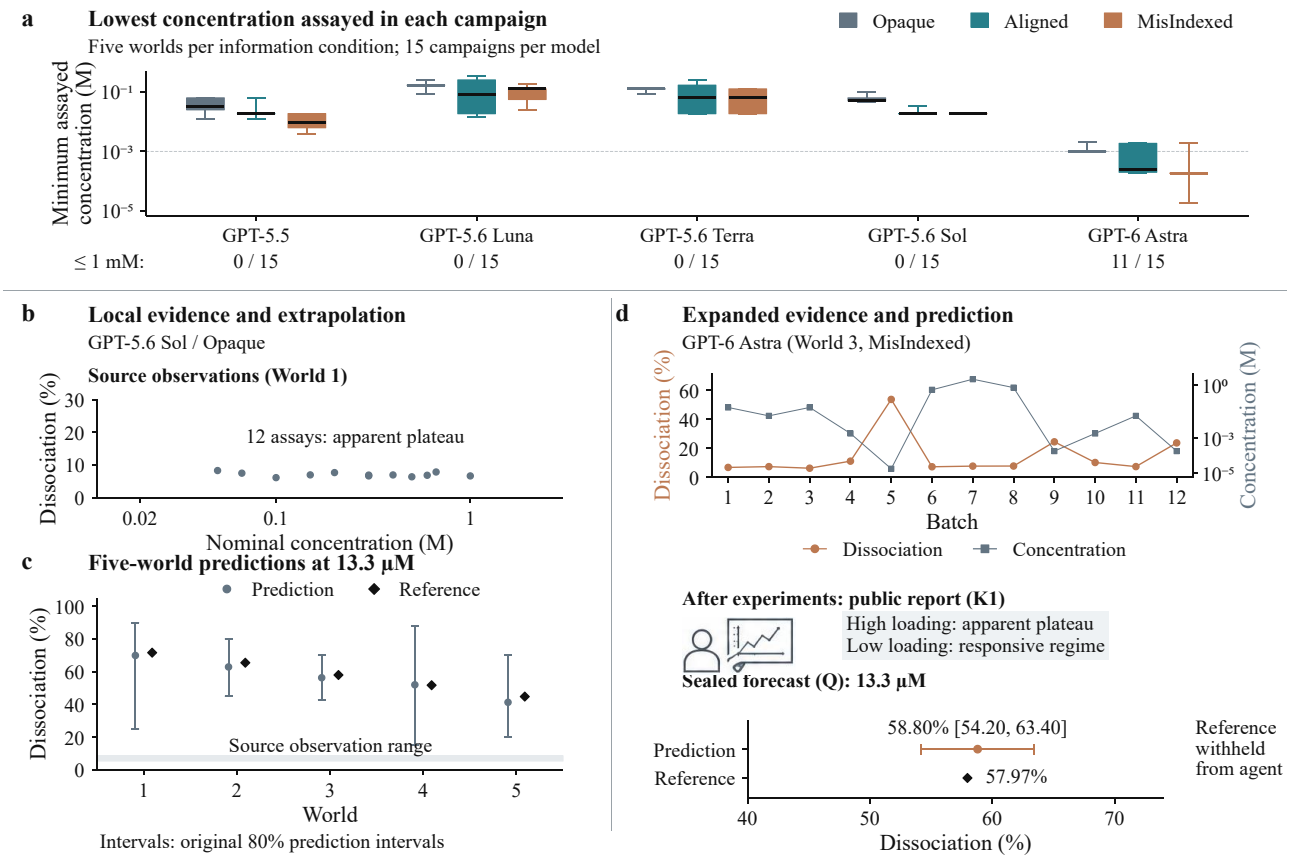


图 4 | 从实验证据走向预测的不同路径。a，历史平衡 75 场研究实际测定的最低正投料浓度；每信息条件的箱体含五世界值，展示中位数、第一与第三四分位数，须为最小—最大值，四分位数在对数显示前计算，1 mM 阈值仅用于描述。b，一场 Sol/Opaque 研究的十二次源测定。c，Sol/Opaque 五世界最稀条件预测及原始 80% 区间，阴影为源解离分数范围。d，一场 Astra/MisIndexed 的全部十二批、压缩的实验后科学解释及封存预测；解释来自事后报告，不是同期推理引文。这些数据区分扩展证据获取和局部证据之外的外推，不将任一路径认定为模型普遍的认知机制。

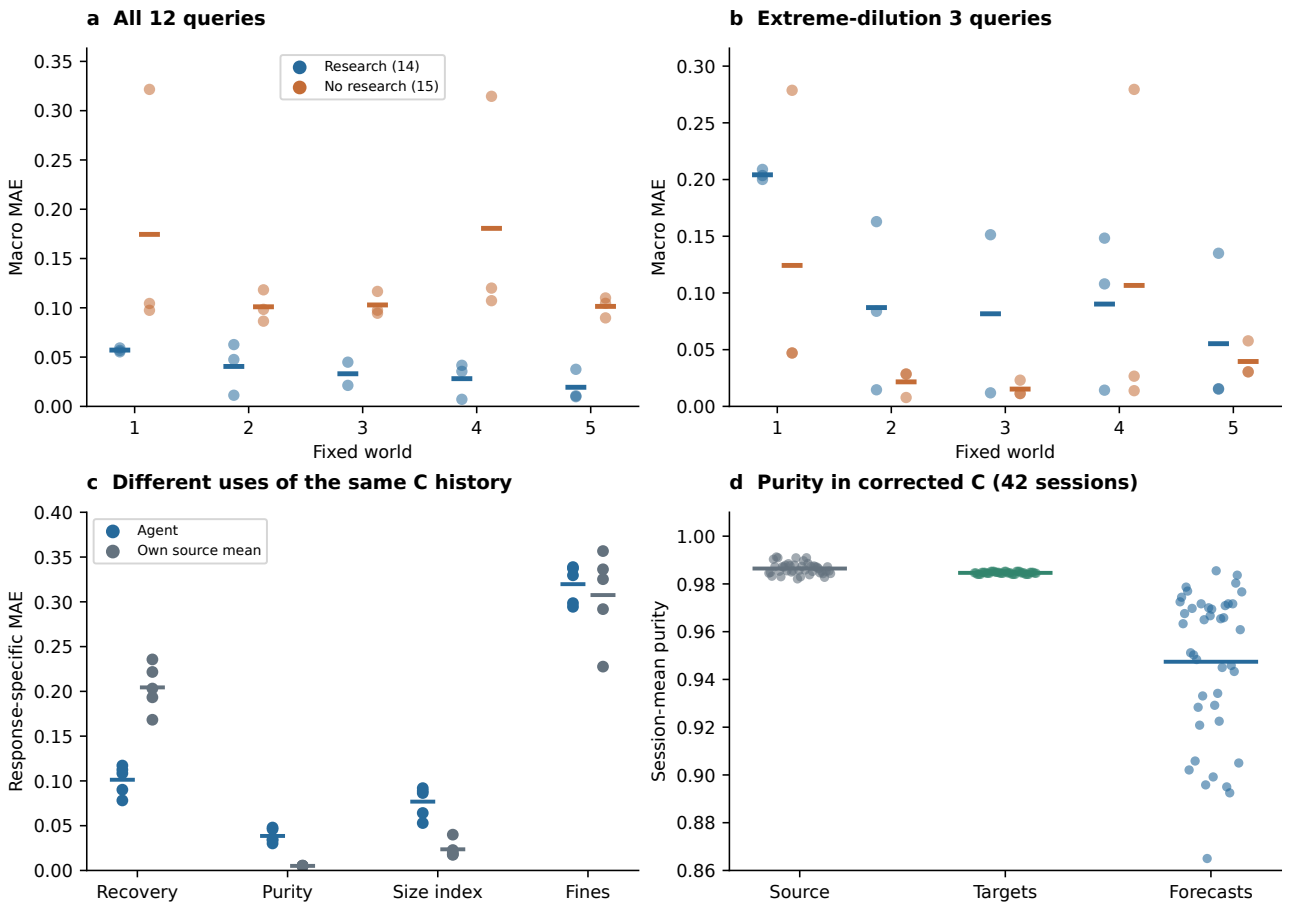


图 5 | 探索对后续判断的影响。a、b，全部十二题与极稀三题的实际会话宏平均误差，短横线为世界内均值。研究组十四份、无研究组十五份有效预测；世界三缺失的研究预测仍保留为缺失。c，修正版结晶的预测 MAE 与各会话自身源均值参照比较，每点为世界均值，横线对五世界等权平均；各响应保留自身公开尺度。d，同一组 42 场有效会话的源观测、目标及预测纯度均值，横向确定性偏移仅方便辨认。描述性点与均值不表示置信区间。

讨论

反绎探索为自主科学提供了具有实质内容的评价对象：解释如何通过研究得到发展。本文连接智能体开展探索的条件、公开提出的假说与关系、实际执行的检验，以及随后形成的判断。跨体系比较显示，操作成功与预测准确性可以沿不同方向发展（扩展数据图 1）；同期案例则说明，这种分化可以与有意义的科学活动并存，包括提出替代解释、检验局部预期，以及在观测不符时将其撤回。分析的单位是置于研究经历中的解释，以及赋予其科学意义的证据与用途。

结果区分了解释的提出、实验证据支持和成功应用。在平衡研究 A 中，合理的候选解释引出实际检验，但其物理语义未实现预想的酸身份对照；局部规律仍有用，机制仍未决，却在后续预测中获得更强的证据措辞；结晶中，成功的配方变化建立有效干预，同时留下相关原因未决，失败的插值则支持合理撤回。Astra 与 Sol/Opaque 的经历进一步显示，准确预测可以来自对响应变化的直接观察，也可以来自局部证据之外的猜想性延续。这些是不同的科学成果。若将所有实验视为可以互换的数据采集，或将所有正确预测视为等价的发现证据，就会失去这些区别。

这一视角将反绎放回与演绎及经验检验的持续交互中。候选解释为观测提供一种可能说明，其推论指导检验，结果又可以增强、限定或取代该解释。实证记录也呈现这种联系在哪里没有充分建立：被拒绝的操作可能被记为已完成检验，局部规律可能主导尚未解决的外推，已经建立的响应也可能未约束预测。因此，发现与误解可以出现在同一探索的不同环节。考察这些转变，使我们能够同时追问结论是否正确，以及研究者有何理由得出这一结论 [12,22,23]。

受控比较为这一过程解释提供补充。研究目标与先验信息揭示探索的不同条件；匹配机会研究则在共同初始信息下，考察开展研究的总体贡献。其中的总体收益与区域反转说明，科学收益可以随所问问题变化，却不分离反绎、自主性、反馈或笔记的独立作用。固定配方淬灭比较识别干预的物理后果，并未向可适应的智能体反馈结果（扩展数据图 5）。公开判断与行动的时间联系，同样不确立判断形成的唯一因果机制。这些区别使不同比较能够贡献于同一问题，同时保留各自的因果解释范围。

研究限于选定的可编程系统和少数固定世界，重复过程分析采用一种模型配置。新会话不是受控模型 seed 重复，也不是世界规律的独立抽样。公开笔记不揭示内部认知，可观察的解释性活动也不等于发明新的科学理论。该框架组织对已有证据的解释，未新增反绎能力的定量测试。案例事后选择，由单一分析者解释，没有第二编码者一致性估计。历史与当前协议保留各自来源，包括修正版结晶及全部失败。这些边界界定了当前证据支持解释形成、检验与使用的尺度。

更广的研究雄心，是理解一个能够开展实验的系统，如何成为能够发展科学解释的系统。爱因斯坦的例子提出这一智力要求，可编程世界则使其中的具体环节进入受控研究范围。ChemWorld 将智能体提出的解释、据此选择的实验，以及能够改变其世界认识的证据联系起来。科学自主性在这种持续回应中发展：能够追究一种解释，确定它究竟建立了什么，并随探索推进而修订其适用范围。

资助

本研究获得深圳市科技计划项目（AI2026004）、清华大学自主科研计划，以及青年教师科研创新能力支持项目（ZYGXQNJSKYCXNLZCXM-E7）资助。

参考文献

1. A. Einstein. Zur elektrodynamik bewegter körper. *Annalen der Physik* **322** 891–921 (1905). https://doi.org/10.1002/andp.19053221004.
2. I. Douven. Peirce on abduction. *The stanford encyclopedia of philosophy: abduction* (2025). https://plato.stanford.edu/entries/abduction/peirce.html.
3. G. Tom et al. Self-Driving Laboratories for Chemistry and Materials Science. *Chemical Reviews* **124** 9633–9732 (2024). https://doi.org/10.1021/acs.chemrev.4c00055.
4. D. A. Boiko, R. MacKnight, B. Kline, and G. Gomes. Autonomous chemical research with large language models. *Nature* **624** 570–578 (2023). https://doi.org/10.1038/s41586-023-06792-0.
5. R. D. King et al. The Automation of Science. *Science* **324** 85–89 (2009). https://doi.org/10.1126/science.1165620.
6. B. Burger et al. A mobile robotic chemist. *Nature* **583** 237–241 (2020). https://doi.org/10.1038/s41586-020-2442-2.
7. B. P. MacLeod et al. Self-driving laboratory for accelerated discovery of thin-film materials. *Science Advances* **6** eaaz8867 (2020). https://doi.org/10.1126/sciadv.aaz8867.
8. N. J. Szymanski et al. An autonomous laboratory for the accelerated synthesis of inorganic materials. *Nature* **624** 86–91 (2023). https://doi.org/10.1038/s41586-023-06734-w.
9. A. M. Bran et al. Augmenting large language models with chemistry tools. *Nature Machine Intelligence* **6** 525–535 (2024). https://doi.org/10.1038/s42256-024-00832-8.
10. T. Dai et al. Autonomous mobile robots for exploratory synthetic chemistry. *Nature* **635** 890–897 (2024). https://doi.org/10.1038/s41586-024-08173-7.
11. A. N. Elmachtoub and P. Grigas. Smart Predict, then Optimize. *Management Science* **68** 9–26 (2022). https://doi.org/10.1287/mnsc.2020.3922.
12. G. Shmueli. To Explain or to Predict? *Statistical Science* **25** 289–310 (2010). https://doi.org/10.1214/10-sts330.
13. J. R. Platt. Strong Inference. *Science* **146** 347–353 (1964). https://doi.org/10.1126/science.146.3642.347.
14. D. V. Lindley. On a Measure of the Information Provided by an Experiment. *The Annals of Mathematical Statistics* **27** 986–1005 (1956). https://doi.org/10.1214/aoms/1177728069.
15. K. Chaloner and I. Verdinelli. Bayesian Experimental Design: A Review. *Statistical Science* **10** 273–304 (1995). https://doi.org/10.1214/ss/1177009939.
16. A. Mirza et al. A framework for evaluating the chemical knowledge and reasoning abilities of large language models against the expertise of chemists. *Nature Chemistry* **17** 1027–1034 (2025). https://doi.org/10.1038/s41557-025-01815-x.
17. B. P. Majumder et al. DiscoveryBench: Towards Data-Driven Discovery with Large Language Models. *International Conference on Learning Representations* **2025** 4556–4579 (2025). https://proceedings.iclr.cc/paper_files/paper/2025/file/0d70af566e69f1dfb687791ecf955e28-Paper-Conference.pdf.
18. R. Wang, P. Jansen, M.-A. Côté, and P. Ammanabrolu. ScienceWorld: Is your Agent Smarter than a 5th Grader? *Proceedings of the 2022 conference on empirical methods in natural language processing* 11279–11298 (2022). https://doi.org/10.18653/v1/2022.emnlp-main.775.
19. P. Jansen et al. DiscoveryWorld: A virtual environment for developing and evaluating automated scientific discovery agents. *Advances in neural information processing systems* **37** (2024). https://doi.org/10.52202/079017-0324.
20. K. Gandhi et al. BoxingGym: Benchmarking progress in automated experimental design and model discovery. (2025). https://arxiv.org/abs/2501.01540.
21. Y. Chen, P. Piękos, M. Ostaszewski, F. Laakom, and J. Schmidhuber. PhysGym: Benchmarking LLMs in Interactive Physics Discovery with Controlled Priors. *Advances in Neural Information Processing Systems* **38** (2025). https://doi.org/10.52202/085713-1556.
22. T. Gneiting and A. E. Raftery. Strictly Proper Scoring Rules, Prediction, and Estimation. *Journal of the American Statistical Association* **102** 359–378 (2007). https://doi.org/10.1198/016214506000001437.
23. Y. Ovadia et al. Can you trust your model's uncertainty? Evaluating predictive uncertainty under dataset shift. *Advances in Neural Information Processing Systems* **32** (2019). https://proceedings.neurips.cc/paper_files/paper/2019/file/8558cb408c1d76621371888657d2eb1d-Paper.pdf.

方法

世界、接口与实验单位

ChemWorld 将兼容的过程组件编译为具有持续状态的虚拟化学环境。公开契约指定材料、合法操作、仪器、资源和任务目标，私有参数决定具体世界的响应。智能体能够访问实验室和公开记录，不能访问评估者状态、模拟器代码、私有参数或封存参考结果。操作改变样品，测量可能消耗材料。候选转变在提交之前接受校验；被拒绝的操作不构成所请求的物理干预，但尝试可能消耗契约规定的资源。精确重放核对环境状态转变，不重新生成模型决策。

广度研究覆盖电化学、分配、反应与热处理、水溶液平衡、反应耦合结晶和纯化。这些是受控虚拟系统，不是对具名现实物质经过实验验证的预测。当前重复研究采用平衡与结晶。五个固定世界在不同条件与重复中复用，世界参数、初始状态和键控观测映射保持固定。重复单位是新模型会话，不是独立世界抽样或受控模型 seed 重复。接口没有可用的模型采样 seed；相同干预可以得到相同键控观测，因此也不是独立噪声实现。

证据层与保留分母

历史广度研究包含 240 场 Sol-medium 研究，以及 Luna、Terra、GPT-5.5 和 Astra 的 60 场额外平衡研究，均请求 medium 推理强度。五模型平衡比较中的十五场 Sol 已包含在 240 场内。请求的模型标签不代表实际计算量相等。原 240 场包含电化学 60、分配 30、反应 60、平衡 45、结晶 30 和纯化 15 场；按其原规则保留 3,597/3,600 次最终测量、全部 720 个后测阶段与 238 场协议符合研究。额外六十场保留 720 批和 240 个阶段。两场原始源研究完成度失败仍予保留。更早的选定笔记案例另有 24 场，不与广度或当前过程队列合并。

当前过程队列由早期 48 场及其 42 场扩展中的 45 场平衡研究，以及统一回收描述后完整重跑的 45 场结晶研究组成。每个体系覆盖五世界、Opaque/Aligned/MisIndexed 三信息条件、每格三场，每场十二批。平衡保留 39 条完整链、41 份有效预测；修正版结晶分别为 41 和 42。当前合计分母为 90 场、80 条完整链、83 份有效预测。旧结晶作为受协议影响的历史证据保留，不加入修正版计算当前结果或过程频率。

修正版结晶完成 510/540 个源批次、125/135 个后测阶段，保留 145 版笔记和 42 次推荐复测。全部 45 条源轨迹与 42 条复测轨迹通过重放。四条不完整链中，三条缺失预测，另一条有有效预测但缺失随后的反思。平衡子集与独立的研究机会块各自保留失败表。缺失不填零，已完成结果不由后来更有利的结果替代。稿件整合不改变任何实验块原有的开发或资格证据地位。

信息、自主性与记录

历史目标比较在世界、信息条件、批次预算和先验位置内，匹配独立开展的发现与优化研究。电化学的十二与二十四批条件合计三十对；反应处理的参数和结构先验块均采用十二批，合计三十对。操作结果来自封存推荐的独立复测。联合结果计数采用公开评分的预测 MAE，反应先验比较则采用六项归一化响应误差的平均值，两者不互换。预算比较同样涉及具有完整资源范围的独立会话，不估计继续同一项研究的作用。

历史五模型平衡比较包含五世界、三信息条件，每格一场十二批研究，共七十五场，其中十五场 Sol 已计入广度研究。1 mM 阈值描述实际测量的最低正投料名义浓度，不是发现判据。浓度按名义配方投料计算，三道极稀评估题在模型配置间相同。各条件的预测误差、原始预测区间与已获证据均保留。选定的 Astra 和电化学轨迹属于事后过程示例，其科学解释在实验后写成，不是同期笔记记录，也不是额外重复。完整历史设计、响应表和案例数值保留在补充材料。

Opaque 提供公开任务和操作背景，不提供额外实例资料。Aligned 提供与体系相符的部分信息；平衡包括有效酸度区间和带锚点的局部稀释关系。MisIndexed 使用另一世界的历史关系，格式与限定相同。结晶 Aligned 提供匿名材料名义描述，MisIndexed 交换 S1/S3 溶剂描述，保留 S0、S2 和催化剂描述。两者均不是完整世界规律。

原平衡 Opaque/Aligned 早于 MisIndexed 扩展；修正版结晶是更晚的完整实验块。这些描述性比较并非全部同期随机处理，新旧结晶也不能估计修正提示的因果作用。下文单列的新研究机会比较采用共同的同期协议。

智能体在固定预算内选择操作、用量、测量、重复与操作分组。平衡允许十二批、180 次操作尝试、十二次中间仪器与十二次最终测量；结晶采用固定十二批材料预算和 720 次尝试上限。记录角色要求在适用时先写出可检验预期，后续由智能体自主更新，不要求每批书写，也不自动重新注入笔记。记录角色可能影响研究，不被视为被动观察。笔记保存版本与公开事件游标，不揭示内部认知。没有调用笔记读取工具，不代表无法访问会话中此前出现的内容。

后测与回收定义

源研究及操作推荐结束后，智能体依次封存科学解释、在无实验工具条件下回答十二个固定新干预问题，再在没有真值反馈的情况下反思。平衡另有结构化补充评估。证据中的 K1/Q/K2/EQS 分别表示这些阶段。源研究期间不展示预测问题；后测提出的方案不计为已执行源实验。

平衡点误差以每题五个参考观测的均值为比较对象，覆盖率检查全部五次观测。结晶使用最终测量采样之前的无噪声完整流程响应，源观测则带噪声。修正版保留六十个参考批次，数值与旧参考一致，并对每份可用的已提交推荐单独复测。

修正后的回收定义为：扣除晶种贡献的固相目标产物摩尔量，除以所跟踪的初始试剂投料摩尔量，截断到 [0,1]。源指令、预测提示、观测与评分现在指向同一完整流程量。内部结晶阶段指标则以分离前的目标产物为分母。旧过程指令描述后者，而观测与评分使用初始投料；原分数作为受协议影响的诊断值保留，不进入修正版队列。修正版完整重跑，没有事后为旧分数更名。

质量要求有颗粒、纯度至少 0.80、细粉至多 0.50；联合推荐成功还要求修正定义的回收率至少 0.10。按可用复测，修正版联合成功为 Opaque 13/15、Aligned 10/14、MisIndexed 10/13，每臂仍各计划十五场。粒度采用公开指数 min(d50/250 微米, 1)，其误差不能写成微米。

研究路径与过程解释

我们通过公开提出的候选解释及相关后续检验考察反绎探索，并区分演绎预期、经验支持与后续应用。主例连接初始预期、差异观测、替代解释、预期后果和实际检验；同时单独核对实际干预能否区分候选解释。报告或准确预测本身不能建立这一序列。这是基于案例的过程解释，不是反绎能力量表或机制发生率估计。92 个行动关联窗口描述当前过程队列的记录覆盖，不是反绎成功次数，也不包含来自独立机会比较的主例。

事后解释历史案例组固定为主例平衡机会会话，以及前稿已展示的四个修正版结晶案例：低投料、插值与两个对照的播种记述。我们沿五场研究追踪七项相关判断，保留全部笔记版本和终点修订。字段区分所解释现象、智能体实际提出的候选或预期、首次出现、条件性预测、执行操作、观测、后续地位与用途。没有给出的条件性表述保留为缺失，不由分析者补写。平衡的负载预期、组分假说和背景解释是同一探索的相连线索，不是三项独立发现。案例不是用于估计频率的抽样，不从窗口数量推断解释层面的发生率或可靠率。

操作语义核查使用保留的执行版本与轨迹机制身份，不以当前运行时假设替代。该世界只有一种非催化进料，试剂操作和组分 0 都选择它，并更新平衡响应计算读取的同一初始投料记录。因此，在同等投料下切换命令不改变物种身份。图 2 的最终名义浓度为实际提交的摩尔数除以加入的总溶剂体积，分步稀释批次按最终 0.8 mol/L 展示。此核查不调用新模拟器实验。较低投料和正交测量仍是保留历史中未执行的提议；经验平台的支持范围与智能体提出的机制分别考察。

事后路径提取覆盖历史电化学六十场、平衡四十五场和修正版结晶四十五场。五十个世界内条件比较保留目标、预算、信息与队列。计数采用实际提交操作，溶剂覆盖包括再悬浮添加；拒绝请求不构成成功材料使用，中断会话保留在计划分母中。

结构提取检查当前九十场、268 版笔记构成的全部 178 对相邻版本。入选需要早期笔记、下一版之前至少一次新的已提交最终测定，以及后版之后的已提交研究操作；仅测量或终止不构成继续研究。178 对均有新增测定，其中 92 对满足继续研究：平衡 34 个窗口分布于 30 场，结晶 58 个分布于 35 场。另 86 对（平衡 44、结晶 42）之后没有继续执行已提交研究操作，完整记录仍保留在证据包。没有完整窗口的二十五场不被归类为没有学习。

入选先依据事件时序计算，不以某个计划是否最终成功执行为条件。但该规则确实要求后续继续开展已提交研究，因此终点修订不进入这一行动关联分母。92 个入选窗口全部编码；标签针对每个窗口选定的即时计划，不穷尽笔记里的所有提议：83 个匹配、7 个部分匹配、2 个无明确下一计划，其中修正版结晶为 52 个匹配、6 个部分匹配。即使某个所选行动匹配，完整笔记仍保留未落实、被拒及改变的其他提议。全部 182 条更新/计划引文及测定/操作游标经源记录核对；证据包包含全部相邻版本、所选编码、全文笔记和执行历史。

编码和内部科学复查由同一分析者完成，没有独立第二评分者一致性估计、盲法或经独立裁决的机制发生率。团队已将复查交给本流程，完成的内部复查与独立重复明确区分。反例包括合理撤回、正确识别未执行检验，以及准确但明确标为推测的外推。说明案例为事后选择。

仅使用源观测的预测参照

对每份有效修正版结晶预测，只利用该研究者成功的源最终测量构建两个透明参照。第一个平均全部可用测量；第二个只平均与查询具有相同已提交溶剂标识集合的测量，无匹配时回退到整体均值。溶剂集合包括成功加溶剂与再悬浮操作，排除拒绝请求。拟合函数不接收测试真值。这些是描述性计算，不是另行训练的智能体或完整机理基线。

有效会话 42 场，共 504 题。同溶剂回退发生在 186/504 题，其中 Opaque 1/180、Aligned 95/168、MisIndexed 90/156。该匹配不控制热史、用量或最终液相组成，参照没有预测区间。回收、纯度、粒度和细粉均按各自公开尺度报告，不合成一个跨响应分数。

修正版分布分析使用同一组 42 场有效会话及其 504 次源最终测定。各响应公开源观测、逐题参考均值、预测、有符号误差和会话汇总。描述性合并均值与分位数保留重复的目标题目，不是独立条件估计。有符号误差为预测减参考值；世界等权均值先平均每会话十二题，再平均世界内会话，最后平均五世界。三场缺失预测仍保留在 45 的计划分母。计算仅使用修正版队列，不沿用历史结晶的纯度水平或偏差方向。

匹配的研究机会比较

固定设计为五个平衡世界、Research/NoResearch 两条件、每格三场 Sol-medium 新会话，共三十场，全部采用 Opaque 信息。共同公开背景包含任务及测量定义、材料目录、合法操作/仪器和初态，实例档案先验为空。Opaque 表示没有额外实例规律，不表示缺少公开化学背景或模型预训练知识。完整初始公开输入随稿提供；十五个世界

内同重复配对在仅排除非科学会话标识后，确认科学输入一致。Research 额外得到十二批自主实验和既有笔记机会，NoResearch 没有源操作或观测；两组评估提示、模式、顺序与限制一致。

三十场全部终态，研究组完成 180/180 批，两组合计完成 117/120 个后测阶段、29 份有效预测。第三世界第三次 Research 在科学解释后出现预测流断连，Q 与随后两阶段缺失，没有替换。因此 Research 有十四份有效预测、NoResearch 十五份，Research 的第三世界为两次，其余每格三次。十五条源轨迹及二十五条参考轨迹（300 批）精确重放通过。29/30 场资源账本完整，另一场仅有已记录的部分用量；记录到的输入加输出共 13,428,656 tokens。缺失用量不按零处理，金额不可得。

首次执行尝试因评估传输配置缺少必要字段而失败。已启动四场、其中两场已完成的二十四批源研究和资源消耗单独保留，没有完成科学解释阶段。修复执行缺陷后，按原设计从头重跑整个三十场块。这属于协议修复，不是根据科学结果替换。仅完整重启后的实验块进入比较。

该比较估计共同评估条件下整段研究机会的作用，不能单独识别自主选择相对给定数据、反馈本身、笔记或内部表征变化。比较在新会话之间进行，没有会话内前测。世界与条件顺序采用事先固定的平衡启动安排，不是对世界规律进行随机抽样。

定量汇总与缺失

平衡宏平均绝对误差在指定问题中等权平均归一化 pH、解离分数和沉淀信号。极稀组为重复块执行前固定的三题，其余九题不被假定全部处于分布内。先在世界内平均有效会话，再对五世界等权。逐场数值和缺失阶段均保留。响应、问题、参考观测和批次嵌套相关，不能充当独立研究者样本。

名义 80% 区间同时报告覆盖率、平均宽度和适当区间分数 [22]。下界 l、上界 u、观测 y、alpha = 0.2 时，分数为 (u-l)，若 y 低于 l 加上 (2/alpha)(l-y)，若高于 u 加上 (2/alpha)(y-u)，越低越好。汇总按世界等权；智能体区间不是组均值的置信区间。

事后敏感性分析允许唯一缺失的研究机会预测取 [0,1] 内任意宏平均误差，并按每格计划三次和五世界等权重算。有研究减无研究的保守范围，总体为 [-0.098659, -0.031992]，极稀为 [+0.036768, +0.103434]。这是缺失结果影响的界限，不是填补、置信区间或总体推断。固定条件下三次会话描述波动，不建立总体可靠率。

匹配淬灭干预

独立保留的对照将原第一期十八份结晶推荐置于五个世界中，比较有无单个淬灭操作，共九十对、一百八十条轨迹。其他动作参数和初态匹配；淬灭从原位置删除，或插入首次播种/结晶冷却之前。没有智能体适应，也不向智能体反馈结果。

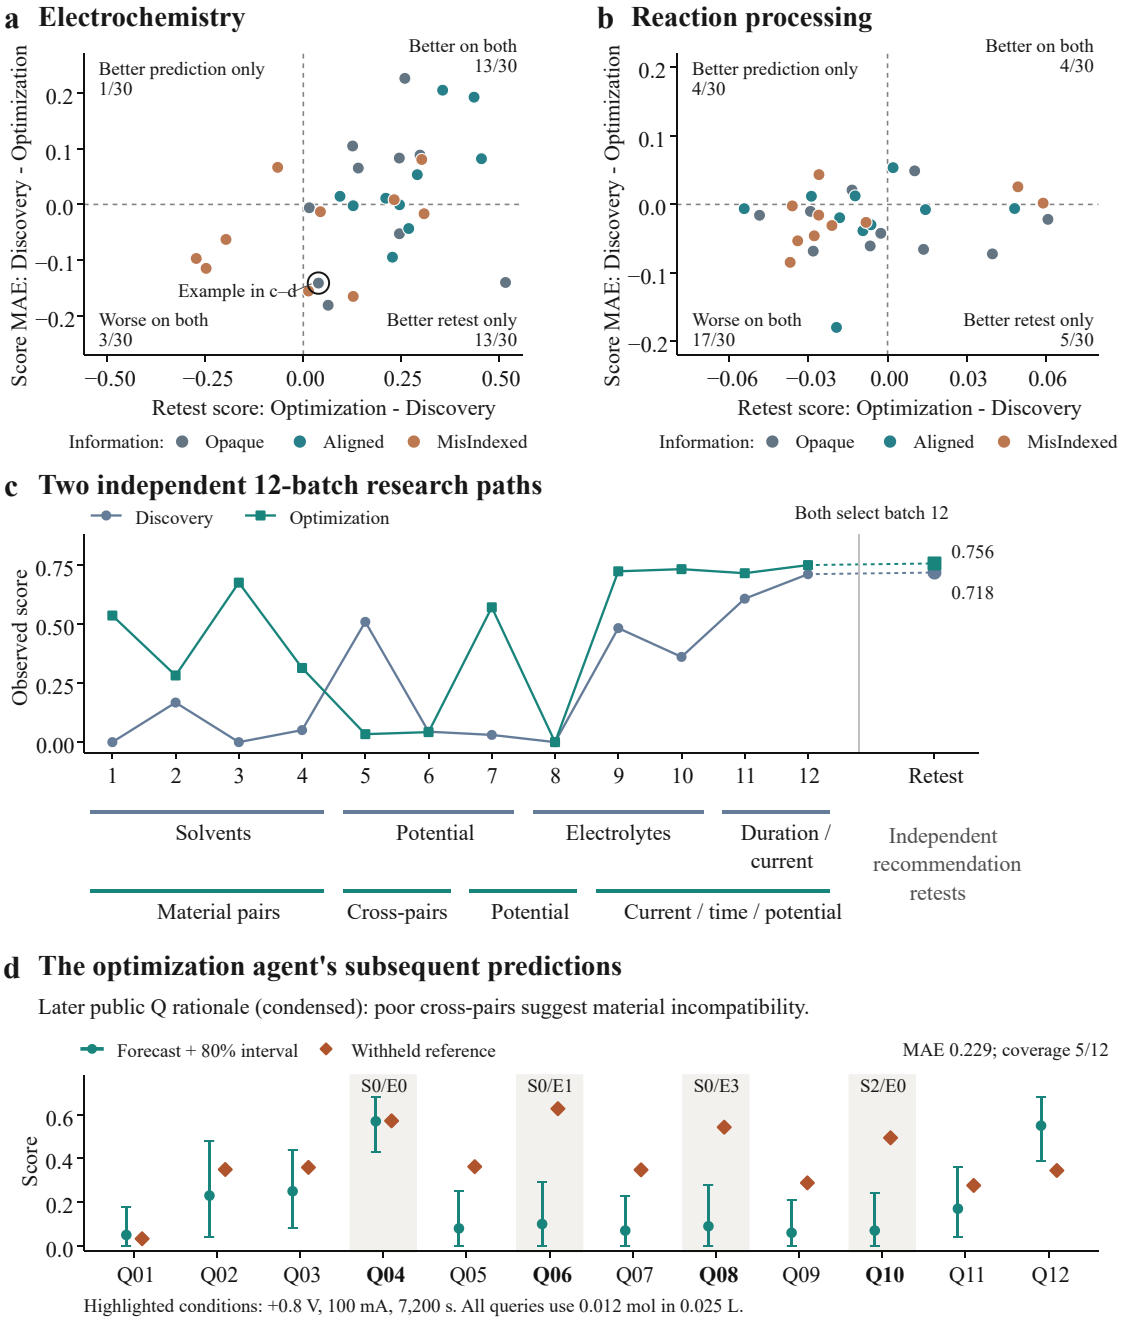
全部轨迹保留并重放，七十五对具有两侧最终测量。五对无淬灭侧缺颗粒，十对有淬灭侧使后续固定冷却请求失效，失败不修复。完整对中，有减无的平均细粉变化为 +0.30937、回收变化为 +0.00741，联合成功从 34 降至 4。这些条件性效果描述实际初始投料回收口径下的物理操作。淬灭改变多个物理状态量，不单独识别冷却速率或科学判断的成因。供体配方来自历史队列，不来自修正版。

数据与代码可用性

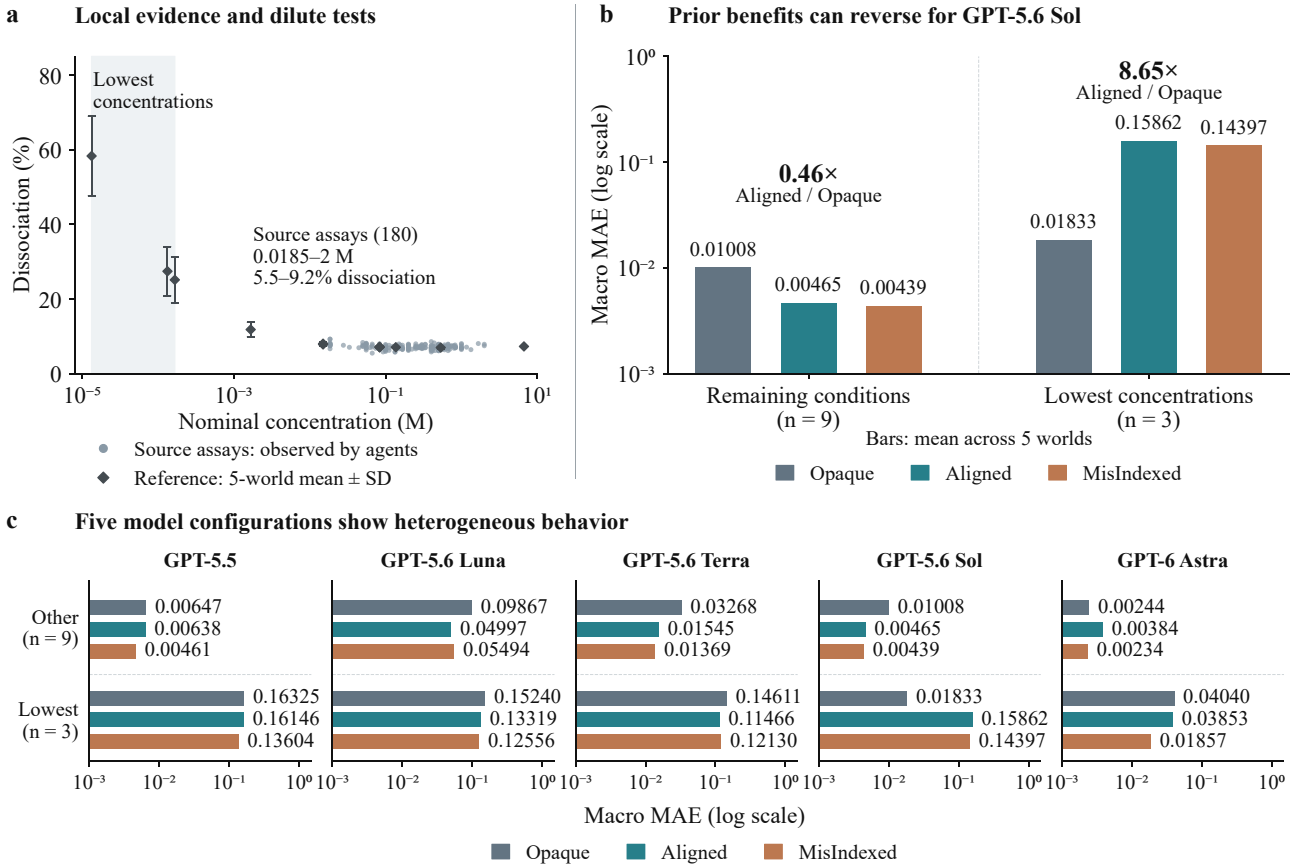
随稿证据包包含完整初始公开输入、1,044 条逐题逐响应预测、全部 270 个计划会话/问题组/响应单元、世界汇总、连续主例、178 对相邻笔记及当前九十场完整公开历史，明确保留缺失预测。原摘要、精确重放与资源记录仍在项目仓库；该包不增加参与者证据，也不构成独立第二评分者复核。补充材料报告误差拆分和编码筛选规则，永久公开存档仍待落实。本轮稿件构建只读取保留结果，不调用模型或模拟器开展新实验。

图 1 为 ImageGen 概念图；图 4 及扩展数据图 1–2 复用原生定量图，图 2、3、5 及扩展数据图 3–5 直接从保留记录和派生汇总绘制。没有定量点位由 ImageGen 生成。证据包补充选定解释历史、操作语义推导、主例测定输入与修正版结晶分布；历史比较和有界案例组详见补充材料。

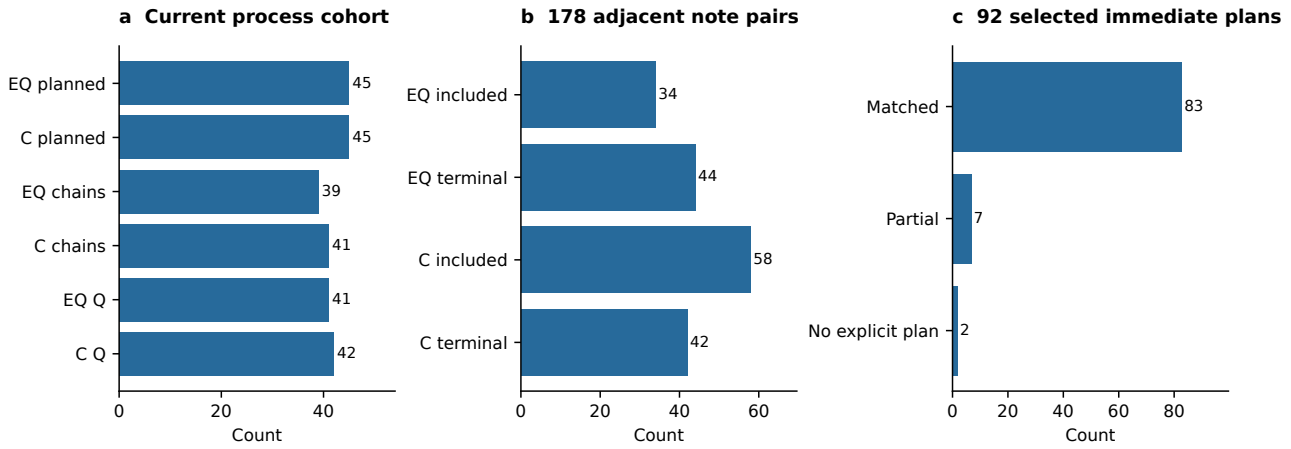
扩展数据



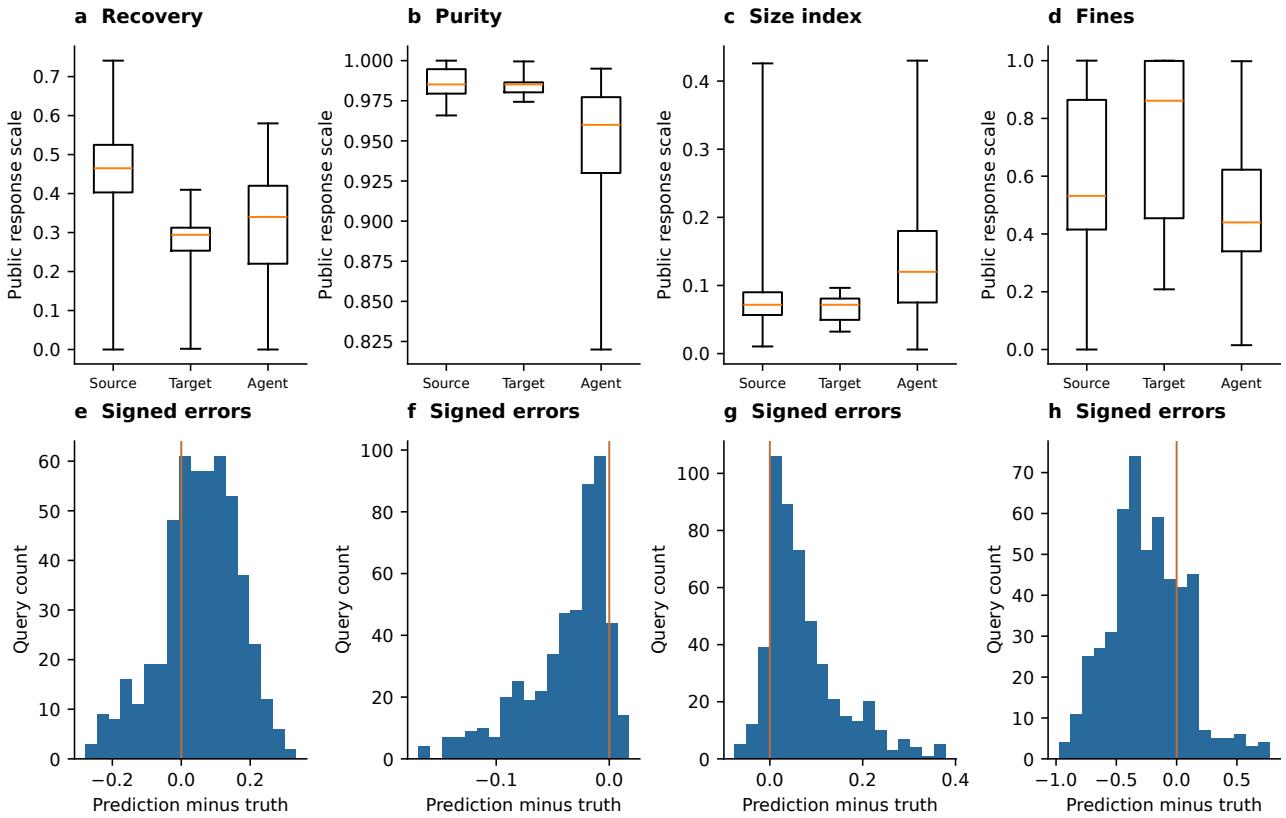
扩展数据图 1 | 不同研究目标下的实验成果与预测准确性。a、b，电化学与反应处理各三十组发现—优化匹配研究；横轴为正表示优化任务的复测评分更高，纵轴为正表示优化任务的预测 MAE 更低，象限标签均相对发现任务评价优化任务。c，两条独立的十二批电化学轨迹及推荐复测，阶段标签概括实际选择。d，该配对中优化研究者的全部十二道预测、原始 80% 区间及封存参考；后续预测理由为压缩表述，不是同期假说记录。本图保留历史协议，不与重复过程队列合并。



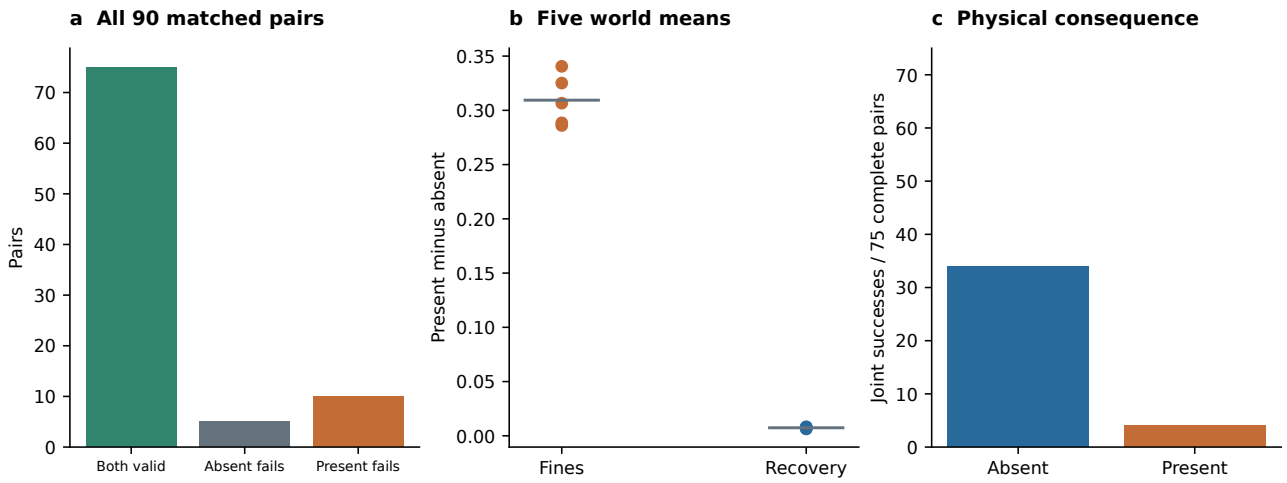
扩展数据图 2 | 部分先验知识的适用范围取决于研究者与判断条件。原平衡比较。a，Sol 的全部 180 次源测定与五世界封存题目均值，误差线为描述性样本标准差，不是置信区间。b，Sol 三种信息条件的五世界宏平均 MAE。c，五种模型配置，采用相同对数误差轴，条形基线为 0.001。最稀三题与其余九题的分组是历史队列的事后分析，在后续重复块之前固定。图中均为历史结果，正文另报的重复队列不加入这些条形。每个模型—世界—信息组合只有一次研究。



扩展数据图 3 | 记录覆盖与选定即时计划。a，当前过程队列的计划分母、完整链和有效预测。b，全部 178 对相邻笔记，其中 34 对平衡、58 对结晶在后一笔记后仍有实际提交的研究动作；其余分别为 44 与 42 对。图中 terminal 表示无后续提交的研究，不表示没有修订。c，92 项选定即时计划中 83 匹配、七项部分匹配、两项不明确。这些数量描述时序及选定计划—行动对应，不是解释性假说数或学习成功数。



扩展数据图 4 | 修正版结晶的响应分布。a–d，42 场有效预测会话的全部 504 次源测定、504 条目标题目与每响应 504 项预测。箱体为中位数及四分位范围，须为全范围。相同世界的会话重复使用目标值，不能视作 504 个独立条件。e–h，同批题目的预测减参考值有符号误差。纯度下移直接从本修正版队列计算。粒径采用公开无量纲指数，不是微米；各响应尺度不同。三场缺失预测的会话仍保留于 45 的计划分母，但不在此图填值。



扩展数据图 5 | 匹配淬灭对物理结果的影响。十八份历史推荐置于五世界，比较有无一个淬灭操作。a，全部九十对及失败：七十五对具有两侧最终测定，五对无淬灭侧缺少颗粒，十对有淬灭侧使后续固定冷却请求失效。b，完整对的逐世界平均变化，横线平均五世界。c，75 个完整对的联合成功数。这些是实际初始投料回收口径下的物理效果；智能体不适应、不接收对照结果，不能据此推断判断形成的效果。