ARTICLE 16 October 2026

自主研究如何塑造科学理解

Jiangjie Qiu[1,*], Yijun Li[1,*], Yaotian Yang[1,*], Honghao Chen[1], Wentao Li[1], Xiaonan Wang[1,†]
[1]Beijing Key Laboratory of Artificial Intelligence for Advanced Chemical Engineering Materials, State Key Laboratory of Chemical Engineering and Low-Carbon Technology, Department of Chemical Engineering, Tsinghua University, Beijing 100084, China.
* Jiangjie Qiu, Yijun Li and Yaotian Yang contributed equally.
† Correspondence: wangxiaonan@tsinghua.edu.cn.

全部插图为 ImageGen 预览，点位与几何仅作示意；精确数值见补充材料。

随着 AI Scientist 与自主实验室迈向持续运行的科研闭环，机器正从实验执行者发展为自主组织科学探索的研究主体。然而，科学认识如何在自主研究中形成，并引导研究的继续展开，仍缺乏系统理解。我们提出 ChemWorld，一组由热力学、动力学及耦合物理化学规律驱动的可编程化学世界，允许独立控制科学规律与信息供给。通过六个化学体系的重复研究、连续记录与受控比较，我们连接研究目标、已有知识、实验选择与不断发展的科学判断。智能体能够将预期转化为实际检验、修订解释并建立有用的关系；匹配世界中的预测也保留了实际化学响应的差异。然而，更有效的实验方案未必带来更准确的预测。结晶研究改善了预测，但智能体与同一批观察的简单均值在不同响应上各有优势；平衡研究的整体预测收益则与极稀条件下的判断恶化并存。这些发现将有用认识的形成与自主探索的组织联系起来，同时表明证据获取、关系形成与后续应用可以取得不同程度的进展。ChemWorld 将这些过程纳入受控实证研究，推进了对机器如何通过自主探索产生、修订和运用科学知识的理解。

自主研究者不仅解释已有观察，也通过选择实验改变自己有机会获得的证据。实验与测量的选择决定哪些现象变得可见、哪些科学关系能够接受检验，以及哪些问题仍有机会被进一步追究。随着 AI Scientist 与自主实验室从执行操作发展为组织持续研究 [1,2]，证据如何产生、又如何转化为科学认识，成为理解机器科研自主性的核心问题。这种自主性的科学价值，在于机器能够通过自己的研究形成怎样的认识。

机器人科学家与自主实验室已经展示了假说检验、材料发现和反应优化能力 [3–6]。语言模型智能体进一步连接科学指令、实验工具与反馈驱动的规划 [7,8]。这些成果表明，机器能够组织富有成效的实验循环，同时也留下了关于这些循环产生何种知识的问题：当已有知识不足以确定答案时，智能体如何通过自主组织的实验形成并拓展科学认识？有效方案或准确的最终预测，都不能单独说明哪些判断得到了研究的支持、这些判断怎样形成，以及它们如何参与后续研究 [9,10]。

研究中获得的证据，既取决于研究目标，也取决于研究者不断发展的认识。一项解释可以引出新的比较；意外观察可以限定这一解释、促使研究者提出替代解释，或使尚未解决的边界成为下一项实验问题 [11–13]。由此形成的判断又会影响后续干预与测量的选择。因此，有用的局部关系、修订后的预期和尚未解决的问题，可以在同一项研究中共同出现。理解这一发展过程，需要追踪科学判断怎样获得支持、怎样依据观察改变，又怎样引导进一步探究。这些转变将知识的形成与使其成为可能的研究过程联系起来。

我们提出 ChemWorld，将实验自主性与科学规律、信息供给的独立控制结合起来，研究这一过程。在由热力学、动力学及耦合物理化学关系驱动的可编程化学世界中，智能体自主选择实验与测量，评价者则能够检查实际执行的操作、获得的观察及未向研究者公开的参照结果。通过六个化学体系的重复研究、连续记录与受控比较，我们将研究目标和已有知识与实验路径、科学关系的形成和修订，以及这些关系在后续行动和预测中的运用联系起来。这一设计使科学探索与科学认识的共同发展成为能够开展受控实证研究的对象。

使自主科学探索成为实验研究对象

ChemWorld 将材料、操作和仪器组合为由热力学、动力学及耦合过程关系驱动的持续化学世界。反应、热处理、平衡、分离与结晶组件可以连接为多阶段流程。样品状态持续保留：上游反应或热历史会改变下游分离与测量。智能体在固定资源额度内选择数量、处理顺序、测量及后续实验；评价者独立控制世界参数与公开信息，记录实际提交的操作，并获得不向研究者公开的参照结果（图 1）。

这一安排使证据选择与证据解释能够共同接受检查。知识测试和给定数据任务考察重要的科学能力 [14,15]，交互式发现环境也已经将行动与观察连接起来 [16–19]。近期智能体研究还考察了化学结构假说的修订与解释表征的构建 [20,21]。ChemWorld 在可组合化学过程中追踪这些研究活动。公开记录确定智能体看见和提出了什么，执行记录确定哪些干预改变了样品，独立世界响应检验后续预测。操作请求可能失败而没有产生预期实验；在一种条件下得到支持的关系，在另一条件下仍可能未决。

研究设计包含四个互补矩阵、450 场计划研究。目标—信息矩阵包括电化学与反应处理各 90 场；过程矩阵包括分配、纯化、平衡和反应耦合结晶各 45 场；机会矩阵在平衡与结晶中分别比较有研究与无研究，每体系 30 场；另有 30 场使用匹配水相世界（方法；扩展数据图 2）。

Opaque 提供任务与操作合同，不附加实例资料；Aligned 提供正确但不完整的信息；MisIndexed 提供指定错配。发现任务强调研究科学关系，优化任务强调形成有效方案。世界、接口和额度按各固定块设计保持，每单元有三次独立开启的会话，模型采样随机种子不可控。这些对照规定研究的起始条件，实际路径由智能体组织。

实验结束后，研究者依次封存科学说明、在无实验室访问条件下预测十二项新干预，并在没有真值反馈时反思。我们将同期判断与操作、观察、修订和后续用途连接起来。新增实验块全部 300 场的公开经历均已阅读，包括不完整经历与失败检验；随后按解释内容选取示例轨迹。研究标签将下文案例与补充材料中的完整记录和关键时点对应。450 场设计说明条件覆盖，

条件对照估计后果，精选经历定位具体转变而非其普遍发生率。分析始终区分世界真值、当时可用证据与实际采用的判断。

科学探索的组织与调整

研究从目标、已有信息和受约束的行动空间出发。智能体选择比较哪些条件、重复哪些流程，以及何时转向新的问题。这些决定同时塑造已经获得的证据与仍可开展的实验。目标和信息对照展示不同起点的后果，连续记录则揭示观察与判断如何进入探索的调整。

在重复电化学矩阵中，相较发现任务，优化任务使世界等权的推荐复测分数从 0.4813 升至 0.5852，产率从 0.1310 升至 0.4225；但分数、产率和法拉第效率的预测误差分别从 0.1539、0.0665 和 0.1677 升至 0.1829、0.0781 和 0.2218，三个误差方向均见于全部五个世界（图 2a、b）。形成更有效的方案，并不保证对新干预的判断更准确。

信息也产生分化的后果。反应优化任务中，Aligned 相较 Opaque 使推荐分数从 0.2735 升至 0.4429，产率从 0.5502 升至 0.7116；风险预测误差从 0.2389 降至 0.1226，而转化率误差从 0.0355 升至 0.1595，四个方向均见于五个世界（图 2c、d）。同一份信息既可以支持更有效的干预和更准确的风险判断，也可能伴随更不准确的转化率预测。

连续记录显示结果怎样进入下一次实验选择。纯化研究 A 区分了预期的响应与继续某种流程所需的结果（图 3a）。无洗流程已得到纯度 0.8140、回收 0.0479；增加有机相量提高了回收，却使纯度停留在 0.7886，低于要求的 0.80。第 11 批之前，研究者预测 0.005 L 的小体积洗涤可以跨过纯度门槛，并事先规定行动标准：只有回收同时超过 0.0479，才重复这一洗涤方案。这里区分了预期的科学响应与继续推进流程的条件。

第 11 批纯度达到 0.8013，回收却只有 0.0441。纯度预期实现，继续条件没有满足。因此，第 12 批回到较早的无洗流程，重复得到纯度 0.8149、回收 0.0368。终末说明承认合格状态可重复，同时回收存在变动；后续预测保留了观察到的纯度—回收权衡。两个响应在下一项决定中承担不同作用：洗涤满足了预期的纯度门槛，而回收决定研究者是否继续推进这一方案。

纯化研究 B 展示判断如何改变之后仍可获得的证据。前四批回收偏低后，研究者提出可能遗漏了一个投料组分，并说明后续会补入该组分。接下来四批实际使用两种投料命令，但两者消耗同一共享库存；库存耗尽使计划中的温度实验无法完成。终末笔记正确地将这些拒绝或空白操作排除于温度响应证据之外。依据对进料的解释采取行动，改变了材料使用，也改变了后续探索的范围。

同一科学问题也可以沿不同路径展开。历史五模型平衡研究展示了获得准确极稀预测的两种途径（扩展数据图 7）。一位 Astra 研究者主动进入稀释区域，观察到偏离较高浓度平台的新响应，并在后续说明和预测中采用这一变化。Sol/Opaque 研究则未直接采样该区域，通过局部观察上的外推获得了准确的极稀预测。观察到新响应与成功推断这一响应，是不同的科学成就。相似的预测表现，使证据与推断的形成经历成为理解各项研究贡献的关键。

科学认识的形成与演化

当观察开始为进一步探索提供依据，科学理解也随之发展。一项关系可以支持新的检验，意外结果可以限定解释，尚未解决的边界可以成为实验问题。以下经历将这些变化与研究者自己提出并执行的比较联系起来。

反应研究 A 追踪一项预期如何从观察进入新实验，再进入后续应用（图 3b）。390 K、加热 1,800 s 后直接终止，转化率为 0.41718；另一批同样加热后不立即淬灭，而等待 1,800 s，虽然降温约 44 K，转化率仍升至 0.61847。研究者据此认为，停止外部加热并不等于化学变化结束。末批之前，它预测若先淬灭再等待相同时长，转化应保持在约 0.42，而不是未淬灭等待的约 0.62。

末批真正执行这一顺序，得到转化率 0.42724。随后笔记保留了淬灭操作与抑制进一步转化之间的局部关系。这项证据明确了哪一段处理历史仍具有化学后果；后续预测将该关系用于新流程，但未观测溶剂和投料条件下的迁移仍较不准确。该比较支持已测顺序下的操作预期；不同的冷却历史使热作用与其他作用仍未分离（方法）。

承担优化任务的电化学研究 B，把极性依赖的范围变成了实验问题（图 3c）。十批材料与时长研究之后，研究者记录正极性特异性尚未经过匹配反向检验，并留出这一比较和一次精确重复。其事前原句是：“If negative potential retains high yield, the assumed polarity specificity is rejected”（若负电位仍保留较高产率，就否定此前假定的极性特异性）。第 11 批在 −1.0 V 下仍得到产率 0.384；正电位流程及其末批重复分别约为 0.911 和 0.905。终末说明将认识从表面的极性特异性修订为极性优势，后续预测也保留反向产物。修订后的关系更准确，也仍然有用：这里的认识进展，是将表面的排他性改为有支持的优势关系。

三条经历以不同方式连接判断与研究：纯化将既有继续标准用于新观察，反应处理检验局部操作预期，电化学修订科学关系的内容。这些变化改变了研究者有理由继续追求或预期的内容。判断的价值，部分体现在它开启什么新的比较，以及比较结果如何进一步发展这项关系。

电化学研究 A 展示从局部结果进入后续判断的另一种路径。它以匹配的正负极性比较开始：负电位产生响应，所测正电位条件基本不活跃。后续批次沿负侧细化材料和时长，终末笔记明确将极性结论限制于已测流程。然而，随后的数值预测仍给未经检验、位于已研究电位幅值之内的正侧条件近背景响应，区间没有覆盖参照结果。公开声明的适用边界与新判断中的实际应用可以分离。

匹配世界矩阵考察不同底层化学如何进入证据与后续判断（图 4）。五对水相世界共享公开说明与部分参数，区别在于是否耦合额外中性离子对。

匹配世界研究 A 中，研究者事先提出：尖锐沉淀起始点和被缓冲的溶解响应将支持溶解度限制解释，而平滑变化也容许经验分配描述。六次测定之后，它提出更密集的浓度采样、中点重复与增加投料；后六批实施这些选择，十二次实际观察构成所用关系的证据基础（图 4d；补充材料）。最终说明保留平滑单调关系，预测也明确表示，由于没有分辨出尖锐阈值，将采用这一关系。匹配世界研究 B 先提出将浓样从 0.75 M 稀

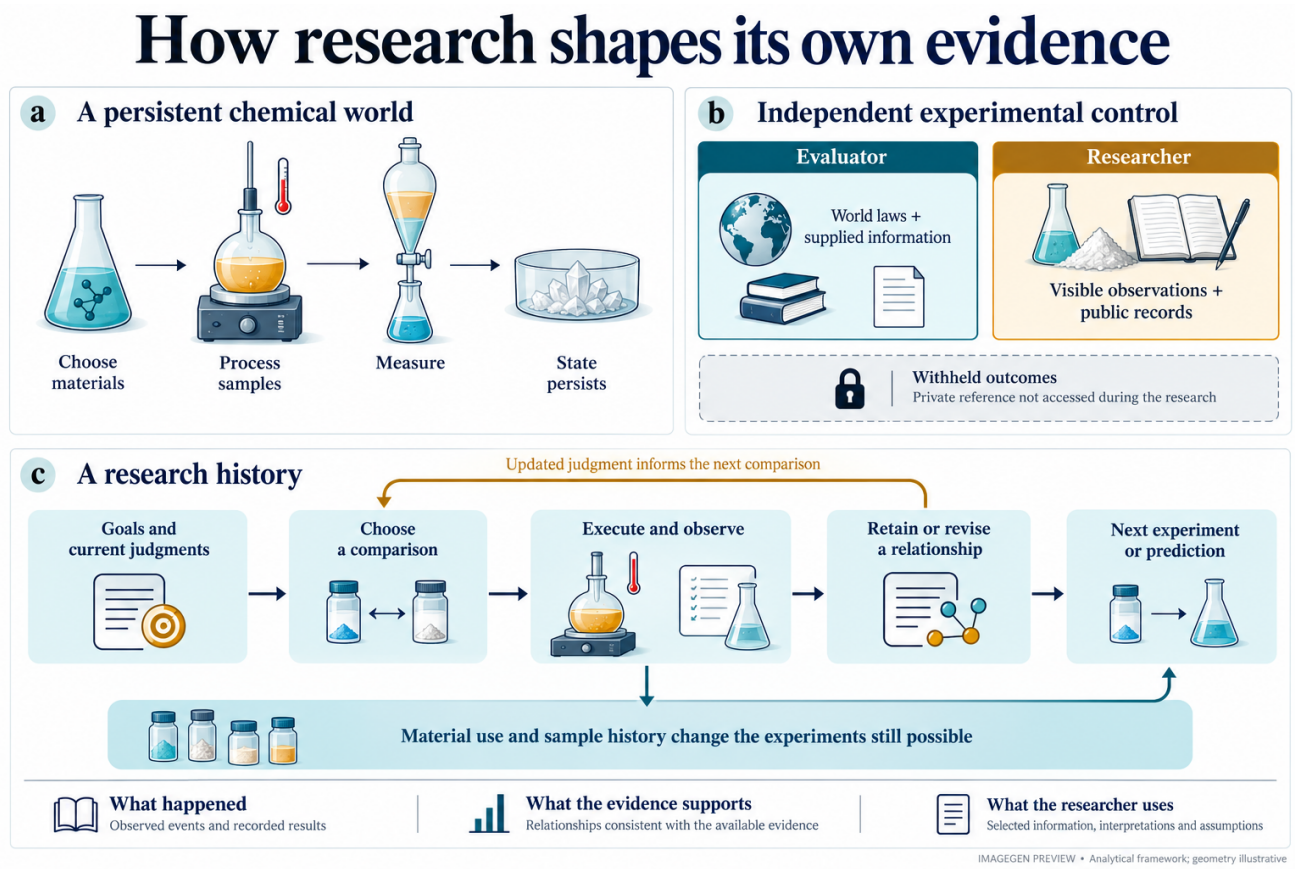


图 1 | 自主研究塑造自身的证据基础。a，智能体在持续化学世界中选择材料、操作和测量。b，底层规律与信息供给独立受控，参照结果不向研究者公开。c，公开预期、所选比较、观察、判断修订和后续行动在研究历史中连接；资源与样品状态限制剩余实验机会。ImageGen 概念预览。

释至 0.375 M 的响应预期，再执行稀释；归一化 pH 从 0.08045 升至 0.10803。研究者支持近似可逆性，但最近的独立配制对照为 0.4 M，沉淀读数也来自不同仪器。这些记录连接了明确提出的候选、实际选择的比较与后来采用的关系。

在整个矩阵中，将实际动作在配对世界重放，表明三十场研究均获得至少一个在两个响应通道上相差三倍测定标准差的观察。研究者选择的实验因而接触到了物理上可区分的响应。

最终预测也反映了这些世界差异。事后分析在十二个共同查询上，比较 B 减 A 的三会话预测均值之差与五次参照观测均值之差（图 4a—c）。非零参照差异中，pH、解离与沉淀方向分别在 54/57、48/57 和 39/39 项上一致，其余 3、3 和 21 项参照差异为零。全部 180 个比较均保留；在参照差异达到三倍测定标准差的描述性子集中，方向分别在 48/48、10/10 和 27/27 项上一致。

预测也保留了差异的幅度（图 4e）。归一化 pH、解离与沉淀的平均绝对差异误差分别为 0.002256、0.002945 和 0.002368；如果对两个世界给出相同预测，误差则为 0.026007、0.007239 和 0.024840。相较这一零差异参照，预测误差分别降低 91.3%、59.3% 和 90.5%，且每个响应在全部五对世界中均更准确。这些结果描述最终三会话平均预测的性质；本块没有无研究组，提供的起始观察接近但不完全相同，因此未单独识别研究带来的增益。

互补经历显示，认识也可以通过失败预期继续发展（扩展数据图 8）。更强混合推翻暂定的分配平台；第四次结晶热循环没有延续第三次的改善；进一步稀释使可回收颗粒消失，收窄了原先设想的操作窗口。这些检验通过修订判断作出贡献，即使最终方案没有改善。实验未分离同时变化的因素时，它们各自的作用仍然未决。

解释实验经历还要求确定哪些操作实际发生过。有的研究者把回滚操作视为已完成检验，另一些则明确排除它们（扩展数据图 6）。焦点加热案例的公开返回同时包含成功标识、回滚信息和零时间及温度变化，后续说明将这段含糊的执行历史带入判断。这些案例显示，接口信号及其解释共同塑造研究者视为可用的证据。

这些经历显示，成功干预可以建立有范围的关系，未实现的预期则可以带来有依据的修订。经验规律能够在机制尚未解决时指导进一步研究。认识的发展，体现为实际比较什么、证据建立了什么，以及哪些问题仍值得继续探索。

自主探索中科学进展的性质与条件

前述经历将科学进展定位于关系的建立、预期的修订和后续检验的选择。下面进一步考察，这些研究能够支持怎样的新条件判断。实验结束后，智能体在不能继续访问实验室时回答新的问题。机会矩阵将其预测与未获得研究机会的智能体比较：两个体系分别在五个固定世界、每组每世界三次新会话中，比较十二批研究与不开展源实验；两组共享 Opaque 信息与评价。

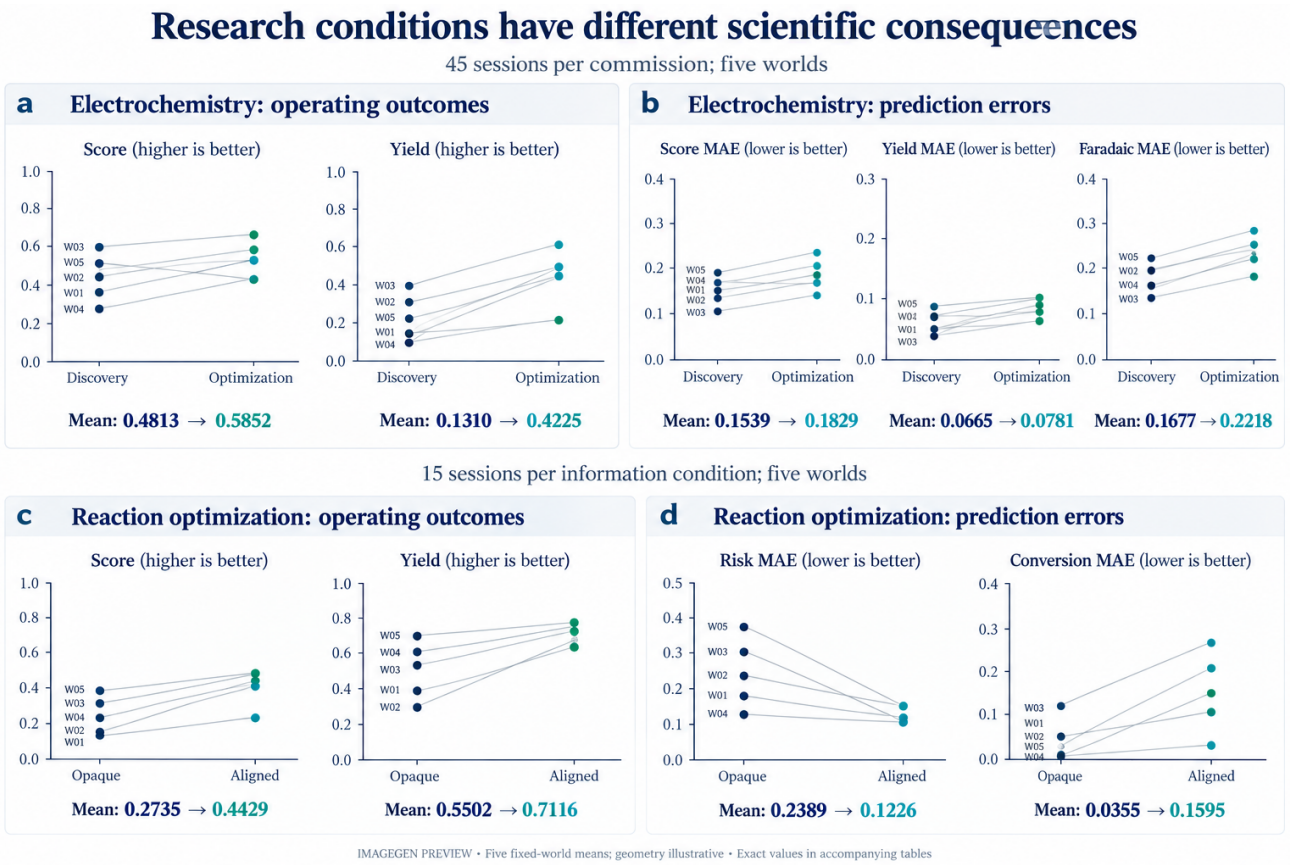


图 2 | 目标与信息对操作和预测具有不同后果。a、b，电化学发现与优化比较，每任务 45 场，覆盖五固定世界与三信息条件。c、d，反应优化中 Opaque 与 Aligned 比较，每组十五场。预览示意世界内条件比较，汇总数值标签依据保留结果；生成点位与连线不精确再现逐场值、世界均值或不确定性。精确数值与可用响应分母见补充材料。ImageGen 预览，几何仅作示意。

该对照估计选择实验、接收反馈和记录判断这一完整研究机会的作用。

结晶比较确立了明显的研究收益（图 5a）。三十场均有有效预测。相较无研究，世界等权 MAE 在纯度上从 0.13853 降至 0.01661，在粒径指数上从 0.23619 降至 0.07641；回收误差从 0.13532 降至 0.11579，细粉误差从 0.37683 降至 0.30110。纯度的名义 80% 区间覆盖从 0.46667 升至 0.98333，宽度从 0.44744 缩至 0.09743。研究经历带来更准确的预测，也形成了覆盖更多参照结果的更窄区间。

第二层比较考察同一批研究历史还能够支持怎样的预测（图 5b）。十五场 Research 会话中，源观测均值参考在纯度、粒径上的误差为 0.00450、0.01786，均低于智能体的 0.01661、0.07641，且两项均见于全部十五场。回收的方向相反：智能体 0.11579 优于参考 0.18828，十五场中十四场更好。这一替代预测规则只使用本场公开源观测，拟合时不接收目标真值，并在相同目标上评分。常数参考有效捕捉了稳定响应，智能体则作出了更好的回收预测。研究具有价值，而如何使用这些观察又带来随响应变化的优势。较早修正版结晶队列提供了独立的支持性比较（扩展数据图 3）。

同一队列也区分了更好的点预测与更好的不确定性估计（图 5c）。细粉区间宽度从 0.68500 缩至 0.38450，覆盖却从 0.42778 降至 0.35556。兼顾宽度与漏覆盖惩罚的区间评分，世界等权均值从 1.4794 恶化至 1.8047，全部五个世界均恶化。研究降低了细粉的平均点预测误差，但形成的区间表现出超出其实际表现所支持的确定性。收益与局限属于同一比较中的同一响应。

平衡机会比较揭示区域边界（图 5d）。十四份有效 Research 预测与十五份 NoResearch 预测之间，整体归一化宏平均误差从 0.132086 降至 0.035632，五个世界均改善；事前指定的三道极稀问题误差却从 0.061467 升至 0.103677，四个世界恶化，其他九道则从 0.155625 降至 0.012950。允许缺失的 Research 预测取合法范围内任意误差，也不会逆转两个总体方向（方法）。研究改善了多数预测，另一区域的判断却变得更不可靠。

平衡研究 A 使这一转变在时间上连续可见（扩展数据图 5）。最初依赖投料量的预期，被观察到的局部平台所修订。研究者考虑替代解释并更换加料命令；但两种命令加入同一物种，因此证据建立了局部规律，并未完成所设想的化学身份比较。终末说明仍保留多个解释。后续极稀预测却继续偏重固定酸性背景，给出解离度 0.085、80% 区间 [0.035, 0.350]，而参照均值为 0.716032。研究所获得的关系在局部有用；进入后续判断时，这段经历又被赋予了实验尚未解决区域中的解释分量。

科学进展具有相互联系的不同层次：实验取得了什么成果，证据建立了什么认识，研究者能够据此对新条件作出什么推断。一方面的进展可以与另一方面的未决问题共存。其他信息条件与历史比较见补充材料和扩展数据图 1。

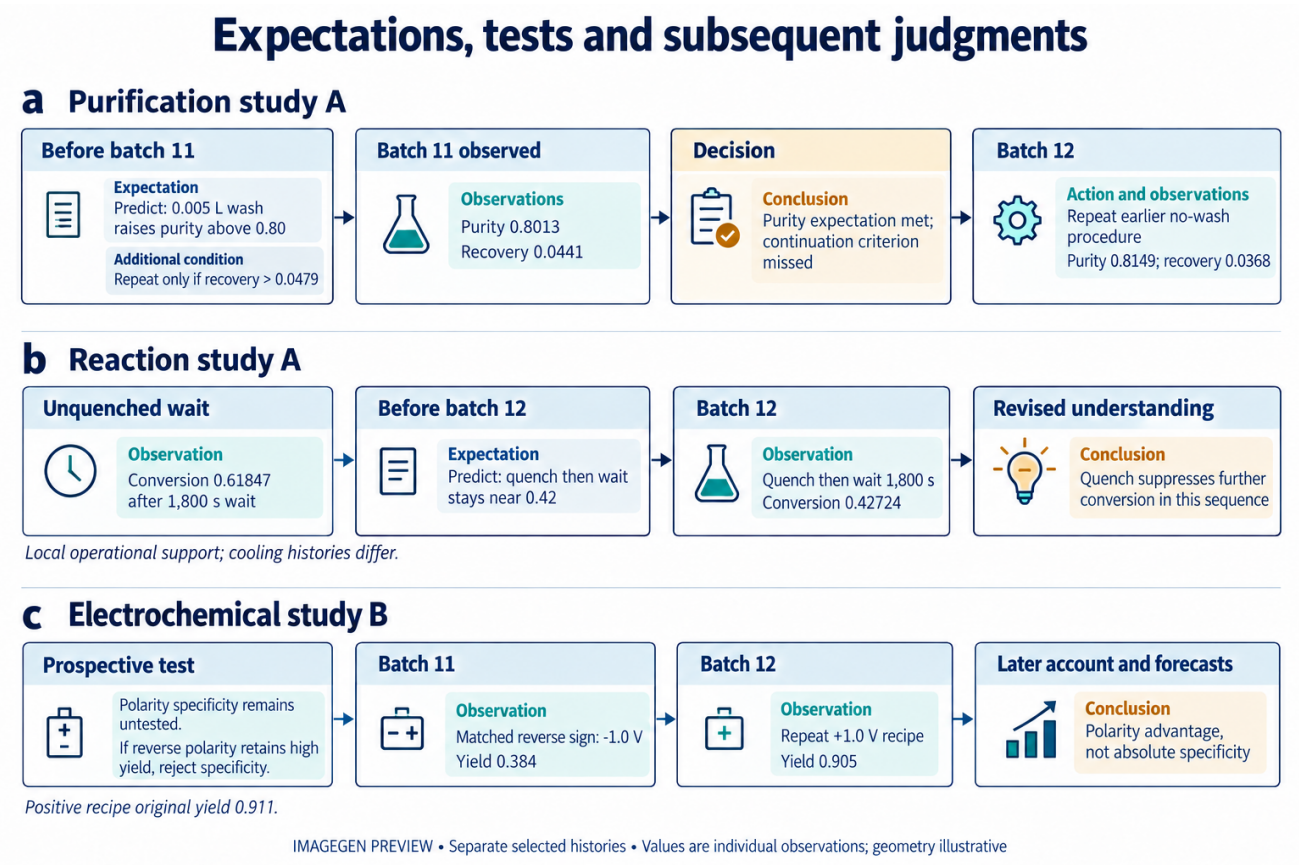


图 3 | 预期、检验与后续判断。a，纯化研究 A：小洗量实现纯度预期，但回收未达到事前继续标准，研究者因此重复无洗流程。b，反应研究 A：未淬灭等待引出淬灭后等待的预测与检验，获得局部支持。c，电化学研究 B：事前否定判据先于反向检验提出；反向仍产生明显产物，使特异性修订为极性优势，末批重复正侧流程。各行是独立选取的经历，数值是个别观察。ImageGen 预览，精确记录与时点见补充材料。

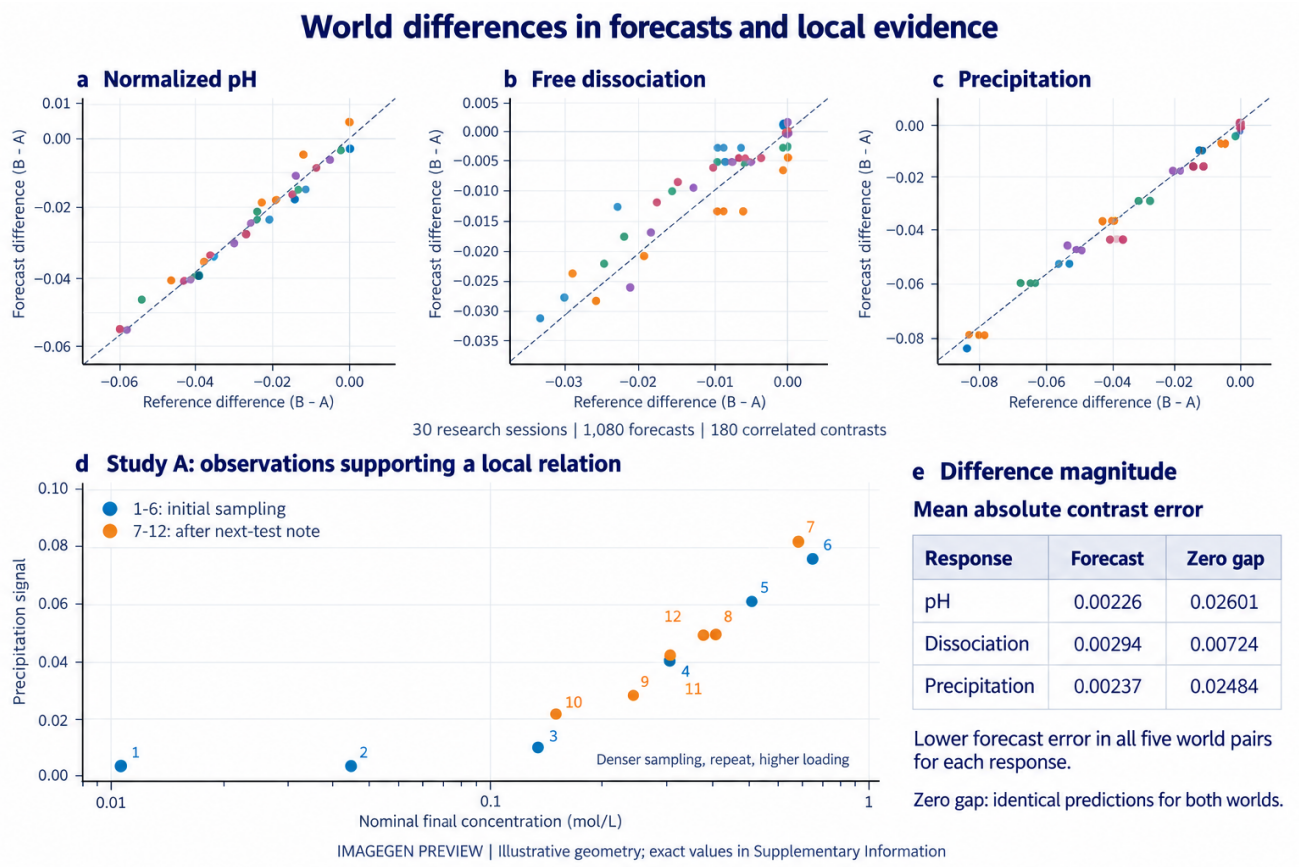


图 4 | 预测中的世界差异与局部关系的观察基础。a—c，网络 B 减 A 的参照响应差及三会话预测均值之差。分析保留全部 180 个相关比较，包括零差与小差；每世界每查询参照为五次观测均值，虚线表示一致。d，匹配世界研究 A 十二次测定，第 7—12 批位于下一检验笔记之后。e，预测差异的绝对误差与零差异参照比较，后者对应两个世界给出相同预测。数值标签依据保留结果。ImageGen 预览，点位仅作示意；精确数值及逐世界对汇总见补充材料。

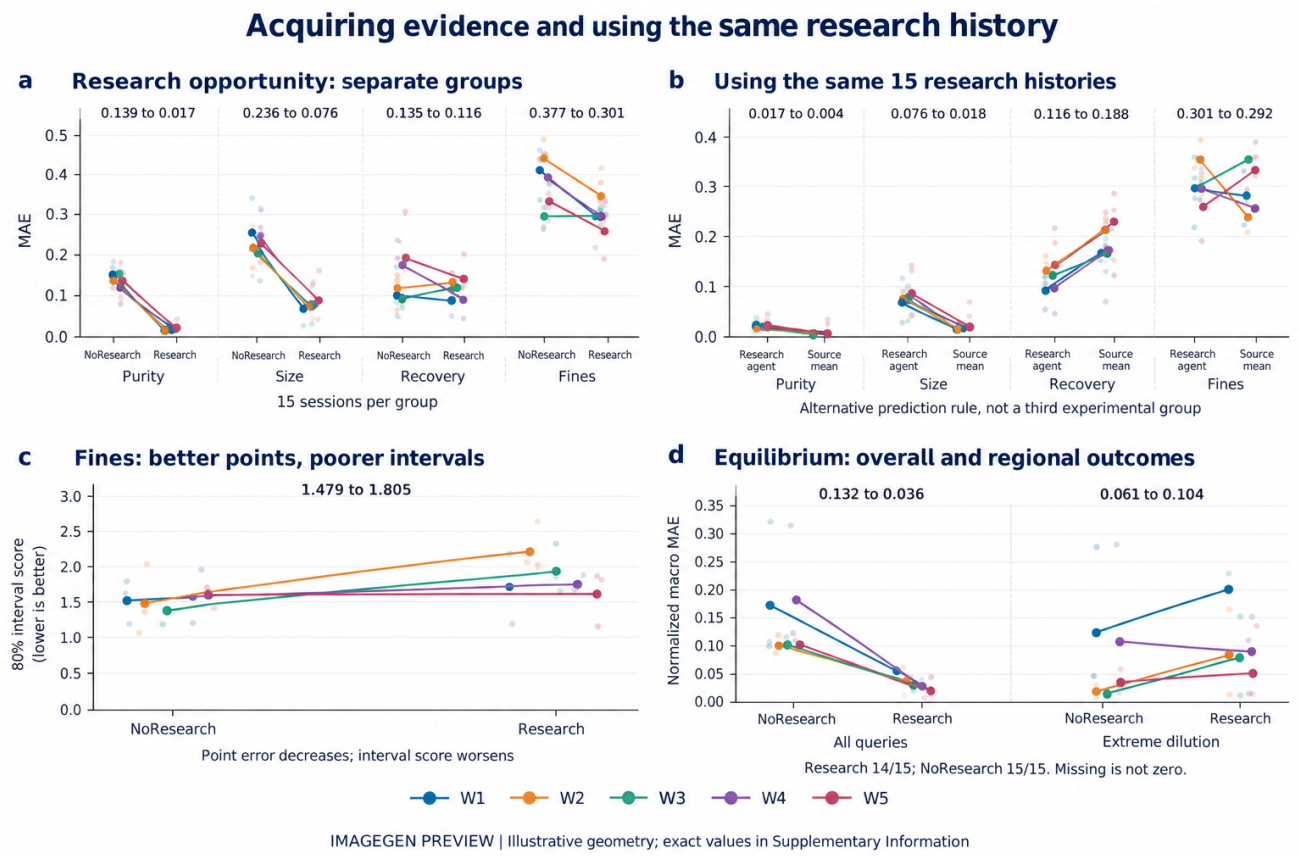


图 5 | 获取证据、使用观察与表达不确定性。a，结晶 Research 与 NoResearch 点误差，每组十五份有效预测。b，Research 预测与由同一十五场源历史计算、在相同目标上评分的常数参考比较；这是另一种预测规则，不是第三个实验组。c，细粉名义 80% 预测区间评分，越低越好。d，独立保留的平衡机会比较，分别为全部查询与事前指定极稀区域；Research 十四份、NoResearch 十五份，第三世界 Research 有两次可用重复，缺失值不记为零。汇总数值标签依据保留结果。ImageGen 预览，生成的会话点与世界连线仅作示意，不表示精确数值、同一智能体的学习过程或置信区间；精确数值见补充材料。

讨论

在自主科研中，智能体不仅解释实验结果，也通过选择实验塑造自己能够获得的证据。研究目标、已有知识与发展中的判断共同影响哪些实验被开展、哪些现象变得可见，以及后续还能够研究什么。ChemWorld 中的连续记录显示，研究者会根据观察调整实验选择，将已有判断带入新的比较，并依据实验结果建立或修订科学关系。科学认识因此不仅是研究的结果，也能够成为继续组织研究的依据。

这些研究展示了多种具有实际内容的认识进展。研究者能够从观察中形成前瞻性预期，并通过新的实验获得支持；能够主动检验原有关系的边界，将过于绝对的判断修订为更准确的经验关系；也能够在微观机制尚未解决时建立指导后续推断的局部认识。匹配化学世界中的研究后预测进一步保留了不同世界的实际响应差异，表明研究者形成的判断可以反映其所探索世界的不同性质。发现新现象、建立有效关系、修订原有预期和作出有根据的推断，因而构成不同形式的科学进展，也各自留下不同的未决问题。

形成有用认识，并不意味着这些认识能够在所有后续判断中得到可靠应用。受控比较表明，研究可以大幅提高预测准确性，但其收益依赖所考察的响应和条件。在结晶研究中，同一实验历史可以支持优于简单观测均值的回收率预测，也可以在较稳定的响应上不及这一参照。平衡研究则表明，整体预测收益可以与特定区域的判断恶化并存；更好的点预测也不必然伴随更可靠的不确定性表达 [10,22,23]。这些结果表明，建立有用关系、判断其适用范围，以及在后续研究中持续依据证据作出判断，可以取得不同程度、甚至不同方向的进展。一项研究能够建立可靠的局部认识，同时在随后的概括和应用中出现偏离。

受控比较与连续记录共同连接了认识的形成及其研究条件。前者检验研究目标、信息供给或实验机会带来的后果，后者追踪判断何时提出、依据哪些观察修订，以及如何进入后续行动。匹配世界则允许对照实际获得的信息与最终预测，检查科学判断是否反映世界规律的差异。当前重复矩阵集中于固定可编程世界中的一种模型配置，过程分析依据公开判断和实际操作。将这一研究扩展到其他模型与真实实验室，并在持续探索中干预候选解释，可以进一步检验这些过程的普遍性，以及具体认识对后续研究选择的作用。

ChemWorld 将研究者如何获得证据、实验实际上建立了什么认识，以及这些认识如何引导后续探索联系起来，使知识的形成与使用成为能够接受实验研究的科学对象。这推进了对机器如何通过自己组织的探究形成、修订和拓展科学认识的研究。

参考文献

1. G. Tom et al. Self-Driving Laboratories for Chemistry and Materials Science. *Chemical Reviews* **124** 9633–9732 (2024). https://doi.org/10.1021/acs.chemrev.4c00055.
2. D. A. Boiko, R. MacKnight, B. Kline, and G. Gomes. Autonomous chemical research with large language models. *Nature* **624** 570–578 (2023). https://doi.org/10.1038/s41586-023-06792-0.
3. R. D. King et al. The Automation of Science. *Science* **324** 85–89 (2009). https://doi.org/10.1126/science.1165620.
4. B. Burger et al. A mobile robotic chemist. *Nature* **583** 237–241 (2020). https://doi.org/10.1038/s41586-020-2442-2.
5. B. P. MacLeod et al. Self-driving laboratory for accelerated discovery of thin-film materials. *Science Advances* **6** eaaz8867 (2020). https://doi.org/10.1126/sciadv.aaz8867.
6. N. J. Szymanski et al. An autonomous laboratory for the accelerated synthesis of inorganic materials. *Nature* **624** 86–91 (2023). https://doi.org/10.1038/s41586-023-06734-w.
7. A. M. Bran et al. Augmenting large language models with chemistry tools. *Nature Machine Intelligence* **6** 525–535 (2024). https://doi.org/10.1038/s42256-024-00832-8.
8. T. Dai et al. Autonomous mobile robots for exploratory synthetic chemistry. *Nature* **635** 890–897 (2024). https://doi.org/10.1038/s41586-024-08173-7.
9. A. N. Elmachtoub and P. Grigas. Smart Predict, then Optimize. *Management Science* **68** 9–26 (2022). https://doi.org/10.1287/mnsc.2020.3922.
10. G. Shmueli. To Explain or to Predict? *Statistical Science* **25** 289–310 (2010). https://doi.org/10.1214/10-sts330.
11. J. R. Platt. Strong Inference. *Science* **146** 347–353 (1964). https://doi.org/10.1126/science.146.3642.347.
12. D. V. Lindley. On a Measure of the Information Provided by an Experiment. *The Annals of Mathematical Statistics* **27** 986–1005 (1956). https://doi.org/10.1214/aoms/1177728069.
13. K. Chaloner and I. Verdinelli. Bayesian Experimental Design: A Review. *Statistical Science* **10** 273–304 (1995). https://doi.org/10.1214/ss/1177009939.
14. A. Mirza et al. A framework for evaluating the chemical knowledge and reasoning abilities of large language models against the expertise of chemists. *Nature Chemistry* **17** 1027–1034 (2025). https://doi.org/10.1038/s41557-025-01815-x.
15. B. P. Majumder et al. DiscoveryBench: Towards Data-Driven Discovery with Large Language Models. *International Conference on Learning Representations* **2025** 4556–4579 (2025). https://proceedings.iclr.cc/paper_files/paper/2025/file/0d70af566e69f1dfb687791ecf955e28-Paper-Conference.pdf.
16. R. Wang, P. Jansen, M.-A. Côté, and P. Ammanabrolu. ScienceWorld: Is your Agent Smarter than a 5th Grader? *Proceedings of the 2022 conference on empirical methods in natural language processing* 11279–11298 (2022). https://doi.org/10.18653/v1/2022.emnlp-main.775.
17. P. Jansen et al. DiscoveryWorld: A virtual environment for developing and evaluating automated scientific discovery agents. *Advances in neural information processing systems* **37** (2024). https://doi.org/10.52202/079017-0324.
18. K. Gandhi et al. BoxingGym: Benchmarking progress in automated experimental design and model discovery. (2025). https://arxiv.org/abs/2501.01540.
19. Y. Chen, P. Piękos, M. Ostaszewski, F. Laakom, and J. Schmidhuber. PhysGym: Benchmarking LLMs in Interactive Physics Discovery with Controlled Priors. *Advances in Neural Information Processing Systems* **38** (2025). https://doi.org/10.52202/085713-1556.
20. T. Han et al. MolQuest: A Benchmark for Agentic Evaluation of Abductive Reasoning in Chemical Structure Elucidation. *arXiv* (2026). https://doi.org/10.48550/arXiv.2603.25253.
21. W. Li, T. Zheng, Y. Song, G. Y. Wong, and S. See. ULTRADISCOVERY: Abductive Exploration in an Interconnected, Epistemically Open Universe. *arXiv* (2026). https://doi.org/10.48550/arXiv.2610.03092.
22. T. Gneiting and A. E. Raftery. Strictly Proper Scoring Rules, Prediction, and Estimation. *Journal of the American Statistical Association* **102** 359–378 (2007). https://doi.org/10.1198/016214506000001437.
23. Y. Ovadia et al. Can you trust your model's uncertainty? Evaluating predictive uncertainty under dataset shift. *Advances in Neural Information Processing Systems* **32** (2019). https://proceedings.neurips.cc/paper_files/paper/2019/file/8558cb408c1d76621371888657d2eb1d-Paper.pdf.

方法

世界、接口与实验单位

ChemWorld 将兼容的过程组件编译为具有持续状态的虚拟化学环境。公开契约指定材料、合法操作、仪器、资源和任务目标，私有参数决定具体世界的响应。智能体能够访问实验室和公开记录，不能访问评估者状态、模拟器代码、私有参数或封存参考结果。操作改变样品，测量可能消耗材料。候选转变在提交之前接受校验；被拒绝的操作不构成所请求的物理干预，但尝试可能消耗契约规定的资源。精确重放核对环境状态转变，不重新生成模型决策。

广度研究覆盖电化学、分配、反应与热处理、水溶液平衡、反应耦合结晶和纯化。这些是受控虚拟系统，不是对具名现实物质经过实验验证的预测。整合重复设计通过互补矩阵覆盖六个体系。五个固定世界在不同条件与重复中复用，世界参数、初始状态和键控观测映射保持固定。重复单位是新模型会话，不是独立世界抽样或受控模型 seed 重复。接口没有可用的模型采样 seed；相同干预可以得到相同键控观测，因此也不是独立噪声实现。

整合矩阵与新增会话覆盖

四矩阵覆盖设计包含 450 场计划研究，由新增 300 场与保留 150 场组成。目标—信息矩阵在电化学和反应处理中各采用五世界 × 三信息 × 两任务 × 三会话，每体系 90 场。过程矩阵新增发现任务下分配 45 场、优化任务下纯化 45 场，各为五世界 × 三信息 × 三会话，加上保留的平衡 45 场与修正版结晶 45 场。机会矩阵包括新结晶 30 场和保留平衡 30 场，均为五世界 × 研究/无研究 × 三会话，全部 Opaque。保留的 30 场匹配世界研究构成第四矩阵。保留 150 场、历史广度 300 场与新增 300 场明确区分；共同覆盖结构不意味着协议和时期相同。

新参与者使用 gpt-5.6-sol，要求 medium 推理强度。源研究允许十二批，十五位无研究参与者没有源实验。科学说明、十二题预测与反思依次封存，没有参考真值反馈。300 场取得 288 条完整链、298 份有效预测、3,379/3,420 次源终检和 898/900 个有效封存阶段。电化学 90/90 全链、1,080 次终检；反应 88/90 全链、1,080 次终检、88 份有效预测；分配 45/45 全链、540 次终检；纯化 35/45 全链、499/540 次终检，但 45 份预测均保留；结晶 30/30 全链、30 份预测、180 次研究终检。285 份源回放和 240 份推荐回放凭据已验证。

十场纯化保留材料耗尽造成的缺口，不替换经历。一场反应在工具预算耗尽后缺少预测，另一场预测因区间不符合评估要求而无效；相关操作及后来可用说明全部保留。按预先确定的技术补跑规则，四场明确服务中断在主队列完成后补跑；中断尝试全部保留，不增加科学单位。此前运行时开发尝试与本块分开。已完成的科学结果全部保留。

新矩阵测量与汇总

各响应保留原生评估定义。电化学和纯化参照为单个固定键终末观测；分配为采样前无噪声相分数；反应点误差参照五观测均值，覆盖使用十二题共六十个参考观测；结晶为终检采样前无噪声响应及初始投料回收。分配使用名义 90% 区间，其他体系为 80%。两个分配相分数互补，并非独立证据。不形成跨响应、跨体系科学能力总分。

先计算每场响应误差和区间诊断，再在每个固定世界内平均可用会话，最后对五世界等权。电化学任务比较还在每世界内平均三种信息条件，每任务 45 份预测全部可用。反应优化的 Opaque—Aligned 比较每组 15 份有效预测；另两个存在缺失的反应条件各为 14/15，并明确标记。纯化保留源预算不完整会话的可用预测。计划响应缺失时，不给完整网格估计；可用案例均值不将缺失填为零。重复会话、问题和响应共享世界，不作为独立抽样来估计置信区间或显著性。固定格的三次重复描述波动，不建立总体可靠率。

操作比较使用封存推荐的独立复测，与新查询干预下的预测分开。分数和产率保留公开定义，分别汇总。区间宽度、经验覆盖和保留评估器提供的适当区间评分与点误差共同报告；新结晶机会比较采用 alpha=0.2 及对应合法响应尺度。研究与无研究共享科学背景和封存评估，研究额外提供实验预算、经历与记录机会。差异估计整个组合，而非某个推理操作。

新研究经历的完整精读

新增 300 场均精读，包括十五份无研究说明、873 版笔记和 31,922 条公开操作。899 份非空封存内容中，一份含无效预测，因此仅 898 个有效阶段；另有一份预测缺失。电化学 268 版笔记、7,647 条操作；反应 293 版、7,917 条；分配与纯化 262 版、13,253 条；结晶 50 版、3,105 条。逐场阅读核对 1,363 处公开原句。缺失笔记、失败检验、被拒请求、终点修订及后期反思均保留；阅读覆盖不是解释成功率分母。

每项焦点判断区分实际提出的现象、候选解释或经验预期、首次表述、前瞻后果、真正提交的干预、测量、修订地位与后续用途。条件计划不算已执行检验，后来预测不倒填入此前笔记。终末解释可以支持后来预测的用途判断，不能单独证明此前源行动受其引导。依据源阶段公开契约与冻结执行语义，区分请求被拒、状态回滚和任务质量失败。反应风险超阈值不意味着回滚，直接加热与控制器配置具有不同温度上限。淬灭改变温度与风险、推进时钟但不积分额外反应，淬灭前等待则可能继续反应。反应研究 A 比较的冷却历史不同，因此淬灭后等待支持局部操作关系，不能分离热作用与非热作用。结晶晶种专题比较请求量和提交量，不将重复被拒请求当作剂量。

全部经历均作语义阅读，示例判断则按解释意义事后选取。同一会话可以有证据支持与结果不同的多项判断。我们在完整轨迹中追踪具体判断，并在比较中保留会话与世界层级；不推断内部认知，也不以单一成败标签概括整

场研究。解释与来源核查由助手分析流程承担，没有独立人类编码、盲法或第二评分者一致性估计。下文旧行动关联窗口及解释历史保留原定义和分母。

同队列源观测参考与执行状态解释

我们进一步汇总十五场新结晶 Research 结果中已经保留的源观测参考。这是既有输出的事后分析，不执行模型或模拟器实验。常数参考使用本场响应完整的公开终检测量均值；原有最近邻参考按原公开配方特征空间选择最接近问题的源配方。目标真值只用于评分。响应完整要求四个评价响应均为数值，不依据响应高低或任务成败筛选：180 次源测定中 179 次满足；第一世界第三重复的一次测定缺少完整响应向量，该场参考由十一项源测定拟合。十五场及每响应 180 道问题全部保留。误差使用与智能体相同的无噪声测定前参照，先在世界内平均会话，再对世界等权。这些只给点预测的参考诊断已有观察的利用，区别于 NoResearch 组。逐场误差、拟合数和源均值保留于证据包。这是相同历史上的预测规则比较，不是第三实验组、内部理解程度的测量，或研究机会效应的因果分解。

在支持性的加热经历重建案例中，可见返回外层包含 `ok: true` 和 `experiment_completed: true`，同时还包含 `transaction_status: rolled_back`、明确回滚错误，以及零温度和时间变化。因此，两次请求的 600 s 操作不能构成 1,200 s 化学暴露。冲突的公开标识与后来说明及预测一并保留；这一案例没有将智能体推理与接口歧义的作用分开。另一场则明确将回滚加热排除于化学解释。控制器与直接加热上限按各自公开合同核对。这些执行检查定位证据差异，不把每种不一致都解释为化学误解。

历史与保留证据层

历史广度研究包含 240 场 Sol-medium 研究，以及 Luna、Terra、GPT-5.5 和 Astra 的 60 场额外平衡研究，均请求 medium 推理强度。五模型平衡比较中的十五场 Sol 已包含在 240 场内。请求的模型标签不代表实际计算量相等。原 240 场包含电化学 60、分配 30、反应 60、平衡 45、结晶 30 和纯化 15 场；按其原规则保留 3,597/3,600 次最终测量、全部 720 个后测阶段与 238 场协议符合研究。额外六十场保留 720 批和 240 个阶段。两场原始源研究完成度失败仍予保留。更早的选定笔记案例另有 24 场，不与广度或保留平衡—结晶过程队列合并。

保留平衡—结晶过程队列由早期 48 场及其 42 场扩展中的 45 场平衡研究，以及统一回收描述后完整重跑的 45 场结晶研究组成。每个体系覆盖五世界、Opaque/Aligned/MisIndexed 三信息条件、每格三场，每场十二批。平衡保留 39 条完整链、41 份有效预测；修正版结晶分别为 41 和 42。该保留队列合计分母为 90 场、80 条完整链、83 份有效预测。旧结晶作为受协议影响的历史证据保留，不加入修正版计算当前结果或过程频率。

修正版结晶完成 510/540 个源批次、125/135 个后测阶段，保留 145 版笔记和 42 次推荐复测。全部 45 条源轨迹与 42 条复测轨迹通过重放。四条不完整链中，三条缺失预测，另一条有有效预测但缺失随后的反思。平衡子集与独立的研究机会块各自保留失败表。缺失不填零，已完成结果不由后来更有利的结果替代。稿件整合不改变任何实验块原有的开发或资格证据地位。

信息、自主性与记录

历史目标比较在世界、信息条件、批次预算和先验位置内，匹配独立开展的发现与优化研究。电化学的十二与二十四批条件合计三十对；反应处理的参数和结构先验块均采用十二批，合计三十对。操作结果来自封存推荐的独立复测。联合结果计数采用公开评分的预测 MAE，反应先验比较则采用六项归一化响应误差的平均值，两者不互换。预算比较同样涉及具有完整资源范围的独立会话，不估计继续同一项研究的作用。

历史五模型平衡比较包含五世界、三信息条件，每格一场十二批研究，共七十五场，其中十五场 Sol 已计入广度研究。1 mM 阈值描述实际测量的最低正投料名义浓度，不是发现判据。浓度按名义配方投料计算，三道极稀评估题在模型配置间相同。各条件的预测误差、原始预测区间与已获证据均保留。选定的 Astra 和电化学轨迹属于事后过程示例，其科学解释在实验后写成，不是同期笔记记录，也不是额外重复。完整历史设计、响应表和案例数值保留在补充材料。

Opaque 提供公开任务和操作背景，不提供额外实例资料。Aligned 提供与体系相符的部分信息；平衡包括有效酸度区间和带锚点的局部稀释关系。MisIndexed 使用另一世界的历史关系，格式与限定相同。结晶 Aligned 提供匿名材料名义描述，MisIndexed 交换 S1/S3 溶剂描述，保留 S0、S2 和催化剂描述。两者均不是完整世界规律。

原平衡 Opaque/Aligned 早于 MisIndexed 扩展；修正版结晶是更晚的完整实验块。这些描述性比较并非全部同期随机处理，新旧结晶也不能估计修正提示的因果作用。下文单列的新研究机会比较采用共同的同期协议。

智能体在固定预算内选择操作、用量、测量、重复与操作分组。平衡允许十二批、180 次操作尝试、十二次中间仪器与十二次最终测量；结晶采用固定十二批材料预算和 720 次尝试上限。记录角色要求在适用时先写出可检验预期，后续由智能体自主更新，不要求每批书写，也不自动重新注入笔记。记录角色可能影响研究，不被视为被动观察。笔记保存版本与公开事件游标，不揭示内部认知。没有调用笔记读取工具，不代表无法访问会话中此前出现的内容。

后测与回收定义

源研究及操作推荐结束后，智能体依次封存科学解释、在无实验工具条件下回答十二个固定新干预问题，再在没有真值反馈的情况下反思。平衡另有结构化补充评估。证据中的 K1/Q/K2/EQS 分别表示这些阶段。源研究期间不展示预测问题；后测提出的方案不计为已执行源实验。

平衡点误差以每题五个参考观测的均值为比较对象，覆盖率检查全部五次观测。结晶使用最终测量采样之前的无噪声完整流程响应，源观测则带噪声。修正版保留六十个参考批次，数值与旧参考一致，并对每份可用的已提交推荐单独复测。

修正后的回收定义为：扣除晶种贡献的固相目标产物摩尔量，除以所跟踪的初始试剂投料摩尔量，截断到 [0,1]。源指令、预测提示、观测与评分现在指向同一完整流程量。内部结晶阶段指标则以分离前的目标产物为分母。旧过程指令描述后者，而观测与评分使用初始投料；原分数作为受协议影响的诊断值保留，不进入修正版队列。修正版完整重跑，没有事后为旧分数更名。

质量要求有颗粒、纯度至少 0.80、细粉至多 0.50；联合推荐成功还要求修正定义的回收率至少 0.10。按可用复测，修正版联合成功为 Opaque 13/15、Aligned 10/14、MisIndexed 10/13，每臂仍各计划十五场。粒度采用公开指数 min(d50/250 微米, 1)，其误差不能写成微米。

研究路径与过程解释

我们追踪公开提出的关系与预期、实际实验、获得的观察、修订和后续用途。科学说明或准确预测本身不能建立这一序列。解释基于具体历史，不构成一般推理能力量表。新实验块的五条具名核心历史为纯化研究 A、B，反应研究 A 和电化学研究 A、B；补充材料将稳定标签对应到信息条件、完整公开记录、笔记版本、操作位置及批次序列。匹配世界研究 A、B 保留独立实验块中的身份与锚点。选例在完整阅读之后进行，仍是事后选择。早期 92 个行动关联窗口描述保留平衡—结晶队列的记录覆盖，平衡机会案例不属于该窗口队列。

事后解释历史案例组固定为主例平衡机会会话，以及修正版结晶队列中的四个案例：低投料、插值与两个对照的播种记述。我们沿五场研究追踪七项相关判断，保留全部笔记版本和终点修订。字段区分所解释现象、智能体实际提出的候选或预期、首次出现、条件性预测、执行操作、观测、后续地位与用途。没有给出的条件性表述保留为缺失，不由分析者补写。平衡的负载预期、组分假说和背景解释是同一探索的相连线索，不是三项独立发现。案例不是用于估计频率的抽样，不从窗口数量推断解释层面的发生率或可靠率。

操作语义核查使用保留的执行版本与轨迹机制身份，不以当前运行时假设替代。该世界只有一种非催化进料，试剂操作和组分 0 都选择它，并更新平衡响应计算读取的同一初始投料记录。因此，在同等投料下切换命令不改变物种身份。扩展数据图 5 的最终名义浓度为实际提交的摩尔数除以加入的总溶剂体积，分步稀释批次按最终 0.8 mol/L 展示。此核查不调用新模拟器实验。较低投料和正交测量仍是保留历史中未执行的提议；经验平台的支持范围与智能体提出的机制分别考察。

事后路径提取覆盖历史电化学六十场、平衡四十五场和修正版结晶四十五场。五十个世界内条件比较保留目标、预算、信息与队列。计数采用实际提交操作，溶剂覆盖包括再悬浮添加；拒绝请求不构成成功材料使用，中断会话保留在计划分母中。

结构提取检查保留九十场、268 版笔记构成的全部 178 对相邻版本。入选需要早期笔记、下一版之前至少一次新的已提交最终测定，以及后版之后的已提交研究操作；仅测量或终止不构成继续研究。178 对均有新增测定，其中 92 对满足继续研究：平衡 34 个窗口分布于 30 场，结晶 58 个分布于 35 场。另 86 对（平衡 44、结晶 42）之后没有继续执行已提交研究操作，完整记录仍保留在证据包。没有完整窗口的二十五场不被归类为没有学习。

入选先依据事件时序计算，不以某个计划是否最终成功执行为条件。但该规则确实要求后续继续开展已提交研究，因此终点修订不进入这一行动关联分母。92 个入选窗口全部编码；标签针对每个窗口选定的即时计划，不穷尽笔记里的所有提议：83 个匹配、7 个部分匹配、2 个无明确下一计划，其中修正版结晶为 52 个匹配、6 个部分匹配。即使某个所选行动匹配，完整笔记仍保留未落实、被拒及改变的其他提议。全部 182 条更新/计划引文及测定/操作游标经源记录核对；证据包包含全部相邻版本、所选编码、全文笔记和执行历史。

另对五条具名新历史及两条具名匹配世界历史进行内部复核，分别核对引文原句、笔记游标与实际比较的先后、操作参数、测量和后续说明或预测。公开材料保留完整笔记、批次动作与科学后测，并为每例列出支持的发现及范围边界。复核仍由同一助手流程承担，已知稿件及结果，不构成盲法或独立复核。

内部复核为事后、非盲分析，没有独立第二评分者一致性估计。反例包括合理撤回、正确识别未执行检验，以及准确但明确标为推测的外推。

匹配化学世界与解释历史

保留的匹配世界前瞻实验包含五组参数配对、两种化学网络、每世界三次 Sol-medium 新会话，共三十场。网络 A 将弱酸解离与自由离子直接沉淀耦合，B 额外包含中性水相离子对。每对的酸解离、溶度积、阳离子、活度和初态参数，以及公开操作契约相同。自主研究前提供两次实际起始测定，分别为 6×10^{-7} mol 配 0.080 或 0.075 L；配对的无噪声响应在每个通道相差不超过一个声明的终检标准差。任务提供化学背景与投料、稀释、尺度维度，不公开私有网络身份与参数。初始笔记因而位于给定观测之后，并非无证据前测。

执行候选的资格检查覆盖 230 个物理状态与测定、三十次精确重放及 120 项运行时均值核对。五次有界干扰参数重拟合中，受测直接网络族不能充分拟合网络 B；这不证明相对于所有替代解释均可识别。更早失败的物理候选单独保留。这些检查描述世界实际具有的信息结构，不描述智能体的学习。

每场十二个自主批次后，依次封存科学解释、十二道预测及不反馈真值的反思。源研究期间不展示题目，但智能体可能主动访问对应物理条件。三十场全部完成，合计 360 次源终检、九十个封存阶段及 1,080 条逐题逐响应预测。八十版笔记来自二十场各三版、十场各两版，不能假设每场都有连续中期修订。同一世界的三次新会话共享固定观测随机键，模型采样 seed 不可控。

实际源动作序列在自身及配对世界原样重放，三十次源回放与六十条自身/配对轨迹均通过。区分量为无噪声均值的绝对差除以终检标准差：归一化 pH 为 0.002，两项比例各 0.006。360 次终检中，326 次在至少一个通道达到三倍标准差，158 次在至少两个通道达到该值；三十场均包含后一类测定。阈值表示物理信息，不表示统计显著性或研究者识别了机制。反事实回放固定动作，不估计智能体面对另一种观测后会如何适应。

预测误差以每题五个保留参考观测的均值计算，区间覆盖检查全部五个观测；同世界会话共享这些参考。先在世界内平均会话，再对十世界等权。名义 80% 预测区间不是均值的置信区间，较高经验覆盖率必须与宽度一起理解，不能单独证明校准良好。该块没有无研究组，化学规律也不同于研究机会比较。

事后预测差异分析保留全部 1,080 条预测。对于五参数对、十二共同查询和三个响应，先在每世界平均三场预测，再计算 B 减 A，与五次参照观测均值之差比较。600 条实际参照操作序列均与共同查询定义一致。全部 180 个比较保留，包括零差、预测并列值和反向差异。幅度准确性用每响应全部六十个比较的预测差异与参照差异之间的平均绝对误差衡量。零差异参照为两个世界给出相同预测，其误差等于参照绝对差的平均值；相对误差降低为一减去两项汇总 MAE 的比值，不逐题除以很小的差异。另按参数对分别报告误差，呈现五对世界之间的变动。

描述性子集采用三倍单次测定标准差的参照差异门槛（pH 为 0.002，比例为 0.006），这是物理尺度而非显著性阈值。查询共享世界，若干终点浓度重复；每世界三场是模型采样种子不可控的新会话。分析测量最终预测对世界差异的敏感性；起始观测接近但不完全相同，且没有无研究组，因此不识别相对基线的变化或研究的独立效应。

结合实际动作，精读全部八十版笔记与九十个封存阶段；六十七条选定焦点历史保留 365 条经核对引文。另对 105 场既有研究的 309 版笔记进行回溯阅读，追踪 112 条选定历史和 218 个笔记锚点，四个选定封存后续增加十三个锚点。105 场由保留九十场与十五场研究机会会话组成，不是新增实验。历史可在同一会话内相互交叠，并包含终点修订；它们是按解释相关性选择的描述单位，不是独立发现或总体发生频率。初始预期、候选解释、经验关系、实际检验和后续使用分别记录，分析者不补入原文没有的因果或条件表述。

源操作共 1,901 次尝试：1,893 次提交、六次回滚、两次验证拒绝；另外 131 次恢复的工具故障单独计数。第一轮启动包含四场启动失败、二十六场未启动，没有科学操作；修复线程配置后，整块三十场重新执行。旧失败与资源记录完整保留，不因科学结果优劣替换已完成结果。

仅使用源观测的预测参照

对每份有效修正版结晶预测，只利用该研究者成功的源最终测量构建两个透明参照。第一个平均全部可用测量；第二个只平均与查询具有相同已提交溶剂标识集合的测量，无匹配时回退到整体均值。溶剂集合包括成功加溶剂与再悬浮操作，排除拒绝请求。拟合函数不接收测试真值。这些是描述性计算，不是另行训练的智能体或完整机理基线。

有效会话 42 场，共 504 题。同溶剂回退发生在 186/504 题，其中 Opaque 1/180、Aligned 95/168、MisIndexed 90/156。该匹配不控制热史、用量或最终液相组成，参照没有预测区间。回收、纯度、粒度和细粉均按各自公开尺度报告，不合成一个跨响应分数。

修正版分布分析使用同一组 42 场有效会话及其 504 次源最终测定。各响应公开源观测、逐题参考均值、预测、有符号误差和会话汇总。描述性合并均值与分位数保留重复的目标题目，不是独立条件估计。有符号误差为预测减参考值；世界等权均值先平均每会话十二题，再平均世界内会话，最后平均五世界。三场缺失预测仍保留在 45 的计划分母。计算仅使用修正版队列，不沿用历史结晶的纯度水平或偏差方向。

保留的平衡研究机会比较

固定设计为五个平衡世界、Research/NoResearch 两条件、每格三场 Sol-medium 新会话，共三十场，全部采用 Opaque 信息。共同公开背景包含任务及测量定义、材料目录、合法操作/仪器和初态，实例档案先验为空。Opaque 表示没有额外实例规律，不表示缺少公开化学背景或模型预训练知识。完整初始公开输入随稿提供；十五个世界内同重复配对在仅排除非科学会话标识后，确认科学输入一致。Research 额外得到十二批自主实验和既有笔记机会，NoResearch 没有源操作或观测；两组评估提示、模式、顺序与限制一致。

三十场全部终态，研究组完成 180/180 批，两组合计完成 117/120 个后测阶段、29 份有效预测。第三世界第三次 Research 在科学解释后出现预测流断连，Q 与随后两阶段缺失，没有替换。因此 Research 有十四份有效预测、NoResearch 十五份，Research 的第三世界为两次，其余每格三次。十五条源轨迹及二十五条参考轨迹（300 批）精确重放通过。29/30 场资源账本完整，另一场仅有已记录的部分用量；记录到的输入加输出共 13,428,656 tokens。缺失用量不按零处理，金额不可得。

首次执行尝试因评估传输配置缺少必要字段而失败。已启动四场、其中两场已完成的二十四批源研究和资源消耗单独保留，没有完成科学解释阶段。修复执行缺陷后，按原设计从头重跑整个三十场块。这属于协议修复，不是根据科学结果替换。仅完整重启后的实验块进入比较。

该比较估计共同评估条件下整段研究机会的作用，不能单独识别自主选择相对给定数据、反馈本身、笔记或内部表征变化。比较在新会话之间进行，没有会话内前测。世界与条件顺序采用事先固定的平衡启动安排，不是对世界规律进行随机抽样。

定量汇总与缺失

平衡宏平均绝对误差在指定问题中等权平均归一化 pH、解离分数和沉淀信号。极稀组为重复块执行前固定的三题，其余九题不被假定全部处于分布内。先在世界内平均有效会话，再对五世界等权。逐场数值和缺失阶段均保留。响应、问题、参考观测和批次嵌套相关，不能充当独立研究者样本。

名义 80% 区间同时报告覆盖率、平均宽度和适当区间分数 [22]。下界 l、上界 u、观测 y、alpha = 0.2 时，分数为 (u-l)，若 y 低于 l 加上 (2/alpha)(l-y)，若高于 u 加上 (2/alpha)(y-u)，越低越好。汇总按世界等权；智能体区间不是组均值的置信区间。

事后敏感性分析允许唯一缺失的研究机会预测取 [0,1] 内任意宏平均误差，并按每格计划三次和五世界等权重算。有研究减无研究的保守范围，总体为 [-0.098659, -0.031992]，极稀为 [+0.036768, +0.103434]。这是缺失结果影响的界限，不是填补、置信区间或总体推断。固定条件下三次会话描述波动，不建立总体可靠率。

匹配淬灭干预

独立保留的对照将原第一期十八份结晶推荐置于五个世界中，比较有无单个淬灭操作，共九十对、一百八十条轨迹。其他动作参数和初态匹配；淬灭从原位置删除，或插入首次播种/结晶冷却之前。没有智能体适应，也不向智能体反馈结果。

全部轨迹保留并重放，七十五对具有两侧最终测量。五对无淬灭侧缺颗粒，十对有淬灭侧使后续固定冷却请求失效，失败不修复。完整对中，有减无的平均细粉变化为 +0.30937、回收变化为 +0.00741，联合成功从 34 降至 4。这些条件性效果描述实际初始投料回收口径下的物理操作。淬灭改变多个物理状态量，不单独识别冷却速率或科学判断的成因。供体配方来自历史队列，不来自修正版。

数据与代码可用性

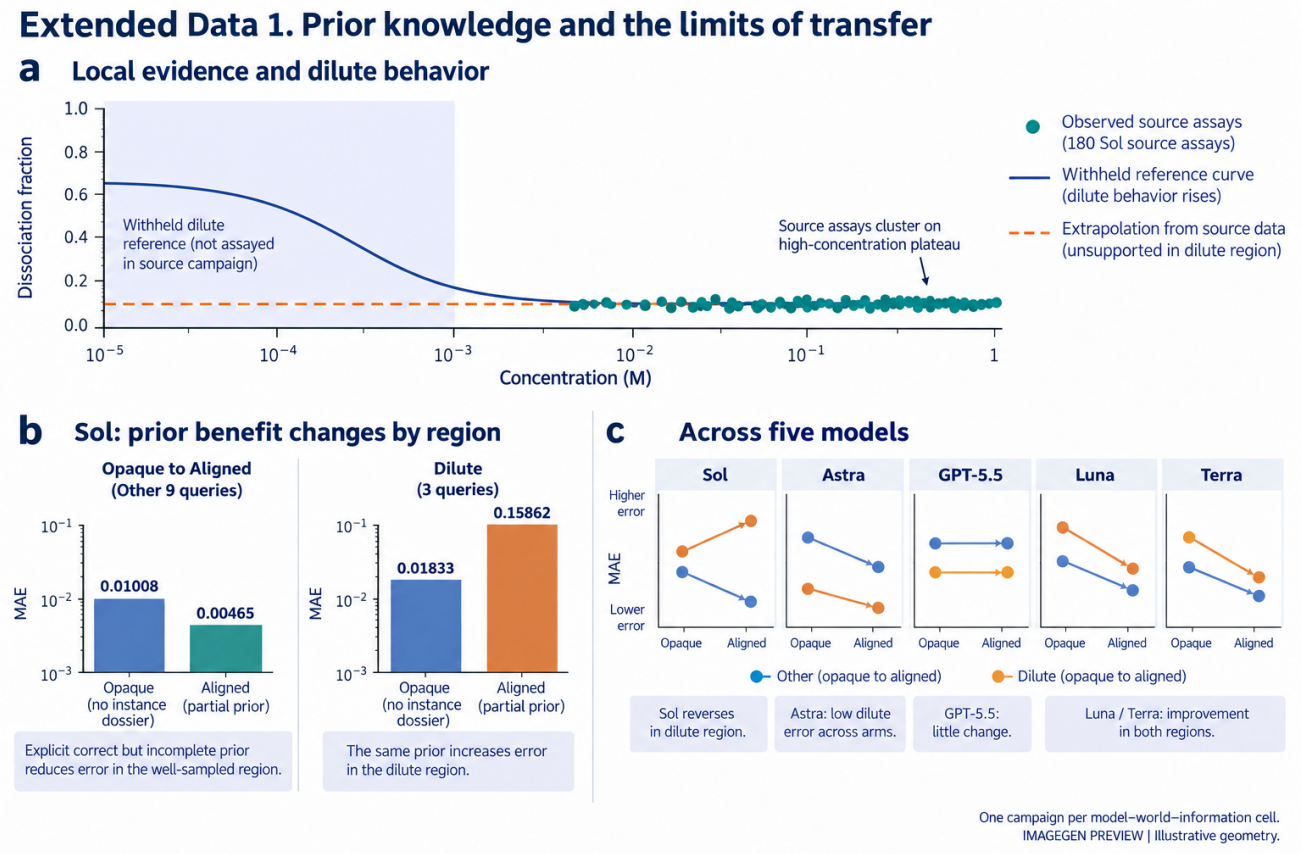
随稿证据包包含新增 300 场机器摘要、全部 1,380 个计划会话—响应行、推荐结果、失败、完整整理的公开经历、语义精读与引文锚点，以及五体系覆盖表和四矩阵设计。保留平衡机会数据、旧 90 场过程队列 178 对相邻笔记、修正版结晶分布与 30 场匹配世界经历分别可查。缺失明确保留；公开科学内容纳入，原始提供方封包和凭据不纳入。原回放与资源记录保留在项目证据位置，永久公开存档仍待落实。

本稿五张主图与八张扩展图均为已标注的 ImageGen 预览。数值标签依据保留结果，生成的几何、曲线和会话点仅作示意。数值表与源记录提供精确数据，图 2、4、5 的数据绘图另存为核对底稿。补充材料分别说明各实验块，并保留全部 34 张历史数值表。

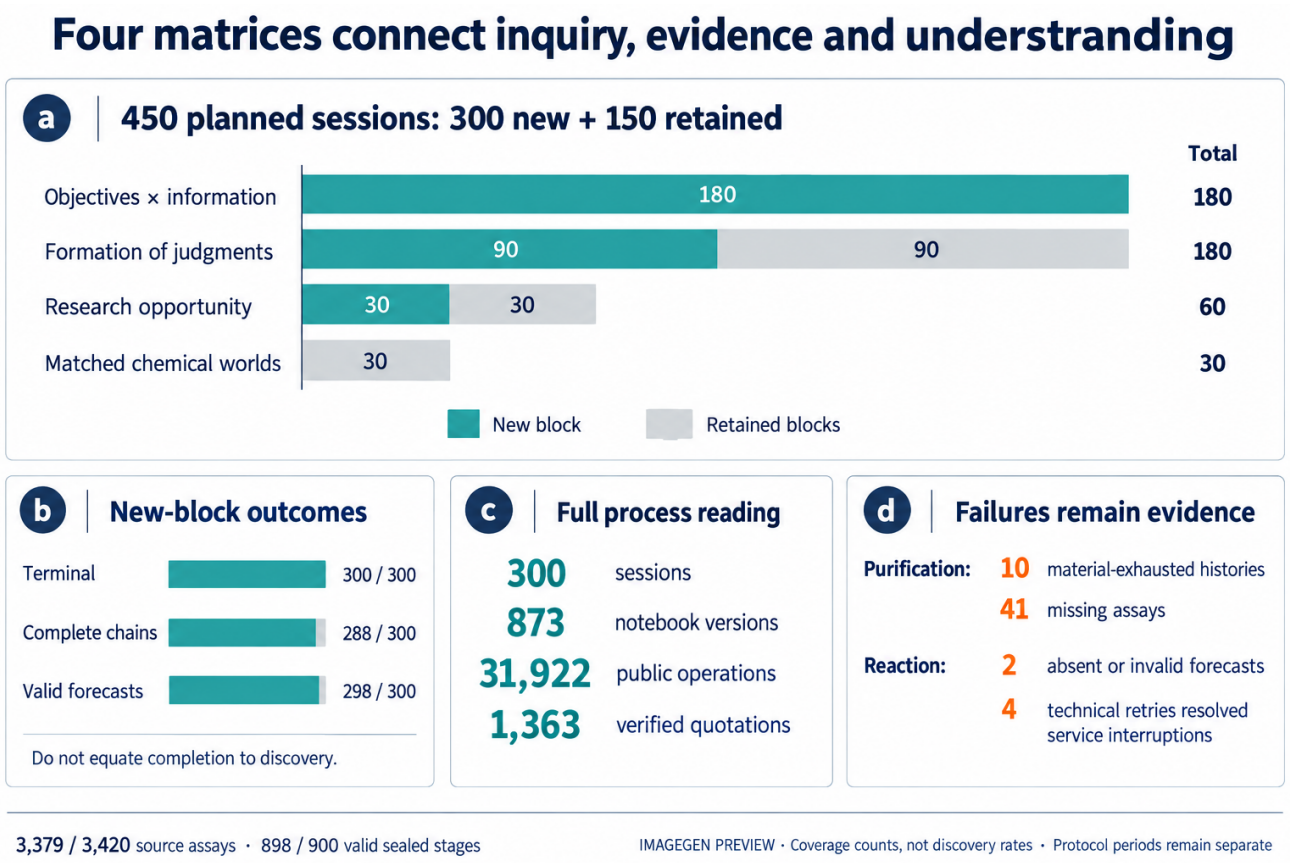
资助

本研究获得深圳市科技计划项目（AI2026004）、清华大学自主科研计划，以及青年教师科研创新能力支持项目（ZYGXQNJSKYCXNLZCXM-E7）资助。

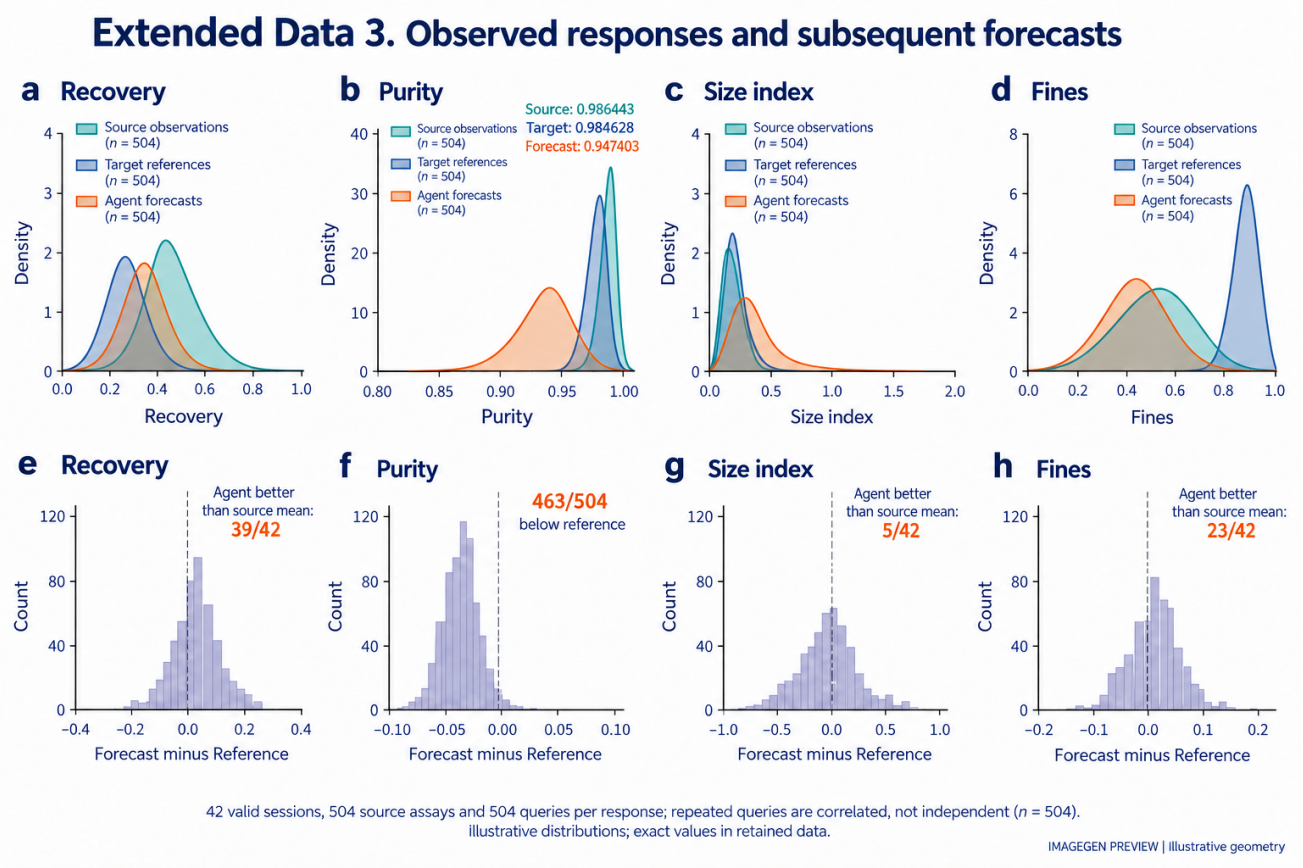
扩展数据



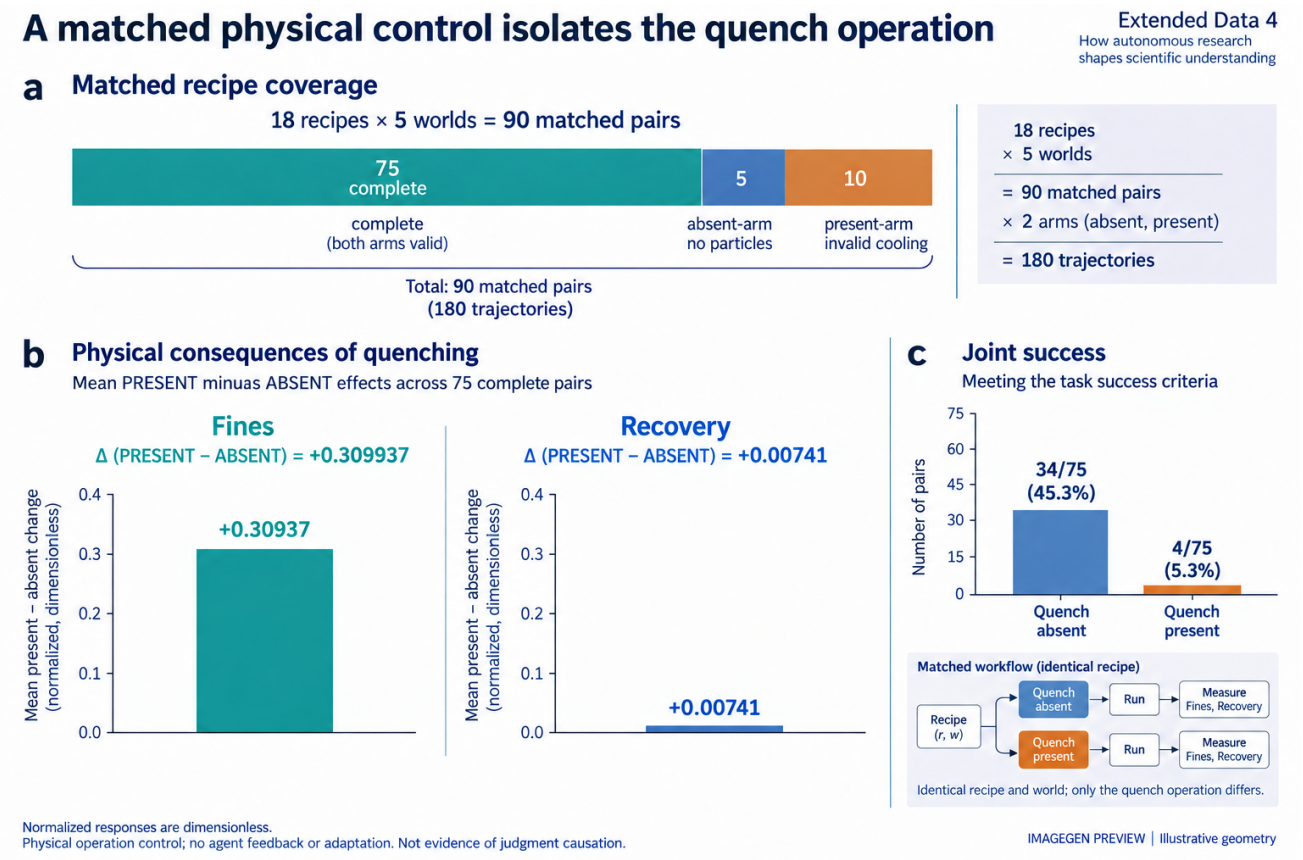
扩展数据图 1 | 局部先验与迁移范围。a，局部平台、极稀参照行为与未经支持的延续示意。b，历史 Sol/Opaque 与 Aligned 在两组条件的误差。c，五模型的定性模式，不是数值效应估计。历史各条件仅一场；极稀分组在该队列中为事后划分，在后续重复块前固定。本图不合并重复队列估计。ImageGen 预览：几何仅作示意，精确数值见保留证据。



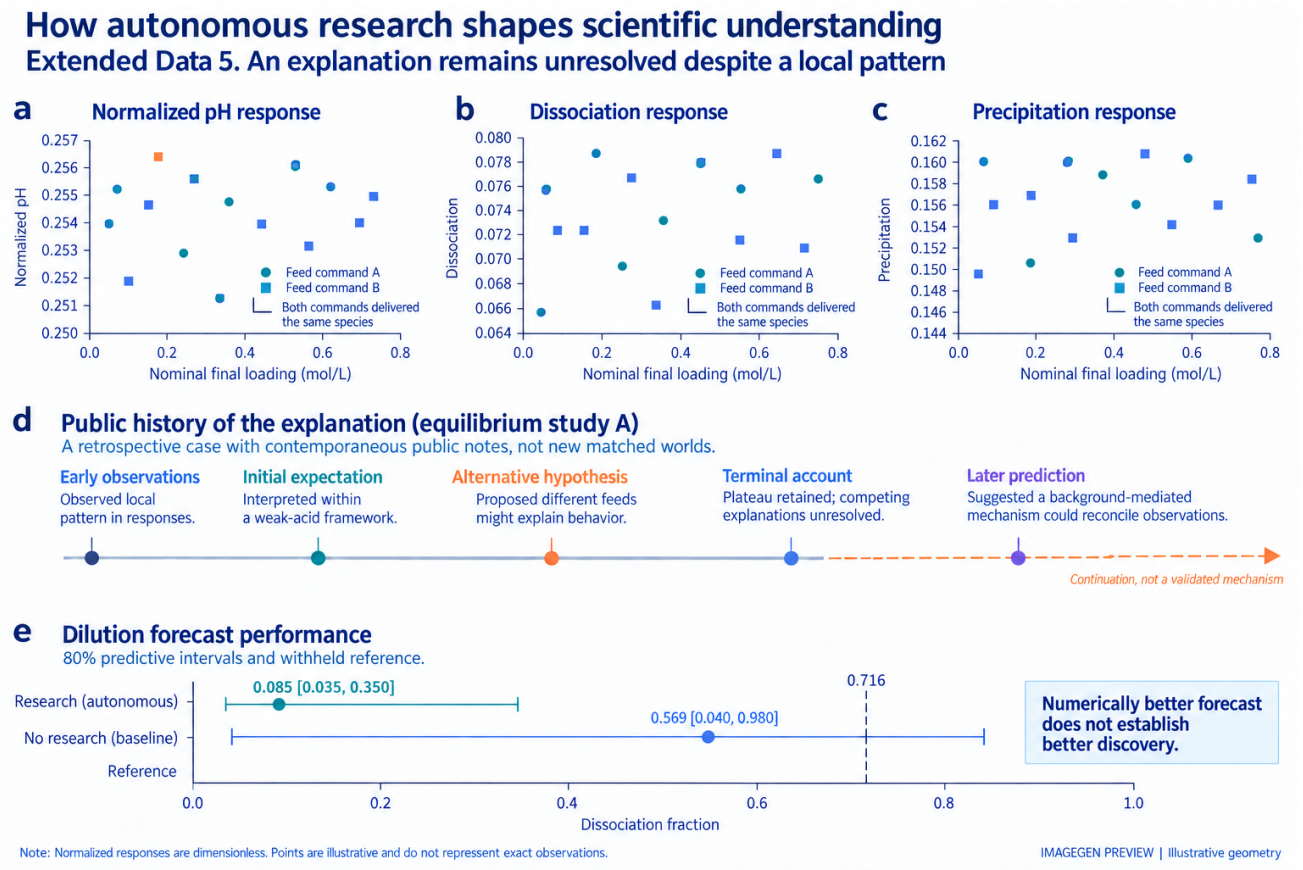
扩展数据图 2 | 整合设计与新实验覆盖。a，四矩阵共 450 场计划研究，新增 300 场、另 150 场按独立协议保留。b，新块保留 288 条完整链与 298 份有效预测；完成不等于科学成功。c，完整精读覆盖 873 版笔记和 31,922 条公开操作，核对 1,363 处引文。d，十场纯化因材料耗尽缺少 41 次终检，两场反应预测缺失或无效。四场服务中断经技术补跑解决，不替换科学结果。ImageGen 预览：几何仅作示意。



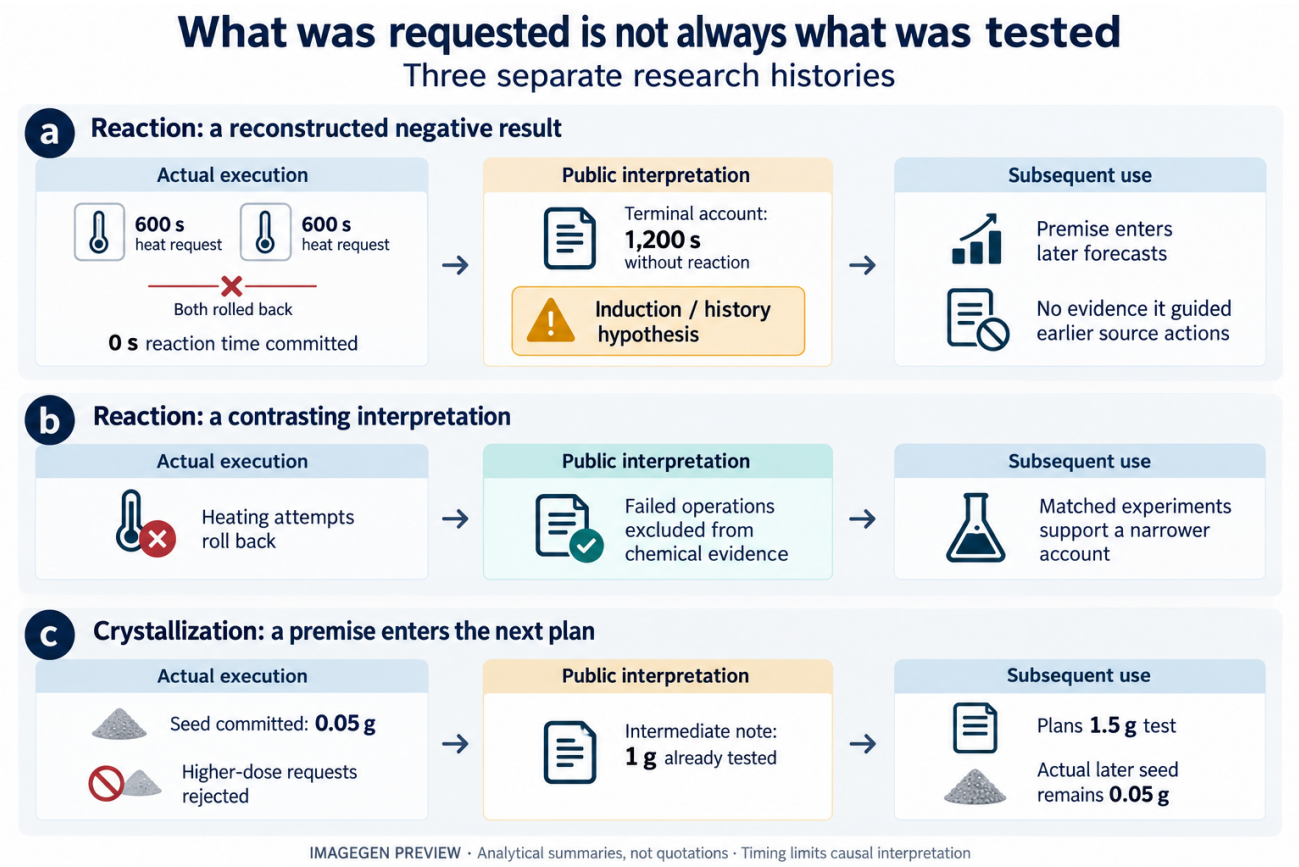
扩展数据图 3 | 修正版结晶响应分布。a–d，源观测、目标参照与智能体预测的分布示意。e–h，有符号误差分布示意，其几何与分箱计数不是实测值。保留队列含 42 份有效预测，每响应有 504 源测定和 504 题；共享目标不是独立研究者样本。数字标注来自保留汇总；粒径为无量纲指数。三份缺失预测仍计入 45 场计划分母。ImageGen 预览：几何仅作示意，精确数值见保留证据。



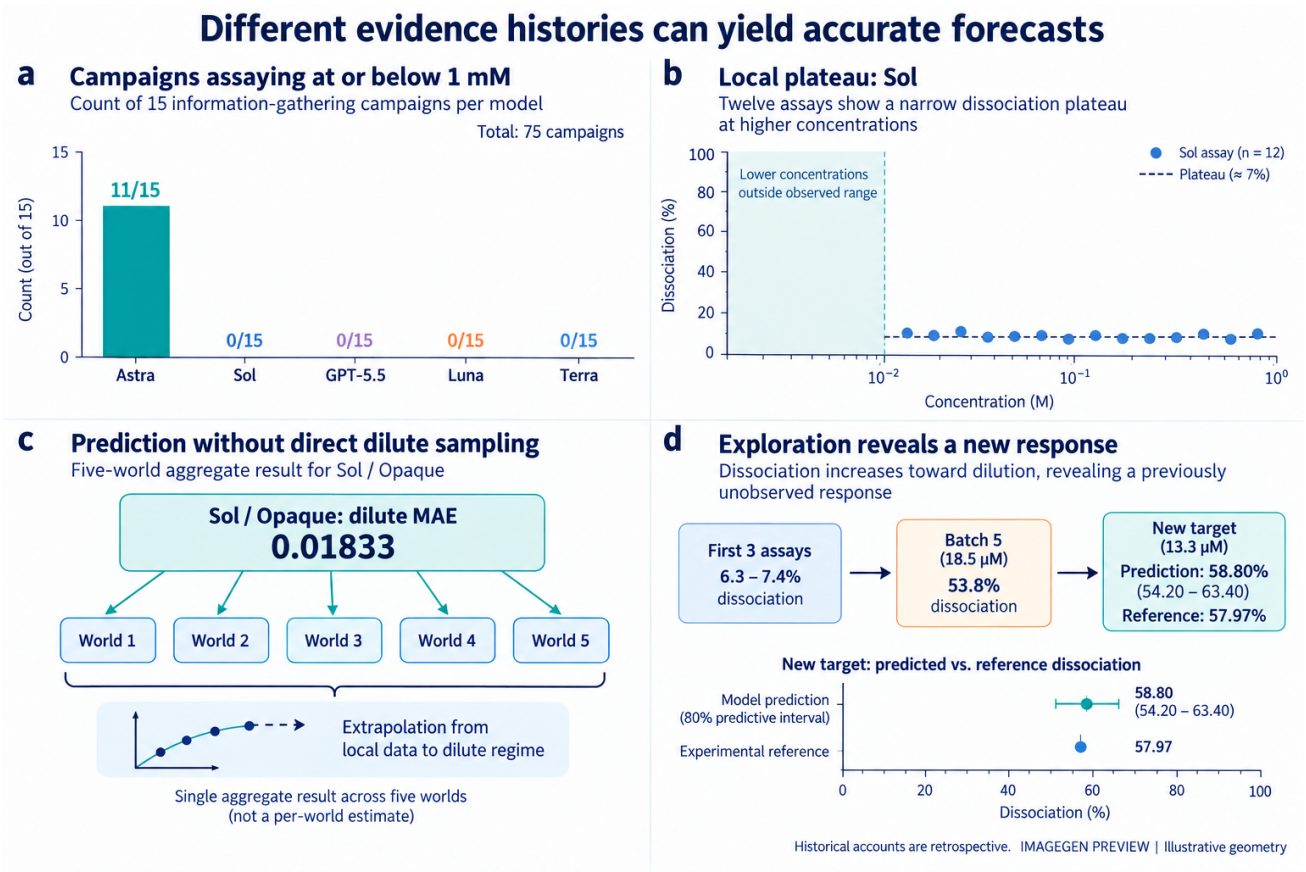
扩展数据图 4 | 淬灭操作的匹配物理效应。a，十八个历史配方在五世界形成九十对，七十五对完整，五个无淬灭组无颗粒，十个有淬灭组使后续冷却无效。b，完整配对中有淬灭减无淬灭的平均变化。c，同一 75 对中的联合任务成功。结果采用已实现的初始投料回收口径；智能体未适应或接收这些结果，不据此推断判断形成效应。ImageGen 预览：几何仅作示意，精确数值见保留证据。



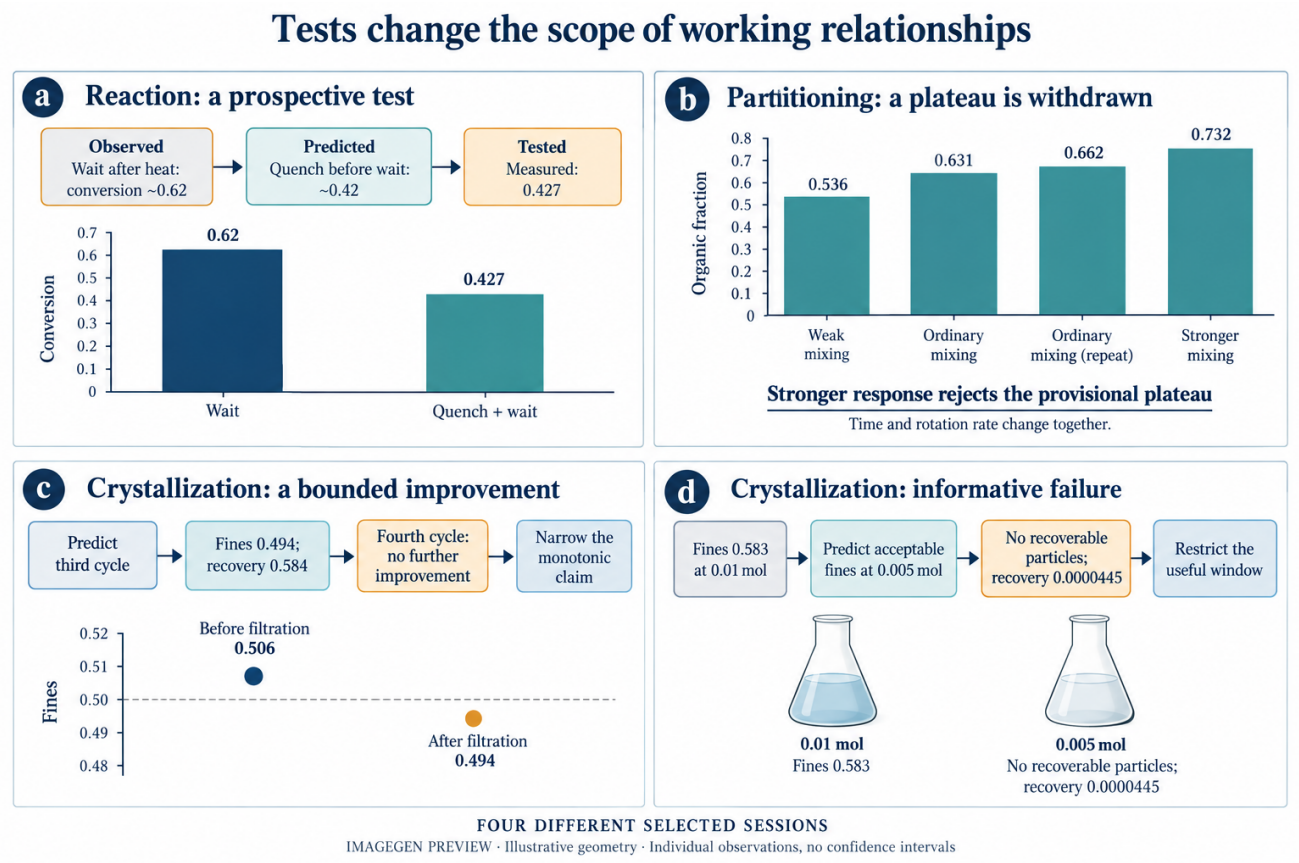
扩展数据图 5 | 局部模式与未解决的解释。a–c，平衡研究 A 的源响应模式示意；试剂命令与组分命令在该执行版本中加入同一物种。d，公开历史从初始预期连接终点未决与后续使用；文字为分析概括，不是额外引文。e，保留的极稀解离预测、原始 80% 预测区间与封存均值。数值准确性不建立发现机制。ImageGen 预览：几何仅作示意，精确数值见保留证据。



扩展数据图 6 | 重建实验实际检验了什么。a，一场反应的两次回滚加热在终末说明中成为 1,200 s 阴性结果，后来预测引用诱导期或历史解释。b，另一场将回滚加热排除在化学解释之外。c，一版结晶中途笔记在实际仅提交 0.05 g 时声称已检验 1 g，再提出更高剂量。时点区分后来预测用途与后续源行动受到影响。焦点加热返回同时含外层成功及完成标识、明确回滚错误和零时间及温度变化；这是接口呈现与经历重建的共同证据。不同经历并非随机纠错组。ImageGen 预览：文字为分析概括，几何仅作示意。



扩展数据图 7 | 从证据到预测的不同路径。a，各模型 15 场中到达不高于 1 mM 的数量。b，示意性的局部解离平台。c，Sol/Opaque 极稀 MAE 是五世界汇总，不是每世界单独数值。d，一场 Astra 研究的选定阶段、封存预测及原 80% 预测区间。历史科学说明为事后记录；结果不建立固定模型特征。ImageGen 预览：几何仅作示意，精确数值见保留证据。



扩展数据图 8 | 检验改变工作关系的范围。a，事前淬灭—等待预期为转化约 0.42，实际为 0.427。b，更强混合使分配平台预期被撤回，时长与转速仍混杂。c，第三次结晶热循环取得近阈值结果，第四次未继续改善。d，进一步稀释未保留可回收颗粒，收窄拟议操作窗口。各面板为不同选定研究；数值是单次观测，不是处理均值或置信区间估计。ImageGen 预览：几何仅作示意，精确记录随稿保留。