

可编程化学世界：从实验自主性走向科学理解

Jiangjie Qiu^{1,†}, Yijun Li^{1,†}, Yaotian Yang^{1,†}, Honghao Chen¹, Wentao Li¹, Xiaonan Wang^{1,*}

¹ Beijing Key Laboratory of Artificial Intelligence for Advanced Chemical Engineering Materials, State Key Laboratory of Chemical Engineering and Low-Carbon Technology, Department of Chemical Engineering, Tsinghua University, Beijing 100084, China

[†] Jiangjie Qiu, Yijun Li 和 Yaotian Yang 为共同第一作者。

* 通讯作者: wangxiaonan@tsinghua.edu.cn

摘要

自驱动实验室正日益自主决定开展哪些实验、获取哪些证据。然而，设备与流程约束、实验成本、安全要求和未知机制，使其科学学习难以在真实实验室中得到系统检验。我们提出 ChemWorld，在可组合、可编程的化学世界中连接实验自由与评价者的独立控制：智能体在持续演化的样品上组合操作，评价者则分别配置过程规律与所提供的信息。通过跨体系研究与五种模型配置的定向比较，我们将自主研究历史连接到操作成果和新干预下的封存预测。更好的实验成果并不必然伴随更准确的预测。在一种平衡研究配置中，正确但不完整的先验改善了一个区间的预测，却在极端稀释条件下使误差达到无该先验时的 8.7 倍。五种配置在同一任务中形成了不同的证据获取与外推模式：准确预测既出现在未直接采样新区间的研究中，也出现在通过自主实验观察到响应变化之后。结晶则揭示了另一方向的偏离：实验已确立近乎恒定的纯度水平，预测却系统性低估它。这些发现揭示了自主研究者延伸或偏离实验证据的不同方式，使可编程化学世界成为研究科学学习的实验仪器，并指向能够检验所得关系何时应当延续、何时需要修订的实验规划。

引言

自驱动实验室通过自动化执行与自适应实验规划，拓展着实验科学的能力边界^{1,2}。机器人科学家已经能够生成生物学假设并通过实验检验³，后续平台也展示了自主材料搜索与反应优化⁴⁻⁷。移动机器人还可结合互补的分析仪器开展探索性合成⁸。语言模型智能体连接科学指令、工具与实验室操作^{9,10}，多智能体研究团队则已设计出随后接受实验验证的生物分子¹¹。随着系统获得选择操作顺序、中间测量和后续实验的自由，它们也越来越多地塑造自身的研究路径。这一科学机遇从执行流程和优化条件，延伸到了决定获取哪些证据，以及这些证据意味着什么。

更大的实验自由度也使科学学习更难评价。不同研究路径可能获得同样成功的操作结果，却揭示化学体系的不同侧面。一个有效配方既可能来自可迁移的解释，也可能来自仅在局部有效的经验规则。面向决策的学习同样区分预测误差与使用预测所作决策的质量¹²。真实实验室提供丰富的发现可能性，但每一种已实现的工作流程都受到设备、材料和操作程

序的实际约束。未知机制、持续演化的物料状态以及重复实验的成本，使得我们难以受控比较自主研究者如何获取和使用证据。因此，理解它们的进步，需要把实验成就与产生这些成就的研究历史和判断连接起来。

我们将自主实验获得的认识与新干预下的预测连接起来，研究智能体的科学学习。同一研究者的实验历史和公开科学报告揭示其获取了哪些证据，以及如何将这些证据用于尚未测量的条件。信息增益准则与自适应设计策略为选择有信息量的实验提供了形式化方法¹³⁻¹⁵，强推断则强调通过实验区分竞争假设¹⁶。这些研究传统提示我们，应将证据获取与据此形成的结论一同评价。

现有基准评价这一过程的不同组成部分。ChemBench 通过问答评价化学知识与推理¹⁷，DiscoveryBench 评价基于给定数据集的假设发现¹⁸。优化基准提供可重复的目标函数^{19,20}。交互式化学与科学发现环境支持多步实验²¹⁻²³；BoxingGym 将实验设计连接到模型发现及基于解释的预测²⁴。Science-Gym 评价主动数据采集与方程发现²⁵，PhysGym 则在交互式物理发现中明确改变所提供的先验知识²⁶。

ChemWorld 将这一研究带入具有持续样品状态和灵活操作的可组合化学过程。评价者对兼容世界规律与所提供信息的控制，支持研究条件之间的匹配比较。我们跟踪同一研究者，从自主选择实验操作，到推荐的独立复测以及新干预下的封存预测。完整操作历史使这些结果能够与研究者的实际获取的证据联系起来。

我们的结果连接了自主科学学习的两个特征。实验成果与预测准确性可能对同一组研究者给出不同排序；面对相同的化学世界，研究者还会获取不同证据，走向不同的外推路径：有的将局部平台延伸到其已经失效的条件，有的从局部观测准确外推，还有的先通过实验遇见新的响应，再对其作出预测。结晶研究进一步揭示了另一项困难：当实验所得关系仍然稳定时，如何在预测中保留它。追踪这些路径，使我们能够研究自主研究者如何判断哪些关系应当延续、哪些需要修订。

结果

追踪受控化学世界中的自主实验

ChemWorld 将化学过程构建为可组合、可操作的实验世界。反应、热过程、相平衡、分离、结晶等组件通过兼容接口连接，共同维护物料、能量与样品状态。研究环境既可以支持单一过程的表征，也可以将反应与萃取、洗涤、浓缩或结晶连接为多阶段流程，使上游操作的后果传递到下游处理与最终测量。通过配置过程组件、连接关系、模型参数和可用仪器，平台能够构建不同的研究环境，并通过增加过程模型和观测组件持续扩展。

智能体在这些世界中自主组织实验：选择材料与投料比例，调整操作参数与流程顺序，并根据中间结果决定继续处理、重复实验或终止当前实验。样品状态在操作之间持续保留，使反应、热处理与分离历史共同影响后续结果。测量同样需要主动选择，不同观测通道具有各自的信息、噪声和资源代价，研究者因而需要同时考虑实验进展与证据获取。评价者则独立配置兼容的过程规律与公开信息，支持在相同世界中比较不同研究条件，或在共用公开接口下改变隐藏规律。完整的操作、观测和资源记录将研究者的选择与其后果连接起来，并支持环境轨迹的精确重放（图 1）。

本研究的跨体系部分采用 GPT-5.6 Sol medium，在六类化学体系中开展 240 场自主研究；平衡参数任务进一步纳入四种模型配置的 60 场研究，用于比较证据获取与外推行为。各研究块包含五个世界和三种信息条件：Opaque 不提供额外的实例特定先验，Aligned 提供正确但不完整的信息，MisIndexed 提供固定的错配信息；各组均保留开展实验所需的公开操作约定。研究结束后，按任务要求对封存的推荐方案进行独立复测。原始研究者保留自己的实验历史，随后提供科学报告、新条件下的封存预测与回顾性反思，期间不获得参考结果反馈。由此，操作成果与预测判断能够追溯到同一研究者实际获取的证据。完整实验矩阵、资源配置与评价协议见方法。

一场 12 批次结晶研究展示了研究者如何调整实验流程（图 2）。前四批均因细晶过多而失败；第 5 批改变了包括冷却与加种顺序在内的多项条件，首次获得可行结果。第 8 批的回收率进一步达到 45.5%，封存配方在独立复测中获得 43.9%，并继续满足质量约束。随后减少溶剂又导致质量约束失守。研究者对连续干预的选择，同时塑造了实验结果及其后续科学判断所依据的证据。




图 1 ChemWorld 作为自主科学研究的受控实验仪器。**a**，固定数据集、真实实验室与单一终点评分所带来的评价挑战。**b**，自主研究将实验选择、过程执行、测量和证据驱动的调整连接在一个具有持续状态的物理世界中。隐藏规律与公开信息可分别改变，研究历史可被重放，操作表现、预测与不确定性分别评价。对于有此要求的任务，操作推荐先封存并独立复测。随后，原始会话在保留研究历史的情况下，依次提供科学报告（K1）、封存预测（Q）和回顾性证据反思（K2）。Q 和 K2 均不接收目标结果反馈。**c**，匹配世界下的信息条件、独立的 12 与 24 批次研究资源配置，以及 Sol medium 在六类体系中的 240 场研究与四种额外模型配置的 60 场定向平衡研究。图内“Mismatched information”对应 MisIndexed。预算比较仅适用于同时具有两档资源配置的体系。完整矩阵见方法及补充表 A1、F3。




图 2 一场完整的自主结晶研究。a, W04/MisIndexed 会话中全部 12 批来源实验的最终检测结果。青色表示满足质量约束，赭色表示失败；虚线为 50% 的细晶比例上限。第 5 批首次可行，第 8 批被封存为推荐方案，第 11 批违反细晶约束，第 12 批重复所选配方。b, 第 8 批的全部 12 次操作调用，归为 10 个可见阶段。中间粒径检查为 26.6% 细晶，最终检测为 25.4%；温度为请求的目标值。独立复测使用该封存配方和不同的观测随机种子。c, 三组“观测、后续行动、结果”序列。问题由作者根据操作记录重建，K1 在实验结束后撰写。回收率扣除晶种贡献。可行性要求纯度至少 80%、细晶比例至多 50%，且存在颗粒；细晶指小于 20 微米的颗粒。案例选择与工艺变化的解释见补充方法说明。

操作与预测收益不必同步

我们首先考察，研究者交付更好的实验方案时，是否也能更准确地预测新条件下的结果。在允许选择材料并调整电学或热处理条件的电化学与反应任务中，研究者分别以形成并检验科学认识（discovery），或获得高得分流程（optimization）为优先目标。两类研究在匹配条件下独立开展，随后分别评价推荐方案的复测得分和新条件下的得分预测误差（图 3）。在 30 对电化学研究中，optimization 有 26 对获得更高的复测得分，其中 13 对的预测平均绝对误差（MAE）也更低，另外 13 对却更高。在反应处理中，discovery 则在 30 对中的 17 对上同时获得更好的复测与预测结果。两项评价区分了单一实验成功指标会混为一谈的研究成果。




图3 研究目标、操作结果与预测判断。a、b，电化学（a）和反应处理（b）各30对匹配研究，覆盖五个世界。正差值表示优化委托在相应终点上更好；象限文字标明表现较好的委托，圆环标出选定案例。c，两个独立的12批次研究中的全部批次得分、记录的操作变化，以及封存推荐的独立复测。连线连接相邻观测；探索研究第11-12批包含分段电解与中间测量。d，优化研究的全部12个原始预测、标称80%预测区间和留出参考观测。理由概括自随后与Q预测一同提供的公开回答。阴影标出电学设置相同而材料组合不同的四个查询，其中同时保留一个准确预测与若干低估。配对固定世界、信息组、预算和先验作用位置。计数与参考值定义见方法。

一个电化学配对将这种差异与实际研究路径联系起来（图3c、d）。Discovery先比较材料与条件，再延长时间并提高电流上限；optimization则在筛选材料组合后，进一步调整有潜力组合的操作条件。Optimization最终交付了复测得分更高的方案，得分为0.756，discovery为0.718；其预测MAE却更高，分别为0.229和0.088。在若干交叉组合实验表现较差后，optimization研究者的公开预测理由将这些组合归为低活性。对于新条件下一个先前测过的组合，它给出0.070的预测，参考值为0.494；对另一个组合，预测与参考值则分别为0.570和0.572。两个独立研究结束时，操作与预测给出了相反的排序：optimization的推荐方案复测得分更高，discovery对新条件的预测更准确。

增加研究资源同样没有使两类收益同步。在独立的 12 与 24 批次研究比较中，电化学、相分配及结晶的部分预测得到改善；但结晶推荐的可行数量没有增加，平均复测回收率也未提高（补充图 S4）。实验资源能够改善预测，却不必同时改善最终交付的方案。

相关科学知识也能够提供实质帮助。在反应参数先验研究中，Aligned 将 discovery 与 optimization 的宏平均预测 MAE 分别从 0.102 降至 0.057、从 0.139 降至 0.084；两种委托下均在五个世界中的四个优于 Opaque（补充图 S2a、b）。资源与知识由此提供了改善预测的具体途径，与复测揭示的流程改进共同构成研究成果。接下来的问题是，研究者如何将实验所得关系用于尚未观察过的条件。平衡任务使这一外推过程变得直接可见。

同一化学任务产生不同的证据获取与外推路径

在平衡任务中，研究者可以改变投料、稀释与加料顺序，随后预测新条件下的 pH、电离分数和沉淀响应。过程规律始终不变，但进一步稀释会改变电荷平衡中各项贡献的相对大小，使电离响应离开高浓度下的局部平台。Sol 的 15 场研究中，180 次来源检测均处于高于 0.018 M 的名义浓度，电离分数集中在 5.5% – 9.2%；最低浓度测试条件下的参考均值则在五个世界中达到 44.8% – 71.6%（图 4a）。这使我们能够区分研究者实际观察到的关系与新条件要求的外推。

在 Sol 的研究中，正确先验的预测收益在不同测试区间发生了反转。Aligned 将其余九个条件的宏平均 MAE 从 Opaque 的 0.01008 降至 0.00465，却将三个最低浓度条件的误差从 0.01833 升至 0.15862，约为 8.7 倍；两个方向均出现在全部五个世界中（图 4b；补充表 F2）。三个最低浓度条件的标称 80% 区间覆盖率也由 Opaque 的 93.3% 降至 Aligned 的 2.2%。原始回答显示，Opaque 能在未实际采样稀溶液的情况下外推电离分数的上升，Aligned 则主要延续平台或弱局部趋势（补充图 S8c）。其中一个 Aligned 回答虽承认平台未必延伸至零投料，仍给出 8.04% [5.30%, 10.80%] 的预测，而参考均值为 65.46%。这份回答在解释中承认了平台的适用边界，却在封存预测中继续延用了平台水平。

五种模型配置在相同科学条件下呈现出不同的泛化模式（图 4c；补充表 F3）。我们在同样的五个世界、三种信息条件和每场 12 批次额度下，将 Sol 与 medium 配置的 GPT-5.5、GPT-5.6 Luna、GPT-5.6 Terra 和 GPT-6 Astra 比较。Sol 呈现强烈的先验收益反转；Luna 和 Terra 则在两组查询中均因 Aligned 而降低平均误差，GPT-5.5 的变化较小。Astra 在三种信息组下均保持较低的最低浓度查询误差，MAE 为 0.01857 – 0.04040，原始区间覆盖率为 82.7% – 92.4%。同一任务与信息协议由此揭示了研究者使用科学知识的不同表现：先验可以在两个查询区间均带来收益，也可以在区间之间发生收益反转。




图 4 局部证据、先验收益反转与跨模型的不同外推模式。**a**, Sol 的 180 次来源检测与 12 个留出条件, 后者显示五个世界的参考均值及样本标准差; 阴影标出三个最低浓度条件。**b**, Sol 在其余九个条件与最低三个条件上的宏平均 MAE, 倍数比较 Aligned 与 Opaque。**c**, 相同世界、信息与预算协议下的五种模型配置, 每个查询组均保留三种信息组。**b**、**c** 的柱形显示五个世界的均值, 对数轴从 0.001 起; 宏平均 MAE 对归一化 pH、电离分数和沉淀信号等权平均。统计单位、分组构建及完整数值见方法和补充表 F2–F3。

实验历史进一步揭示了证据获取的差异。Astra 的 15 场研究中有 11 场对不高于 1 mM 的正投料样品进行了检测, 其余四种配置各自的 15 场研究中均为零场 (图 5a)。

Sol/Opaque 则从局部观测出发准确预测了稀释响应, 三个最低浓度条件的 MAE 为 0.01833 (图 5b、c)。准确外推因此也出现在从未直接采样该区间的研究中。

一场 Astra 研究展示了先获取新证据、再作出外推的另一条路径 (图 5d)。在世界 3/MisIndexed 会话中, 前三批的电离分数为 6.3%–7.4%。第 5 批将浓度降至 18.5 μ M, 测到 53.8%; 后续批次返回较高浓度, 并探索分段稀释、追加投料与延长等待。随后形成的公开科学报告区分了高浓度平台和低浓度响应。研究者继而对 13.3 μ M 给出 58.80% [54.20%, 63.40%] 的封存预测, 参考均值为 57.97%。这条记录将自主观测到响应变化、在科学报告中识别这一变化, 以及对新条件作出准确预测连接起来。

仅看预测准确性, 会掩盖这些研究路径的差异。Sol/Opaque 准确外推至观测范围之外, Astra 案例则先取得平台之外的证据, 再预测变化后的响应。将预测连接回实验历史, 才能同时看见通向成功结果的不同路径, 以及在稀释条件下失准的局部规律延伸。




图 5 自主实验与准确外推的不同路径。**a**，每场研究实际检测过的最低正投料名义浓度。每个模型有三个信息组箱线图，每箱包含五个世界：箱体为原始尺度的四分位区间，中线为中位数，须为最小值至最大值，纵轴采用对数刻度。虚线和计数标出 1 mM 这一描述阈值。**b**，Sol 世界 1/Opaque 的 12 次检测呈现局部观测平台。**c**，Sol/Opaque 在五个世界中对 13.3 μM 的预测、原始 80% 预测区间与参考均值；阴影覆盖这些来源研究的电离观测范围。**d**，Astra 世界 3/MisIndexed 研究的全部 12 批电离分数（左轴）和名义浓度（右轴，对数刻度），以及实验结束后的 K1 报告与随后对 13.3 μM 的封存 Q 预测。报告文字概括自公开报告，预测保留原始 80% 区间。这些回顾性选取的案例将已获取证据与后续预测连接起来；案例选择和轨迹分析见方法。

预测系统性低估了实验中稳定的纯度

平衡研究揭示了预测观测范围之外响应变化的挑战；Sol 的结晶研究则揭示了保留稳定关系的另一项困难。来源与留出条件下的平均纯度分别为 98.53% 和 98.51%，各世界留出纯度范围的平均跨度仅为 2.44 个百分点；12 与 24 批次条件下的预测均值却分别为 93.54% 和 94.89%，360 次预测中有 335 次偏低（图 6a）。

同一批研究中，回收率与纯度的对照显示了这一偏离的响应特异性。我们以每场研究自身的公开最终检测均值作为基线，对其所有留出条件给出同一预测，不使用额外实验或留出结果。智能体的回收率预测在 30 场研究中的 26 场优于该基线，纯度预测却没有任何一场更好（图 6b）；纯度的平均 MAE 分别为 4.35 和 0.48 个百分点。同一研究者能够对变化的回收率作出超出均值基线的有效预测，却未能可靠保留实验已呈现的稳定纯度水平。

纯度误差主要表现为整体向下偏移。平均有符号偏差为 -4.29 个百分点，各研究整体偏移项合计占总平方误差的 87.6% （补充表 G2）。信息条件与研究预算会改变回收率和纯度的相对表现，预测区间也未能可靠容纳纯度误差（图 6c、d）。Aligned 与 MisIndexed 报告了比 Opaque 更宽的平均区间，覆盖率却更低。因此，主要误差来自偏离实验已确立的纯度水平，同时伴有对条件间较小变化的预测误差。




图 6 结晶预测对实验证据的偏离具有响应特异性。**a**，来源观测与留出参考的平均纯度，各涉及 30 场研究；与两档预算下的预测比较，每档各 15 场。柱形对各研究均值等权平均。**b**，智能体 MAE 低于来源均值预测器的研究数量，按各响应分别比较；基线对每个留出配方使用同一研究的公开最终检测均值。**c**，不同信息组和预算下的回收率与纯度 MAE，每根柱包含五个世界。**d**，各信息组和预算下的原始标称 80% 纯度区间覆盖率：对五场研究、每场 12 个查询汇总；虚线表示标称水平。统计单位、基线定义与纳入范围见方法。

讨论

实验获得的关系既可能被延伸得过远，也可能未被充分保留。在 Sol/Aligned 的平衡研究中，预测将局部平台延伸到了响应已经明显改变的稀释条件；在结晶研究中，预测则系统性低于实验与留出条件共同呈现的稳定纯度。这两种方向相反的偏离，将科学泛化的问题具体化为：哪些实验认识应当随干预而修订，哪些应当继续成立²⁷？

模型比较揭示了相同实验设置下不同的科学研究行为。Sol/Opaque 从局部观测成功外推；Astra 则经常获取更低浓度的实验证据，并在选定案例中先观察到响应变化，再准确预测它。相近的预测成功可以伴随不同的证据历史。另一方面，Sol/Aligned 的一个回答虽在文字中描述了平台的适用边界，数值上仍延续平台水平：能够表述适用边界，与在定量判断中使用它，是不同的研究成就。ChemWorld 将实验选择、已获取证据、公开报告与封存预测连接起来，使这些差异变得可见。科学学习的评价需要这种研究过程与结果的连接，同时检验条件变化下的不确定性估计^{28,29}。

这些观察提出了一项科学智能体设计原则：将已学关系在何种条件下保持、在何种条件下改变，明确纳入实验选择的目标，并据此选择能够区分竞争解释的实验¹⁶。Astra 的轨迹提供了一个已经执行的例子：在封存预测之前，主动观察到局部平台之外的响应。一些 Sol 研究者则直到回顾阶段才提出微量投料实验，另一个结晶配对也在这一较晚阶段提出热处理测试（补充材料 C.4 及补充图 S5）；这些建议尚未执行。设计上的关键，是将此类判断提前，使其在预测封存之前就参与证据获取的决策。

跨体系结果覆盖一个模型配置在六类体系中的研究；五模型平衡比较复用世界和读出，每个模型—世界—信息条件包含一次研究，分组分析属于探索性分析。分离采样、先验使用与证据解释的贡献，以及检验向真实实验室的迁移，是后续工作。本文评价新干预下的预测与公开科学报告；完整机理理解和内部信念修订需要进一步证据³⁰。可编程世界使自主研究行为成为可受控考察的对象，将研究者的成果与其获取的证据、以及将证据延伸至新条件的方式联系起来。