

可编程化学世界：从实验自主性走向科学理解

中文正文译稿

摘要

自驱动实验室正越来越多地自主设计流程并推进研究路径。设备与流程约束、实验成本、安全要求和未知机制，使其科学学习难以得到系统研究。我们提出 **ChemWorld**：在可编程化学世界中，智能体对持续演化的样品组合实验操作，评价者则独立控制过程规律与所提供的信息。我们采用同一智能体配置，在六类体系中开展 240 场研究，将自主研究历史连接到操作结果与新干预条件下的封存预测。智能体能够调整流程，并可从资源和知识中获益，但操作表现与预测能力的改善并不必然同步。正确的部分先验信息在一个区间改善了平衡预测，却在极端稀释条件下使误差达到未提供该信息时的 8.7 倍。预测在平衡响应发生变化时延续了平台，却偏离了近乎恒定的结晶纯度。这些发现表明，判断实验所得知识的适用范围，是从实验自主性走向科学理解的核心挑战之一。

自驱动实验室通过自动化执行、持续反馈和对有效条件的高效搜索，拓展着实验科学的能力边界。语言模型智能体进一步连接科学指令、工具与实验室操作，为更加灵活的研究流程打开了空间¹⁻³。随着系统获得选择操作顺序、中间测量和后续实验的自由，它们也越来越多地塑造自身的研究路径。这一科学机遇从执行流程和优化条件，延伸到了决定获取哪些证据，以及这些证据意味着什么。

更大的实验自由度也使科学学习更难评价。不同研究路径可能获得同样成功的操作结果，却揭示化学体系的不同侧面。一个有效配方既可能来自可迁移的解释，也可能来自仅在局部有效的经验规则。真实实验室提供丰富的发现可能性，但每一种已实现的工作流程都受到设备、材料和操作程序的实际约束。未知机制、持续演化的物料状态以及重复实验的成本，使得我们难以受控比较自主研究者如何获取和使用证据。因此，理解它们的进步，需要把实验成就与产生这些成就的研究历史和判断连接起来。

我们考察科学理解的一个可观察组成部分：自主研究者如何使用自己获取的证据，预测新干预下的结果。研究历史、公开科学报告和封存预测，将实验成就与对关系适用范围的判断连接起来。预测是观察这一能力的一个窗口；它本身并不足以证明完整的机理理解。

ChemWorld 为这一研究提供了计算环境。优化基准提供可重复的目标函数^{4,5}，交互式化学环境和科学发现环境则支持多步实验与知识评价⁶⁻⁸。**ChemWorld** 将可组合的化学过程、持续的实验状态和灵活操作，与评价者对世界条件及信息条件的控制结合起来。研究者可以在可执行的化学域内组织实验；评价者则可以配置兼容的世界、比较研究条件，并保留完整的操作历史。由此，自主取证及其后续使用成为可以开展受控研究的对象。

我们考察六类化学体系中的 240 场研究，跟踪原始研究者从实验选择到操作推荐、科学报告与封存预测的全过程。智能体能够形成适应性流程，并从额外资源与相关知识中获益，但操作表现和预测能力的改善并不总是同步。更值得关注的是，正确先验信息的预测收益在平衡体系的不同响应区间发生反转；结晶研究者虽然能有效预测回收率，却不必要地偏离了稳定的纯度关系。这些发现使适用性判断成为科学学习的一个关键维度：判断已观察到的关系何时应当延续、何时应当改变，以及哪些实验能够区分这两种情况。

结果

受控化学世界中的开放式实验

ChemWorld 通过兼容的过程组件与观测组件构造可执行世界。操作会改变组成、相分配、热历史和剩余物料；测量则从操作后的状态中揭示预先定义的量。智能体可以组合操作，在允许的范围内改变顺序，重复实验，并选择中间测量。这里的开放式实验，是指在声明的化学域和资源域内组合有效流程。过程历史具有实际影响，每一步操作都可能同时改变物理样品与后续决策可利用的证据（图 1）。

平台支持两种互补的自由度。研究者选择如何探索一个世界；评价者配置兼容的过程模型、私有参数和所提供的信息。世界可以在兼容的公开接口背后发生变化，也可以保持不变而改变研究者获得的信息。观测来自智能体实际开展的实验，因此，信息既可能影响它观察到什么，也可能影响它如何解释这些观测。有限域资格检查在参考配置与生成配置中核验状态转移、资源核算和重放的一致性（见英文完整版“方法”）。

本研究包含 240 场研究，按每个研究块五个世界、三个信息组组织。Opaque 提供可用的公开实验约定与匿名标识；Aligned 增加正确但不完整的标称信息；MisIndexed 提供固定的错配或重新指派。同一智能体配置在 12 或 24 批次的研究资源额度内自主选择实验。对于需要操作推荐的任务，封存推荐会接受独立复测。随后，原始会话在保留研究上下文的情况下，依次给出科学报告（K1）、留出条件预测（Q）和回顾性证据反思（K2）。预测与回顾阶段均不接收参考结果反馈，K2 也不能修改已封存的 Q。

一个 12 批次的结晶研究过程展示了这种自主性如何实际发挥作用（图 2）。前四批的细晶比例达到 99.5%-100.0%，未满足颗粒质量约束。第 5 批取消骤冷，并在加晶种前引入受控冷却，以 30.3% 的细晶比例首次得到可行结果。进一步调整改善了回收率：第 5-7 批中，较低的冷却终点伴随着回收率从 40.0% 提升至 45.0%；第 8 批减少晶种用量，获得来源实验中最高的可行回收率 45.5%。其封存配方在独立复测中得到 43.9% 的回收率和 28.4% 的细晶比例。第 11 批减少溶剂体积，细晶比例上升至 72.6%，且回收率没有改善；第 12 批回到所选操作区域并继续满足约束。这一路径连接了失败尝试、流程调整、局部改善与再次触及约束的过程。早期有多个条件同时改变。有关成核历史的解释来自后续科学报告，操作记录无法还原当时的推理过程。

全部 240 场研究均保留在分析中，包括两场未完成最终检测预算的研究。实验选择、物理后果和后续判断由此连接起来，使我们能够考察不同研究条件如何塑造研究成果。




图 1 ChemWorld 作为自主科学研究的受控实验仪器。a, 固定数据集、真实实验室与单一终点评分所带来的评价挑战。b, 自主研究将实验选择、过程执行、测量和证据驱动的调整连接在一个具有持续状态的物理世界中。隐藏规律与公开信息可分别改变, 研究历史可被重放, 操作表现、预测与不确定性分别评价。对于有此要求的任务, 操作推荐先封存并独立复测。随后, 原始会话在保留研究历史的情况下, 依次提供科学报告 (K1)、封存预测 (Q) 和回顾性证据反思 (K2)。Q 和 K2 均不接收目标结果反馈。c, 匹配世界下的信息条件、独立的 12 与 24 批次研究资源配置, 以及六类体系中已经完成的 240 场研究。图内 “Mismatched information” 对应 MisIndexed。预算比较仅适用于同时具有两档资源配置的体系。




图 2 一场完整的自主结晶研究。**a**, 事后选取的 W04/MisIndexed 会话中全部 12 批来源实验。数值为记录的最终检测结果; 青色表示满足质量约束, 赭色表示失败。虚线表示 50% 的细晶比例上限。第 5 批首次可行, 第 8 批最终被封存为推荐方案, 第 11 批违反细晶约束, 第 12 批重复所选配方。**b**, 来源第 8 批的全部 12 次操作调用, 归为 10 个可见阶段。中间粒径检查读数为 26.6% 细晶, 最终检测为 25.4%。温度表示请求的目标值, 而非实测温度轨迹。独立复测使用封存的第 8 批配方和不同的观测随机种子。**c**, 三组“观测、后续行动、结果”序列。问题由作者根据操作记录重建, 并非模型当时的原话; K1 在实验序列结束后撰写。第 5 批同时改变多个工艺条件, 因此无法单独识别取消骤冷的作用。回收率不计入品种质量。可行性要求纯度至少 80%、细晶比例至多 50%, 且存在颗粒; 细晶指小于 20 微米的颗粒。本例用于展示研究过程, 不用于估计总体发生频率。

研究目标与资源塑造实验和预测收益

研究委托表达不同的优先目标，但不规定实验路径。**Discovery**（探索）优先发展并检验具有解释力和预测力的科学陈述；**Optimization**（优化）优先寻找高得分的操作流程。我们比较在世界、信息条件、预算和先验作用位置上匹配的独立研究，并分别评价操作推荐与留出条件预测（图 3）。

结果同时呈现目标专门化和共同收益。在电化学的 30 对研究中，优化委托有 26 对获得更高的推荐复测得分：其中 13 对的得分预测平均绝对误差（MAE）也更低，另外 13 对的 MAE 则更高。在反应处理体系中，探索委托在 30 对中的 17 对同时优于优化委托的两个终点。不区分委托类型时，复测得分较高的一方在 14 对电化学研究和 9 对反应处理研究中预测更差。这些描述性排序表明，操作成就与预测成就需要分别评价；两种委托均不具有内在的普遍优势。

一组选定的电化学配对使这种区别更加具体（图 3c）。探索研究先比较材料与条件，随后延长反应时长并提高电流上限。优化研究围绕一个有潜力的溶剂-电解质组合继续改进，将观测得分从第 3 批的 0.675 提高到第 12 批的 0.749。探索与优化推荐的独立复测得分分别为 0.718 和 0.756，而预测 MAE 分别为 0.088 和 0.229。优化智能体在公开预测理由中，根据表现不佳的跨组合实验，将若干组合判断为低活性。对于一个先前测试过、但处于新条件下的组合，它预测得分为 0.070，80% 预测区间为 0-0.240，而参考值为 0.494；另一个组合则被准确预测为 0.570，参考值为 0.572（图 3d）。完整预测与原始研究路径，将总体对比连接到了一个具体的迁移判断。

增加研究资源在若干设置下带来明显的预测收益（图 4）。24 批次条件对应独立会话，并具有更大的实验和计算资源额度。电化学得分 MAE 在探索委托下从 0.17378 降至 0.11222，在优化委托下从 0.17811 降至 0.10818；两组各 15 对比较中分别有 11 对和 12 对改善。电化学的全部六项响应在总体上均有所改善，逐一剔除任一世界后，其平均变化方向仍保持一致。

相分配体系的有机相分数 MAE 从 0.08291 降至 0.02379，在 15 对中有 13 对改善。正确的流程选择从 30 题中的 25 题增加至 30 题全部正确。标称 90% 区间覆盖率从 78.3% 升至 98.9%，同时平均区间宽度从 0.25122 缩小至 0.18553。结晶回收率 MAE 也从 0.10433 改善至 0.07937，但满足质量要求的推荐仍为 15 场中的 12 场，平均复测回收率则从 0.42054 降至 0.39939。细晶比例的区间覆盖率从 35.6% 提高到 43.9%，但每场研究仍低于标称的 80%。

相关科学信息提供了另一条改善路径。在反应参数研究中，**Aligned** 信息使探索宏平均 MAE 从 0.10186 降至 0.05701，使优化误差从 0.13893 降至 0.08384；两种委托下均在五个世界中的四个优于 **Opaque**（补充图 S2a、b）。在其他研究块中，没有某一信息组具有共同的优势。

这些研究产生了有用的流程与预测，而收益取决于研究条件和所评价的响应。完整配对结果与设计分层见补充表 E3-E7；补充分析还在纯化体系中区分了回收率与满足质量要求的交付。总体收益进一步引出一个更具体的问题：当需要预测的条件改变时，同一项信息的价值是否可能反转？




图3 研究目标、操作结果与预测判断。a、b，电化学（a）和反应处理（b）中全部 30 对目标匹配研究，每个体系使用五个重复出现的世界。正差值表示优化委托在相应终点上更好；象限文字标明表现较好的委托。计数只依据差值的严格正负号，没有最小效应量或显著性阈值。圆环标出选定案例。c，两个独立的 12 批次研究中的全部批次得分、记录的操作变化，以及封存推荐的独立复测。连线连接相邻观测；这不是从 12 批继续到 24 批的同一会话。探索研究的第 11-12 批包含分段电解与中间测量。d，优化研究的全部 12 个原始预测、标称 80% 预测区间和留出参考观测。理由概括自后续公开的 Q 回答，并非实验当时的内部思考。阴影标出电学设置相同而材料组合不同的四个查询，其中同时保留一个准确预测与若干低估。案例为事后选取。配对固定世界、信息组、预算和先验作用位置。EC 参考值为单次固定随机种子的观测；RX 点预测误差以五次观测均值为参考。




图 4 更大的研究资源额度对不同响应产生不同影响。a-f 分别展示电化学探索得分 MAE、电化学优化得分 MAE、相分配有机相分数 MAE、结晶回收率 MAE、结晶细晶比例区间覆盖率和结晶复测回收率。各面板上方给出 12 与 24 批次条件的研究均值，以及改善的世界-信息组配对数。下方给出全部 15 对独立会话的有符号变化，纵向错位仅用于避免标记重叠。a-d 中，变化为 12 批次 MAE 减去 24 批次 MAE；e、f 中，变化为 24 批次值减去 12 批次值。因此，正值均表示较大资源额度更有利。黑色菱形表示配对变化的中位数；零点处灰色标记表示无变化；叉号保留来源检测次数不足的 C-W02/Opaque 配对。各坐标轴采用不同尺度。较大的批次预算还允许更多操作与计算资源。补充图 S3 保留全部六项结果的详细世界-信息组矩阵。

正确先验信息的预测收益可在不同区间发生反转

平衡研究检验的是：浓样品中获得的证据，能否支持强稀释后的预测。全部 15 场研究的名义取样浓度均高于 0.018 M；180 次来源检测中的电离分数介于 5.5% 和 9.2% 之间。在最稀测试条件下，参考均值却介于 44.8% 和 71.6% 之间（图 5a）。实际执行模型中的酸碱电荷平衡与背景离子共同产生局部电离平台；稀释改变了平衡状态，过程规律本身并未改变。Aligned 提供正确的有效 pKa 区间与局部稀释响应，而非完整模型方程（Methods；补充表 H1）。

正确先验信息在这些测试区间呈现一致的收益反转。与 Opaque 相比，Aligned 将九个查询上的宏平均 MAE 从 0.01008 改善至 0.00465，却使最稀的三个查询上的误差从 0.01833 增加至 0.15862，约为同一组条件下 Opaque 误差的 8.7 倍（图 5b；表 1）。这两个方向在全部五个世界中均出现。总体宏平均 MAE 分别为 Opaque 0.01214、Aligned 0.04314 和 MisIndexed 0.03928。浓度分组是事后分析，其余九个查询也包含边界条件，不能全部视为插值。

不确定性表现也随这一反转而改变。Aligned 原始 80% 预测区间在其余九题上覆盖了 91.3% 的参考观测，在最稀三题上却只覆盖 2.2%；Opaque 的对应覆盖率为 90.7% 和 93.3%。因此，能够改善

一部分预测任务的信息，同时伴随着其他区间明显恶化的迁移表现，而不确定性区间没有充分反映这一误差。

表 1. 平衡体系在不同测试区间的预测表现。

信息组	其余九题：MAE	最稀三题：MAE	其余九题：覆盖率	最稀三题：覆盖率
Opaque	0.01008	0.01833	90.7%	93.3%
Aligned	0.00465	0.15862	91.3%	2.2%
MisIndexed	0.00439	0.14397	89.6%	13.8%

数值对每组五个世界和三项响应目标取平均：归一化 pH、电离分数及沉淀信号。覆盖率针对原始 80% 预测区间计算：其余九题每组包含 675 次参考观测覆盖判断，最稀三题每组包含 225 次；这些判断不是独立的世界重复。分组具有探索性。图 5b 展示同一宏平均误差比较；图 5c 则单独展示一个响应和一个查询。

分解宏平均误差可见，在最稀查询上，Aligned 在每个世界的全部三项响应中均更差。其在其余九题上的收益则主要来自沉淀信号，该响应在全部五个世界中均改善；pH 和电离分数的变化方向并不一致（补充表 G1）。因此，总体反转超出了单一电离案例的范围，但不意味着各响应表现完全相同。

在最稀条件下，Opaque 预测跟随了电离分数的升高，而 Aligned 预测仍接近观测到的平台（图 5c）。一个 Aligned 研究探索了 90 倍的浓度范围，其 Opaque 对应研究探索了四倍范围，但两者都没有进入稀释区间。因此，广泛的输入探索可以与缺少响应区间转变证据同时存在。

公开预测解释揭示了使用这些证据的不同方式。四份 Opaque 回答明确采用分段弱酸外推，第五份允许定性地偏离平台。五份 Aligned 回答则均主要延续平台或较弱的局部趋势。MisIndexed 中保留了一个有信息量的反例：一场研究将弱酸解释与平台解释结合，在稀释条件下预测了可观的电离。这些公开表达的预测规则，有助于把研究历史与最终结果连接起来。

这些解释出现的时间进一步揭示了另一种区别。一份 Opaque 科学报告已提出有效酸常数和活性物料池上限；这是智能体假说，而非实际执行模型。在另一场研究中，弱酸外推直到预测阶段才首次被明确表达。其 Aligned 对应研究承认平台不一定延伸至零投料，却仍预测稀释条件下的电离分数为 0.0804，区间为 [0.053, 0.108]；相比之下，Opaque 预测为 0.629，区间为 [0.45, 0.80]，参考均值为 0.65463。表达一个适用边界与成功应用该边界，是可以区分的两项成就。

这种反转提示，知识既可能塑造证据的组织方式，也可能影响被带入新条件的解释。先验锚定以及对竞争性解释的保留，是未来可以考察的候选解释；当前比较跟踪完整研究过程，尚未分离这些贡献。另一个互补问题同样重要：当观测关系仍然稳定时，预测能否保留它？




图 5 实验证据、区间收益反转与原始平衡预测。**a**，全部 180 次来源检测与 60 个留出参考均值（五个世界、12 个配方），横轴为名义浓度。菱形为五次评价者观测的均值；圆点为单次来源检测。配方与历史各不相同，因此这些散点不构成受控的浓度-响应曲线。阴影标出三个稀释测试条件。**b**，其余九题与最稀三题的宏平均 MAE。空心点保留每个信息组的全部五个世界，短横线表示均值。倍数在同一组条件内比较 Aligned 与 Opaque。分组和三响应汇总与表 1 相同，均属探索性分析。**c**，五个世界中最稀配方（13.3 微摩尔每升）的原始电离预测与五次参考观测均值。横向浅色带涵盖全部来源电离观测的 5.5%-9.2% 范围，并非不确定性区间。保留世界 3 的 MisIndexed 反例。所有参考值均对智能体隐藏；原始 80% 预测区间与各研究的来源范围见补充表 F1。

结晶研究者虽能有效预测回收率，预测却偏离稳定纯度

结晶揭示了适用性的另一面：某项响应保持近似稳定，预测却偏离了它。来源纯度与留出纯度的平均值分别为 98.53% 和 98.51%，而 12 批次与 24 批次条件下的预测均值分别为 93.54% 和 94.89%。360 次预测中有 335 次偏低（图 6a）。各世界留出纯度范围的平均跨度仅为 2.442 个百分点。

模型分别追踪固相目标产物与杂质。依赖过饱和度的成核与生长改变回收率和颗粒群体，而有限的杂质转移使这些条件下仍可保持高纯度。纯度由固相组成计算；近乎恒定的水平是观测结果，并非预设常数（Methods；补充材料 H）。

这种偏离具有响应特异性。一个基线对每场研究的所有留出条件重复预测该研究自身公开最终检测值的均值，不使用额外实验或留出结果。智能体的回收率预测在 30 场研究中的 26 场优于该基线，细晶比例预测在 21 场中更好；但粒径预测仅有四场更好，纯度预测则没有任何一场更好（图 6b）。智能体与基线的平均回收率 MAE 分别为 9.18 和 17.14 个百分点，纯度 MAE 则分别为 4.35 和 0.48 个百分点。同一批研究者能够有效预测变化的回收率，却未能保留近乎恒定的纯度关系。完整误差幅度与最近邻参考见补充表 E1。

对保留数据的分解，将每场研究的纯度整体偏移与不同条件间的变化预测误差分开（补充表 G2）。平均有符号偏差为 -4.29 个百分点；各研究平均偏差的平方合计占总平方误差的 87.6%。分别对预测与参考值去均值后，平均残差均方根误差（RMSE）为 1.89 个百分点，而参考值的平均标准差为

0.60 个百分点；30 场研究中有 29 场前者超过后者。因此，整体低估占主导，同时还存在变化预测误差。这是对预测输出的诊断，并未识别内部修订过程。

信息条件对不同响应也产生相反影响。在 12 批次条件下，与 Opaque 相比，Aligned 和 MisIndexed 在每个世界中均改善了回收率 MAE，却恶化了纯度 MAE；对每一种比较，两侧均符合来源要求的四个配对也全部呈现这一方向。在 24 批次条件下，这一联合方向分别只出现在五个世界中的两个和三个（图 6c）。这种效应取决于响应与研究资源配置。

预测区间并未始终容纳纯度误差（图 6d）。在 12 批次条件下，标称 80% 区间的覆盖率分别为 Opaque 98.3%、Aligned 60.0% 和 MisIndexed 23.3%；在 24 批次条件下，分别为 95.0%、73.3% 和 55.0%。两档预算下，Aligned 和 MisIndexed 的平均区间都比 Opaque 更宽。因此，较差覆盖率不能简单归结为区间较窄；与此同时，Opaque 的高覆盖率本身也不足以证明区间校准良好或足够集中。




图 6 结晶预测对实验证据的偏离具有响应特异性。**a**，来源观测与留出参考的平均纯度，各涉及 30 场研究；与两档预算下的预测比较，每档各 15 场。柱形对各研究均值等权平均。**b**，智能体 MAE 低于来源均值预测器的研究数量；该预测器对每个留出配方重复使用同一研究的公开最终检测均值。灰色剩余部分表示基线更好，没有平局。比较在各响应内部进行，不跨响应尺度比较。**c**，不同信息组和预算下的回收率与纯度 MAE，每根柱包含五个世界。**d**，各信息组和预算下，五场研究、每场 12 个查询的原始标称 80% 纯度区间覆盖率均值。虚线表示标称水平。五个世界在信息组和独立预算会话间重复出现，查询不是独立的世界重复。全部 30 场研究均保留，包括来源检测次数不足的研究。柱形是描述性汇总，不是置信区间。基线不使用额外实验或留出结果。

平衡与结晶结果共同揭示了迁移实验关系时的互补失败。Aligned 平衡预测在响应发生变化时保留了局部平台；结晶预测则偏离了在所测干预下仍近似稳定的观测纯度水平。两种情况下，过程规

律均保持固定，改变的是条件。这一对比支持将适用性判断作为独立研究对象，超越对经验外推或机理修订的笼统偏好。

成功的 Opaque 平衡预测、混合使用解释的 MisIndexed 回答，以及回收率预测相对于经验基线的优势，都是这一发现不可分割的部分。它们说明困难具有选择性。在自主研究过程中，实验成功、公开表达的解释和预测泛化可以不均衡地发展，从而促使我们更加紧密地连接证据选择与赋予所学关系的适用范围。

讨论

ChemWorld 通过持续的化学状态、可组合操作与受控研究条件，将不断扩展的实验自主性连接到科学理解的研究。这些研究产生有用的流程和预测收益，同时揭示了具有选择性的迁移失败。我们提出，适用性判断是连接实验自主性与科学自主性的关键维度：前者指组织行动的能力，后者指形成、检验和修订解释及其适用范围的能力。留出条件预测为考察这一维度提供了具体窗口。

这些结果也促使我们更深入地理解自主科学中的资源与知识。额外研究机会和相关信息具有可观察的价值，但其作用取决于实际获得的证据以及需要预测的响应。当观测仍停留在同一响应区间时，对输入条件开展更广泛的探索未必能够区分竞争性解释。同样，保留经验关系对于结晶纯度是有效的，但对于稀释条件下的平衡预测却不够。这些发现提示，应当研究智能体如何识别有信息量的边界、协调机理预期与稳定观测，以及如何为尚未排除的解释分配不确定性。我们提出这些能力之间的联系，以组织所观察到的现象，而不要求所有错误都具有同一种内部原因。

评价还应区分表达一个适用边界与成功使用该边界。平衡研究者可以承认平台未必延伸到零投料，却仍在强稀释条件下给出接近平台的预测。将公开解释与封存预测及其不确定性对照，可以揭示这一差距。科学报告提供了关于公开判断的证据，但其表述看似合理，本身不足以证明成功迁移。

一种前瞻性架构可以将竞争性解释与有区分力的实验相连接，在新干预下的预测之前更新关系及其支持条件。15 位平衡研究者中有 11 位在看到预测条件后，在没有参考结果反馈的回顾阶段提出了痕量投料实验。另一个结晶案例也在封存预测后认识到局限并提出后续工作（补充图 S4）。这些实验尚未执行。机会在于把这种认识带入实验选择。一个聚焦的后续检验是：获得诊断性边界处的证据，是否能够改善原研究者的后续预测，从而区分认识到边界与通过实验解决边界问题的价值。

对于真实自驱动实验室，可编程世界提供了开发研究策略并考察其证据后果的环境，随后还需面对真实实验中更加丰富的化学现象与仪器条件。当前观察涉及一个智能体配置、每项研究中重复使用的五个世界、相关联的响应读数，以及若干探索性分析。它们尚未分离证据获取与证据解释，也尚未建立向湿实验室迁移的有效性。跨模型复现可以检验这些现象的适用范围，针对性的证据干预则可以研究其机制。这些延伸工作在同一研究计划中回答不同问题。更广泛的目标，是把实验行动的自由与证据、解释及适用性之间更好的协调结合起来，使自主实验室既能提升其所能实现的成果，也能提升其所能学到的知识。