

可编程化学世界：从实验自主性走向科学理解

中文正文译稿

摘要

自驱动实验室正越来越多地自主设计流程并推进研究路径。设备与流程约束、实验成本、安全要求和未知机制，使其科学学习难以得到系统研究。我们提出 **ChemWorld**：在可编程化学世界中，智能体对持续演化的样品组合实验操作，评价者则独立控制过程规律与所提供的信息。我们采用同一智能体配置，在六类体系中开展 240 场研究，将自主研究历史连接到操作结果与新干预条件下的封存预测。智能体能够调整流程，并可从资源和知识中获益，但操作表现与预测能力的改善并不必然同步。正确的部分先验信息在一个区间改善了平衡预测，却在极端稀释条件下使误差达到未提供该信息时的 8.7 倍。预测在平衡响应发生变化时延续了平台，却偏离了近乎恒定的结晶纯度。这些发现表明，判断实验所得知识的适用范围，是从实验自主性走向科学理解的核心挑战之一。

自驱动实验室通过自动化执行与自适应实验规划，拓展着实验科学的能力边界^{1,2}。机器人科学家已经能够生成生物学假设并通过实验检验³，后续平台也展示了自主材料搜索与反应优化⁴⁻⁷。移动机器人还可结合互补的分析仪器开展探索性合成⁸。语言模型智能体连接科学指令、工具与实验室操作^{9,10}，多智能体研究团队则已设计出随后接受实验验证的生物分子¹¹。随着系统获得选择操作顺序、中间测量和后续实验的自由，它们也越来越多地塑造自身的研究路径。这一科学机遇从执行流程和优化条件，延伸到了决定获取哪些证据，以及这些证据意味着什么。

更大的实验自由度也使科学学习更难评价。不同研究路径可能获得同样成功的操作结果，却揭示化学体系的不同侧面。一个有效配方既可能来自可迁移的解释，也可能来自仅在局部有效的经验规则。面向决策的学习同样区分预测误差与使用预测所作决策的质量¹²。真实实验室提供丰富的发现可能性，但每一种已实现的工作流程都受到设备、材料和操作程序的实际约束。未知机制、持续演化的物料状态以及重复实验的成本，使得我们难以受控比较自主研究者如何获取和使用证据。因此，理解它们的进步，需要把实验成就与产生这些成就的研究历史和判断连接起来。

我们考察科学理解的一个可观察组成部分：自主研究者如何使用自己获取的证据，预测新干预下的结果。研究历史、公开科学报告和封存预测，将实验成就与对关系适用范围的判断连接起来。预测是观察这一能力的一个窗口；它本身并不足以证明完整的机理理解¹³。信息增益准则与自适应设计策略为选择有信息量的实验提供了形式化方法¹⁴⁻¹⁶，强推断则强调通过实验区分竞争假设¹⁷。这些研究传统提示我们，应同时评价获取的证据及据此形成的结论。

现有基准评价这一过程的不同组成部分。**ChemBench** 通过问答评价化学知识与推理¹⁸，**Discovery-Bench** 评价基于给定数据集的假设发现¹⁹。优化基准提供可重复的目标函数^{20,21}。交互式化学与科学发现环境支持多步实验²²⁻²⁴；**BoxingGym** 将实验设计连接到模型发现及基于解释的预测²⁵。**Science-Gym** 评价主动数据采集与方程发现²⁶，**PhysGym** 则在交互式物理发现中明确改变所提供的先验知识²⁷。

ChemWorld 将这一研究带入具有持续样品状态和灵活操作的可组合化学过程。评价者对兼容世界规律与所提供信息的控制，支持研究条件之间的匹配比较。我们跟踪同一研究者，从自主选择实验操作，到推荐的独立复测以及新干预下的封存预测。完整操作历史使这些结果能够与研究者实际获取的证据联系起来。

我们考察六类化学体系中的 240 场研究，跟踪原始研究者从实验选择到操作推荐、科学报告与封存预测的全过程。智能体能够形成适应性流程，并从额外资源与相关知识中获益，但操作表现和

预测能力的改善并不总是同步。更值得关注的是，正确先验信息的预测收益在平衡体系的不同响应区间发生反转；结晶研究者虽然能有效预测回收率，却不必要地偏离了稳定的纯度关系。这些发现使适用性判断成为科学学习的一个关键维度：判断已观察到的关系何时应当延续、何时应当改变，以及哪些实验能够区分这两种情况。

结果

追踪受控化学世界中的自主实验

ChemWorld 由兼容的过程与观测组件构建可执行世界。操作改变组成、相分配、热历史和剩余物料，测量则只呈现约定的量。操作作用于持续存在的样品，其历史决定后续测量与决策所面对的状态。研究者在化学和资源约束内选择合法流程、重复实验及中间测量；评价者则独立配置兼容的过程规律、私有参数和公开信息。因此，世界可以在共用公开接口下变化，也可以保持世界不变而改变研究者获得的信息。由于观测来自实际选择的实验，公开信息可能同时影响证据获取与解释（图 1）。状态转移、资源核算和重放另行验证（Methods）。

研究包含 240 场实验研究，以五个世界和三种信息条件组成区组。Opaque 提供可用的公开实验约定与匿名标识，Aligned 补充正确但不完整的名义信息，MisIndexed 提供固定的错配或重分配。同一智能体配置用于全部研究；预算比较只涉及同时设有两档额度的体系，使用独立的 12 与 24 批次会话。对于有此要求的任务，封存推荐接受独立复测。随后，原始会话保留研究历史，依次提供科学报告（K1）、留出条件预测（Q）和回顾性证据反思（K2）。Q 和 K2 均不获得参考结果反馈，K2 也不能修改 Q。全部研究均纳入，包括两场最终检测次数不足的研究。

一场 12 批次结晶研究展示了这种可追踪性（图 2）。前四批均违反颗粒质量约束，细晶比例为 99.5%-100.0%。第 5 批将流程改为先受控冷却、后加入晶种，首次获得可行结果，细晶比例为 30.3%，回收率为 40.0%。进一步调整使第 8 批的可行回收率升至 45.5%；其封存配方在独立复测中得到 43.9% 回收率和 28.4% 细晶比例。第 11 批减少溶剂后再次违反质量约束，细晶比例达 72.6%。这条轨迹将反复失败、流程调整、局部改善和再次违反约束，与外部评价结果连接起来。多项条件同时改变，因此不能单独识别省略终止反应操作（quench）的作用。图 2 中的问题由作者根据操作记录重建；成核历史解释写于实验结束后，并非实验当时记录的思考。




图 1 ChemWorld 作为自主科学研究的受控实验仪器。a, 固定数据集、真实实验室与单一终点评分所带来的评价挑战。b, 自主研究将实验选择、过程执行、测量和证据驱动的调整连接在一个具有持续状态的物理世界中。隐藏规律与公开信息可分别改变, 研究历史可被重放, 操作表现、预测与不确定性分别评价。对于有此要求的任务, 操作推荐先封存并独立复测。随后, 原始会话在保留研究历史的情况下, 依次提供科学报告 (K1)、封存预测 (Q) 和回顾性证据反思 (K2)。Q 和 K2 均不接收目标结果反馈。c, 匹配世界下的信息条件、独立的 12 与 24 批次研究资源配置, 以及六类体系中已经完成的 240 场研究。图内 “Mismatched information” 对应 MisIndexed。预算比较仅适用于同时具有两档资源配置的体系。




图 2 一场完整的自主结晶研究。**a**, 事后选取的 W04/MisIndexed 会话中全部 12 批来源实验。数值为记录的最终检测结果; 青色表示满足质量约束, 赭色表示失败。虚线表示 50% 的细晶比例上限。第 5 批首次可行, 第 8 批最终被封存为推荐方案, 第 11 批违反细晶约束, 第 12 批重复所选配方。**b**, 来源第 8 批的全部 12 次操作调用, 归为 10 个可见阶段。中间粒径检查读数为 26.6% 细晶, 最终检测为 25.4%。温度表示请求的目标值, 而非实测温度轨迹。独立复测使用封存的第 8 批配方和不同的观测随机种子。**c**, 三组“观测、后续行动、结果”序列。问题由作者根据操作记录重建, 并非模型当时的原话; K1 在实验序列结束后撰写。第 5 批同时改变多个工艺条件, 因此无法单独识别省略终止反应操作 (quench) 的作用。回收率不计入晶种质量。可行性要求纯度至少 80%、细晶比例至多 50%, 且存在颗粒; 细晶指小于 20 微米的颗粒。本例用于展示研究过程, 不用于估计总体发生频率。

操作与预测收益不必同步

研究委托改变优先目标，但不规定实验路径。**Discovery** 优先发展和检验具有解释力与预测力的科学认识，**optimization** 优先获得高分流程。我们比较在世界、信息条件、预算和先验作用位置上匹配的独立研究，分别评价推荐复测与留出预测（图 3）。在 30 对电化学研究中，**optimization** 有 26 对复测得分更高，其中 13 对得分预测的平均绝对误差（MAE）也更低，另外 13 对却更高。在反应处理中，**discovery** 在 30 对中的 17 对上两项表现均更好。因此，两种委托没有预定的总体优势，操作与预测结果需要分别评价。

一个选定的电化学配对使这种分离更具体（图 3c、d）。**Discovery** 先比较材料与条件，再延长时间并提高电流上限。**Optimization** 优化一个有潜力的溶剂-电解质组合，将观测得分从第 3 批的 0.675 提高到第 12 批的 0.749。**Discovery** 与 **optimization** 的推荐复测得分分别为 0.718 和 0.756，预测 MAE 却分别为 0.088 和 0.229。在交叉组合实验表现较差后，**optimization** 智能体的公开预测理由将若干组合判为低活性。对于新条件下一个先前测过的组合，它给出 0.070 [0, 0.240]，参考值为 0.494；同时另一个组合的预测为 0.570，接近参考值 0.572。记录连接了实验证据、公开表达的迁移规则与封存预测，但没有显示每一步优化后的预测质量如何变化。

另一方向的分离也存在：预测收益未必伴随更好的交付结果。24 批次条件使用独立会话，并提供更多实验和计算额度（图 4）。电化学位得分 MAE 在 **discovery** 的 15 对中有 11 对改善，在 **optimization** 的 15 对中有 12 对改善。相分配有机相分数 MAE 在 15 对中有 13 对改善，均值从 0.08291 降至 0.02379。结晶回收率 MAE 也从 0.10433 降至 0.07937，但满足质量约束的推荐数量仍为 15 场中的 12 场，平均复测回收率从 0.42054 降至 0.39939。细晶比例区间覆盖率从 35.6% 升至 43.9%，但每场研究仍低于标称 80%。因此，更多研究机会可以改善部分预测，而不必改善每一项交付结果。

相关科学信息提供了另一种改善途径。在反应参数先验研究中，**Aligned** 将 **discovery** 的宏平均 MAE 从 0.10186 降至 0.05701，将 **optimization** 的误差从 0.13893 降至 0.08384；两种委托下均在五个世界中的四个优于 **Opaque**（补充图 S2a、b）。在其他区组中，没有一种信息条件具有普遍优势。这些收益引出更具体的问题：当预测超出原先支持这些认识的条件时，正确信息的价值是否可能反转？




图 3 研究目标、操作结果与预测判断。a、b，电化学（a）和反应处理（b）中全部 30 对目标匹配研究，每个体系使用五个重复出现的世界。正差值表示优化委托在相应终点上更好；象限文字标明表现较好的委托。计数只依据差值的严格正负号，没有最小效应量或显著性阈值。圆环标出选定案例。c，两个独立的 12 批次研究中的全部批次得分、记录的操作变化，以及封存推荐的独立复测。连线连接相邻观测；这不是从 12 批继续到 24 批的同一会话。探索研究的第 11-12 批包含分段电解与中间测量。d，优化研究的全部 12 个原始预测、标称 80% 预测区间和留出参考观测。理由概括自后续公开的 Q 回答，并非实验当时的内部思考。阴影标出电学设置相同而材料组合不同的四个查询，其中同时保留一个准确预测与若干低估。案例为事后选取。配对固定世界、信息组、预算和先验作用位置。EC 参考值为单次固定随机种子的观测；RX 点预测误差以五次观测均值为参考。




图 4 更大的研究资源额度对不同响应产生不同影响。a-f 分别展示电化学探索得分 MAE、电化学优化得分 MAE、相分配有机相分数 MAE、结晶回收率 MAE、结晶细晶比例区间覆盖率和结晶复测回收率。各面板上方给出 12 与 24 批次条件的研究均值，以及改善的世界-信息组配对数。下方给出全部 15 对独立会话的有符号变化，纵向错位仅用于避免标记重叠。a-d 中，变化为 12 批次 MAE 减去 24 批次 MAE；e、f 中，变化为 24 批次值减去 12 批次值。因此，正值均表示较大资源额度更有利。黑色菱形表示配对变化的中位数；零点处灰色标记表示无变化；叉号保留来源检测次数不足的 C-W02/Opaque 配对。各坐标轴采用不同尺度。较大的批次预算还允许更多操作与计算资源。补充图 S3 保留全部六项结果的详细世界-信息组矩阵。

正确先验信息的预测收益可在不同区间发生反转

平衡研究揭示了正确部分信息的价值随条件区间发生反转。Aligned 提供正确的有效 pKa 区间与局部稀释响应，而非完整模型方程 (Methods; 补充表 H1)。相对于 Opaque，它将九个查询的宏平均 MAE 从 0.01008 降至 0.00465，却将最稀三个查询的误差从 0.01833 升至 0.15862，约为同组条件下 Opaque 误差的 8.7 倍 (图 5b; 表 1)。五个世界中均出现这两个方向。浓度分组为事后分析，其余九题包含边界条件，并非只有插值条件。

实际获得的证据没有进入稀释响应区间。全部 15 场研究的采样名义浓度均高于 0.018 M，180 次来源检测的电离分数范围为 5.5%-9.2%。最稀测试条件下，参考均值却为 44.8%-71.6% (图 5a)。在执行模型中，背景离子电荷平衡产生局部平台；稀释改变平衡，而不改变过程规律。一个 Aligned 研究覆盖 90 倍浓度范围，其 Opaque 对应研究覆盖四倍范围，但两者均未进入稀释区间 (补充材料 C)。因此，广泛的输入探索仍可能未观测到响应区间之间的转变。

反转具有响应特异性，但不限于电离分数。Aligned 在其余九题的收益主要来自沉淀信号，pH 和电离分数的变化方向不一致；在最稀三题上，每个世界的三项响应均恶化 (补充表 G1)。其原始 80% 预测区间在其余九题覆盖 91.3% 的参考观测，在最稀三题仅覆盖 2.2%；Opaque 的对应值为 90.7% 和 93.3%。因此，报告的不确定性未能充分反映迁移误差。

表 1. 平衡体系在不同测试区间的预测表现。

信息组	其余九题：MAE	最稀三题：MAE	其余九题：覆盖率	最稀三题：覆盖率
Opaque	0.01008	0.01833	90.7%	93.3%
Aligned	0.00465	0.15862	91.3%	2.2%
MisIndexed	0.00439	0.14397	89.6%	13.8%

数值对每组五个世界和三项响应目标取平均：归一化 pH、电离分数及沉淀信号。覆盖率针对原始 80% 预测区间计算：其余九题每组包含 675 次参考观测覆盖判断，最稀三题每组包含 225 次；这些判断不是独立的世界重复。分组具有探索性。图 5b 展示同一宏平均误差比较；图 5c 则单独展示一个响应和一个查询。

在最稀条件下，Opaque 预测跟随电离分数的上升，而 Aligned 预测仍接近观测平台（图 5c）。公开预测解释将这一差别与证据使用方式联系起来。四个 Opaque 回答调用分段弱酸外推，第五个允许偏离平台；全部五个 Aligned 回答主要延续平台或弱局部趋势。MisIndexed 保留了一个反例：它结合平台与弱酸解释，预测稀释时电离分数明显升高。一个 Aligned 回答甚至承认平台未必延伸至零投料，却仍给出 0.0804 [0.053, 0.108] 的电离预测，参考均值为 0.65463。因此，表达适用边界与在封存预测中成功使用它，是可以分离的成果。

互补的问题是：当一种关系在新条件下仍然稳定时，预测能否保留它？




图 5 实验证据、区间收益反转与原始平衡预测。**a**，全部 180 次来源检测按真实名义浓度绘制（0.0185–2 M）。12 个菱形汇总 60 个留出参考均值：每个菱形对五个世界取平均，误差棒表示世界间样本标准差（SD）；各世界的参考值本身为五次评价者观测的均值。来源响应带仅覆盖实际采样浓度范围。竖向阴影标出三个稀释测试条件，其中没有来源检测。配方与历史各不相同，因此这不是受控的浓度-响应曲线。**b**，其余九题与最稀三题的宏平均 MAE。柱形为均值，误差棒为五个世界间的样本 SD，空心点保留每个世界。世界在信息组及区间之间重复使用；SD 不是置信区间。倍数在同一区间内比较 Aligned 与 Opaque。探索性分组和三响应汇总与表 1 相同。**c**，五个世界中最稀配方（13.3 微摩尔每升）的原始电离预测与五次参考观测均值。横向浅色带涵盖全部来源电离观测的 5.5%–9.2% 范围，并非不确定性区间。保留世界 3 的 MisIndexed 反例。所有参考值均对智能体隐藏；原始 80% 预测区间与各研究的来源范围见补充表 F1。

有效的回收率预测与系统性纯度低估并存

结晶揭示了互补的适用性失败：某项响应保持近似稳定，预测却偏离了它。来源与留出纯度的均值分别为 98.53% 和 98.51%，12 与 24 批次条件下的预测均值却分别为 93.54% 和 94.89%。360 次预测中有 335 次偏低（图 6a），各世界留出纯度范围的平均跨度仅为 2.442 个百分点。模型分别追踪固相目标产物和杂质：依赖过饱和度的成核与生长改变回收率和颗粒群体，而有限的杂质转移使纯度保持较高水平。因此，纯度近似恒定是测试条件下的观测结果，而非预设常数（Methods；补充材料 H）。

这种偏离具有响应特异性。一个基线对每场研究的所有留出条件重复使用该研究自身的公开最终检测均值，不使用额外实验或留出结果。智能体回收率预测在 30 场研究中的 26 场优于该基线，纯度预测则没有任何一场更好（图 6b）。智能体的平均纯度 MAE 为 4.35 个百分点，基线为 0.48 个百分点。同一批研究者对变化回收率的预测可以优于该基线，却未能保留近乎恒定的纯度。细晶、粒径和最近邻比较见补充表 E1。

对保留数据的分解，将每场研究的纯度整体偏移与不同条件间的变化预测误差分开（补充表 G2）。平均有符号偏差为 -4.29 个百分点，各研究平均偏差的平方合计占总平方误差的 87.6%。因此，整体低估占主导，但去均值后的 RMSE 在 30 场研究中的 29 场仍超过参考值的标准差。系统性水平偏移与残余变化误差均有贡献。这种输出层面的诊断并未识别内部修订过程。

信息条件进一步限定了这一解释。在 12 批次条件下，Aligned 和 MisIndexed 相对于 Opaque 在每个世界中均改善回收率 MAE，却恶化纯度 MAE；在 24 批次条件下，这一联合方向分别只出现在五个世界中的两个和三个（图 6c）。预测区间也未能可靠地容纳纯度误差（图 6d）。两档预算下，Aligned 与 MisIndexed 的平均区间均比 Opaque 更宽，因此较差覆盖率不能简单归因于报告的不确定性较窄；反之，Opaque 的高覆盖率本身也不足以证明校准或集中程度良好。这些效应同时取决于响应与研究资源配置。




图 6 结晶预测对实验证据的偏离具有响应特异性。a，来源观测与留出参考的平均纯度，各涉及 30 场研究；与两档预算下的预测比较，每档各 15 场。柱形对各研究均值等权平均。b，智能体 MAE 低于来源均值预测器的研究数量；该预测器对每个留出配方重复使用同一研究的公开最终检测均值。没有平局。比较在各响应内部进行，不跨响应尺度比较。c，不同信息组和预算下的回收率与纯度 MAE，每根柱包含五个世界。d，各信息组和预算下，五场研究、每场 12 个查询的原始标称 80% 纯度区间覆盖率均值。虚线表示标称水平。五个世界在信息组和独立预算会话间重复出现，查询不是独立的世界重复。全部 30 场研究均保留，包括来源检测次数不足的研究。柱形是描述性汇总，不是置信区间。基线不使用额外实验或留出结果。

讨论

在所测研究中，操作表现与预测表现的改善并不总是一致。**Aligned** 平衡预测将局部观测到的电离平台延伸到响应已经变化的条件，而结晶预测偏离了仍近似稳定的纯度。这些互补错误提示，评价应在实验表现和预测准确性之外关注适用性判断：研究者能否利用已获取的证据，判断哪些关系在新干预下仍应成立。这一视角补充了关于实验自主性与科学知识产出之区别的更广泛讨论²⁸。观测到的模式并未证明两类失败具有共同的内部原因。

跟踪原研究者从自主选择实验到封存预测的全过程，使这些判断能够追溯到当时可用的证据。实验历史、公开解释、点预测和不确定性提供互补记录：承认一种关系存在边界，并不证明预测遵守了这些边界。平衡结果体现了这一差距，包括明确承认观测平台未必延伸至零投料，却仍大幅低估稀释条件下的响应。预测不确定性同样需要根据实际结果检验，尤其是在分布变化时^{29,30}。

这些发现提示，实验选择应在改善当前任务表现的同时，检验表观规律的适用边界。区分竞争解释的实验提供了一条路径¹⁷。一些研究者在接触查询条件、但未获得参考反馈的回顾阶段，提出了可能有信息量的后续实验（补充材料 C.4；补充图 S4）。这些建议出现在预测封存之后，且未被执行。由此可以提出一个聚焦的后续检验：在诊断性边界处获取证据，是否改善原研究者后续的预测及不确定性估计。

当前证据涉及一个智能体配置、每项研究中重复使用的五个世界，以及相互关联的读出和若干探索性比较。它尚未分离证据获取与解释的贡献，也未建立向真实实验室迁移的有效性。公开解释与预测支持行为层面的分析，不能据此重建内部信念修订。可编程世界在保留研究者自由选择流程的同时，使这些区分能够接受针对性检验。进展应通过有用的实验结果，以及体现已获取证据适用范围的预测来评价。